

Analisi Numerica e Statistica

Statistica inferenziale

Federica Porta

Dipartimento di Scienze Fisiche, Informatiche e Matematiche
Università di Modena e Reggio Emilia

a.a. 2025/2026

Corso di Laurea in Ingegneria Informatica - sede di Mantova



UNIMORE
UNIVERSITÀ DEGLI STUDI DI
MODENA E REGGIO EMILIA

L'inferenza statistica

Definizione

Si definisce **popolazione** un insieme i cui elementi hanno in comune almeno una caratteristica (o attributo).

L'inferenza statistica

Definizione

Si definisce **popolazione** un insieme i cui elementi hanno in comune almeno una caratteristica (o attributo).

Esempi di popolazioni:

Gli ingegneri che si sono laureati in Italia dal 1987 al 2020; i giorni con vento superiore ai 100 Km/h a Trieste nel mese di aprile dal 1900 al 2020; gli italiani aventi diritto al voto per il senato alle elezioni politiche del 2018; i corpi celesti dell'universo.

L'inferenza statistica

Definizione

Si definisce **popolazione** un insieme i cui elementi hanno in comune almeno una caratteristica (o attributo).

Esempi di popolazioni:

Gli ingegneri che si sono laureati in Italia dal 1987 al 2020; i giorni con vento superiore ai 100 Km/h a Trieste nel mese di aprile dal 1900 al 2020; gli italiani aventi diritto al voto per il senato alle elezioni politiche del 2018; i corpi celesti dell'universo.

Esempi di caratteristiche nel caso degli ingegneri:

l'età al momento della laurea; il voto finale conseguito; l'età al momento del primo impiego come ingegnere; il primo stipendio; ecc.

L'inferenza statistica

Ogni caratteristica della popolazione viene misurata da un valore numerico per ciascuno degli N elementi che la compongono. Di conseguenza uno studio completo della popolazione implicherebbe un insieme di N numeri.

In genere, però, N è così grande da rendere impraticabile, per ovvi motivi, la misurazione della caratteristica per l'intera popolazione. Ci si limita dunque a farlo solo per un suo sottoinsieme, spesso assai limitato, detto **campione**.

Lo scopo dell'inferenza statistica è quello di inferire, cioè fare delle deduzioni o delle previsioni sulla popolazione mediante l'esame di un suo campione.

Campioni casuali

Matematicamente, la caratteristica oggetto di studio è una variabile aleatoria X la cui distribuzione ci è più o meno sconosciuta. Tale variabile aleatoria sottostante alla popolazione in questione avrà una media ed una varianza:

$$\mu = \mu_X = E(X), \quad \sigma^2 = \sigma_X^2 = Var(X).$$

Definizione

Si chiama **campione casuale di dimensione n** , estratto da una popolazione avente X come variabile aleatoria sottostante, un insieme di n variabili aleatorie $X_1, X_2, \dots, X_n$, con X_i indipendenti ed aventi la stessa distribuzione di X .

Quando si misura la caratteristica della popolazione limitandosi ad un campione di dimensione n , si ottengono n misure $x_1, x_2, \dots, x_n$: ciò equivale ad una singola esecuzione dell'esperimento rappresentato dalla variabile n -dimensionale $(X_1, X_2, \dots, X_n)$ con risultato $(x_1, x_2, \dots, x_n)$.

Stimatori

Sia $X_1, X_2, \dots, X_n$ un campione di una data popolazione la cui distribuzione è nota in funzione di un parametro incognito θ . Si vuole stimare θ mediante una appropriata funzione dei risultati campionari x_i .

Definizione (Stimatore)

Si definisce **statistica** una funzione $g(X_1, X_2, \dots, X_n)$ delle variabili casuali X_i (e quindi, a sua volta, una variabile casuale) che non contiene parametri. Uno **stimatore** è una statistica che viene utilizzata per stimare un parametro incognito θ .

Definizione (Stima)

Sia $\theta = f(X_1, X_2, \dots, X_n)$ uno stimatore e $x_1, x_2, \dots, x_n$ un valore misurato del campione. Il valore $\hat{\theta} = f(x_1, x_2, \dots, x_n)$ è detto **stima puntuale** del parametro θ .

Definizione (Stimatore corretto)

Uno stimatore T del parametro θ si dice **corretto** se la sua media coincide con θ medesimo, ossia $E(T) = \theta$.

Media campionaria

Problema: determinare una stima della media μ di una popolazione.

Media campionaria

Problema: determinare una stima della media μ di una popolazione.

Definizione

Si chiama **media campionaria** di un campione $X_1, X_2, \dots, X_n$ la variabile casuale $\bar{X}$ così definita

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Media campionaria

Problema: determinare una stima della media μ di una popolazione.

Definizione

Si chiama **media campionaria** di un campione $X_1, X_2, \dots, X_n$ la variabile casuale $\bar{X}$ così definita

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Teorema

La media campionaria è uno stimatore corretto della media vera μ , ossia

$$E(\bar{X}) = E(X) = \mu.$$

Teorema

La varianza della media campionaria vale quella di X diviso n , ossia

$$Var(\bar{X}) = \frac{1}{n} Var(X) = \frac{\sigma^2}{n}.$$

Media campionaria

I due teoremi appena visti ci dicono che la media campionaria $\bar{X}$ ha media coincidente con la media μ della popolazione da cui proviene il campione e la sua dispersione attorno a μ è inversamente proporzionale a $\sqrt{n}$
 $\Rightarrow$ al crescere di n i valori delle corrispondenti medie campionarie tendono a concentrarsi sempre più attorno alla media della popolazione.

Per n grandi, ha quindi senso stimare μ calcolando la media aritmetica dei valori misurati x_i , ossia

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

La quantità $\bar{x}$ è il valore misurato della media campionaria $\bar{X}$.

Varianza campionaria

Definizione

Si chiama **varianza campionaria** di un campione $X_1, X_2, \dots, X_n$, $n > 1$, la variabile casuale S^2 così definita

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Teorema

La varianza campionaria S^2 è uno stimatore corretto della varianza vera σ^2 , ovvero:

$$E(S^2) = \sigma^2.$$

Varianza campionaria

Sulla base della definizione di varianza di una variabile casuale, apparirebbe più naturale utilizzare il seguente stimatore

$$\tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Tuttavia $\tilde{S}^2$ non è uno stimatore corretto per la varianza, infatti

$$E(\tilde{S}^2) = \frac{n-1}{n} \sigma^2.$$

Distribuzione chi-quadro


Definizione

Date n variabili aleatorie X_i normali standardizzate indipendenti, la variabile aleatoria somma dei loro quadrati è detta **chi-quadro** (o **chi-quadrato**) con n gradi di libertà ed è indicata con χ_n^2 . Si ha dunque

$$\chi_n^2 = \sum_{i=1}^n X_i^2, \quad X_i \simeq N(0, 1).$$

Distribuzione chi-quadro

Una distribuzione χ_n^2 ha una funzione di densità $f(x)$ che è nulla per $x < 0$. Per n piccolo, $f(x)$ ha il picco massimo vicino all'origine ed è sempre più dispersa e sempre più simmetrica per n grande.



Distribuzione chi-quadro

Dalla definizione di χ_n^2 segue immediatamente che, se $X_1, X_2, \dots, X_n$ è un campione casuale estratto da una popolazione distribuita normalmente con media μ e varianza σ^2 , allora la variabile aleatoria

$$Z^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2$$

segue una distribuzione χ_n^2 .

Si può poi dimostrare che la varianza campionaria S^2 è proporzionale ad una distribuzione chi-quadro con $n - 1$ gradi di libertà:

$$\frac{n-1}{\sigma^2} S^2 \simeq \chi_{n-1}^2.$$

Distribuzione t di Student

Definizione


Se Z è una variabile aleatoria normale standardizzata e χ_n^2 è una variabile aleatoria chi-quadro con n gradi di libertà, se Z e χ_n^2 sono indipendenti, allora la distribuzione della variabile aleatoria

$$T_n = \frac{Z}{\sqrt{\chi_n^2/n}}$$

prende il nome di **distribuzione t di Student** con n gradi di libertà.

Distribuzione t di Student

Per n grandi, la distribuzione di Student tende alla normale standardizzata.



Quantili

In analogia con la terminologia già introdotta per la distribuzione $N(0,1)$, le soluzioni x_α e t_α delle equazioni

$$p(\chi_n^2 \leq x_\alpha) = \alpha, \quad p(T_n \leq t_\alpha) = \alpha$$

saranno chiamati **quantili** relativi ad α .

Per gli esercizi, verrà fatto uso di tabelle con i valori tabulati dei quantili.

QUANTILI DELLA LEGGE CHI-QUADRO: $P[\chi_n^2(x)] \leq \alpha$

n	0.005	0.01	0.025	0.05	0.10	0.90	0.95	0.975	0.99	0.995
1	.00004	.00016	.00098	.0039	.015	2.706	3.841	5.024	6.635	7.879
2	0.0100	0.0201	0.0506	0.103	0.211	4.605	5.991	7.378	9.210	10.597
3	0.0717	0.115	0.216	0.352	0.584	6.251	7.815	9.348	11.345	12.838
4	0.207	0.297	0.484	0.711	1.064	7.779	9.488	11.143	13.277	14.860
5	0.412	0.554	0.831	1.145	1.610	9.236	11.070	12.832	15.086	16.750
6	0.676	0.872	1.237	1.635	2.204	10.645	12.592	14.449	16.812	18.548
7	0.989	1.239	1.690	2.167	2.833	12.017	14.067	16.013	18.475	20.278
8	1.344	1.647	2.180	2.733	3.490	13.362	15.507	17.535	20.090	21.955
9	1.735	2.088	2.700	3.325	4.168	14.684	16.919	19.023	21.666	23.589
10	2.156	2.558	3.247	3.940	4.865	15.987	18.307	20.483	23.209	25.188

QUANTILI DELLA LEGGE t DI STUDENT: $P[T_n(x)] \leq \alpha$

n	$\alpha=0.90$	$\alpha=0.95$	$\alpha=0.975$	$\alpha=0.98$	$\alpha=0.99$	$\alpha=0.995$
1	3.078	6.314	12.71	15.894	31.821	63.66
2	1.886	2.920	4.303	4.849	6.965	9.925
3	1.638	2.353	3.182	3.482	4.541	5.841
4	1.533	2.132	2.776	2.999	3.747	4.604
5	1.476	2.015	2.571	2.757	3.365	4.032
6	1.440	1.943	2.447	2.612	3.143	3.707
7	1.415	1.895	2.365	2.517	2.998	3.499
8	1.397	1.860	2.306	2.449	2.896	3.355
9	1.383	1.833	2.262	2.398	2.821	3.250
10	1.372	1.812	2.228	2.359	2.764	3.169

Intervalli di fiducia (o confidenza)

Uno stimatore è una variabile aleatoria che serve per stimare un parametro ignoto θ della nostra popolazione.

Intervalli di fiducia (o confidenza)

Uno stimatore è una variabile aleatoria che serve per stimare un parametro incognito θ della nostra popolazione.

Ovviamente i parametri che ci interessa maggiormente stimare sono la media μ e la varianza σ^2 .

Intervalli di fiducia (o confidenza)

Uno stimatore è una variabile aleatoria che serve per stimare un parametro incognito θ della nostra popolazione.

Ovviamente i parametri che ci interessa maggiormente stimare sono la media μ e la varianza σ^2 .

In questo ambito di problemi, un esempio di domanda comune è la seguente:

Dato un campione, quale intervallo del tipo $(\bar{x} - \delta, \bar{x} + \delta)$ conterrà la media incognita μ con probabilità del 95%? Oppure del 99%

Intervalli di fiducia (o confidenza)

Definizione

Si definisce **intervallo di fiducia (o confidenza)** di livello $100(1 - \alpha)\%$ per il parametro θ un intervallo (θ_1, θ_2) tale che

$$p(\theta_1 \leq \theta \leq \theta_2) = 1 - \alpha,$$

dove $\theta_1 = f_1(X_1, X_2, \dots, X_n)$ e $\theta_2 = f_2(X_1, X_2, \dots, X_n)$ sono variabili aleatorie funzione del campione casuale.

In genere interessano piccoli valori di α ($\alpha = 0.05$ oppure $\alpha = 0.01$) corrispondenti ad alti livelli di fiducia nell'intervallo (95% o 99%).

Eseguito l'esperimento, mediante i valori misurati $x_1, x_2, \dots, x_n$ del campione, si ricava l'intervallo numerico (θ_1^*, θ_2^*) , dove gli estremi sono $\theta_1^* = f_1(x_1, x_2, \dots, x_n)$ e $\theta_2^* = f_2(x_1, x_2, \dots, x_n)$, il quale costituisce una stima per intervalli del parametro θ al livello di fiducia $100(1 - \alpha)\%$.

Stima della media di una popolazione normale

Supponiamo che la popolazione abbia distribuzione normale.

Descriviamo alcuni metodi per stimare la media della variabile aleatoria sottostante alla popolazione.

Distinguiamo due casi:

- (a) caso di varianza nota
- (b) caso di varianza incognita.

Stima della media di una popolazione normale

(a) Caso di varianza nota

Supponiamo che $\sigma^2 = \text{Var}(X)$ sia nota.

Lo stimatore della media vera μ è la media campionaria, della quale sappiamo che

$$E(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Inoltre, si può dimostrare che, essendo la popolazione distribuita normalmente, anche $\bar{X}$ è normale. Di conseguenza la variabile casuale

$$\bar{Z} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

segue la distribuzione normale standardizzata, la cui densità di probabilità è $\Phi(x)$.

Sia $u_{\frac{\alpha}{2}}$ il quantile relativo ad $1 - \frac{\alpha}{2}$, ovvero


$$\Phi(u_{\frac{\alpha}{2}}) = 1 - \frac{\alpha}{2}.$$

Allora, essendo $\Phi(-u_{\frac{\alpha}{2}}) = 1 - \Phi(u_{\frac{\alpha}{2}}) = \frac{\alpha}{2}$, segue che

$$\begin{aligned} p\left(-u_{\frac{\alpha}{2}} \leq \bar{Z} \leq u_{\frac{\alpha}{2}}\right) &= 1 - p\left(|\bar{Z}| > u_{\frac{\alpha}{2}}\right) = \Phi(u_{\frac{\alpha}{2}}) - \Phi(-u_{\frac{\alpha}{2}}) = \\ &= \Phi(u_{\frac{\alpha}{2}}) - 1 + \Phi(u_{\frac{\alpha}{2}}) = \\ &= 2\Phi(u_{\frac{\alpha}{2}}) - 1 = 2\left(1 - \frac{\alpha}{2}\right) - 1 = 1 - \alpha. \end{aligned}$$

Stima della media di una popolazione normale

$$p\left(-u_{\frac{\alpha}{2}} \leq \bar{Z} \leq u_{\frac{\alpha}{2}}\right) = 1 - \alpha.$$



$$\begin{aligned} p\left(-u_{\frac{\alpha}{2}} \leq \bar{Z} \leq u_{\frac{\alpha}{2}}\right) &= p\left(-u_{\frac{\alpha}{2}} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq u_{\frac{\alpha}{2}}\right) = p\left(-\frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}} \leq \bar{X} - \mu \leq \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}\right) \\ &= p\left(-\bar{X} - \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}} \leq -\mu \leq -\bar{X} + \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}\right) = p\left(\bar{X} - \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}} \leq \mu \leq +\bar{X} + \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}\right) \end{aligned}$$

Stima della media di una popolazione normale

La probabilità che $\bar{Z}$ appartenga all'intervallo si può riscrivere come

$$p\left(-u_{\frac{\alpha}{2}} \leq \bar{Z} \leq u_{\frac{\alpha}{2}}\right) = p\left(\bar{X} - \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}} \leq \mu \leq \bar{X} + \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}\right).$$

Quindi concludiamo che

$$p\left(\bar{X} - \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}} \leq \mu \leq \bar{X} + \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}\right) = 1 - \alpha.$$

Di conseguenza, **l'intervallo bilaterale**

$$\left[\bar{X} - \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}, \bar{X} + \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}\right]$$

che è aleatorio, in quanto è tale il suo punto centrale $\bar{X}$, **contiene con probabilità $1 - \alpha$ il valore vero μ .**

Eseguito l'esperimento, l'intervallo di fiducia di livello $1 - \alpha$ si ottiene dall'intervallo aleatorio sostituendo alla media campionaria $\bar{X}$ la media aritmetica $\bar{x}$ dei valori osservati negli n esperimenti:

$$\mu \in \left[\bar{x} - \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}, \bar{x} + \frac{\sigma}{\sqrt{n}}u_{\frac{\alpha}{2}}\right].$$

Stima della media di una popolazione normale

Osservazioni

- Se cresce il numero n degli esperimenti, l'ampiezza dell'intervallo diminuisce, e dunque la stima si fa **più informativa**: fare esperimenti è costoso, ma poi “ripaga”.
- Se invece aumenta il grado di fiducia, diminuisce α e il quantile u cresce; di conseguenza cresce l'ampiezza dell'intervallo e quindi la stima diventa **meno informativa**.

Stima della media di una popolazione normale

Analogamente, possiamo determinare gli **intervalli di fiducia unilaterali**. Indicando con u_α il quantile relativo a $1 - \alpha$, si ha

$$p(\bar{Z} \leq u_\alpha) = p(\bar{Z} \geq -u_\alpha) = 1 - \alpha$$

o, equivalentemente

$$p\left(\mu \geq \bar{X} - \frac{\sigma}{\sqrt{n}}u_\alpha\right) = p\left(\mu \leq \bar{X} + \frac{\sigma}{\sqrt{n}}u_\alpha\right) = 1 - \alpha.$$

Gli intervalli aleatori, rispettivamente destro e sinistro

$$\left[\bar{X} - \frac{\sigma}{\sqrt{n}}u_\alpha, +\infty\right), \quad \left(-\infty, \bar{X} + \frac{\sigma}{\sqrt{n}}u_\alpha\right]$$

contengono la media con probabilità $1 - \alpha$.

Una volta eseguito l'esperimento, tali intervalli saranno approssimati con

$$\left[\bar{x} - \frac{\sigma}{\sqrt{n}}u_\alpha, +\infty\right), \quad \left(-\infty, \bar{x} + \frac{\sigma}{\sqrt{n}}u_\alpha\right].$$

Esempio

Per determinare la durata del cambio di un'auto vengono scelti casualmente 200 cambi dalla produzione, che supponiamo distribuita normalmente con deviazione standard uguale a 4000 km. Essi vengono testati finchè presentano un difetto serio. Se la durata media dei 200 cambi sottoposti a test è 50000 km, quali sono gli intervalli di fiducia bilaterali e unilaterali sinistri della durata media dell'intera produzione al 95%, al 97.5% e al 99%?

I dati sono $n = 200$, $\bar{x} = 50000$, $\sigma = 4000$. I livelli di fiducia sono $\alpha = 0.05$, 0.025 e 0.01 , indicando con $u_{\frac{\alpha}{2}}$ il valore per cui $\Phi(u_{\frac{\alpha}{2}}) = 1 - \frac{\alpha}{2}$, abbiamo

$$\Phi(u_{0.025}) = 0.9750 \quad \Rightarrow \quad u_{0.025} \simeq 1.96$$

$$\Phi(u_{0.0125}) = 0.9875 \quad \Rightarrow \quad u_{0.0125} \simeq 2.24$$

$$\Phi(u_{0.005}) = 0.9950 \quad \Rightarrow \quad u_{0.005} \simeq 2.57$$

Esempio

Gli intervalli di fiducia bilaterali $1 - \alpha$ sono dati da $\left[\bar{x} - \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}}, \bar{x} + \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}} \right]$.

Essendo $\sigma/\sqrt{n} \approx 282.84$, si ha

$$\alpha = 0.050 \quad \Rightarrow \quad \mu \in [50000 - 555, 50000 + 555] = [49445, 50555]$$

$$\alpha = 0.025 \quad \Rightarrow \quad \mu \in [50000 - 634, 50000 + 634] = [49366, 50634]$$

$$\alpha = 0.010 \quad \Rightarrow \quad \mu \in [50000 - 727, 50000 + 727] = [49273, 50727].$$

Gli intervalli unilaterali sinistri di fiducia $1 - \alpha$ sono del tipo $\left(-\infty, \bar{x} + \frac{\sigma}{\sqrt{n}} u_{\alpha} \right]$.

In questo caso, mettiamo 0 anzichè $-\infty$ come estremo sinistro degli intervalli (la durata di un cambio non può essere negativa) e otteniamo così

$$\alpha = 0.050 \quad \Rightarrow \quad \mu \in (0, 50000 + 464] = (0, 50464]$$

$$\alpha = 0.025 \quad \Rightarrow \quad \mu \in (0, 50000 + 555] = (0, 50555]$$

$$\alpha = 0.010 \quad \Rightarrow \quad \mu \in (0, 50000 + 659] = (0, 50659].$$

All'aumentare del livello di fiducia, aumenta l'ampiezza dell'intervallo.

Stima della media di una popolazione normale

(b) Caso di varianza incognita

Supponiamo ora, come accade nella pratica, che la varianza σ^2 non sia nota. In tal caso si procede come nel caso precedente, sostituendo a σ^2 lo stimatore corretto della varianza campionaria

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

In particolare, si standardizza $\bar{X}$ sostituendo σ con S :

$$\bar{Z} = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

Si dimostra che la variabile così ottenuta è distribuita come una t di Student con $n-1$ gradi di libertà e, pertanto, potremo scrivere

$$\bar{Z} = T_{n-1}.$$

Indichiamo poi con $t_{\frac{\alpha}{2}}$ il quantile relativo ad $1 - \frac{\alpha}{2}$ relativo alla t di Student:

$$p(T_{n-1} \leq t_{\frac{\alpha}{2}}) = 1 - \frac{\alpha}{2}.$$

Stima della media di una popolazione normale

Allora possiamo scrivere

$$p\left(-t_{\frac{\alpha}{2}} \leq T_{n-1} \leq t_{\frac{\alpha}{2}}\right) = 1 - \alpha$$

o, equivalentemente

$$p\left(\bar{X} - \frac{S}{\sqrt{n}}t_{\frac{\alpha}{2}} \leq \mu \leq \bar{X} + \frac{S}{\sqrt{n}}t_{\frac{\alpha}{2}}\right) = 1 - \alpha.$$

L'intervallo bilaterale aleatorio:

$$\left[\bar{X} - \frac{S}{\sqrt{n}}t_{\frac{\alpha}{2}}, \bar{X} + \frac{S}{\sqrt{n}}t_{\frac{\alpha}{2}}\right]$$

conterrà con probabilità $1 - \alpha$ la media vera μ . Eseguito l'esperimento, daremo una stima di μ di livello di fiducia $1 - \alpha$ mediante l'intervallo osservato

$$\mu \in \left[\bar{x} - \frac{\hat{\sigma}}{\sqrt{n}}t_{\frac{\alpha}{2}}, \bar{x} + \frac{\hat{\sigma}}{\sqrt{n}}t_{\frac{\alpha}{2}}\right]$$

dove $\bar{x}$ e $\hat{\sigma}$ sono la media e la varianza campionaria osservate.

Esempio

Durante 8 prove su strada un prototipo di furgone ha consumato rispettivamente 14, 12, 11, 13, 15, 12, 16, 13 litri di gasolio per 100 km di percorrenza. Supponendo che la distribuzione dei consumi segua approssimativamente la distribuzione normale, costruire gli intervalli di fiducia al 95% e al 99% della media vera del consumo di quel prototipo.

Calcoliamo la media e la varianza campionaria

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{106}{8} = 13.25$$

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{19.5}{7} \approx 2.79 \Rightarrow \hat{\sigma} = \sqrt{2.79} \approx 1.67.$$

Indicato poi con $t_{\frac{\alpha}{2}}$ il quantile della t di Student relativo ad $1 - \frac{\alpha}{2}$, l'intervallo di fiducia $1 - \alpha$ è il seguente

$$\left[\bar{x} - \frac{\hat{\sigma}}{\sqrt{n}} t_{\frac{\alpha}{2}}, \bar{x} + \frac{\hat{\sigma}}{\sqrt{n}} t_{\frac{\alpha}{2}} \right].$$

Esempio

Dalla tavola della distribuzione di Student (con $n - 1 = 7$ gradi di libertà), si ottiene

$$T_7(t_{0.025}) = 0.975 \Rightarrow t_{0.025} \simeq 2.365 \Rightarrow \mu \in [11.85, 14.65]$$

$$T_7(t_{0.005}) = 0.995 \Rightarrow t_{0.005} \simeq 3.499 \Rightarrow \mu \in [11.18, 15.32].$$

Stima della varianza di una popolazione normale

Consideriamo il problema della stima della varianza di una popolazione, la quale si suppone sia distribuita come una normale di media μ e varianza σ^2 .

Sia $X_1, X_2, \dots, X_n$ un campione estratto dalla popolazione. La variabile aleatoria

$$V = \frac{n-1}{\sigma^2} S^2 = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2$$


segue una distribuzione χ_{n-1}^2 .

Indicato con x_1 il valore per cui l'area alla sua sinistra sottesa dalla densità di probabilità χ_{n-1}^2 vale $\frac{\alpha}{2}$ e con x_2 il valore per cui l'area alla sua destra vale $\frac{\alpha}{2}$, segue che

$$p(x_1 \leq V \leq x_2) = 1 - \alpha.$$

Stima della varianza di una popolazione normale

$$p(x_1 \leq V \leq x_2) = 1 - \alpha.$$



Stima della varianza di una popolazione normale

Sostituendo V con la sua espressione esplicita, si ottiene

$$p\left(x_1 \leq \frac{n-1}{\sigma^2} S^2 \leq x_2\right) = 1 - \alpha$$

da cui, con alcuni passaggi algebrici

$$p\left(\frac{(n-1)S^2}{x_2} \leq \sigma^2 \leq \frac{(n-1)S^2}{x_1}\right) = 1 - \alpha.$$

Possiamo dunque affermare che, a livello di fiducia $1 - \alpha$, l'intervallo osservato

$$\left[\frac{(n-1)\hat{\sigma}^2}{x_2}, \frac{(n-1)\hat{\sigma}^2}{x_1}\right]$$

contiene la varianza vera σ^2 della popolazione.

Essendo x_1 e x_2 rispettivamente a denominatore del secondo estremo e del primo estremo dell'intervallo di fiducia cercato, x_1 va calcolato per difetto e x_2 per eccesso.

Esempio

Un campione di dimensione 7 di una popolazione normale ha varianza campionaria $\hat{\sigma}^2 = 0.098$. Si chiede di calcolare gli intervalli di fiducia della varianza vera della popolazione ai livelli 90% e 95%.

Per $n = 7$, $\alpha = 0.10$ e $\alpha = 0.05$ abbiamo:

$$\chi_6^2(x_1) = p(\chi_6^2 \leq x_1) = 0.050 \Rightarrow x_1 \approx 1.63$$

$$\chi_6^2(x_2) = p(\chi_6^2 \leq x_2) = 0.950 \Rightarrow x_1 \approx 12.60$$

$$\chi_6^2(x_1) = p(\chi_6^2 \leq x_1) = 0.025 \Rightarrow x_1 \approx 1.23$$

$$\chi_6^2(x_2) = p(\chi_6^2 \leq x_2) = 0.975 \Rightarrow x_1 \approx 14.45.$$

Di conseguenza, gli intervalli di fiducia richiesti sono

$$\alpha = 0.10 \Rightarrow \left[\frac{6 \cdot 0.098}{12.6}, \frac{6 \cdot 0.098}{1.63} \right] \approx [0.046, 0.361]$$

$$\alpha = 0.05 \Rightarrow \left[\frac{6 \cdot 0.098}{14.45}, \frac{6 \cdot 0.098}{1.23} \right] \approx [0.040, 0.479].$$

Test d'ipotesi

Molto spesso vengono formulate delle **ipotesi di lavoro** che riguardano un parametro θ di una popolazione (ad es. la sua media o la sua varianza).

Tale ipotesi, detta anche **ipotesi nulla** H_0 , consiste spesso nell'ipotizzare che tale parametro sia uguale ad un certo valore:

$$H_0 : \theta = \theta_0.$$

In contrapposizione all'ipotesi nulla, si può formulare un'**ipotesi alternativa** H_A . Ad esempio, possiamo ipotizzare alternativamente che il parametro non assuma il valore dato:

$$H_A : \theta \neq \theta_0.$$

Se l'ipotesi nulla H_0 si rivela essere vera, automaticamente l'ipotesi H_A è falsa.

Il test d'ipotesi è un test statistico che permette di decidere se accettare o respingere una data ipotesi di lavoro.

Test riguardanti la media di una popolazione normale

(a) Test nel caso di varianza nota

Sia $X_1, X_2, \dots, X_n$ un campione proveniente da una distribuzione normale.

1. L'ipotesi nulla H_0 è $\mu = \mu_0$, ossia che la media della popolazione abbia un dato valore μ_0 .
2. Consideriamo la statistica $\bar{Z} \simeq N(0, 1)$ ottenuta normalizzando la media campionaria $\bar{X}$, ossia

$$\bar{Z} = \frac{\bar{X} - \mu_0}{\sigma} \sqrt{n}$$

dove σ^2 è la varianza della popolazione che assumiamo nota.

Test riguardanti la media di una popolazione normale

3. Il problema è quello di testare l'ipotesi nulla

$$H_0 : \mu = \mu_0$$

contro l'ipotesi alternativa

$$H_A : \mu \neq \mu_0.$$

L'ipotesi nulla è da rifiutare se il valore osservato della media campionaria $\bar{Z}$ è “troppo grande” o “troppo piccolo”, dove “troppo grande” o “troppo piccolo” sono quantificati dal valore del rischio di prima specie che si intende correre. Più precisamente, fissata uguale ad α la probabilità di tale rischio, se indichiamo con $u_{\frac{\alpha}{2}}$ il quantile relativo al valore $1 - \frac{\alpha}{2}$, la probabilità di rifiutare l'ipotesi nulla quando è vera è

$$\begin{aligned} p\left(|\bar{Z}| > u_{\frac{\alpha}{2}} \mid \mu = \mu_0\right) &= p\left((\bar{Z} < -u_{\frac{\alpha}{2}}) \cup (\bar{Z} > u_{\frac{\alpha}{2}}) \mid \mu = \mu_0\right) \\ &= p\left(\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} < -u_{\frac{\alpha}{2}}\right) \cup \left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > u_{\frac{\alpha}{2}}\right)\right) \\ &= \alpha \end{aligned}$$

α viene spesso detto il **livello di significatività del test** (tanto più piccolo è α , tanto più è significativo il test).

Test riguardanti la media di una popolazione normale

4. La **regione di rifiuto** è costituita da tutti i valori di $\bar{X}$ per cui

$$\bar{X} < \mu_0 - \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}}, \quad \text{oppure} \quad \bar{X} > \mu_0 + \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}}.$$

Posto

$$x_1 = \mu_0 - \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}}, \quad x_2 = \mu_0 + \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}}$$

abbiamo determinato l'intervallo $[x_1, x_2]$, detto **intervallo di accettazione**.

La regione di rifiuto è l'insieme dei valori della statistica test che conducono al rifiuto dell'ipotesi nulla. Può essere anche vista come l'insieme dei valori della statistica test che non è probabile che si verifichino quando l'ipotesi nulla è vera, mentre è probabile che si verifichino quando l'ipotesi nulla è falsa.

5. Per testare l'ipotesi nulla, si calcola la media $\bar{x}$ del campione:
se $\bar{x} \notin [x_1, x_2] \Rightarrow$ l'ipotesi nulla H_0 viene rifiutata in favore dell'ipotesi alternativa H_A
se $\bar{x} \in [x_1, x_2]$, l'ipotesi nulla non viene rifiutata.

Osservazione

In statistica, “non rifiutare” non significa “accettare” (andrebbero effettuati ulteriori test per stabilire con maggiore probabilità che l'ipotesi nulla sia corretta).

Test riguardanti la media di una popolazione normale

Il test precedente era di tipo **bilaterale**.

Esiste anche la possibilità di eseguire test **unilaterali** in cui, all'ipotesi nulla $H_0 : \mu = \mu_0$, si contrappone una delle due seguenti ipotesi alternative:

$$H_A : \mu < \mu_0, \quad \text{oppure} \quad H_A : \mu > \mu_0.$$

Indicato con u_α il quantile che soddisfa l'equazione

$$\Phi(u_\alpha) = 1 - \alpha$$

valgono le seguenti relazioni

$$p(\bar{Z} < -u_\alpha) = p\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} < -u_\alpha\right) = \alpha$$

$$p(\bar{Z} > +u_\alpha) = p\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > +u_\alpha\right) = \alpha$$

Test riguardanti la media di una popolazione normale

Posto quindi

$$\xi_1 = \mu_0 - \frac{\sigma}{\sqrt{n}}u_\alpha, \quad \xi_2 = \mu_0 + \frac{\sigma}{\sqrt{n}}u_\alpha$$

le due precedenti probabilità diventano

$$p(\bar{X} < \xi_1) = \alpha \quad p(\bar{X} > \xi_2) = \alpha.$$

La prima delle due probabilità ci assicura che, nel caso $H_A : \mu < \mu_0$, se rigettiamo l'ipotesi nulla a favore di quella alternativa quando il valore di $\bar{x}$ è maggiore di ξ_1 , l'errore di prima specie commesso è uguale ad α . La seconda probabilità ci garantisce invece un errore della stessa entità nel caso si rifiuti l'ipotesi nulla a favore dell'ipotesi alternativa $H_A : \mu > \mu_0$ se la media calcolata $\bar{x}$ è maggiore di ξ_2 .




Le due semirette $(-\infty, \xi_1]$, $[\xi_2, +\infty)$ sono le **regioni di rifiuto**, mentre l'intervallo $[\xi_1, \xi_2]$ è l'**intervallo di accettazione**.

La probabilità di rigettare l'ipotesi nulla quando questa è vera è pari ad α .

Nel caso di test unilaterale per la media (nota la varianza), si procede quindi nel modo seguente:

- se $H_A : \mu < \mu_0$, l'ipotesi H_0 si rigetta se $\bar{x} < \xi_1$
- se $H_A : \mu > \mu_0$, l'ipotesi H_0 si rigetta se $\bar{x} > \xi_2$.

Test riguardanti la media di una popolazione normale



Esempio

Si supponga di avere un campione di 200 cambi per autovetture, provenienti da una popolazione di cambi la cui durata in Km è distribuita normalmente con deviazione standard $\sigma = 3250$ Km.

Possiamo assumere con un rischio pari al 5% che la durata media della popolazione costituita da tutti i cambi di quel tipo sia di 44800 Km, se la durata media del campione analizzato è stata di 44500 Km?

I dati che abbiamo sono i seguenti:

$$n = 200, \quad \bar{x} = 44500, \quad \mu_0 = 44800, \quad \sigma = 3250.$$

Seguiamo la procedura indicata per il test d'ipotesi relativo alla media di una distribuzione normale (varianza nota).

1. L'ipotesi nulla è $H_0 : \mu = \mu_0 = 44800$ contro l'ipotesi alternativa $H_A : \mu \neq \mu_0$.
2. La statistica da testare è

$$\bar{Z} = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \simeq \frac{\bar{X} - 44800}{230}.$$

3. Il rischio α di prima specie per questo test bilaterale è uguale al 5%.

Esempio

4. Dalle tavole della normale standard ricaviamo $u_{\frac{\alpha}{2}} = u_{0.025} \approx 1.96$.
5. La regione di rifiuto è $[x_1, x_2]$ con $x_1 = \mu_0 - \delta$ e $x_2 = \mu_0 + \delta$.
Essendo $\delta = \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}} = 230 \cdot 1.96 \approx 450$, tale regione corrisponde a

$$[44800 - 450, 44800 + 450] = [44350, 45250].$$

Poiché il valore calcolato di $\bar{X}$ è $\bar{x} = 44500$, esso è interno all'intervallo di accettazione e, quindi, l'ipotesi nulla non può essere rigettata.

Test riguardanti la media di una popolazione normale

(b) Test nel caso di varianza incognita

Sia $X_1, X_2, \dots, X_n$ un campione proveniente da una distribuzione normale.

1. L'ipotesi nulla H_0 è $\mu = \mu_0$, ossia che la media della popolazione abbia un dato valore μ_0 .
2. In questo caso la varianza σ^2 è supposta incognita. Si sostituisce σ^2 , con la varianza campionaria S^2 e si ottiene la statistica

$$T_{n-1} = \frac{\bar{X} - \mu_0}{S} \sqrt{n}$$

dove T_{n-1} è distribuita come una t di Student con $n - 1$ gradi di libertà. In questo caso, il test viene spesso indicato come **test t**.

Test riguardanti la media di una popolazione normale

3. Volendo testare l'ipotesi nulla $H_0 : \mu = \mu_0$ in contrapposizione con l'ipotesi alternativa $H_A : \mu \neq \mu_0$, fissata uguale ad α la probabilità del rischio di rigettare l'ipotesi nel caso in cui sia vera, si ha

$$\begin{aligned} & p \left((T_{n-1} < -t_{\frac{\alpha}{2}}) \cup (T_{n-1} > t_{\frac{\alpha}{2}}) \mid \mu = \mu_0 \right) \\ &= p \left(\left(\frac{\bar{X} - \mu_0}{S/\sqrt{n}} < -t_{\frac{\alpha}{2}} \right) \cup \left(\frac{\bar{X} - \mu_0}{S/\sqrt{n}} > t_{\frac{\alpha}{2}} \right) \right) = \alpha \end{aligned}$$

dove $t_{\frac{\alpha}{2}}$ è il quantile della t di Student relativo al valore $1 - \frac{\alpha}{2}$.

Di conseguenza, la **regione aleatoria di rifiuto** della ipotesi nulla diventa

$$\bar{X} < \mu_0 - \frac{S}{\sqrt{n}} t_{\frac{\alpha}{2}}, \quad \text{oppure} \quad \bar{X} > \mu_0 + \frac{S}{\sqrt{n}} t_{\frac{\alpha}{2}}.$$

Eseguito l'esperimento e indicato con $\hat{\sigma}$ il valore osservato di S , risulta dunque determinato il seguente **intervallo di accettazione**:

$$[x_1, x_2] = \left[\mu_0 - \frac{\hat{\sigma}}{\sqrt{n}} t_{\frac{\alpha}{2}}, \mu_0 + \frac{\hat{\sigma}}{\sqrt{n}} t_{\frac{\alpha}{2}} \right]$$

4. Se il valore osservato $\bar{x} \notin [x_1, x_2]$, l'ipotesi H_0 viene rigettata a favore di H_A ; se invece $\bar{x} \in [x_1, x_2]$ l'ipotesi H_0 non viene rifiutata.