



Dispense del corso di

FONDAMENTI DI ELETTRONICA

Prof. Francesco Maria Puglisi
Università di Modena and Reggio Emilia



Sommario

1.	Introduzione	1
2.	Basi dell'Elettronica	4
2.1.	Circuito Aperto e Corto Circuito	5
2.2.	Sorgenti Ideali di Tensione e Corrente	6
2.3.	Resistore	7
2.4.	Potenza e Convenzioni	8
2.5.	Leggi di Kirchhoff	10
2.6.	Resistori: Serie e Parallelo	10
2.7.	Condensatore	11
2.8.	Induttore.....	12
2.9.	Carica e Scarica di un Condensatore	13
2.10.	Principio di Sovrapposizione degli Effetti	15
2.11.	Circuiti Equivalenti: Teoremi di Thevenin e Norton	17
2.12.	DC vs. AC.....	18
2.13.	Analisi Complessa e Impedenza	20
2.14.	Diodi.....	24
2.15.	Interruttori.....	27
2.15.1	Interruttori allo Stato Solido	27
2.15.2	Transistor Bipolare a Giunzione.....	29
2.15.2.1	Curve di Ingresso e di Uscita.....	30
2.15.2.2	Regioni di Funzionamento	31
2.15.2.3	Usare il BJT come Interruttore	32
2.15.3	Transistor Metallo-Ossido-Semiconduttore ad Effetto di Campo.....	34
2.15.4	Considerazioni sulla Potenza	36
2.15.5	Dissipatori Termici	36
2.15.6	Safe Operating Area.....	37
2.16.	Amplificatore Operazionale.....	38
2.17.	Analogico vs. Digitale.....	41
3	Circuiti Digitali.....	43
3.1	Unità Logico-Aritmetica.....	43
3.2	Encoder.....	44
3.3	Priority Encoder	45
3.4	Decoder	46
3.5	Multiplexer e De-multiplexer	47

3.6	Circuiti Combinatori e Sequenziali.....	48
3.7	Clock	48
3.7.1	Ring Oscillator	49
3.8	JK Flip-Flop.....	50
3.9	Registri a Scorrimento	50
3.9.1	Serial-In Serial-Out (SISO)	51
3.9.2	Serial-In Parallel-Out (SIPO).....	51
3.9.3	Parallel-In Serial-Out (PISO).....	52
3.9.4	Parallel-In Parallel-Out (PIPO).....	53
3.9.5	Registri a Scorrimento Bidirezionali	53
3.10	Macchine a Stati Finiti	54
3.11	Famiglie Logiche	55
3.12	Interfaccia Open Collector.....	56
3.13	CPUs, (GP)GPUs, Microcontrollori.....	57
3.14	PLAs e FPGAs	59
3.15	ASICs	60
4.	Sensori	61
4.1.	Caratteristiche	61
4.1.1.	Caratteristiche statiche.....	61
4.1.2.	Caratteristiche dinamiche	63
4.1.3.	Caratteristiche di affidabilità	63
4.2.	Sensori di Temperatura	64
4.2.1.	Termocoppie.....	64
4.2.2.	Termoresistenze (RTD)	68
4.2.3.	Termistori	69
4.2.4.	Sensori Integrati	70
4.2.5.	Pirometri.....	70
4.3.	Sensori di Forza.....	70
4.3.1.	Estensimetri (strain gauge).....	71
4.3.2.	Sensori Piezoelettrici	74
4.4.	Sensori di Coppia	74
4.4.1.	Sensori di Coppia con Estensimetri	74
4.4.2.	Sensori di Coppia Ottici	75
4.5.	Sensori di Posizione	76
4.5.1.	Potenziometri	76
4.5.2.	Encoder.....	77

4.5.3.	Resolver	80
4.6.	Sensori di Accelerazione	82
4.6.1.	Piezo	83
4.6.2.	MEMS (Micro Electro Mechanical Systems)	83
4.7.	Sensori Magnetici	85
4.7.1.	Sensori di Hall	85
4.7.2.	Sensori Magnetoresistivi	88
4.8.	Sensori di Corrente	89
4.8.1.	Shunt.....	89
4.8.2.	Trasformatori.....	90
5.	Attuatori.....	91
5.1	Attuatori Termici	91
5.2	Diodi Emittitori di Luce	93
5.3	Solenoidi	93
5.4	Altoparlanti.....	94
5.5	Attuatori Piezoelettrici (MEMS)	94
5.6	Ponte H	96
5.7	Modulazione di Larghezza di Impulso	97
6.	Circuiti di Alimentazione.....	100
6.1	Regolatori Lineari.....	101
6.1.1	Regolatori Fissi.....	106
6.1.2	Regolatori Variabili	107
6.1.3	Regolatori Low-Dropout	108
6.2	Convertitori a Commutazione (switching).....	108
6.2.1	Convertitore Buck.....	108
6.2.2	Convertitore Boost	113
6.2.3	Convertitore Bidirezionale.....	115
7	Conversione A/D e D/A.....	117
7.1	Conversione Analogico/Digitale	117
7.1.1	Campionamento	117
7.1.2	Aliasing.....	119
7.1.3	Quantizzazione	121
7.1.4	Codifica	122
7.1.5	Circuito di Campionamento.....	123
7.2	Tipologie di ADC.....	126
7.2.1	Flash ADC.....	126


7.2.2	ADC ad Approssimazioni Successive.....	127
7.2.3	Comparazione tra ADC	129
7.2.4	ADC Avanzati: l'ADC Sigma-Delta	129
7.3	Tipologie di DAC.....	130
7.3.1	DAC R-2R.....	130
7.3.2	DAC ad Approssimazioni Successive.....	134
7.3.3	DAC Sigma-Delta.....	135
7.4	Filtro di Ricostruzione.....	135
8.	Protocolli di Comunicazione Cablata	138
8.1	Serial Peripheral Interface (SPI).....	140
8.1.1	Principio di Funzionamento.....	141
8.1.2	Slaves Indipendenti	142
8.1.3	Daisy Chain	142
8.1.4	Polarità e Fase del Clock	143
8.1.5	Registri SPI ed Errori	144
8.1.6	Sequenza delle Operazioni	147
8.1.7	Vantaggi e Svantaggi.....	147
8.2	Protocollo Inter-Integrated Circuit (I ² C)	148
8.2.1	Principi di Funzionamento	149
8.2.2	Vantaggi e Svantaggi.....	150
9.	Dichiarazione di Non Responsabilità	152

1. Introduzione

Un sistema elettronico è un'interconnessione fisica di componenti elettronici in grado di raccogliere informazioni da un processo fisico, elaborare le informazioni e, nel caso dei sistemi di controllo elettronici, agire sul processo fisico.

Ciò avviene con l'ausilio di dispositivi di input come i sensori, che raccolgono informazioni dal processo fisico e le convertono in segnali elettrici, effettuando così un'operazione di conversione dell'energia. In seguito, il sistema sfrutta i componenti elettronici per manipolare ed elaborare le informazioni (ad esempio, eseguire qualche tipo di operazione matematica sul segnale). Infine, il sistema utilizza l'energia elettrica per compiere un'azione in uscita al fine agire sul processo fisico controllato. In particolare, in questo passaggio il sistema converte l'energia elettrica in un tipo di energia compatibile con il processo fisico che si vuole controllare per mezzo di dispositivi chiamati attuatori.

Esistono molti modi per rappresentare un sistema, ad esempio matematicamente, descrittivamente o schematicamente. I sistemi elettronici sono generalmente rappresentati schematicamente come una serie di blocchi interconnessi, con ogni blocco contraddistinto dal proprio insieme di ingressi e uscite.




Di conseguenza, anche il più complesso dei sistemi elettronici di controllo può essere rappresentato da una combinazione di semplici blocchi, in cui ogni blocco contiene o rappresenta un singolo componente o un sottosistema completo. La rappresentazione di un sistema elettronico o di un sistema di controllo di processo come un insieme di blocchi interconnessi è comunemente nota come diagramma a blocchi.

I sistemi elettronici hanno sia input che output: gli output sono prodotti, tipicamente, dall'elaborazione degli input. Il comportamento del sistema (cioè il modo in cui elabora gli input per produrre gli output) può cambiare in base agli input. Pertanto, gli input di un sistema sono la "causa" del cambiamento, mentre l'azione risultante che si verifica sull'output del sistema a causa di ciò è l'"effetto".

In altre parole, un sistema elettronico può essere classificato come "causale" poiché esiste una relazione diretta e conseguenziale tra i suoi input e i suoi output. L'analisi dei sistemi elettronici e la teoria del controllo di processo si basano generalmente su questa relazione causa-effetto. In generale, un sistema elettronico non può essere solo un insieme di ingressi e uscite, deve "fare qualcosa", anche se questa azione è molto semplice come monitorare un interruttore o accendere e spegnere una luce. Sappiamo che i sensori sono dispositivi di input che rilevano o trasformano le misurazioni di quantità del mondo reale in segnali elettrici


che possono quindi essere elaborati. Questi segnali elettrici possono essere sotto forma di tensione o corrente all'interno di un circuito. I dispositivi di uscita, invece, sono chiamati attuatori, e convertono il segnale elaborato in una determinata operazione o azione.



Nella figura sopra, riportiamo l'esempio di un sistema audio dotato di cancellazione del rumore per un'esperienza di guida più confortevole. Un microfono (dispositivo di input – un sensore) rileva le onde sonore all'interno dell'auto e le converte in segnali elettrici. Tali segnali vengono poi “condizionati” (elaborati): ad esempio, il segnale audio può essere filtrato e amplificato. Quindi, le informazioni vengono convertite dal dominio analogico a quello digitale. Le informazioni digitalizzate vengono poi ulteriormente elaborate da un sistema di elaborazione digitale (tipicamente un microcontrollore o un microprocessore). In questo esempio, il sistema di elaborazione digitale elaborerà il segnale audio per implementare la cancellazione attiva del rumore. Quindi, l'informazione viene riconvertita nel dominio analogico (per il momento, potrebbe non essere del tutto chiaro il motivo per cui è conveniente trasformare un segnale dal dominio analogico al dominio digitale e poi riconvertirlo al dominio analogico, ma discuteremo questo punto in dettaglio più avanti). Dopo la riconversione al dominio analogico, il segnale viene ulteriormente elaborato: ad esempio, il segnale audio può ora essere fortemente amplificato per pilotare correttamente un altoparlante (dispositivo di uscita - un attuttore) che alla fine produrrà onde sonore in quanto pilotato da i segnali elettrici provenienti dall'amplificatore.


Naturalmente, un sistema elettronico può essere molto più complesso e può anche essere un'interconnessione di più sottosistemi che lavorano tutti insieme all'interno dello stesso sistema generale. Un sistema audio potrebbe, ad esempio, prevedere il collegamento di un lettore CD, un lettore DVD, un lettore MP3 e un ricevitore radio, prevedendo un certo numero di ingressi multipli allo stesso amplificatore che a sua volta pilota uno o più set di altoparlanti stereo o surround di tipo home theater. Un sistema elettronico è quindi complesso, ed è realizzato sotto forma di circuito discreto. Un circuito discreto è un circuito composto da componenti che vengono prodotti separatamente e quindi assemblati tipicamente su una scheda a circuito stampato (PCB), che può ospitare diversi circuiti integrati (IC). Un circuito integrato, a sua volta, è costituito da componenti e interconnessioni fabbricati simultaneamente (nella produzione di massa, ottenendo un prezzo molto basso per circuito integrato) sullo stesso pezzo di semiconduttore (tipicamente silicio). Il processore è un esempio di IC che, insieme ad altri componenti, è assemblato in un

PCB (Printed Circuit Board). La PCB viene quindi montato insieme ai connettori e agli elementi meccanici aggiuntivi nel modulo finale chiamato ECU (unità di controllo elettronica), vedere la figura seguente.



Tutti i singoli sottosistemi che compongono un complesso sistema elettronico sono interconnessi tra loro per sfruttare le informazioni prodotte da ciascun sottosistema: questa rete di sottosistemi forma un sistema complesso, in cui tutti i sottosistemi possono essere chiaramente identificati. È interessante notare come questo evidenzia chiaramente il ruolo centrale di un altro componente di ogni sistema elettronico: le linee di comunicazione e i relativi protocolli (che descrivono il modo in cui vengono scambiate le informazioni). Tutti

Communication system



i moduli possono comunicare tra loro e con un'unità di controllo diagnostica (che registra gli eventi relativi al malfunzionamento). I dati registrati nell'unità di controllo diagnostico possono quindi essere scaricati e analizzati dai tecnici. Le comunicazioni avvengono sfruttando diversi bus, che sono linee di collegamento fisiche, come schematizzato nella figura a lato: il bus di controllo è dedicato a trasportare segnali che abilitano o disabilitano la comunicazione tra due o più specifiche unità e specifica quali operazioni devono essere eseguite; il bus indirizzi contiene l'indirizzo (un numero seriale) che identifica ogni unità coinvolta nella comunicazione; infine, il bus dati contiene i dati effettivi da comunicare.


2. Basi dell'Elettronica

L'obiettivo di questa parte del corso è quello di fornire allo studente una panoramica degli aspetti teorici più fondamentali dell'elettronica, necessari per comprendere concetti più avanzati. Per questo si chiama Basi dell'Elettronica: fornisce al lettore un'introduzione di base all'elettronica che racchiude tutti gli strumenti necessari che verranno utilizzati in seguito, rafforzando le nozioni eventualmente già acquisite dal lettore.

Un circuito comprende una serie di parti interconnesse, ciascuna delle quali impone una propria relazione unica (detta relazione costitutiva) tra due grandezze elettriche: tensione (V) e corrente (I).

Sono queste relazioni, e la loro varietà, che consentono al progettista di circuiti creativo di progettare molti circuiti utili e diversi fra loro. Una volta che sappiamo come le parti sono collegate per formare un circuito, possiamo quindi descrivere quel circuito in termini di relazioni che impone alle tensioni e alle correnti.


Qui introduciamo le principali grandezze elettriche che ci interessano: tensione e corrente. Per capire cosa sono è istruttivo tracciare un'analogia tra i sistemi elettrici e idraulici (sebbene nessuna analogia possa essere considerata esatta): la corrente elettrica è simile al flusso dell'acqua e la tensione è simile alla pressione dell'acqua. Dato un tubo in cui l'acqua può fluire (vedi figura successiva), la portata sarà regolata dalla differenza di pressione dell'acqua tra le sue due estremità. Le dimensioni del tubo determineranno il rapporto tra la portata d'acqua e la differenza di pressione tra le due estremità: un tubo più sottile resisterà al flusso d'acqua, mentre uno più largo permetterà a più acqua di fluire. Allo stesso modo, un componente elettronico determinerà la relazione tra la tensione ai suoi capi e la corrente che lo attraversa.




Allora, cos'è una corrente elettrica? In breve, e senza entrare nei dettagli della fisica, la corrente elettrica è il movimento ordinato, in un pezzo di materiale, di quegli elettroni all'interno del materiale che sono disponibili a muoversi se soggetti ad una tensione. In materiali come rame, argento e la maggior parte dei metalli ci sono molti elettroni liberi (elettroni che non sono legati a un atomo e sono quindi liberi di muoversi se soggetti a una tensione), in modo che una tensione relativamente piccola porti a una corrente sostanziale. Altri materiali come plastica e vetro sono noti come isolanti e hanno pochi elettroni liberi, quindi solo una corrente minuscola riesce a scorrere, anche quando viene applicata una tensione molto elevata. Convenzionalmente, si assegna la direzione positiva della corrente a quella opposta rispetto a quella in cui si muovono gli elettroni (vedi figura precedente). Questa convenzione vale per ragioni storiche.

Cos'è la tensione? La risposta ovvia è che è ciò che incoraggia il flusso di elettroni liberi. In molti casi si produce una tensione con mezzi chimici, come nelle batterie convenzionali; in altri è prodotta da un circuito elettronico. La tensione si misura in Volt (V), e conoscere la tensione in un punto generico ha senso solo se la tensione è nota anche in un altro punto, quello di riferimento. Ciò significa che la tensione è in realtà una quantità differenziale ed è possibile definire una tensione in un punto dello spazio solo se un valore di tensione arbitrario di riferimento è definito in un altro punto (ben specificato) dello spazio. In genere, nei circuiti elettrici viene preso a riferimento un punto (denominato massa) che si assume essere ad un potenziale arbitrariamente settato a 0 V, rispetto al quale vengono calcolati i valori di tensione nei vari punti del circuito.



La differenza tra corrente e tensione può anche essere correlata al modo in cui vengono misurate (vedi figura sotto). La corrente, misurata in Ampere (A), viene solitamente misurata da un misuratore di corrente (chiamato anche amperometro) attraverso il quale scorre effettivamente la corrente da misurare. Solitamente si vuole misurare la corrente senza disturbare il ramo del circuito nel quale fluisce, cioè senza ostacolare o perturbare in alcun modo il flusso di corrente. Per questo motivo, gli amperometri sono generalmente progettati per avere quella che viene chiamata bassa impedenza (il concetto sarà chiarito successivamente). La tensione viene solitamente misurata da un voltmetro i cui due terminali sono collegati ai punti del circuito la cui differenza di tensione deve essere misurata. Come per l'amperometro, per evitare che il collegamento di un voltmetro disturbi il circuito, i voltmetri sono progettati per avere un'impedenza elevata, ovvero impediscono, per quanto possibile, la deviazione di qualsiasi corrente attraverso il voltmetro.



Spesso abbiamo bisogno di discutere di tensioni e correnti e di dar loro dei nomi. Le correnti sono indicate da frecce sovrapposte al filo che trasporta quella corrente, mentre una tensione è indicata da una freccia che si estende tra i due terminali a cui viene misurata la tensione.



2.1. Circuito Aperto e Corto Circuito




Iniziamo a vedere i primi componenti elettronici ideali di questo corso: il circuito aperto e il corto circuito. La prima cosa da dire su tali componenti è che non esistono nel mondo reale! Si tratta infatti di componenti idealizzati (e, in quanto tali, impossibili da realizzare) che però forniscono un modello abbastanza utile per il comportamento di componenti reali in alcune situazioni: ecco perché vogliamo studiare tali oggetti idealizzati.

Un circuito aperto è un componente a due terminali che supporta qualsiasi tensione applicata tra i due terminali garantendo l'assenza di corrente attraverso di sé. Pertanto, la sua relazione costitutiva è $I = 0$:

infatti, indipendentemente dalla tensione applicata, la corrente attraverso un circuito aperto sarà sempre zero.

Un cortocircuito è un componente a due terminali che supporta qualsiasi corrente attraverso di sé garantendo una caduta di tensione nulla ai suoi capi. Pertanto, la sua relazione costitutiva è $V = 0$: infatti, indipendentemente dalla corrente che lo attraversa, la tensione ai capi di un cortocircuito sarà sempre zero.

Di seguito sono riportati i simboli del circuito aperto e del corto circuito, insieme alle loro relazioni costitutive.



2.2. Sorgenti Ideali di Tensione e Corrente


Per rappresentare in un circuito quei componenti che forniscono tensione (ad esempio una batteria) o corrente introduciamo due elementi idealizzati: la sorgente di tensione ideale e la sorgente di corrente ideale.

La sorgente di corrente ideale è un componente a due terminali che garantisce sempre un flusso di corrente dato, fisso e costante attraverso i suoi terminali qualsiasi sia la tensione ai suoi capi (di qualsiasi polarità: positiva o negativa). Pertanto, la sua relazione costitutiva è $I = I^*$, dove I^* è un valore di corrente ben determinato: infatti, indipendentemente dalla tensione ai suoi capi, la sorgente di corrente ideale fornirà sempre una corrente pari a I^* attraverso i suoi terminali. È interessante notare che nel caso in cui $I^* = 0$ la sorgente di corrente ideale si riduce a circuito aperto.


La sorgente di tensione ideale è un componente a due terminali che garantisce sempre una determinata tensione fissa ai suoi capi resiste qualsiasi sia la corrente che lo attraversa (in qualsiasi direzione). Pertanto, la sua relazione costitutiva è $V = V^*$, dove V^* è un valore di tensione ben determinato: infatti, indipendentemente dalla corrente che lo attraversa, la sorgente di tensione ideale fornirà sempre una tensione pari a V^* ai suoi capi. È interessante notare che nel caso in cui $V^* = 0$ la sorgente di tensione ideale si riduce a un cortocircuito.

Di seguito sono riportati i simboli della sorgente di tensione ideale e della sorgente di corrente ideale, insieme ad un diagramma che mostra esplicitamente la relazione tra V (la caduta di tensione tra i due terminali) e I (la corrente attraverso il componente). Tale diagramma, in generale, è chiamato diagramma I - V (o V - I). Il simbolo della sorgente di tensione ideale è costituito da due linee parallele orizzontali. Il valore di tensione associato alla sorgente di tensione ideale corrisponde alla differenza tra la tensione al terminale con la linea più lunga (cosiddetto terminale positivo) e la tensione al terminale con la linea più corta (cosiddetto terminale negativo). Attenzione: questi sono solo nomi e non significano necessariamente che la tensione al polo positivo debba essere più positiva che al polo negativo! Ad esempio, se una sorgente di tensione fornisce 5 V, significa che la tensione al terminale positivo (linea lunga) è maggiore di 5 V rispetto alla tensione al terminale negativo (linea corta). Tuttavia, se una sorgente di tensione fornisce -7 V significa che la tensione al terminale positivo (linea lunga) è di 7 V inferiore (e quindi più negativa) rispetto alla tensione al terminale negativo (linea corta). Spesso vengono utilizzati simboli alternativi, come mostrato nella figura successiva. Il simbolo della sorgente di corrente ideale è costituito da un cerchio che racchiude una freccia, la cui direzione punta nella direzione della corrente definita positiva. Ad esempio, se una sorgente di corrente fornisce 3 A e la sua freccia punta verso l'alto significa che c'è una corrente di 3 A che scorre dal terminale inferiore verso il

terminale superiore. Se, invece, c'è una sorgente di corrente che eroga -4 A e la sua freccia punta verso l'alto significa che c'è effettivamente una corrente di 4 A che scorre dal terminale superiore verso il terminale inferiore.



2.3. Resistore



Probabilmente il componente più elementare e importante nell'elettronica di base è il resistore. Un resistore è un dispositivo a due terminali che stabilisce una relazione costitutiva lineare tra la corrente che lo attraversa e la tensione ai suoi terminali. In particolare, questa relazione è denominata Legge di Ohm e si legge come:

$$V = RI \quad [R] = \Omega = V/A$$


dove V è la tensione ai capi del resistore, I la corrente che lo attraversa e R il parametro principale che caratterizza il resistore, ovvero la resistenza. Per ragioni di accuratezza occorre precisare che la parola "resistore" si riferisce al dispositivo, mentre la parola "resistenza" si riferisce ad una sua specifica proprietà. Tuttavia, in pratica, il termine "resistenza" viene spesso utilizzato anche per indicare il dispositivo (il resistore). La resistenza si misura in Ohm (corrispondenti a V/A), il cui simbolo è la lettera greca maiuscola omega, Ω . A volte ci si riferisce al reciproco della resistenza, cioè alla conduttanza.

$$G = R^{-1} \quad [G] = S = A/V$$

La conduttanza è misurata in Siemens (S), corrispondente ad A/V . Quindi la legge di Ohm può essere riscritta come:

$$I = GV$$

Nella figura seguente sono riportati il diagramma I-V e il simbolo della resistenza. Come si può vedere dal diagramma (e anche dalla relazione costitutiva), se ad un resistore viene applicata una tensione positiva (definita secondo la direzione della freccia di tensione in figura), allora una corrente positiva (definita secondo la direzione della freccia corrente nella figura) scorre. Allo stesso modo, se viene applicata una tensione negativa a un resistore, scorre una corrente negativa. Quindi, tensione e corrente hanno sempre lo stesso segno (attenzione: a tal proposito la direzione delle frecce di tensione e corrente è importante). In particolare, se scegliamo un'altra convenzione per le direzioni di tensioni e correnti (ad esempio invertiamo la direzione della corrente positiva, quindi invertiamo la freccia della corrente ma lasciamo invariata la freccia della tensione) tensione e corrente avranno sempre segni opposti. Ciò ha importanti conseguenze dal punto di vista della valutazione della potenza elettrica, come discusso nel successivo sottocapitolo.



In sintesi, la relazione costitutiva di un resistore (legge di Ohm) è:

$$V = R \cdot I \quad \text{dove} \quad R = \text{Resistenza} \quad [R] = \Omega = \text{Ohm} \quad , \quad \begin{cases} R \rightarrow 0 & \rightarrow \text{corto circuito} \\ R \rightarrow \infty & \rightarrow \text{circuito aperto} \end{cases}$$

$$R = G^{-1} = \text{Conduttanza} \quad [G] = \Omega^{-1} = S = \text{Siemens} \quad \rightarrow \quad I = G \cdot V$$

2.4. Potenza e Convenzioni

La potenza è una grandezza definita come il prodotto tra tensione e corrente e si misura in Watt (W).

$$P = VI \quad [P] = W = VA$$


Tra le tante possibili classificazioni di dispositivi e componenti, ce n'è una molto interessante che distingue tra componenti (o dispositivi) attivi e passivi. A prescindere dalle definizioni precise e complete di componenti attivi e passivi (che esula dagli scopi di questo opuscolo), possiamo dire che, secondo questa classificazione, un componente passivo richiede sempre (dissipa) potenza per funzionare, mentre un dispositivo attivo può produrre (generare) energia durante il lavoro. Naturalmente questa produzione di energia è sempre tale da verificare il principio di conservazione dell'energia: in altre parole, la potenza generata proviene sempre da una fonte di energia (quindi l'energia non viene né creata né distrutta, ma solo trasformata). I dispositivi passivi includono, ad esempio, resistori, condensatori, induttori e diodi (tra gli altri). Esempi di dispositivi attivi sono le sorgenti di tensione (come le batterie) e le sorgenti di corrente. È istruttivo ora dare un'occhiata al diagramma I-V di un resistore, tenendo presente che:

1. Il resistore è un componente passivo
2. Per un resistore, secondo le direzioni delle frecce scelte nella figura sopra, tensione e corrente hanno sempre lo stesso segno

Poiché la potenza è il prodotto di tensione e corrente, significa che, per un resistore, la potenza è sempre positiva. Questa proprietà è in realtà più generale e si applica a tutti i dispositivi passivi (sebbene non lo dimostreremo).

Ora, il fatto che la potenza sia sempre positiva è il risultato della scelta arbitraria della direzione delle frecce per la tensione e la corrente. Convenzionalmente, per i dispositivi passivi adottiamo la convenzione della figura seguente, secondo la quale la freccia della corrente (che definisce la direzione delle correnti positive) e la freccia della tensione (che definisce la direzione delle tensioni positive) puntano in direzioni opposte. In questo caso la potenza per il resistore sarà positiva, poiché sarà sempre il prodotto di quantità che hanno lo stesso segno. Ma se scelgo, ad esempio, che la direzione della corrente positiva sia opposta a quella riportata nella figura sopra, allora tensione e corrente avrebbero sempre segni opposti, e la potenza sarebbe sempre negativa! I due approcci sono entrambi corretti, poiché abbiamo libertà di scelta sulle direzioni delle frecce, ma convenzionalmente adottiamo la cosiddetta *convenzione dell'utilizzatore* per i dispositivi passivi (quella secondo la quale le frecce di corrente e tensione puntano in direzioni opposte). In questo modo, la potenza sarà sempre positiva per i dispositivi passivi (dissipano sempre energia).

Invece, per i dispositivi attivi adottiamo convenzionalmente la *convenzione del generatore* secondo la quale le frecce di corrente e di tensione puntano nella stessa direzione. Per questa convenzione, una potenza positiva significa che il dispositivo sta generando energia e non la dissipa! Tuttavia i dispositivi attivi, in alcune condizioni, possono anche dissipare potenza e in questo caso la loro potenza sarà negativa (a patto di adottare la *convenzione del generatore*). In ogni caso siamo sempre liberi di scegliere la convenzione che più ci piace, ma una volta scelta dobbiamo mantenere la coerenza con segni, simboli e relative interpretazioni per evitare errori. Di seguito un esempio:



Nella figura sopra, la *convenzione dell'utilizzatore* è adottata sia per una sorgente di tensione (a) che per un resistore (b). La *convenzione dell'utilizzatore* implica che una potenza positiva significhi dissipazione di potenza. Il diagramma I-V del resistore indica chiaramente che la potenza è sempre positiva, quindi il resistore dissipa sempre potenza e non può mai fornire energia. In effetti, la potenza dissipata su un resistore può essere scritta come:

$$P = V \cdot I = R \cdot I^2 = V^2/R$$

e poiché R è definito positivo, allora anche P è sempre positivo. Il diagramma I-V della sorgente di tensione indica che la potenza può essere positiva o negativa, a seconda della direzione della corrente. Se la corrente è positiva (secondo la direzione della freccia della corrente), allora la potenza sarà positiva, quindi la sorgente

di tensione dissiperà potenza (in accordo con la convenzione che abbiamo scelto). Al contrario, se la corrente è negativa, la potenza sarà negativa e quindi la sorgente di tensione genererà potenza.


2.5. Leggi di Kirchhoff

Di seguito un brevissimo riassunto su cosa sia un circuito dal punto di vista topologico e sulle leggi di Kirchhoff. Questa trattazione non ha la pretesa di essere completa e il lettore è incoraggiato a consultare libri o note di ingegneria elettrica di base qualora la seguente breve discussione risultasse ostica da comprendere.

Un circuito elettrico è interamente definito dai suoi componenti e dalle loro connessioni, e può essere visto in termini di rami e nodi. Un nodo è una giunzione in cui si collegano due o più elementi ed è caratterizzato da un valore di tensione univoco. Un ramo è un percorso che collega due nodi ed è caratterizzato da un valore unico della corrente. Per risolvere le tensioni e le correnti nel circuito è sufficiente considerare le relazioni costitutive di tutti gli elementi nei circuiti insieme a due leggi, dette leggi di Kirchhoff.

La prima legge di Kirchhoff, chiamata anche legge di Kirchhoff alle correnti (KCL), afferma che, per qualsiasi nodo (giunzione) in un circuito elettrico, la somma delle correnti che entrano in quel nodo è uguale alla somma delle correnti che escono da quel nodo; o equivalentemente, la somma algebrica delle correnti afferente ad un nodo è zero.

La seconda legge di Kirchhoff, chiamata anche legge di Kirchhoff (KVL) alle tensioni, afferma che la somma algebrica delle differenze di potenziale (tensioni) attorno a qualsiasi anello chiuso è zero.



$$KCL \rightarrow \sum_{node} I = 0, \quad KVL \rightarrow \sum_{loop} V = 0$$

Si dice che due dispositivi sono in configurazione parallela se condividono gli stessi nodi. Data la KVL, sperimentano anche la stessa tensione. Al contrario, si dicono in configurazione in serie se giacciono lungo lo stesso ramo. In questo caso, sperimenteranno la stessa corrente come conseguenza della KCL.

2.6. Resistori: Serie e Parallelo

Come conseguenza delle KVL e KCL, due resistori in serie R_1 e R_2 si comporteranno come un unico resistore con resistenza R :

$$R = R_1 + R_2$$

Due resistor in parallelo R_1 and R_2 si comporteranno come un singolo resistore con resistenza R :

$$R = \frac{R_1 \cdot R_2}{R_1 + R_2}$$

La derivazione di queste semplici regole è la seguente e si basa sull'uso della KCL, della KVL e della relazione costitutiva del resistore (cioè la legge di Ohm).

- Collegamento in serie – Partitore di tensione: la stessa corrente scorre in entrambi i resistori, mentre la tensione ai capi dei due resistori può essere diversa. Chiamando I_1 e I_2 la corrente in R_1 e R_2 , V_1 e V_2 la tensione su R_1 e R_2 , V la tensione su tutta la serie e I la corrente su tutta la serie, ne consegue che:


$$I = I_1 = I_2 \quad e \quad V = V_1 + V_2 \quad \rightarrow \quad V_1 = R_1 \cdot I \quad e \quad V_2 = R_2 \cdot I$$

$$V = (R_1 + R_2) \cdot I = R_{eq} \cdot I \quad \rightarrow \quad R_{eq} = R_1 + R_2$$

- Collegamento in parallelo - Partitore di corrente: stessa tensione sui resistori, mentre la corrente che fluisce nei due resistori può essere diversa. Chiamando I_1 e I_2 la corrente in R_1 e R_2 , V_1 e V_2 la tensione su R_1 e R_2 , V la tensione su tutto il parallelo e I la corrente attraverso tutto il parallelo, ne consegue che:

$$V = V_1 = V_2 \quad e \quad I = I_1 + I_2 \quad \rightarrow \quad I_1 = G_1 \cdot V \quad e \quad I_2 = G_2 \cdot V$$

$$I = (G_1 + G_2) \cdot V \quad \rightarrow \quad R_{eq} = \frac{1}{\frac{1}{R_1} + \frac{1}{R_2}} = \frac{R_1 \cdot R_2}{R_1 + R_2} = R_1 || R_2$$




2.7. Condensatore


Il condensatore è un componente lineare in grado di immagazzinare carica elettrica, come una sorta di contenitore. Stabilisce una relazione lineare tra la carica immagazzinata e la tensione ai suoi terminali.

$$Q = C \cdot V \quad \text{dove} \quad Q = \text{carica elettrica} \quad [Q] = C = \text{Coulomb}$$

Siccome per definizione:

$$I = \frac{dQ}{dt} \quad \rightarrow \quad I = C \cdot \frac{dV}{dt} \quad \text{dove} \quad C = \text{capacità} \quad [C] = F = \text{Farad}$$






Le equazioni precedenti possono essere interpretate come segue. Se viene applicata una tensione al condensatore, immagazzinerà una certa carica e, viceversa, se una certa carica è immagazzinata nel condensatore, il condensatore mostrerà una certa tensione ai suoi terminali. Affinché la carica venga immagazzinata nel condensatore, è necessario che una certa corrente fluisca dentro (carica) o fuori (scarica) il condensatore. La corrente in un condensatore scorre solo quando la tensione ai suoi capi cambia nel tempo. Nella figura sopra sono riportati l'andamento della corrente e della tensione nel tempo per due casi esemplificativi: i) corrente costante fornita al condensatore da una sorgente di corrente ideale (che provocherà la carica del condensatore e l'aumento lineare della tensione nel tempo) e ii) forma d'onda di corrente con un comportamento costante a tratti fornita al condensatore (che provocherà la carica e la scarica del condensatore nel tempo). Nello specifico, nel secondo esempio è istruttivo vedere come il valore della corrente in un determinato istante di tempo non sia correlato al valore della tensione ma solo alla sua derivata nel tempo. Ciò implica anche che il valore iniziale della tensione (al tempo $t=0$) nel secondo esempio non può essere determinato se non è noto a priori (dipende dalla storia precedente del condensatore). In effetti, l'unica informazione fornita dal grafico è che la corrente a $t=0$ è nulla, il che significa solo che la tensione non può variare nel tempo, ma non fornisce informazioni sul valore effettivo della tensione ai capi del condensatore.

2.8. Induttore

L'induttore è il duale del condensatore ed è un componente lineare in grado di immagazzinare energia magnetica. Stabilisce una relazione lineare tra la tensione ai suoi terminali e la variazione nel tempo della corrente attraverso di essa.

$$V = L \cdot \frac{dI}{dt}$$

dove L è l'induttanza, misurata in Henry [H].




L'equazione precedente può essere interpretata come segue. Se viene applicata una tensione all'induttore, la corrente che lo attraversa varierà nel tempo, immagazzinando o estraendo dell'energia magnetica. La tensione su un induttore appare in risposta alle variazioni di corrente nel tempo. In altre parole, l'induttore lascia fluire corrente (indipendentemente dalla sua grandezza) con caduta di tensione zero ai suoi terminali

(più o meno come un cortocircuito) ma solo se la corrente si mantiene costante nel tempo. Nella figura sopra, il comportamento di corrente e tensione nel tempo è riportato per una forma d'onda di tensione con un comportamento costante a tratti fornita all'induttore (che ne causerà la carica e la scarica nel tempo). In particolare, è istruttivo vedere come il valore della tensione in un determinato istante di tempo non sia correlato al valore della corrente ma solo alla sua derivata nel tempo. Ciò implica anche che il valore iniziale della corrente (al tempo $t=0$) non può essere determinato se non è noto a priori (dipende dalla storia precedente dell'induttore). In effetti, l'unica informazione che fornisce il grafico è che la tensione a $t=0$ è nulla, il che significa solo che la corrente non può variare nel tempo, ma non fornisce informazioni sul valore effettivo della corrente nell'induttore.

2.9. Carica e Scarica di un Condensatore

È istruttivo vedere come si comporta un componente “reattivo” (il perché condensatori e induttori vengono detti componenti reattivi sarà chiarito in seguito) come un condensatore in un circuito che include anche altri componenti. Un classico esempio è il circuito RC mediante il quale è possibile caricare un condensatore. Il circuito è composto da una sorgente di tensione costante e da un interruttore ideale, che si comporta come un circuito aperto se è spento e come un corto circuito se è acceso. Consideriamo inoltre che il passaggio dallo stato OFF allo stato ON e viceversa sia istantaneo.



Per $t < 0$ l'interruttore è OFF e si comporta come un circuito aperto. Quindi, nessuna corrente può fluire attraverso di esso e nell'intero circuito (poiché tutti gli elementi sono in serie). L'assenza di corrente nel circuito implica i) nessuna caduta di tensione attraverso il resistore; ii) nessuna variazione di tensione ai capi del condensatore. Infatti:

$$\begin{aligned} I &= I_{switch} = I_R = I_C = 0 \\ I_C &= C \frac{dV_C}{dt} = 0 \quad \rightarrow \quad \frac{dV_C}{dt} = 0 \\ I_R &= V_R/R = 0 \quad \rightarrow \quad V_R = 0 \end{aligned}$$

Si noti come l'unica conclusione che possiamo trarre dallo stato del condensatore è che la tensione ai suoi capi (e quindi la carica in esso immagazzinata) non può cambiare, ma non viene detto nulla sul suo valore. Questa è infatti una condizione iniziale che deve essere nota a priori. In questo esempio, facciamo l'ipotesi di una tensione iniziale nulla ai capi del condensatore. Pertanto, la tensione ai capi dell'interruttore è uguale a quella fornita dalla sorgente di tensione. Nel caso più generale in cui ai capi del condensatore è presente una tensione iniziale diversa da zero, allora la tensione sull'interruttore è chiaramente la differenza tra quella fornita dalla sorgente di tensione e quella presente sul condensatore.

All'istante $t = 0$, l'interruttore viene commutato bruscamente nello stato ON e il suo comportamento cambia improvvisamente a quello di un cortocircuito ideale. Ora l'equazione che governa il circuito è:

$$V_b - RI_R(t) - V_C(t) = 0$$

Considerando che la corrente nel resistore è la stessa di quella nel condensatore, e la relazione costitutiva del condensatore, otteniamo:

$$V_b - RC \frac{dV_C(t)}{dt} - V_C(t) = 0$$

cioè un'equazione differenziale del primo ordine, che insieme alla condizione iniziale sulla tensione ai capi del condensatore $V_C(0)$ forma un problema di Cauchy. La soluzione di questo problema è:

$$V_C(t) = (V_b - V_C(0)) \left[1 - e^{-\frac{t}{RC}} \right] + V_C(0)$$

Se assumiamo, per esempio, $V_C(0) = 0$, allora:

$$V_C(t) = V_b \left[1 - e^{-\frac{t}{RC}} \right]$$

E la carica nel condensatore:

$$Q_C(t) = CV_C(t) = CV_b \left[1 - e^{-\frac{t}{RC}} \right]$$

Di conseguenza, non appena l'interruttore passa allo stato ON, la tensione ai capi del condensatore inizia a crescere rapidamente seguendo un esponenziale negativo, per poi rallentare e saturare alla tensione fornita dalla sorgente di tensione. La dinamica temporale del processo di carica è dettata dal valore RC , che ha dimensione fisica uguale a quella del tempo, ed è spesso chiamato costante di tempo del circuito. Dopo un tempo $= RC$ dal momento in cui l'interruttore è chiuso, il processo di carica ha raggiunto circa il 68% del suo completamento. Dopo un tempo $= 3RC$, quasi il 95% del processo di carica è completo. Il comportamento della carica ai capi del condensatore (che è proporzionale alla tensione ai capi del condensatore) è riportato con una linea rossa continua nella figura sottostante (asse y destro) per il caso in cui $V_C(0) = 0$.


La corrente nel circuito è:

$$I_C = I_R = C \frac{dV_C(t)}{dt} = \frac{V_b - V_C(0)}{R} e^{-\frac{t}{RC}}$$

che si semplifica come segue se si assume $V_C(0) = 0$.

$$I_C = I_R = C \frac{dV_C(t)}{dt} = \frac{V_b}{R} e^{-\frac{t}{RC}}$$


In particolare, la corrente a $t = 0$ salta bruscamente da 0 fino al valore massimo $\frac{V_b - V_C(0)}{R}$ e quindi scende esponenzialmente a zero, con la stessa dinamica temporale della tensione ai capi del condensatore. Il comportamento della corrente nel circuito (che è proporzionale alla tensione ai capi del resistore) è riportato con una linea nera tratteggiata nella figura sottostante (asse y sinistro) per il caso in cui $V_C(0) = 0$.




Per comprendere i dettagli del processo di carica, è istruttivo ricordare che, quando l'interruttore è su ON, la tensione fornita dalla batteria si divide tra il resistore e il condensatore. La loro somma è vincolata ad essere costante, tuttavia le due singole quantità possono cambiare nel tempo. In particolare, supponendo che $V_C(0) = 0$, all'inizio il condensatore è scarico e quindi tutta la tensione erogata dalla batteria ricade sulla resistenza. Ciò significa che la corrente nel circuito sarà alta, poiché è proporzionale alla tensione ai capi del resistore. Mentre la corrente (alta) scorre, carica (rapidamente) il condensatore, che ora mostra una tensione più alta ai suoi capi. Ciò riduce la tensione sul resistore e anche la corrente nel circuito. La corrente (ora più piccola) provoca la continuazione del processo di carica ma ad una velocità inferiore. Maggiore è la tensione ai capi del condensatore, più piccola sarà quella ai capi del resistore e anche la corrente nel circuito, il che rallenta ancora di più il processo di carica. Alla fine, il processo termina (a $t = \infty$) quando la tensione ai capi del condensatore è uguale a quella fornita dalla sorgente di tensione, senza caduta di tensione sul resistore e senza corrente nel circuito. Si noti che la corrente è la forza trainante della variazione di tensione attraverso il condensatore. Infatti, per caricare più velocemente un dato condensatore, sarebbe necessaria una R più piccola (una R più piccola implica una costante di tempo RC più piccola), che però si traduce in una corrente più alta (e infatti la linea nera tratteggiata nella figura sopra è inversamente proporzionale a R).

2.10. Principio di Sovrapposizione degli Effetti


Finora ci siamo occupati di circuiti molto semplici in cui c'era sempre una sola fonte di alimentazione (sia in tensione che in corrente). Tuttavia, la maggior parte dei circuiti ha più di una sorgente. Come analizzare tali circuiti? Sicuramente applicare KVL e KCL insieme alla relazione costitutiva di tutti i componenti è il modo corretto. Tuttavia, esiste un modo molto semplice e intuitivo di trattare tali circuiti, grazie al cosiddetto principio di sovrapposizione. La strategia consiste nello scomporre il circuito in un insieme di sottocircuiti modificati in modo tale che ognuno dei sottocircuiti mantenga solo una fonte di alimentazione mentre le altre saranno eliminate. Si utilizza poi l'analisi circuitale per determinare le cadute di tensione (e/o le correnti) all'interno dei vari sottocircuiti, separatamente per ogni sottocircuito. In fine, si sommano gli effetti (i valori di tensione e corrente) dei vari sottocircuiti. Per eliminare una sorgente di tensione, la impostiamo a zero volt, quindi la sostituiamo con un cortocircuito (di fatto, equivalente a una sorgente di tensione zero). Allo stesso modo, per eliminare una sorgente di corrente, la impostiamo a zero ampere, sostituendola quindi con un circuito aperto (di fatto equivalente ad una sorgente di corrente zero). Quindi, una volta determinate le cadute di tensione e/o le correnti per ciascun sottocircuito, i valori vengono tutti "sovrapposti" (sommati algebricamente) per trovare le effettive cadute di tensione e le effettive correnti nel circuito originale con tutte le sorgenti di alimentazione. Diamo un'occhiata a questo circuito di esempio:





Applichiamo ad esso il principio di sovrapposizione. Dato che abbiamo due sorgenti di alimentazione in questo circuito, dovremo analizzare due sottocircuiti, uno con solo la batteria da 28 V (riportato qui in basso - notare che la sorgente di tensione da 7 V è stata sostituita da un cortocircuito):




... e uno con la sola sorgente da 7 V, ovvero (si noti che la sorgente di tensione a 28 V è stata sostituita da un cortocircuito):



Analizzando separatamente il circuito con la sola batteria da 28 V (figura seguente - pannello di sinistra) e il circuito con la sola batteria da 7 V (figura seguente - pannello di destra), otteniamo i seguenti valori di tensione e corrente:



Ora, quando si sovrappongono i valori di tensione e corrente, bisogna stare molto attenti a considerare la polarità (della caduta di tensione) e la direzione (del flusso di corrente), in quanto i valori devono essere sommati algebricamente. Applicando i valori di tensione e corrente sovrapposti, otteniamo:




Si noti che è sufficiente sommare solo le correnti e poi calcolare le cadute di tensione applicando le relazioni costitutive su ciascun componente nel circuito completo. Viceversa è possibile sommare solo le cadute di tensione e poi calcolare le correnti applicando le relazioni costitutive a tutti i componenti nel circuito completo. Infine, lo stesso risultato si ottiene sommando sia le cadute di tensione che le correnti.

Sebbene abbiamo analizzato il caso di circuiti puramente resistivi (solo resistori, oltre ai generatori), il principio di sovrapposizione può essere esteso a circuiti che includono componenti reattivi (come induttori e

condensatori) introducendo il concetto generalizzato di impedenza (vedi sottocapitoli successivi). Tuttavia, funziona solo per circuiti rappresentati da equazioni lineari. Il requisito della linearità significa che il principio è applicabile solo per determinare la tensione e la corrente, non la potenza! Le dissipazioni di potenza, essendo calcolate tramite funzioni non lineari, non si sommano algebricamente. Ciò implica che, per calcolare correttamente la potenza generata o dissipata da ciascun elemento, è necessario prima calcolare la tensione e la corrente su tutti i componenti utilizzando il principio di sovrapposizione, quindi calcolare la potenza per ciascun elemento. Il requisito di linearità implica anche che questo teorema non può essere applicato nei circuiti in cui la resistenza di un componente cambia con la tensione o la corrente (caso che non abbiamo visto). Un altro prerequisito per il teorema di sovrapposizione è che tutti i componenti devono essere "simmetrici", nel senso che si comportano allo stesso modo se la polarità della tensione viene invertita (in sostanza, non ci accorgiamo della differenza se un elemento simmetrico viene capovolto). I resistori, proprio come gli induttori e i condensatori, non hanno un comportamento specifico per una specifica polarità (sebbene alcuni particolari condensatori possano mostrare dipendenza dalla polarità, ma questa è un'altra storia), quindi i circuiti che abbiamo studiato finora soddisfano tutti questo criterio. Il principio di sovrapposizione trova anche impiego nello studio dei circuiti a corrente alternata (AC) e dei circuiti con elementi a semiconduttore, dove le componenti AC sono spesso mescolate (sovrapposte) ad una componente DC (una discussione sui segnali AC e DC è riportata nel sottocapitolo 2.12).

2.11. Circuiti Equivalenti: Teoremi di Thevenin e Norton

In molti casi è utile considerare un circuito o una porzione di circuito come un "circuito equivalente". Il concetto di "circuito equivalente" è illustrato nella figura seguente. Supponiamo di avere un circuito (ad esempio quello della figura seguente) e supponiamo che il circuito sia racchiuso in una scatola opaca che ci impedisce di vedere come è organizzato il circuito.




Vediamo solo due fili che escono dalla scatola opaca, che possiamo nominare terminali A e B. Anche se ignoriamo il contenuto della scatola opaca, potremmo testare il comportamento del circuito utilizzando questi due terminali (ad esempio forzando forme d'onda di tensione specifiche su di essi e misurando le forme d'onda di corrente risultanti). Da queste informazioni saremo in grado di disegnare un circuito che si comporta esattamente come risulta dalle misurazioni effettuate. Il circuito non sarà necessariamente identico al contenuto della scatola opaca ma si comporterà allo stesso modo. Abbiamo abbozzato un cosiddetto circuito equivalente. Il concetto di circuito equivalente è estremamente utile per rappresentare porzioni di circuito complesse in modo semplice. In generale, due importanti teoremi (di Thevenin e di Norton) affermano che un generico circuito lineare non dinamico (cioè senza C e L) osservato da due nodi può essere rappresentato in termini di (cioè si comporterà come) un circuito equivalente fatto solo di due componenti. In particolare:

Il teorema di Thevenin afferma che un generico circuito lineare non dinamico osservato da due nodi può essere rappresentato da una sorgente di tensione (V_{th}) in serie con un resistore (R_{th}). Specifica inoltre come

calcolare la tensione della sorgente di tensione e la resistenza del resistore. Tuttavia noi non tratteremo questa procedura.


Il teorema di Norton afferma che un generico circuito lineare non dinamico black box osservato da due nodi può essere rappresentato da una sorgente di corrente (I_{no}) in parallelo con un resistore (R_{no}). Specifica inoltre come calcolare la corrente della sorgente di corrente e la resistenza del resistore. Tuttavia noi non tratteremo questa procedura.



Nella figura sopra, i teoremi di Thevenin e Norton sono stati applicati allo stesso circuito, dando due rappresentazioni che sono ovviamente equivalenti (poiché sono rappresentazioni equivalenti dello stesso circuito, quindi identiche tra loro dal punto di vista comportamentale). Pertanto, ci sono anche modi per passare da una rappresentazione all'altra. Entrambi i teoremi possono essere generalizzati per includere componenti L e C, utilizzando il concetto di impedenza (vedi i seguenti sottocapitoli).


2.12. DC vs. AC

Quando si tratta di segnali è in generale importante distinguere i cosiddetti segnali DC (Direct Current, ossia in corrente continua) dai segnali AC (Alternated Current, ossia in corrente alternata). Si noti che, nonostante i loro nomi, DC e AC sono etichette con cui identifichiamo proprietà specifiche di qualsiasi segnale, non necessariamente un segnale di corrente. Un segnale DC è definito come una funzione del tempo perfettamente costante. Ad esempio, si dice che un generatore di tensione ideale che fornisce una tensione costante nel tempo, come quella mostrata in rosso nella figura seguente, sia una sorgente di tensione DC. Una fonte comune di tensione DC è una cella di una batteria. Al contrario, un segnale AC non solo cambia nel tempo, ma inverte periodicamente il suo segno. Solo per citare un esempio, l'energia elettrica viene fornita ad aziende e residenze sotto forma di tensione alternata. La forma d'onda per antonomasia dei segnali AC è la sinusoide, come quella rappresentata in verde nella figura a destra, il cui semiperiodo positivo corrisponde alla direzione positiva della corrente e viceversa. Tuttavia, si incontrano frequentemente segnali di forma arbitraria, come quello mostrato in grigio nella figura a destra (etichettato come "variabile"). A volte vengono fatte altre distinzioni, come il segnale pulsante evidenziato in blu nella figura sopra. Un tale segnale non è un segnale AC di per sé, poiché non inverte periodicamente il suo segno. Tuttavia, non è un segnale DC poiché cambia nel tempo. In effetti, possiamo vedere questo segnale come se avesse una componente DC sovrapposta a una AC. Si potrebbero fare anche altre distinzioni. Tuttavia, ci concentreremo sulla forma d'onda prototipica dei segnali AC, cioè l'onda sinusoidale, poiché, secondo l'analisi di Fourier, tutti i segnali possono essere visti come una sovrapposizione di onde sinusoidali con diverse ampiezze, fasi e frequenze. In matematica, l'analisi di Fourier è lo studio del modo in cui funzioni arbitrariamente complicate possono essere rappresentate o approssimate dalla somma di funzioni trigonometriche più semplici. Il processo di scomposizione di un segnale arbitrario (in rosso nella figura sotto), nelle sue componenti trigonometriche (onde colorate nella figura sotto) è



chiamato trasformazione di Fourier. La sua uscita, la trasformata di Fourier, è spesso chiamata lo spettro di un segnale ed è rappresentata in verde e arancione nella figura sottostante (lungo l'asse delle frequenze).

In questo esempio, il segnale in rosso (di forma arbitraria) è considerato periodico, con il suo periodo che va dal tempo $t = 0$ a $t = T$ (nella figura sotto è mostrato un solo periodo). Secondo l'analisi di Fourier, questo segnale può essere rappresentato esattamente come la somma di un numero infinito di componenti (onda 0, onda 1, onda 2, ..., onda ∞) che sono onde sinusoidali (o, equivalentemente, cosinusoidali) a frequenze diverse, ciascuna con ampiezza e fase ben specificate. La prima componente (onda 0) ha frequenza zero e rappresenta il valore medio del segnale nell'intervallo $[0, T]$. Poiché il segnale è considerato periodico, questo è anche il valore medio dell'intero segnale. Si noti che questa componente è, di per sé, la componente DC del segnale.




L'ampiezza (in verde) e la fase (in arancione) di questa sinusoide a frequenza zero definiscono quindi il valore medio del segnale, e sono visualizzate sull'asse della frequenza. Le altre componenti sono definite a frequenze specifiche, che sono multipli interi di $\Delta\omega = 2\pi/T$. Ciascuna di queste componenti ha la propria ampiezza (in verde) e fase (in arancione), che appaiono come punti lungo l'asse della frequenza. Pertanto, se si conoscono l'ampiezza e la fase di ciascuna componente, il segnale originale può essere riprodotto esattamente. L'analisi di Fourier dice esattamente come calcolare l'ampiezza e la fase di ogni componente, ma la sua rigorosa dimostrazione matematica esula dagli scopi di questo opuscolo. È sufficiente comprendere che tutte le informazioni contenute nel segnale come mostrato nel dominio del tempo possono essere guardate da un'altra prospettiva, cioè osservando i valori dell'ampiezza e della fase delle diverse componenti in frequenza. Si noti che ad ogni frequenza possiamo associare un numero complesso, la cui grandezza rappresenta l'ampiezza della componente e la cui fase rappresenta la fase della componente. Pertanto, la trasformata di Fourier (spettro) di un segnale è una funzione complessa della frequenza (cioè, associa un numero complesso a ciascun valore di frequenza, che contiene tutte le informazioni necessarie per specificare completamente quella componente). Nella figura sopra, l'ampiezza e la fase sono rappresentate da due linee diverse, rispettivamente in verde e in arancione. È importante notare che l'assunzione di un segnale periodico (nel dominio del tempo) si traduce in uno spettro discreto. Infatti, nell'esempio sopra, le componenti sono definite a specifiche frequenze discrete che sono multipli interi di $\Delta\omega = 2\pi/T$, che è inversamente proporzionale a T . Se T è finito, cioè il segnale è periodico, le frequenze risultanti sono discrete. In altre parole, lo spettro è definito solo a frequenze specifiche. Prendiamo ora in considerazione un segnale

non periodico. Un tale segnale può essere visto matematicamente come un segnale che è periodico ma ha un periodo infinitamente esteso. Se prendiamo il limite per $T \rightarrow \infty$, allora $\Delta\omega \rightarrow 0$. Ciò significa che lo spettro di un segnale non periodico sarà continuo e non discreto, cioè definito a tutti i possibili valori di frequenza.

Il messaggio più importante di questo sottocapitolo è che, come risultato dell'analisi di Fourier, se è nota la risposta di un sistema a un ingresso sinusoidale a qualsiasi frequenza, allora è possibile conoscere la risposta del sistema a qualsiasi tipo di input, semplicemente perché un input arbitrario può essere visto come una somma di componenti sinusoidali. Questo è il motivo per cui esamineremo frequentemente la cosiddetta risposta in frequenza dei circuiti, ovvero la relazione ingresso-uscita per un ingresso sinusoidale a frequenza arbitraria. Nello specifico, i dispositivi più semplici che mostrano un comportamento dipendente dalla frequenza e come tali possono essere analizzati osservando il loro comportamento nel dominio della frequenza sono componenti reattivi come induttori e condensatori.

2.13. Analisi Complessa e Impedenza

Finora ci siamo occupati di circuiti alimentati solo da sorgenti DC. Abbiamo appreso che, in tali circuiti, in ogni ramo la corrente sarà DC, così come la tensione ai capi dei diversi componenti. Anche nel caso in cui il comportamento del circuito cambia nel tempo (ad esempio, se un interruttore cambia il suo stato in un determinato istante di tempo), si verificheranno alcuni effetti transitori in modo che la corrente e la tensione ai capi dei componenti cambino nel tempo, ma solo per convergere su un altro valore DC. È ora utile cercare di capire cosa succede se i circuiti elettrici, e in particolare alcuni componenti elettrici, vengono alimentati con tensioni o correnti AC.



Intuitivamente, se viene applicata una tensione AC su un resistore, la corrente che lo attraversa sarà anche un segnale AC con la stessa frequenza e la stessa fase. La sua ampiezza sarà solo proporzionale al segnale di tensione AC e inversamente proporzionale alla resistenza del resistore. Questa è chiaramente una conseguenza della legge di Ohm. Infatti, se $v(t) = V\sin(\omega t + \theta)$, allora:

$$i(t) = \frac{v(t)}{R} = \frac{V}{R}\sin(\omega t + \theta) = I\sin(\omega t + \theta)$$

È facile vedere che la corrente ha esattamente la stessa forma della tensione. Diciamo che, per un resistore, corrente e tensione sono iso-frequenziali e in fase tra loro. Diverso è invece il caso dei condensatori e degli induttori. Infatti, prendendo l'esempio del condensatore, se su di esso viene applicata una tensione AC, la corrente che lo attraversa sarà anche un segnale AC con la stessa frequenza ma non con la stessa fase. Questa è una conseguenza della relazione costitutiva del condensatore. Infatti, se $v(t) = V\sin(\omega t + \theta)$, allora:

$$i(t) = C \frac{dv(t)}{dt} = \omega C V \cos(\omega t + \theta) = I\sin\left(\omega t + \theta + \frac{\pi}{2}\right)$$

È facile vedere che la corrente non ha la stessa identica forma della tensione. Per un condensatore, la corrente e la tensione sono iso-frequenziali ma non in fase l'una con l'altra. In realtà sono sfasati di 90° (quando ciò accade i due segnali si dicono in quadratura). Inoltre, è istruttivo notare che l'ampiezza della corrente, I , dipende non solo dall'ampiezza della tensione alternata e dalla capacità ma anche, curiosamente, dalla frequenza del segnale di tensione alternata (diversamente dal caso della resistenza). Considerazioni

simili possono essere fatte sull'induttore (il lettore è incoraggiato a svolgere i calcoli nel caso dell'induttore per verificare le conseguenze). Si noti, di conseguenza, che nel caso del resistore la quantità

$$\frac{v(t)}{i(t)} = R$$

è una costante a valore reale, mentre nel caso del condensatore e dell'induttore è funzione del tempo. Ad esempio, nel caso del condensatore:

$$\frac{v(t)}{i(t)} = \frac{V}{\omega CV} \frac{\sin(\omega t + \theta)}{\sin\left(\omega t + \theta + \frac{\pi}{2}\right)} = \frac{1}{\omega C} \frac{\sin(\omega t + \theta)}{\sin\left(\omega t + \theta + \frac{\pi}{2}\right)}$$

Pertanto, sembra che non sia possibile per i componenti reattivi determinare una quantità come la resistenza per il resistore, ovvero un numero che incarni pienamente la relazione tra la tensione e la corrente. In effetti, questa quantità può essere determinata ma sarà un numero complesso anziché un numero reale. Per capire come e perché, introduciamo ora una rappresentazione alternativa dei segnali AC in termini di fasori, cioè vettori rotanti rappresentati da numeri complessi. Sono introdotti perché semplificano notevolmente il calcolo matematico nei circuiti con resistori e componenti reattivi e forniscono una relazione universale che consente di trattare componenti resistivi e reattivi in modo unificato.


Nel caso del condensatore, lo scopo è riscrivere la tensione applicata in termini diversi. In generale, ricordando il Teorema di Eulero (dove j è l'unità immaginaria):

$$e^{j\omega t} = \cos \omega t + j \cdot \sin \omega t$$

possiamo trovare un modo utile per riscrivere la tensione applicata, considerata una generica onda cosinusoidale, come:

$$v(t) = V \cdot \cos(\omega t + \theta) = \text{Re}\{V \cdot e^{j\theta} \cdot e^{j\omega t}\} = \text{Re}\{\tilde{V} \cdot e^{j\omega t}\}$$

dove V è l'ampiezza della tensione (un numero reale), θ è la fase iniziale della tensione, mentre $\tilde{V} = V \cdot e^{j\theta}$ è la tensione complessa, un numero complesso avente modulo V e fase θ . Si noti che la tensione è ora scritta come la parte reale del prodotto di due termini. Il primo termine è la tensione complessa, un numero complesso che contiene informazioni sull'ampiezza e la fase della tensione, mostrato in arancione nel piano complesso a destra. Il secondo termine è l'unico che dipende dal tempo e contiene informazioni sulla dipendenza dal tempo della tensione (cioè la sua frequenza di oscillazione). Di per sé, anche il secondo termine è un numero complesso, di ampiezza unitaria e fase che dipende linearmente dal tempo. In altre parole, può essere visto come un vettore rotante di lunghezza unitaria, che ruota ad una frequenza angolare ω . Il prodotto dei due termini è un vettore rotante di lunghezza pari all'ampiezza della tensione, che a $t = 0$ forma un angolo θ con l'asse reale, e che ruota nel tempo con una frequenza angolare ω . Lo scopo di questa trasformazione del formalismo è di derivare un'espressione per la corrente che abbia la stessa forma di quella usata per la tensione. La corrente nel condensatore è ovviamente:



$$i(t) = C \cdot \frac{dv(t)}{dt} = -C \cdot V \cdot \omega \cdot \sin(\omega t + \theta) = C \cdot V \cdot \omega \cdot \cos\left(\omega t + \theta + \frac{\pi}{2}\right) \\ = \operatorname{Re}\left\{C \cdot V \cdot \omega \cdot e^{j\theta} \cdot e^{j\omega t} \cdot e^{j\frac{\pi}{2}}\right\}$$

Notiamo che la suddetta espressione è di fatto la parte reale del prodotto di un numero complesso e di un vettore unitario rotante. Infatti, ha la forma:

$$i(t) = \operatorname{Re}\{\tilde{I} \cdot e^{j\omega t}\}$$

Dove $\tilde{I} = \omega \cdot C \cdot V \cdot e^{j\theta} \cdot e^{j\frac{\pi}{2}}$ è la cosiddetta corrente complessa, mostrata in blu nella figura precedente. Poiché $e^{j\frac{\pi}{2}} = j$, e poiché $V \cdot e^{j\theta} = \tilde{V}$, allora:

$$\tilde{I} = j \cdot \omega \cdot C \cdot \tilde{V}$$

Pertanto, adottando questo nuovo formalismo possiamo vedere chiaramente che sia la corrente che la tensione possono essere scritte nella stessa forma, ovvero come la parte reale del prodotto tra la corrente (o tensione) complessa e un vettore unitario rotante che ruota alla velocità angolare del segnale di corrente e tensione (che infatti sono iso-frequenziali). In particolare, è possibile definire l'impedenza del condensatore come

$$Z_C = \frac{\tilde{V}}{\tilde{I}} = \frac{1}{j\omega C} = -j \frac{1}{\omega C}$$

Troviamo quindi che per il condensatore, mentre è impossibile stabilire una relazione lineare tra la corrente e la tensione, è possibile definire una relazione lineare tra la corrente complessa e la tensione complessa. Nello specifico, il rapporto tra la tensione complessa e la corrente complessa è chiamato impedenza ed è un numero complesso, misurato in Ohm. Essendo formata da una tensione complessa e da una corrente complessa, l'impedenza di un componente elettrico porta informazioni su *i)* il rapporto tra l'ampiezza della tensione e l'ampiezza della corrente, codificata nell'ampiezza dell'impedenza; *ii)* lo sfasamento tra le forme d'onda di tensione e di corrente, codificato nella fase dell'impedenza. Nel caso del condensatore, si può infatti notare che:

$$|Z_C| = \frac{1}{\omega C} \quad \angle Z_C = -\frac{\pi}{2}$$

che infatti codificano correttamente i risultati delineati in precedenza, ovvero *i)* l'ampiezza della corrente dipende non solo da quella della tensione ma anche dalla frequenza del segnale AC; *ii)* i segnali di tensione e di corrente sono in quadratura.

Calcoli simili possono essere svolti nel caso dell'induttore. Questa volta inizieremo l'analisi dalla corrente. La corrente AC generica attraverso un induttore può essere scritta come (considerando un'onda cosinusoidale generica):

$$i(t) = I \cdot \cos(\omega t + \theta) = \operatorname{Re}\{I \cdot e^{j\theta} \cdot e^{j\omega t}\} = \operatorname{Re}\{\tilde{I} \cdot e^{j\omega t}\}$$

dove I è l'ampiezza della corrente (un numero reale), θ è la fase iniziale della corrente, mentre $\tilde{I} = I \cdot e^{j\theta}$ è la corrente complessa, un numero complesso di modulo I e fase θ . Si noti che la corrente è ora scritta come la parte reale del prodotto della corrente complessa e di un vettore rotante di lunghezza unitaria. La tensione ai capi dell'induttore è:

$$v(t) = L \frac{di(t)}{dt} = -L \cdot I \cdot \omega \cdot \sin(\omega t + \theta) = \omega \cdot L \cdot I \cdot \cos\left(\omega t + \theta + \frac{\pi}{2}\right) = \operatorname{Re}\{j \cdot \omega \cdot L \cdot I \cdot e^{j\theta} \cdot e^{j\omega t}\}$$

Anche in questo caso, l'espressione sopra è scritta come la parte reale del prodotto di un numero complesso e di un vettore unitario rotante. Infatti, ha la forma:

$$v(t) = \text{Re}\{\tilde{V} \cdot e^{j\omega t}\}$$

dove $\tilde{V} = \omega \cdot L \cdot I \cdot e^{j\theta} \cdot e^{j\frac{\pi}{2}}$ è chiamata tensione complessa. Poiché $e^{j\frac{\pi}{2}} = j$ e $I \cdot e^{j\theta} = \tilde{I}$, allora:

$$\tilde{V} = j \cdot \omega \cdot L \cdot \tilde{I}$$

Pertanto, anche in questo caso possiamo vedere chiaramente che sia la corrente che la tensione possono essere scritte nella stessa forma, ovvero come la parte reale del prodotto tra la corrente complessa (o tensione) e un vettore unitario rotante che ruota alla velocità angolare del segnale di corrente e tensione (che infatti sono iso-frequenziali). Anche in questo caso, è possibile definire l'impedenza dell'induttore come $Z_L = \frac{\tilde{V}}{\tilde{I}} = j\omega L$

Troviamo quindi che anche per l'induttore, mentre è impossibile stabilire una relazione lineare tra la corrente e la tensione, è possibile definire una relazione lineare tra la corrente complessa e la tensione complessa, per la quale il fattore di proporzionalità è l'impedenza. Per l'induttore:

$$|Z_L| = \omega L \quad \angle Z_L = \frac{\pi}{2}$$

che infatti codificano correttamente i risultati delineati in precedenza, ovvero i) l'ampiezza della corrente dipende anche dalla frequenza del segnale AC; ii) i segnali di tensione e di corrente sono in quadratura. Infine, un esercizio simile può essere fatto per il resistore.

$$v(t) = V \cdot \cos(\omega t + \theta) = \text{Re}\{\tilde{V} \cdot e^{j\omega t}\}$$

$$i(t) = \frac{v(t)}{R} = \text{Re}\left\{\frac{\tilde{V}}{R} \cdot e^{j\omega t}\right\}$$

Anche in questo caso, l'espressione sopra è la parte reale del prodotto di un numero complesso e di un vettore unitario rotante. Infatti, ha la forma:

$$i(t) = \text{Re}\{\tilde{I} \cdot e^{j\omega t}\}$$

dove $\tilde{I} = \frac{\tilde{V}}{R}$. Pertanto, l'impedenza del resistore è semplicemente:

$$Z_R = \frac{\tilde{V}}{\tilde{I}} = R$$

Troviamo quindi che per il resistore è possibile definire una relazione lineare tra la corrente complessa e la tensione complessa, per la quale il fattore di proporzionalità è l'impedenza. Ciò era previsto in quanto, nel caso del resistore, è possibile stabilire direttamente una relazione lineare tra la corrente e la tensione. Per il resistore:

$$|Z_R| = R \quad \angle Z_L = 0$$

che conferma che la tensione e la corrente sono in fase. Come utile riassunto:

- Per i resistori, tensione e corrente sono in fase (oscillano con la stessa frequenza e senza sfasamento); il rapporto tra le grandezze di corrente e tensione non dipende dalla frequenza;
- Per i condensatori corrente e tensione oscillano alla stessa frequenza, ma la prima anticipa la seconda di 90° , cioè sono in quadratura; il rapporto tra le grandezze di corrente e di tensione dipende dalla frequenza;

- Per gli induttori, corrente e tensione oscillano alla stessa frequenza, ma la seconda anticipa la prima di 90°, cioè sono in quadratura; il rapporto tra le grandezze di corrente e tensione dipende dalla frequenza.

In generale, mentre l'impedenza di un resistore è puramente reale e quelle dell'induttore e del condensatore sono numeri puramente immaginari, in generale l'impedenza di un componente generico è un numero complesso con una parte reale e una parte immaginaria.

$$Z = R + jX \quad \text{dove} \quad \begin{cases} R = \text{resistenza} & , \quad [R] = \Omega \\ X = \text{reattanza} & , \quad [X] = \Omega \end{cases}$$

Il suo reciproco è denominato ammettenza:

$$Y \equiv \frac{1}{Z} = G + jB \quad \text{dove} \quad \begin{cases} G = \text{conduttanza} & , \quad [G] = S \\ B = \text{suscettanza} & , \quad [B] = S \end{cases}$$

Si noti come la conduttanza sia il reciproco della resistenza solo per componenti puramente resistivi. Allo stesso modo, la suscettanza è il reciproco negativo della reattanza solo per componenti puramente reattivi. In generale, per un'impedenza non reale e non immaginaria (cioè un'impedenza complessa) la conduttanza non è il reciproco della resistenza e la suscettanza non è il reciproco negativo della reattanza. L'unica relazione sempre valida è quella per cui l'impedenza è il reciproco dell'ammettenza. In conclusione, le relazioni tra $\tilde{V}$ e $\tilde{I}$ trovate per il condensatore, l'induttore e il resistore ci permettono di usare la legge di Ohm usando l'impedenza Z , che è in generale un numero complesso. Possiamo quindi facilmente calcolare il valore dell'impedenza equivalente del collegamento in serie e in parallelo di diversi componenti (compresi quelli reattivi), semplicemente applicando le stesse regole valide per i resistori (ma usando l'impedenza al posto della resistenza).

2.14. Diodi

Un diodo è un dispositivo elettronico a due terminali, non lineare e non simmetrico che conduce la corrente principalmente in una direzione; ha una resistenza bassa (idealmente zero) in una direzione e una resistenza



alta (idealmente infinita) nell'altra. È costituito da un pezzo cristallino di materiale semiconduttore con una giunzione p-n, cioè una giunzione tra due regioni del semiconduttore drogate con droganti differenti, rispettivamente di tipo p e di tipo n. Oggi la maggior parte dei diodi sono realizzati in Si, ma vengono utilizzati anche altri materiali semiconduttori come GaAs, Ge, GaN. Il simbolo del diodo è riportato nella figura sopra, in cui è chiaramente evidenziata la differenza tra i due terminali. I due terminali sono indicati anche con nomi individuali, cioè l'anodo e il catodo. Convenzionalmente, una tensione applicata positiva significa una tensione maggiore all'anodo rispetto al catodo. La direzione positiva della corrente è considerata dall'anodo al catodo. Il diodo è caratterizzato da una relazione esponenziale tra la tensione e la corrente come precedentemente definite, secondo la quale il diodo condurrà una corrente significativa per le tensioni positive, mentre si comporta quasi come un circuito aperto per le tensioni negative. In particolare:

$$I = I_0 \cdot \left[e^{\frac{qV}{kT}} - 1 \right] \quad \text{dove} \quad \begin{cases} I_0 = \text{Corrente di Saturazione Inversa} \\ k = \text{Costante di Boltzmann} \\ T = \text{Temperatura Assoluta} \end{cases} \quad \text{inoltre} \quad q = 1.6 \cdot 10^{-19} \text{ C}$$


La quantità all'esponente viene tipicamente riscritta in termini di rapporto di due tensioni:

$$\frac{qV}{kT} = \frac{V}{kT/q} = \frac{V}{V_T}$$

dove si evidenzia la cosiddetta tensione termica, V_T . La tensione termica è linearmente dipendente dalla temperatura e, a temperatura ambiente, vale circa 26 mV. Pertanto, possiamo riscrivere la relazione I-V di un diodo come:





$$I = I_0 \cdot \left[e^{\frac{V}{V_T}} - 1 \right]$$

È facile notare che, per tensioni positive, il comportamento è quasi esponenziale, soprattutto se $V \gg V_T$. Pertanto, per tensioni positive, cioè quando il dispositivo è in polarizzazione diretta, possiamo facilmente forzare una corrente significativa nel dispositivo. Al contrario, per le tensioni negative, cioè quando il dispositivo è polarizzato inversamente, il termine esponenziale tra parentesi sostanzialmente svanisce, con la corrente che dipende molto debolmente dalla tensione applicata ed è quasi costante al valore $-I_0$. La corrente di saturazione inversa, I_0 , è tipicamente molto piccola e rappresenta in effetti la dispersione non ideale del diodo quando polarizzato inversamente. In prima approssimazione, potremmo dire che un diodo polarizzato in diretta si comporta come un interruttore chiuso (consente il flusso di corrente) mentre un diodo polarizzato in inversa si comporta come un interruttore aperto (nega il flusso di corrente), come illustrato di seguito.



La caratteristica I-V di un tipico diodo è riportata nel pannello in alto a sinistra della figura sottostante. Si può notare come la caratteristica sia effettivamente quasi puramente esponenziale per tensioni positive, mentre tende ad essere quasi indipendente dalla tensione in polarizzazione inversa. Notiamo anche che, per tensioni negative elevate, si verifica un aumento di corrente inaspettato (vedere l'etichetta "real" nel grafico), che non è previsto dall'equazione sopra (vedere l'etichetta "predicted" nel grafico). Questo fenomeno, chiamato breakdown, sarà analizzato in seguito in dettaglio.

Concentriamoci ora sulla regione di polarizzazione diretta. Si può notare che è stato messo in evidenza un valore di tensione specifico (cioè, v_d , tipicamente circa 0.7 V). Questo valore viene in genere indicato come la "soglia" del diodo. In effetti, dal grafico si può apprezzare che quando la tensione applicata è $< v_d$, la corrente è piccola. In questa regione, inoltre, se la tensione cambia in modo significativo (ad esempio scende ampiamente al di sotto di v_d), la corrente non mostra variazioni significative. Al contrario, quando la tensione applicata è $> v_d$, la corrente è significativa e, soprattutto, aumenta molto rapidamente con la tensione applicata. Tuttavia, questa logica è, da un punto di vista fisico, ingannevole. Infatti, se osserviamo la caratteristica I-V su un grafico semilogaritmico, come nel pannello in alto a destra della figura sopra, notiamo che intorno a v_d non accade nulla di critico, ovvero il comportamento del dispositivo non cambia. Quindi, perché è stata individuata in primo luogo una tensione "soglia"? E come è stato determinato il suo valore (poiché non succede nulla di specifico intorno a v_d)? La spiegazione ha radici storiche. Come rappresentato nel pannello in alto a destra della figura sopra, i diodi classici in Si conducono una corrente di quasi 1 mA a una tensione diretta di circa 0.7 V. Alcuni decenni fa, nei circuiti analogici, un valore di corrente di pochi mA era considerato uno spartiacque naturale tra valori di corrente considerati relativamente elevati (al di sopra di pochi mA) e quelli considerati relativamente bassi, ben al di sotto del range dei mA. Da questo punto di





vista, in prima approssimazione, per tensioni applicate inferiori a 0.7 V il diodo non conduce alcuna corrente significativa, mentre per tensioni applicate superiori a 0.7 V il diodo conduce una grande quantità di corrente. Questo si può apprezzare nel pannello in alto a destra della figura sopra, dove si può notare che a 0.6 V la corrente pilotata dal diodo scende al di sotto di 0.1 mA, mentre a 0.8 V sale fino a 100 mA. Questo è il motivo per cui nei diodi è stata identificata una "soglia", intorno a 0.7 V. Si noti che questo valore può facilmente cambiare da diodo a diodo, specialmente in tipi specifici di diodo realizzati con altri materiali come Ge o GaAs. Tuttavia, dal punto di vista fisico, questa soglia è "fasulla", poiché il comportamento del dispositivo non cambia nell'intorno di quella tensione. Tuttavia, questa considerazione pratica porta in primo piano un'approssimazione molto comune utilizzata nell'analisi dei circuiti. Infatti, quando si trattano circuiti con diodi, è sempre utile formulare ipotesi sul loro regime di funzionamento (cioè, se pensiamo che siano polarizzati in diretta o inversamente) e quindi sostituirli con modelli lineari approssimati per risolvere facilmente il circuito. Un modo tipico per approssimare la risposta del diodo è mostrato nel pannello in basso a destra della figura sopra. In particolare, un diodo polarizzato in diretta viene approssimato come una batteria che fornisce una tensione pari a v_d (linea arancione tratteggiata verticale). Al contrario, un diodo polarizzato inversamente viene approssimato con un circuito aperto (linea arancione tratteggiata orizzontale). Secondo questa approssimazione, se una corrente positiva scorre nel dispositivo, la tensione ai suoi capi è v_d , indipendentemente dall'entità della corrente. Se non scorre corrente nel dispositivo, la tensione deve essere inferiore a v_d . Un'approssimazione più brutale, ma frequentemente adottata, è mostrata nel pannello in basso a sinistra della figura sopra, per la quale un diodo polarizzato in avanti viene approssimato come un cortocircuito, ovvero una batteria che fornisce una tensione pari a 0 V. Secondo questa approssimazione, se una corrente positiva scorre nel dispositivo, la tensione ai suoi capi è 0 V, indipendentemente dall'entità della corrente. Se non scorre corrente nel dispositivo, la tensione deve essere negativa. Da un punto di vista generale, il diodo può essere visto come un interruttore a due terminali, poiché in determinate condizioni la corrente può fluire e in altre condizioni no. Tuttavia, è un interruttore controllato direttamente dalla tensione ai suoi capi. Nel successivo sottocapitolo introdurremo l'idea più flessibile di un interruttore a tre terminali, in cui lo stato dell'interruttore non è controllato dalla tensione ai suoi capi ma per mezzo di un terzo terminale di controllo dedicato.

Come abbiamo visto in precedenza, per una grande tensione negativa si verifica un fenomeno imprevisto chiamato breakdown. La regione di breakdown è da evitare, poiché in quelle condizioni il dispositivo non riesce a tollerare il fortissimo campo elettrico che si sviluppa nel semiconduttore. Il risultato è che il dispositivo non riesce a bloccare la corrente e inizia a condurre. La fisica alla base del fenomeno fa sì che la curva I-V sia molto ripida in quella regione che altrove. Inoltre, il fenomeno è associato anche a una forte dissipazione di calore che potrebbe danneggiare permanentemente il dispositivo. Tuttavia, mentre i diodi standard non possono lavorare nella regione di breakdown, esiste un diodo specifico costruito intenzionalmente per funzionare in quella regione, chiamato diodo zener. Questo elemento sarà oggetto di un'analisi più approfondita più avanti in questo opuscolo. Tuttavia, il diodo zener non è l'unica categoria speciale di diodi. Tra i tanti segnaliamo:

- **Diodi Zener** – appositamente ingegnerizzati e realizzati per poter lavorare in regime di breakdown senza subire danni. Sfrutta la notevole pendenza della curva I-V nel regime di breakdown per scopi specifici;
- **Light Emitting Diode (LED)** – realizzato con altri semiconduttori diversi da Si, come GaAs e GaN. Quando è polarizzato in diretta emette luce a una frequenza specifica che dipende dal materiale impiegato. L'intensità della luce è controllata dall'intensità della corrente;
- **Fotodiodo** – elemento duale del LED. Risponde con un flusso di corrente quando viene illuminato. Combinando insieme un LED e un fotodiodo è possibile configurare un sistema di trasmissione wireless.

2.15. Interruttori

Un interruttore a comando elettrico è un dispositivo a tre terminali (tipicamente realizzato per mezzo di un transistor). Gli interruttori sono dispositivi estremamente utili e sono alla base della realizzazione dei circuiti digitali. Gli interruttori consentono di controllare se la corrente può o non può circolare in un ramo. Due terminali sono collegati in serie al ramo del circuito in cui si vuole ottenere il controllo della corrente. Il terzo terminale viene utilizzato come terminale di controllo. Il valore della tensione (o della corrente, a seconda del tipo di transistor utilizzato per implementare l'interruttore) a questo terminale di controllo determina il comportamento del dispositivo tra gli altri due terminali. In prima approssimazione, il comportamento che può essere forzato tra i due terminali rimanenti è o simile a un cortocircuito (in pratica un comportamento a bassa resistenza) o vicino a un circuito aperto. La descrizione dettagliata dei due interruttori a stato solido più utilizzati, ovvero il MOSFET e il BJT, è fornita più avanti in questo opuscolo. Nell'esempio a destra, un interruttore a controllo elettronico viene utilizzato per accendere e spegnere un diodo emettitore di luce. Quando il segnale sulla linea di controllo dell'interruttore forza l'interruttore ad essere spento, nessuna corrente potrà fluire nel ramo controllato, e quindi nel resistore e nel diodo. Di conseguenza, la caduta di tensione su questi due componenti è zero e tutta la tensione erogata dalla batteria cade sull'interruttore. Quando il segnale sulla linea di controllo forza l'interruttore ad essere acceso, il dispositivo si comporterà come un cortocircuito e la tensione della batteria si distribuirà sul resistore e sul diodo, facendo circolare una corrente nel circuito controllato, con la conseguente emissione di luce dal LED.




2.15.1 Interruttori allo Stato Solido

Si tratta di interruttori che convogliano la corrente interamente attraverso cristalli semiconduttori solidi (ad es. Si, GaAs, Ge...) e che non si basano su parti meccaniche o ottiche per eseguire l'azione di commutazione della corrente. Come interruttori a stato solido possono essere adottati diversi dispositivi elettronici e la scelta dipende dai livelli di corrente e tensione richiesti nel circuito. Nello specifico, parametri importanti

sono la tensione tipica che l'interruttore deve sopportare quando è aperto e il livello di corrente tipico che l'interruttore deve sopportare quando è chiuso. Gli interruttori a stato solido più frequentemente adottati sono:

- Transistor bipolare a giunzione (BJT) e transistor metallo-ossido-semiconduttore a effetto di campo (MOSFET) che sono tuttavia limitati a tensioni relativamente basse (poche centinaia di V) e correnti (poche decine di A);
- Transistor bipolare a gate isolato (IGBT) per medie tensioni (fino a 1kV) e correnti elevate (fino a 200-400 A); sono particolarmente adatti per la commutazione ad alta frequenza;
- Raddrizzatori controllati al silicio (SCR) e tiristori per alte tensioni e correnti.

Di recente sono stati introdotti materiali alternativi per migliorare le prestazioni dei transistor quando vengono utilizzati come interruttori a stato solido, in particolare per applicazioni in cui sono richieste potenza, tensione, corrente e frequenza di commutazione relativamente elevate. Se per decenni il Si ha dominato il mondo dei transistor, ora sono stati sviluppati semiconduttori composti che offrono vantaggi unici e caratteristiche superiori, non solo per gli interruttori. Ad esempio, i semiconduttori composti vengono utilizzati per il diodo a emissione di luce (LED), discusso più avanti in questo opuscolo. Nuove applicazioni più esigenti come i sistemi elettronici per automotive e i veicoli elettrici/ibridi (EV/HEV) stanno traendo significativi vantaggi da questi materiali che meglio soddisfano le loro specifiche rigorose. Due soluzioni interessanti sono i transistor di potenza al nitruro di gallio (GaN) e al carburo di silicio (SiC). Questi dispositivi competono con i MOSFET di potenza Si e con la loro evoluzione, i MOSFET a supergiunzione (non trattati in questo opuscolo), specialmente per quelle applicazioni in cui i dispositivi Si non possono funzionare altrettanto bene a parità di costo o viceversa. La figura seguente riporta, nel pannello di sinistra, uno scenario prospettico in cui è facile vedere la posizione dei transistor SiC e GaN rispetto a MOSFET, BJT e altri possibili interruttori in termini di potenza nominale e frequenza di commutazione. Moltissime applicazioni stanno attualmente beneficiando del passaggio dai MOSFET/BJT/IGBT ai transistor SiC e GaN. Un quadro generale delle applicazioni attualmente coperte dagli interruttori GaN e SiC è mostrato nei pannelli a destra.



Un interessante confronto tra diverse tecnologie di interruttori è apprezzabile nel pannello di sinistra della figura seguente, in cui MOSFET, MOSFET a supergiunzione, IGBT, dispositivi in SiC e in GaN sono mostrati in un grafico che riporta la resistenza specifica (la resistenza offerta da un interruttore per area unitaria in condizione di ON, che dovrebbe essere ridotta al minimo) rispetto alla tensione di rottura (la tensione massima tollerata dall'interruttore in condizione di OFF, che dovrebbe essere massimizzata). Vengono anche mostrati i limiti teorici per le tecnologie Si, SiC e GaN. Nel pannello di destra, queste tecnologie vengono

confrontate in termini di diverse proprietà, che evidenziano come i dispositivi SiC siano attualmente la scelta migliore per applicazioni ad alta temperatura, mentre i dispositivi GaN sono più adatti per il funzionamento ad alta tensione.




Di seguito, descriveremo in dettaglio il comportamento del BJT e del MOSFET, poiché IGBT e SCR sono più complicati e affrontarli esula dallo scopo di questo opuscolo. In particolare, BJT e MOSFET sono tipicamente divisi in due gruppi: BJT/MOSFET di segnale e BJT/MOSFET di potenza. I BJT/MOSFET di segnale sono generalmente ottimizzati per gestire correttamente i segnali di frequenza più alta, ma non sono in grado di gestire i livelli di tensione e corrente indicati sopra (sono limitati a poche decine di V e pochi A). I BJT/MOSFET di potenza sono invece ottimizzati per gestire le tensioni e i valori di corrente sopra riportato, ma non possono gestire correttamente i segnali ad alta frequenza. La seguente analisi del comportamento BJT e MOSFET è valida sia per i dispositivi di segnale che di potenza.

2.15.2 Transistor Bipolare a Giunzione

Il Bipolar Junction Transistor (BJT) è un dispositivo a tre terminali ed è stato il primo transistor mai fabbricato. Per comprenderne il principio di funzionamento è obbligatorio avere un'idea chiara di come funziona il diodo (sebbene, per il livello di dettaglio utilizzato in questo opuscolo, non sia necessario conoscere i dettagli microscopici della fisica coinvolta). I tre terminali sono denominati Base (B), Collettore (C) ed Elettore (E). Questi tre terminali corrispondono a tre regioni fisiche del dispositivo. Le regioni C ed E sono drogate con lo stesso tipo di drogaggio (entrambi n o entrambi p), mentre la base è drogata con il tipo di drogaggio opposto rispetto a C ed E. Pertanto, esistono due tipi di dispositivi: npn (con C ed E aventi drogaggio di tipo n e B con drogaggio di tipo p) o pnp (viceversa). I segni convenzionali per le correnti per il BJT npn sono i seguenti: I_B positiva se entrante, I_C positiva se entrante, I_E positiva se uscente. Questi sono abbozzati nella figura sottostante, insieme alla struttura schematica e al simbolo del BJT npn. Si noti che il simbolo ha una freccia che identifica l'emettitore (e lo distingue dal collettore). La freccia è orientata verso l'esterno per il BJT npn, verso l'interno per il pnp. I segni convenzionali per le correnti per il BJT pnp sono invertiti rispetto al npn.

Il comportamento del BJT è più complesso di quello del diodo. A seconda dei valori della tensione e delle correnti ai tre terminali, il dispositivo può comportarsi sia come interruttore che come amplificatore. Qui saremo principalmente interessati al suo comportamento come interruttore. Come affermato in precedenza, esistono molti BJT diversi, caratterizzati da differenti valori nominali di corrente massima (da 1 mA fino a 50 A), tensione massima (da 1 V fino a poche centinaia di V), potenza massima (da 1 mW fino a poche centinaia di W) e frequenza massima (pochi kHz fino a diverse centinaia di GHz). A seconda anche di queste figure di merito, sono disponibili in diverse dimensioni, prezzo e involucro. Nella tabella seguente sono riportati alcuni esempi di BJT commerciali. Come regola generale, i BJT in grado di gestire una potenza maggiore sono più lenti e viceversa. I BJT basati su Ge sono in genere più veloci ma più delicati di quelli Si.

Number	Material	Polarity	Power rating	Voltage rating (Vce)	Current rating	Frequency (MHz)
2N2222	S	N	0.5 W	30	150 mA	250
2N2907	S	P	1.8 W	40	150 mA	200
2N2928	G	P	150 mW	13	2 mA	400
2N6308	S	N	125 W	360	3 A	5
2N6280	S	N	250 W	140	20 A	30




2.15.2.1 Curve di Ingresso e di Uscita

Il BJT è fondamentalmente una sorgente di corrente controllata in corrente. Nello specifico, nel caso del BJT, ciò significa che la corrente al terminale C è principalmente (ma non esclusivamente) controllata dalla corrente al terminale B. Di seguito, prenderemo un BJT npn come esempio per capire come funziona un BJT. Le regioni B ed E del dispositivo formano un'effettiva giunzione p-n (cioè un diodo). Pertanto, se viene applicata una certa V_{BE} , ci aspettiamo che la corrente al terminale B, I_B , sia esponenzialmente dipendente da V_{BE} seguendo la tipica relazione I-V del diodo. Nel BJT, il valore di I_B determina anche la massima corrente che può fluire nel terminale C (nel caso ideale). La relazione tra queste due quantità è lineare:

$$I_C = \beta I_B$$


dove β è un parametro che dipende dalla specifica del BJT, è chiamato guadagno di corrente ed è tipicamente compreso tra 10 e 3000. Un BJT di segnale npn in Si di solito ha un β intorno a 100, mentre i tipici BJT di potenza hanno un β intorno a 20. Questa relazione proporzionale tra la corrente del collettore è vera solo se c'è una tensione sufficientemente grande tra il collettore e l'emettitore, V_{CE} . Si noti che, se questa condizione è soddisfatta, I_C dipende solo da I_B e non da V_{CE} . Il valore critico di V_{CE} oltre il quale I_C non dipende da V_{CE} è chiamato tensione di saturazione ed è di circa 0.2 V per i BJT di segnale npn in Si. Al di sotto di questo valore di tensione, I_C è inferiore a $\beta \cdot I_B$ e dipende da V_{CE} . Queste caratteristiche possono essere viste nei due grafici nella figura seguente. Nel pannello di sinistra è riportata la cosiddetta curva di ingresso (I_B vs. V_{BE}) (a temperatura ambiente), che mostra un chiaro comportamento da diodo. Il valore I_B usato per pilotare il BJT (che dipende solo da V_{BE}) è cruciale nel determinare la relazione tra I_C e V_{CE} , la cosiddetta curva di uscita, mostrata nel pannello di destra della figura seguente per diversi valori di I_B . Come si può notare, per V_{CE} inferiore alla tensione di saturazione (circa 0.2 V nell'esempio riportato) I_C aumenta all'aumentare di V_{CE} , fino al valore $\beta \cdot I_B$. Per V_{CE} maggiori della tensione di saturazione, I_C è uguale a $\beta \cdot I_B$ e non dipende da V_{CE} . Le stesse relazioni valgono nel caso del dispositivo pnp, fatta eccezione per un capovolgimento dei segni della tensione tra i vari terminali. Come osservazione finale, la corrente all'emettitore è la somma della corrente nella base e nel collettore (quest'ultima è tipicamente molto più grande della prima).



2.15.2.2 Regioni di Funzionamento


Sulla base di quanto discusso in precedenza, possiamo identificare tre aree operative. La prima è chiamata regione di cut-off e si ottiene polarizzando il dispositivo con una V_{BE} sufficientemente piccola, tipicamente inferiore a 0.6 – 0.7 V per BJT npn in Si. In effetti, ciò si traduce in un valore di I_B molto basso, quindi la curva di output corrispondente è quasi coincidente con l'asse delle ascisse. Si noti che questa curva approssima bene il comportamento di un circuito aperto tra C ed E. Di conseguenza, possiamo polarizzare il BJT nella regione di cut-off per farlo comportare come un interruttore aperto (tra C ed E, con B come terminale di controllo dell'interruttore). In prima approssimazione, la corrente del collettore sarà quasi zero indipendentemente dal valore di V_{CE} . Al contrario, se V_{BE} è abbastanza grande da avere una I_B considerevole, il dispositivo si accende e può funzionare in due regioni operative: in saturazione o in regione attiva diretta, a seconda del valore di V_{CE} .

In particolare, se V_{CE} è inferiore alla tensione di saturazione, il dispositivo è polarizzato in saturazione. In questa regione, la caratteristica di uscita è molto ripida e quasi coincidente con l'asse y. Si noti che questa curva approssima bene il comportamento di un cortocircuito tra C ed E. Di conseguenza, possiamo polarizzare il BJT nella regione di saturazione per farlo comportare come un interruttore chiuso (tra C ed E, con B come terminale di controllo dell'interruttore). Infine, se V_{CE} è maggiore della tensione di saturazione, allora il dispositivo è polarizzato nella regione attiva diretta, nella quale si comporta come un amplificatore (sebbene la sua spiegazione dettagliata non sarà riportata in questo libretto). La figura a destra riporta tre punti di polarizzazione che si trovano nelle tre diverse regioni operative.



2.15.2.3 Usare il BJT come Interruttore

Come già chiarito nel precedente sottocapitolo, il BJT può funzionare come interruttore, e quindi come dispositivo digitale che presenta due stati: ON (corrispondente al BJT pilotato in saturazione) e OFF (corrispondente al BJT pilotato in cut-off). Questa proprietà permette di utilizzare il BJT come dispositivo per controllare la potenza erogata ad un carico, come illustrato nella figura a destra. In questo esempio, vorremmo controllare la potenza fornita ad un carico resistivo, R . Usiamo un BJT npn come interruttore a stato solido, pilotato da una tensione ad onda quadra (con livello basso = 0 V e livello alto tipicamente uguale a V_{CC} , anche se non necessariamente) sulla sua base con l'emettitore a massa. Il carico è posto tra il collettore e la tensione di alimentazione, V_{CC} . Poiché il BJT verrà utilizzato come interruttore, dobbiamo analizzare il comportamento di questo circuito per le due condizioni (interruttore aperto e chiuso) separatamente.



Quando la tensione di base è bassa, il dispositivo è in stato OFF (cut-off). In questa condizione non può fluire corrente di collettore, e quindi nessuna corrente può fluire sul carico. Pertanto, non ci sarà alcuna caduta di tensione sul carico e V_{CE} è pari a V_{CC} . La condizione di polarizzazione del BJT è quindi: $V_{BE} = 0$ V; $I_B = 0$ A; $I_C = 0$ A; $V_{CE} = V_{CC}$. Questa configurazione è pienamente coerente con la regione di cut-off. Si noti che non c'è dissipazione di potenza sul carico.

Quando la tensione di base è alta, il dispositivo è in stato ON (vogliamo che sia in saturazione). In questa condizione, il BJT si accende e, a seconda del valore di V_{CE} , può essere in saturazione (quello che desideriamo) o in regione attiva diretta. Se assumiamo che il dispositivo sia in saturazione, allora V_{CE} è inferiore o uguale alla tensione di saturazione (circa 0.2 V) e quindi la corrente nel carico (e nel collettore) sarà:

$$I_C = I_R = \frac{V_{CC} - V_{CE}}{R} \geq \frac{V_{CC} - V_{CE,SAT}}{R} \quad I_C = I_R \approx \frac{V_{CC}}{R}$$

con l'ultima approssimazione che vale se V_{CC} è molto più grande della tensione effettiva da collettore a emettitore (come quasi sempre accade, poiché supponiamo che V_{CE} sia inferiore alla tensione di saturazione che è tipicamente molto piccola). Si noti che, se vogliamo che il dispositivo sia in saturazione e non in regione attiva diretta, dobbiamo assicurarci che la corrente di collettore sia inferiore a $\beta \cdot I_B$. Pertanto, una I_B sufficientemente elevata, dati i valori di V_{CC} , β e R , deve essere ottenuta per mezzo di una V_{BE} adeguatamente elevata, in modo che:

$$I_B > \frac{V_{CC}}{\beta R}$$

La tensione sul carico è:

$$V_R = V_{CC} - V_{CE} \geq V_{CC} - V_{CE,SAT} \quad V_R \approx V_{CC}$$

e quindi:

$$V_{CE} \leq V_{CE,SAT} \quad V_{CE} \approx 0 \text{ V}$$

Di conseguenza la potenza sul carico è:

$$P_R = V_R I_R = \frac{(V_{CC} - V_{CE})^2}{R} \geq \frac{(V_{CC} - V_{CE,SAT})^2}{R} \quad P_R \approx \frac{V_{CC}^2}{R}$$



e quella sul BJT è:

$$P_{BJT} = V_{CE} I_C = \frac{V_{CC} - V_{CE}}{R} V_{CE} \approx 0 \text{ W}$$

Nell'equazione precedente, abbiamo considerato che la potenza totale dissipata sul BJT è dovuta solo al termine $V_{CE} \cdot I_C$. Tuttavia, anche il termine $V_{BE} \cdot I_B$ dà un contributo, che è però nella quasi totalità dei casi del tutto trascurabile rispetto al primo. Si noti che, in prima approssimazione (cioè se si considera che lo switch è ideale), non c'è dissipazione di potenza sullo switch e si ottiene la massima dissipazione di potenza possibile sul carico. In un circuito reale con un vero BJT, però, V_{CE} non sarà 0 V (altrimenti non può effettivamente fluire corrente di collettore) quindi ci sarà una certa dissipazione di potenza sul BJT e la potenza erogata al carico è leggermente inferiore rispetto al caso ideale. È necessario prestare attenzione quando si ha a che fare con la quantità di potenza dissipata sul BJT, poiché tale potenza viene sostanzialmente trasformata in calore (che può essere in taluni casi molto elevato e influenzare il comportamento del dispositivo). Naturalmente, il BJT deve essere adeguatamente dimensionato per tollerare il valore della corrente di collettore $I_{CC} = V_{CC}/R$ quando è in stato ON, la tensione $V_{CE} = V_{CC}$ quando è in stato OFF e la dissipazione di potenza P_{BJT} quando è in stato ON. Si noti che, con questa disposizione del circuito, utilizzando un'onda quadra per pilotare il terminale di base, non c'è modo di eseguire il controllo analogico della quantità di potenza data al carico, che sarà 0 W o piena potenza (ossia in prima approssimazione V_{CC}^2/R).

Una nota a margine: abbiamo discusso il comportamento in stato stazionario in entrambi gli stati (cioè, senza considerare cosa succede nelle transizioni tra lo stato OFF e ON). Durante il passaggio dallo stato OFF allo stato ON, il BJT passerà dalla regione di cut-off (V_{CE} alto, I_C trascurabile) alla regione di saturazione (V_{CE} trascurabile o comunque piccolo, I_C elevata), ma nel processo sarà polarizzato per breve tempo nella regione attiva diretta in cui sia V_{CE} che I_C non sono trascurabili. Pertanto, questa transizione è associata ad una breve ma significativa dissipazione di potenza sul dispositivo BJT, che deve essere presa in considerazione nella scelta del BJT per questo tipo di applicazione. Tuttavia, discutere i dettagli di questo fenomeno esula dagli scopi di questo opuscolo.

Si noti che la sorgente di tensione che guida la base del BJT non deve fornire alcuna potenza significativa, poiché la corrente di base necessaria per questo tipo di applicazioni è generalmente bassa (sebbene non zero). La potenza erogata al carico, infatti, viene prelevata da una sorgente di tensione separata (V_{CC}) che invece deve essere in grado di fornire la corrente necessaria, e quindi l'energia necessaria. Ciò significa che anche una porta del computer come una porta USB (che può emettere segnali digitali nell'intervallo 0 V – 5 V con capacità di corrente limitata) può essere utilizzata per controllare i carichi, come mostrato nell'immagine sotto (pannello di sinistra). Tipicamente, un resistore è posto in serie al terminale di base per controllare meglio la tensione effettivamente fornita alla base del BJT (in molti casi, il livello di tensione associato all'1 logico della porta può essere troppo alto).



Un circuito più sofisticato è riportato nel pannello di destra, in cui sono presenti due miglioramenti: i) viene utilizzata una cosiddetta coppia di Darlington al posto di un singolo BJT. La coppia di Darlington è fondamentalmente un BJT potenziato da un altro BJT, che può essere visto complessivamente come un "super-BJT" con un β equivalente elevatissimo, essendo il prodotto dei due β dei due singoli BJT (quindi molto grande); ii) in parallelo al carico è posto un diodo di protezione. Questo diodo viene utilizzato soprattutto quando si tratta di carichi che hanno un qualche tipo di comportamento induttivo (come, ad esempio, i motori in corrente continua). In questo caso, infatti, l'accensione e lo spegnimento improvviso della corrente

sul carico può provocare grandi picchi di tensione sul carico, che possono causare seri danni al carico o al BJT. Questi picchi si verificano poiché la tensione attraverso un induttore è proporzionale alla derivata nel tempo della corrente che lo attraversa. Un diodo di protezione posto in parallelo offre un modo alla corrente di ricircolare quando si verificano le transizioni del BJT dallo stato ON allo stato OFF e viceversa, evitando picchi di tensione molto elevati, attenuando il problema.


Come affermato in precedenza, il BJT controlla se l'alimentazione viene fornita al carico o meno in modo essenzialmente binario. Pertanto, la quantità effettiva di potenza istantanea fornita al dispositivo può essere 0 W o piena potenza. Tuttavia, sebbene con questa disposizione circuitale non si possano ottenere facilmente valori diversi di potenza istantanea, è possibile modulare la potenza media erogata al dispositivo (media su un intervallo di tempo molto maggiore del periodo dell'onda quadra che pilota il circuito). Ad esempio, se utilizziamo un'onda quadra con un ciclo di lavoro (duty cycle, D) del 50%, manterremo il carico completamente alimentato per metà del periodo dell'onda quadra e non alimentato per la metà rimanente. In media, la potenza erogata al dispositivo è quindi la metà della potenza istantanea erogata quando l'interruttore è acceso. In questo senso è possibile controllare la potenza media erogata al dispositivo semplicemente controllando il duty cycle dell'onda quadra, in modo che:

$$P_{AVG} = DP_R \approx D \frac{V_{CC}^2}{R}$$

Questo principio è alla base della tecnica cosiddetta Pulse Width Modulation (PWM), che verrà affrontata nel seguito.

2.15.3 Transistor Metallo-Ossido-Semiconduttore ad Effetto di Campo

Il transistor a effetto di campo (MOSFET) metallo-ossido-semiconduttore è un dispositivo a quattro terminali ed è il transistor più comune che si possa trovare oggi nei circuiti e nei sistemi elettronici. Da una prospettiva generale, il MOSFET si comporta qualitativamente come il BJT, nel senso che le sue caratteristiche di trasferimento e uscita sono molto simili a quelle esibite dal BJT. Tuttavia, la fisica sottostante è completamente diversa (e non verrà discussa qui). I quattro terminali sono denominati Gate (G, simile alla base del BJT), Drain (D, simile al collettore del BJT), Source (S, simile all'emettitore del BJT) e Body (B). Può essere di tipo n (simile al BJT npn) o di tipo p (simile al BJT pnp) e, proprio come qualsiasi transistor, può funzionare come amplificatore o come interruttore. Il pannello di sinistra della figura seguente riporta i simboli di un MOSFET di tipo n. Nel caso del MOSFET di tipo p, la freccia associata al terminale B è invertita. Esistono altri simboli alternativi per il dispositivo MOSFET. Più comunemente, ma non necessariamente, il terminale B è collegato internamente al terminale S, rendendo di fatto il MOSFET un dispositivo a tre terminali, come illustrato nel circuito di esempio nel pannello centrale della figura seguente. In alcuni casi, questa connessione non viene eseguita e il terminale B può essere controllato individualmente per consentire un ulteriore grado di controllo sul dispositivo. Tuttavia, non ci concentreremo su questa possibilità e considereremo in tutti i casi i terminali S e B come collegati tra loro. Pertanto, tratteremo il MOSFET come un dispositivo a tre terminali.



La principale differenza con il BJT è che il MOSFET può essere visto come una sorgente di corrente controllata in tensione, piuttosto che come una sorgente di corrente controllata in corrente. Infatti, nel MOSFET, il gate è elettricamente isolato dal resto del dispositivo, mentre questo non è vero per la base nel BJT. Di conseguenza, la corrente di gate in un MOSFET è sempre zero (se consideriamo un MOSFET ideale e in condizioni DC). Si tratta di una notevole differenza rispetto al BJT, in cui invece la corrente di base non solo non è zero ma è l'elemento chiave che controlla il comportamento complessivo del dispositivo. Invece, nel caso del MOSFET, la quantità chiave che controlla il comportamento del dispositivo è la tensione tra gate e source, V_{GS} . Ancora una volta, mentre nel BJT applichiamo una V_{BE} , che imposta un determinato livello di I_B , che a sua volta determina il comportamento del dispositivo (cioè quale specifica curva di uscita considerare), nel caso del MOSFET applichiamo una V_{GS} la quale determina direttamente il comportamento del dispositivo, in quanto I_G sarà comunque zero. Di seguito, prenderemo un MOSFET di tipo n come esempio per comprendere il comportamento del MOSFET. È possibile ottenere tre regioni operative (come per il BJT).

La prima è chiamato cut-off, e corrisponde al caso di una V_{GS} applicata che è al di sotto di un dato valore di tensione (che è un parametro intrinseco del MOSFET) chiamato tensione di soglia, V_{TH} . In questo caso, la corrente di drain (che in prima approssimazione è uguale alla corrente di source) sarà zero indipendentemente dalla tensione tra drain e source, V_{DS} . Pertanto, nella regione di cut-off abbiamo: $V_{GS} < V_{TH}$; $I_D = I_S = 0$ A. Ovviamente in questa regione il MOSFET si comporta più o meno come un interruttore aperto (tra il drain e il source, con il gate che agisce come un terminale di controllo). Quando invece V_{GS} supera V_{TH} , il dispositivo può essere o nella regione di triodo (corrispondente alla regione di saturazione del BJT) o in regione di saturazione (corrispondente alla regione attiva diretta del BJT), a seconda del valore di V_{DS} . Se V_{DS} è inferiore a $V_{GS} - V_{TH}$ (che è anche chiamata tensione di overdrive, V_{OD} , e quantifica la quantità di V_{GS} applicata in eccesso rispetto a V_{TH}), il dispositivo è in triodo e la corrente I_D aumenta all'aumentare di V_{DS} . Se V_{DS} è invece maggiore o uguale a $V_{GS} - V_{TH}$ (cioè V_{OD}), allora il dispositivo è in saturazione e, in prima approssimazione, la corrente I_D non dipende da V_{DS} . Il valore di I_D in questa regione dipende direttamente da V_{GS} , proprio come il valore della corrente I_C nella regione attiva diretta di un BJT dipende solo da I_B e non da V_{CE} . Tuttavia, se nel BJT I_B e I_C (nella regione attiva diretta) sono correlati da un'espressione lineare, nel caso del MOSFET V_{GS} e I_D (nella regione di saturazione) sono correlati da un'espressione quadratica, in modo che $I_D \propto (V_{GS} - V_{TH})^2$. Il comportamento in termini di curve di uscita è riportato nel pannello di destra della figura sopra. Riassumendo, abbiamo:

Saturazione: $V_{GS} \geq V_{TH}$; $V_{DS} \geq V_{GS} - V_{TH}$; $I_D \propto (V_{GS} - V_{TH})^2 > 0$ (nessuna dipendenza da V_{DS});

Triodo: $V_{GS} \geq V_{TH}$; $V_{DS} < V_{GS} - V_{TH}$; $I_D > 0$ (dipendenza da V_{DS});

Cut-off: $V_{GS} < V_{TH}$; $I_D = 0$.


Nel caso del dispositivo MOSFET, la regione di funzionamento che meglio approssima il comportamento di un interruttore chiuso è la regione di triodo, così come nel dispositivo BJT è la regione di saturazione. Anche il MOSFET può quindi essere utilizzato come interruttore e si applicano considerazioni simili.

2.15.4 Considerazioni sulla Potenza

Ora che abbiamo capito come pilotare carichi tramite transistor, è importante fare alcune considerazioni sulle conseguenze della dissipazione di potenza. Infatti, come abbiamo visto in precedenza, parte dell'energia elettrica verrà inevitabilmente dissipata anche sull'elemento di commutazione (cioè il transistor). Questa è una caratteristica indesiderata che però è presente e merita un'attenzione particolare. In effetti, questa dissipazione di potenza comporterà un aumento della temperatura locale poiché la maggior parte della potenza viene dissipata sotto forma di calore. Ciò significa che, in condizioni di normale funzionamento, il transistor si surriscalda (fenomeno chiamato auto-riscaldamento), il che comporta una serie di conseguenze. Per iniziare, il transistor non funzionerà alla stessa temperatura dell'ambiente in cui è collocato, ma a una temperatura maggiore. Poiché anche il comportamento del dispositivo dipende dalla temperatura, è importante mantenere questo gradiente di temperatura il più piccolo possibile. In generale, una temperatura più elevata del dispositivo riduce la durata del dispositivo e può rappresentare una minaccia per la sua affidabilità e, in casi critici, per la sicurezza generale del circuito e del sistema in cui il circuito è installato. Pertanto, nei casi in cui avvenga un notevole auto-riscaldamento, è necessario adottare sistemi dedicati per favorire la rapida rimozione del calore prodotto localmente per tenere sotto controllo la temperatura ed evitare il surriscaldamento. Ciò si ottiene per mezzo di dissipatori di calore.

2.15.5 Dissipatori Termici

I dissipatori di calore sono semplici pezzi di metallo (o, in generale, di materiali che hanno un'elevata conducibilità termica) che vengono posti a contatto con il transistor di potenza per fornire un rapido e significativo scambio di calore con l'ambiente circostante (es. aria). Sono sagomati in modo tale da massimizzare la loro superficie mantenendo compatto il loro volume, perché lo scambio termico è proporzionale alla superficie di contatto tra il dissipatore e l'ambiente. Un tipico esempio di forma che soddisfa questo criterio è il cilindro cavo a lamelle




perpendicolari, mostrato a destra. Sono posizionati direttamente sopra l'involucro (case o package) del transistor e talvolta viene utilizzata anche una pasta adesiva e termicamente conduttiva per promuovere ulteriormente lo scambio di calore e l'adesione del dissipatore di calore al package del dispositivo.

2.15.6 Safe Operating Area

Un concetto molto importante da discutere quando si ha a che fare con i transistor di potenza è la Safe Operating Area (SOA). La SOA è, infatti, l'insieme dei punti di polarizzazione di un transistor che non comportano alcun rischio o minaccia per l'affidabilità. Viene identificato osservando il grafico in cui sono

mostrate le curve di uscita del transistor (ovvero, il grafico I_C vs. V_{CE} per il BJT, il grafico I_D vs. V_{DS} per il MOSFET). Nel seguito, prenderemo l'esempio del BJT senza perdere di generalità. Innanzitutto bisogna considerare che un transistor può sopportare correnti fino ad un valore massimo non superabile (che dipende dallo specifico transistor in esame). Questo valore è tipicamente determinato dalla robustezza dei fili metallici di collegamento al package: ogni terminale del dispositivo è collegato al relativo pin sul package tramite fili dorati molto sottili, che semplicemente esplodono o fondono se una corrente eccessiva scorre attraverso di essi. Questa corrente è di circa 10 A per i fili di




collegamento tipici e devono essere adottati collegamenti speciali se si desiderano correnti più elevate. Tuttavia, anche in questi casi, si avrà una corrente massima dettata dalla particolare tecnologia di bonding (collegamento) utilizzata. Quando viene raggiunto questo limite, i fili fondono e scollegano fisicamente il transistor dal case. Si noti che, dall'esterno, il transistor sembrerà un circuito aperto (poiché è fisicamente disconnesso dai pin del case) sebbene il dispositivo stesso sia ancora intatto e, potenzialmente, funzionante. In particolare, quando si utilizza il transistor come interruttore, questa limitazione è critica quando il dispositivo è polarizzato nello stato ON (cioè, saturazione per il BJT, triodo per il MOSFET). Poiché in questo stato la V_{CE} (o V_{DS} per un MOSFET) è bassa, anche la potenza dissipata è bassa. Pertanto tale limite non è legato alla dissipazione di potenza ma strettamente al valore di corrente, e rappresenta un primo limite da considerare. Un altro limite ha a che fare con la tensione massima che il dispositivo può sopportare. Come abbiamo visto in precedenza in questo capitolo, questa condizione può essere raggiunta quando il transistor è polarizzato nella regione di cut-off. Elevate tensioni applicate causeranno un campo elettrico molto intenso all'interno del dispositivo. Molto semplicemente, se la tensione supera un valore critico (che dipende dalle caratteristiche dello specifico transistor utilizzato) si verifica il fenomeno di breakdown: il campo elettrico diventa così elevato che il materiale si danneggia irreversibilmente e diventa simile a un conduttore. Questo fenomeno nella maggior parte dei casi non è reversibile e il transistor perderà definitivamente la sua funzionalità. Questo fenomeno dipende dalla tensione applicata, e può quindi verificarsi anche se la corrente è bassa. Anche in questo caso, quindi, questo limite non è correlato all'elevata dissipazione di potenza. Un terzo limite è invece dato dalla potenza massima che il transistor può sopportare. Nella figura sopra, la linea diagonale approssima una curva di potenza costante, in questo caso è la potenza massima che il transistor può sopportare (il cui valore specifico dipende dallo specifico transistor considerato). Sebbene un interruttore non sia mai polarizzato per molto tempo in questa regione, dobbiamo ricordare che il dispositivo può passare attraverso questa regione quando passa dallo stato OFF allo stato ON e viceversa. La regione racchiusa da questi limiti definisce la SOA. La polarizzazione del dispositivo all'interno della SOA è quindi sicura per il funzionamento del dispositivo. Nel diagramma sopra è individuabile un'altra diagonale con pendenza diversa (regione di breakdown secondario) che restringe ulteriormente la SOA ma in questo

contesto non verrà data la spiegazione del suo verificarsi, in quanto correlata a complessi fenomeni di degrado che si verificano nel dispositivo.

In generale, un BJT e un MOSFET con valori nominali di corrente, tensione e potenza massimi simili non avranno SOA simili. Infatti, il MOSFET avrà, tipicamente, una SOA più ampia, più estesa nel limite diagonale. Ciò è dovuto alla seguente considerazione. Quando il dispositivo è polarizzato in una regione in cui viene dissipata una potenza significativa, la temperatura locale aumenterà. Tuttavia, il BJT e il MOSFET reagiscono in modo diverso all'aumento della temperatura. In particolare, il BJT ha una dipendenza positiva della corrente del collettore dalla temperatura. Ciò significa che, se la temperatura aumenta, la corrente del collettore aumenterà. Se questo fenomeno si verifica quando la corrente del collettore è elevata e anche la dissipazione di potenza è elevata, può verificarsi un fenomeno di instabilità termica. In altre parole si può innescare un feedback positivo in base al quale l'aumento della temperatura causerà un aumento significativo di corrente, che a sua volta aumenterà la dissipazione di potenza, aumentando ulteriormente la temperatura e quindi la corrente, e così via. Ciò porterà rapidamente il dispositivo alla distruzione termica. Al contrario, il MOSFET ha una dipendenza negativa della corrente di drain dalla temperatura. Pertanto, un aumento della temperatura dovuto a marcato auto-riscaldamento farà diminuire la corrente di drain, riducendo la dissipazione di potenza. Questo è un meccanismo di feedback negativo che stabilizza la temperatura, prevenendo l'instabilità termica. Di conseguenza, è possibile spingere il MOSFET più vicino al limite di potenza di quanto sia possibile con un BJT.

2.16. Amplificatore Operazionale

Un componente elettronico attivo molto importante e largamente impiegato in una grande varietà di applicazioni (filtraggio, amplificazione, circuiti di conversione A/D e D/A, e anche circuiti digitali) è il cosiddetto Amplificatore Operazionale (Op-Amp). Si tratta di un complesso dispositivo a 5 terminali che funziona come un amplificatore differenziale che, come suggerisce il nome, è un apparato che misura la differenza di due segnali di tensione in ingresso e produce una tensione di uscita proporzionale alla differenza misurata. Pertanto, l'amplificatore operazionale avrà due pin di ingresso e un pin di uscita.




I due terminali/pin di ingresso sono tipicamente etichettati con un "+" e un "-": quello positivo è chiamato ingresso non invertente, l'altro è chiamato ingresso invertente. Attenzione: ciò NON significa che l'ingresso "+" (non invertente) debba essere necessariamente posto a una tensione maggiore di quella invertente. Per il corretto comportamento del dispositivo sono necessari due ulteriori terminali (detti terminali di alimentazione). Infatti l'op-amo non è un componente passivo, e richiede pertanto energia per poter funzionare. L'energia necessaria per il corretto funzionamento del dispositivo è fornita da una sorgente di tensione DC esterna che fornirà una tensione tra i due terminali di alimentazione. Uno di questi due terminali è chiamato terminale di alimentazione positivo e necessita di una tensione maggiore di quella dell'altro terminale di alimentazione (negativo). Anche in questo caso, "terminale di alimentazione positivo (o negativo)" non implica che la tensione qui debba essere necessariamente positiva (o negativa) rispetto al riferimento di massa (punto locale del circuito considerato fisso a 0 V). Tuttavia, a differenza dei pin di ingresso, implica che la tensione sul terminale di alimentazione positivo debba essere maggiore di quella sul

terminale di alimentazione negativo. Le tensioni di alimentazione possono essere (rispetto a massa) sia entrambe positive, sia entrambe negative, che di segno opposto. In quest'ultimo caso (che è tipico) non è necessario che siano simmetriche (sebbene lo siano in genere). Infatti, tipicamente una tensione V_{ss} (il pedice ss sta per supply source) viene fornita al terminale di tensione positivo e una tensione $-V_{ss}$ viene fornita al terminale di tensione negativo. Idealmente, un op-amp fornisce una tensione di uscita che è proporzionale solo alla differenza delle tensioni dei pin di ingresso ($V^+ - V^-$), indipendentemente dai loro valori effettivi. Il fattore di proporzionalità è costante (in prima approssimazione) e chiamato “guadagno”, indicato dalla lettera A.

$$V_{out} = A(V^+ - V^-) = AV_I$$


Il guadagno di un Op-Amp è adimensionale e la sua ampiezza (il segno può essere positivo o negativo) può essere espressa in dB ($A_{dB} = 20 \cdot \log_{10}|A|$). $A_{dB} > 0$ significa che il segnale in ingresso viene amplificato, altrimenti quando $A_{dB} < 0$ il segnale viene attenuato. Il guadagno dovrebbe essere idealmente infinito, ma in casi reali è tipicamente compreso nell'intervallo $10^5 - 10^7$. Ciò significa che anche differenze molto piccole tra le due tensioni di ingresso risulteranno in valori di tensione di uscita piuttosto grandi. La tensione di uscita è però limitata dalla tensione di alimentazione, come mostrato nel pannello di destra della figura sopra, in cui la tensione di uscita è riportata in funzione della tensione differenziale, V_I . Chiaramente, la relazione lineare sopra delineata vale per valori molto piccoli di V_I e la tensione di uscita satura a $+V_{ss}$ o $-V_{ss}$ per tensioni differenziali sufficientemente grandi. In effetti, il range dei valori V_I per i quali vale la relazione lineare (tipica di un amplificatore) è molto ristretto, poiché i valori tipici di V_{ss} sono dell'ordine di pochi volt, mentre il guadagno è dell'ordine di qualche milione. Ciò significa che valori V_I piccoli come $\pm$ pochi microvolt o decine di microvolt causeranno già la saturazione della tensione di uscita. Nella regione di saturazione, V_{out} è insensibile a V_I (il circuito non funziona come amplificatore). Questa caratteristica rende il circuito poco pratico come amplificatore, poiché funzionerebbe bene solo per valori di V_I molto piccoli (la sua gamma di ingresso differenziale è molto piccola).



Un'applicazione in cui l'intervallo di ingresso differenziale molto piccolo dell'amplificatore operazionale viene sfruttato come risorsa è il comparatore. Tale circuito viene utilizzato per confrontare una tensione di ingresso, V_{IN} , con una tensione di riferimento, V_{REF} , per capire se la prima è maggiore della seconda o viceversa. Il circuito è schematizzato nella figura sopra. Chiaramente, l'ingresso differenziale dell'op-amp è $V_{IN} - V_{REF}$. Non appena supera $\pm$ poche decine di microvolt, la tensione di uscita dell'amplificatore operazionale satura a $\pm V_{ss}$. Pertanto, se l'output è V_{ss} , V_{IN} è maggiore di V_{REF} , altrimenti l'output sarà $-V_{ss}$, indicando che V_{IN} è minore di V_{REF} . L'uscita di un comparatore è di natura digitale, in quanto può assumere solo due valori, ovvero $\pm V_{ss}$. Naturalmente, il comparatore non fornisce risultati affidabili quando l'ingresso differenziale è molto piccolo (poiché in quella regione l'intero circuito funziona come un amplificatore). Tuttavia, è un circuito sufficientemente valido per la maggior parte delle applicazioni in cui è necessario un comparatore ed è ampiamente utilizzato in molte applicazioni, alcune delle quali verranno affrontate in seguito (ad es. convertitori A/D).

Un op-amp ideale ha le seguenti proprietà:


- Zero correnti di ingresso (correnti di polarizzazione). La corrente nei due terminali di ingresso è zero, il che significa che il circuito equivalente visto da entrambi i terminali di ingresso è un circuito aperto (impedenza infinita); **questa è una proprietà molto importante che viene spesso sfruttata nei circuiti.**
- Guadagno infinito;
- Estensione di banda infinita. Il guadagno dell'op-amp è costante per tutte le frequenze (cioè a per qualsiasi valore della frequenza del segnale di ingresso);
- L'uscita può assorbire o erogare una quantità arbitrariamente elevata di corrente.



Pertanto, la risposta in frequenza del guadagno di un amplificatore operazionale ideale è descritta da una linea retta costante e continua di valore infinito. Inoltre, in un amplificatore operazionale ideale il guadagno non cambia con la temperatura. Tuttavia, in un vero amplificatore operazionale, rileviamo un guadagno finito (può essere molto grande, ma non infinito) che è costante in frequenza solo fino a una frequenza specifica, detta frequenza di taglio o limite di banda, oltre la quale inizia a diminuire (come mostrato nella figura sopra per un amplificatore operazionale commerciale). La frequenza di taglio, alla quale il guadagno diminuisce di un fattore 2 (equivalente a una riduzione di circa 3 dB) rispetto al guadagno a frequenza zero, definisce la larghezza di banda. Inoltre, un vero amplificatore operazionale mostra correnti di polarizzazione diverse da zero (sebbene molto piccole) ai suoi terminali di ingresso. Pertanto, la corrente nei due terminali di ingresso non è realmente zero, il che significa che il circuito equivalente visto da entrambi i terminali di ingresso non è un circuito aperto (piuttosto un'impedenza di alto valore). Tuttavia, per la maggior parte delle applicazioni pratiche, la corrente assorbita dai terminali di ingresso è del tutto trascurabile e l'approssimazione sopra delineata sostanzialmente è verificata. Infine, l'uscita di un vero amplificatore operazionale può assorbire o generare correnti fino a un determinato limite, che dipende dalle specifiche dell'amplificatore operazionale.

Finora abbiamo visto come l'op-amp può essere sfruttato per realizzare un comparatore. Tuttavia, è chiaro che la natura stessa dell'amplificatore operazionale deve essere quella di un amplificatore differenziale, sebbene abbia il problema di un intervallo di ingresso differenziale molto ristretto. In altre parole, si comporta come un amplificatore differenziale solo per valori di ingresso differenziali molto piccoli. In pratica, questo ci impedisce di utilizzare l'op-amp come amplificatore, quindi è necessario sviluppare strategie per affrontare questo problema. In realtà, è possibile risolvere elegantemente questo problema disponendo l'op-amp in una configurazione di feedback negativo. Non esamineremo i dettagli di come un amplificatore operazionale in configurazione a feedback negativo possa effettivamente fungere da buon amplificatore, ma evidenzieremo due cose importanti che saranno utili in seguito. Il primo è il significato di configurazione a "feedback negativo": si intende una connessione secondo la quale l'uscita dell'op-amp è in qualche modo collegata all'ingresso invertente dell'op-amp stesso tramite alcuni circuiti aggiuntivi (tipicamente semplici e composti da resistori e/o condensatori, anche se possono essere molto più complessi). L'idea generale di una configurazione a feedback negativo è abbozzata di seguito (pannello di destra) e confrontata con una

configurazione "feed-forward" (pannello di sinistra - in questo esempio l'amplificatore operazionale funziona come un comparatore che confronta la tensione di ingresso con un riferimento a massa).



Nella figura sopra, la rete di feedback (il circuito aggiuntivo che collega il terminale di uscita al terminale di ingresso invertente) è rappresentata come una scatola nera (β nella figura sopra). Come già detto, non entreremo nei dettagli di come funziona effettivamente questa classe di circuiti, ma evidenzieremo una proprietà molto importante. Infatti, quando un op-amp è in feedback negativo, e solo in questo caso, emerge una proprietà interessante, chiamata cortocircuito virtuale. Secondo questa proprietà, la tensione ai due pin di ingresso può essere considerata in prima approssimazione la stessa. Questo è molto utile nell'analisi di circuiti che utilizzano op-amp in configurazione di feedback negativo. Solo per aumentare la chiarezza, questa proprietà NON vale quando l'op-amp viene utilizzato come comparatore, poiché non c'è feedback negativo.

2.17. Analogico vs. Digitale

Un'importante distinzione di primo ordine utile a questo punto è quella tra segnali analogici e digitali. I segnali analogici in genere descrivono quantità fisiche come la posizione di un oggetto, la temperatura di un punto nello spazio, la pressione su un'interfaccia, l'intensità della luce in un punto nello spazio e così via. I segnali analogici sono caratterizzati dalla continuità nel tempo, cioè sono funzione continua del tempo il che significa che sono definiti in ogni momento. Inoltre sono definiti a valori reali, cioè il valore assunto dal segnale è un numero reale, caratterizzato in linea di principio con precisione infinita. Ciò significa che, in qualsiasi istante, un segnale analogico può assumerne uno su un insieme infinitamente esteso di valori possibili, ognuno dei quali può richiedere fino a un numero infinito di cifre per essere rappresentato con la massima precisione. Al contrario, un segnale digitale descrive tipicamente quantità come risposte a domande sì/no. In generale, i segnali digitali non sono continui nel tempo, cioè sono definiti solo in istanti di tempo ben specificati (perlomeno dal punto di vista matematico e concettuale). Inoltre, in qualsiasi istante di tempo in cui sono definiti, i segnali digitali possono assumere uno di soli due valori, ad esempio un segnale di tensione digitale può essere 0 V o 5 V. Sono utili sia i segnali analogici che quelli digitali, ed entrambi sono necessari nei sistemi elettronici. Pertanto, circuiti in grado di elaborare segnali analogici e digitali devono essere progettati e incorporati in una piattaforma elettronica unificata. I segnali analogici sono infatti necessari se si vuole interfacciare un sistema elettronico con un qualsiasi sistema fisico. Tipicamente, per mezzo di sensori recuperiamo informazioni che sono codificate in segnali analogici. Allo stesso modo, gli attuatori forniscono alla loro uscita segnali di potenza analogici. Al contrario, i segnali digitali sono utili quando si trattano problemi che coinvolgono la logica e la valutazione di proposizioni logiche (ad esempio, A è maggiore di B?). Inoltre, è spesso utile eseguire operazioni aritmetiche su segnali digitali piuttosto che su segnali analogici. Questo perché i circuiti digitali hanno una serie di vantaggi interessanti che rendono naturalmente il paradigma dell'elettronica digitale più attraente. Infatti, tipicamente l'informazione disponibile in termini di segnali analogici viene convertita in forma digitale e quindi elaborata per mezzo di circuiti digitali. Quindi, quando necessario, i segnali vengono riconvertiti nel dominio analogico per consentire un'ulteriore interazione con i sistemi fisici analogici.

Nello specifico, i domini analogici e digitali hanno caratteristiche peculiari che sono riassunte nella tabella seguente. Soprattutto, il potenziale per il funzionamento a bassa potenza, il basso costo, la resilienza al rumore, la flessibilità e riprogrammabilità dell'hardware sono i vantaggi distintivi dell'approccio digitale, che

ha portato al successo della rivoluzione digitale avvenuta negli ultimi 40 anni che ha profondamente rivoluzionato la nostra vita e la società nel suo insieme.


	Analogico	Digitale
Segnale	Il segnale analogico è un segnale continuo a valori reali (precisione infinita). Rappresentato per antonomasia da onde sinusoidali	I segnali digitali sono segnali a valori binari (precisione finita) discreti nel tempo. Rappresentato per antonomasia da onde quadre
Rappresentazione	Utilizza un intervallo continuo di valori per rappresentare le informazioni	Utilizza valori discreti o discontinui per rappresentare le informazioni
Esempio	Voce umana nell'aria, segnali elettronici analogici in dispositivi analogici	Dati scritti in CD, DVD e altri dispositivi elettronici digitali
Tecnologia	La tecnologia analogica registra le forme d'onda così come sono	Campiona le forme d'onda analogiche in un numero limitato di campioni numerici e le approssima, assegnando etichette in codice binario che vengono registrate nelle memorie digitali
Trasmissione	Soggetto a deterioramento dovuto al rumore durante la trasmissione e il ciclo di scrittura/lettura	Può essere immune al rumore senza deterioramento durante la trasmissione e il ciclo di scrittura/lettura
Rumore	È più probabile che venga influenzato dal rumore, riducendo la precisione	Meno influenzato dal rumore rispetto ai segnali analogici
Flessibilità	L'hardware analogico non è flessibile	L'hardware digitale è flessibile nell'implementazione
Usi tipici	Può essere utilizzato solo in dispositivi analogici. Particolarmente adatto per l'interfacciamento con i sistemi fisici	Più adatto per l'elaborazione avanzata, la trasmissione e ricezione di dati, l'elaborazione logica
Applicazioni	Rilevamento e attuazione	Calcolo, controllo di sistemi, trasmissione robusta ad alta velocità, elaborazione numerica
Banda	L'elaborazione del segnale analogico può essere eseguita in tempo reale e consuma meno larghezza di banda	Consuma più larghezza di banda per veicolare le stesse informazioni
Memoria	Memorizzato sotto forma di forma d'onda	Memorizzato sotto forma di sequenza di bit (cifre binarie)
Potenza	In genere i dispositivi analogici assorbono grande potenza	In genere i dispositivi digitali assorbono una potenza trascurabile
Costo	Il costo, soprattutto di progettazione, è elevato	Il costo di realizzazione è basso (in produzione di massa)

3 Circuiti Digitali

A questo punto dell'opuscolo è già stato introdotto il paradigma logico (digitale) e ne è stata discussa l'utilità. Ora è imperativo capire come sia possibile mettere insieme dispositivi elettronici per formare circuiti che, effettivamente, possano operare su dati digitali. Questo aspetto è legato all'esecuzione di operazioni aritmetiche su numeri con codifica binaria. Tuttavia, questo non è l'unico scopo dei circuiti digitali. In effetti, un altro aspetto importante del paradigma digitale è la possibilità di eseguire operazioni logiche (ed è per questo che i circuiti digitali sono spesso chiamati anche circuiti logici). Per comprendere questo aspetto, è istruttivo pensare a come noi umani siamo (per lo più) esseri logici. Quando prendiamo decisioni e agiamo in base ad esse, la logica lavora in background. La logica è il processo di valutazione di uno o più input, che vengono pesati rispetto a un numero qualsiasi di risultati per intraprendere decisioni e un percorso da seguire. Proprio come applichiamo la logica per prendere tutte le nostre decisioni, i computer usano circuiti logici digitali per prendere le loro. Per farlo usano una serie di porte logiche (circuiti elementari. Giusto per fornire un esempio di vita quotidiana dove possiamo trovare la logica digitale, il semaforo in una città usa la logica quando i pedoni premono il pulsante di segnalazione acustica (che associa un segnale acustico al verde per i pedoni). Il pulsante avvia un processo che utilizza una porta logica AND (spiegato meglio più avanti in questo capitolo). Se qualcuno ha premuto il pulsante di chiamata pedonale E il semaforo è verde per i pedoni, scatterà l'avvisatore acustico. Se una delle condizioni in ingresso a questa operazione logica di tipo AND non è vera, non scatterà l'avvisatore acustico. Più in generale, la logica può essere vista come l'atto di considerare un dato numero di proposizioni logiche (di input) (che possono essere false o vere) e costruire un dato numero di proposizioni logiche (di output) che dipendono logicamente da quelle di input. Si noti che gli unici due possibili valori che una frase logica può assumere (cioè vero e falso) possono essere facilmente rappresentati dai più familiari 1 e 0, con i quali mappiamo i numeri binari. In effetti, esistono diversi modi per rappresentare valori binari (e quindi logici): 1/0 è il modo più comunemente usato. Tuttavia, potremmo anche vederli in una rappresentazione diversa come VERO/FALSO o ALTO/BASSO. Quando i valori sono rappresentati a livello hardware, possono essere associati a livelli di tensione specifici: 0 V è rappresentativo di uno 0 logico, mentre una tensione più alta, solitamente compresa tra meno di 1 V e 3 o 5 V, viene utilizzata per rappresentare un 1 logico. Si noti che, nell'ambito di questo corso, i concetti di porta logica elementare (AND/OR/NOT), il loro comportamento logico e le loro tabelle di verità sono considerati conoscenze preliminari. Anche la struttura interna dell'half-adder e del full adder (esteso anche a più di un bit nell'architettura del sommatore ripple-carry) è considerata conoscenza preliminare. Pertanto, lo studente è invitato a consultare l'eventuale manuale di elettronica digitale e/o il materiale didattico dei precedenti corsi se non del tutto a conoscenza dei concetti sopra indicati.

3.1 Unità Logico-Aritmetica

L'unità logico-aritmetica (ALU) è un elemento fondamentale di molti tipi di circuiti di calcolo, tra cui l'unità di elaborazione centrale (CPU) dei computer, l'unità a virgola mobile (FPU) e l'unità di elaborazione grafica (GPU). È un circuito digitale combinatorio (vedremo in seguito la distinzione tra circuiti combinatori e sequenziali) che esegue operazioni aritmetiche e logiche su numeri binari interi. Gli input di una ALU sono i dati su cui operare, detti operandi, e un codice che indica l'operazione da eseguire (opcode). L'output dell'ALU è il risultato dell'operazione eseguita. In molti casi, l'ALU ha anche ingressi e/o uscite di stato, che trasmettono informazioni su un'operazione precedente o sull'operazione in corso, rispettivamente, tra l'ALU e i registri di stato esterni.



Le operazioni tipiche che possono essere eseguite da una ALU sono:

- Addizione: A e B vengono sommati e la somma compare su Y.
- Somma con riporto: A, B e riporto (indicato dall'ingresso di stato) vengono sommati e la somma compare su Y, col riporto indicato dall'uscita di stato.
- Sottrazione: B viene sottratto da A (o viceversa) e la differenza appare in Y. Per questa funzione, l'uscita di stato è effettivamente un indicatore di "prestito". Questa operazione può essere utilizzata anche per confrontare A e B; in tali casi l'uscita Y può essere ignorata dal processore, che è interessato solo ai bit di stato (in particolare zero e negativo, vedi lista in fondo alla pagina) che risultano dall'operazione.
- Sottrazione con prestito: B viene sottratto da A (o viceversa) con prestito (ingresso di stato) e la differenza appare in Y. Il prestito in uscita è rappresentato dall'uscita di stato.
- Complemento a due: A (o B) viene sottratto da zero e la differenza appare in Y (inverte il segno dell'ingresso).
- Incremento: A (o B) viene aumentato di uno e il valore risultante appare su Y.
- Decremento: A (o B) viene diminuito di uno e il valore risultante appare su Y.
- Pass through: tutti i bit di A (o B) appaiono invariati in Y. Questa operazione viene generalmente utilizzata per determinare la parità dell'operando o se è zero o negativo, oppure per caricare l'operando in un registro del processore.
- AND: in Y compare l'AND (calcolato bit per bit) di A e B.
- OR: in Y compare l'OR (calcolato bit per bit) di A e B.
- XOR: in Y compare lo XOR (calcolato bit per bit) di A e B.
- Complemento a uno (o NOT): tutti i bit di A (o B) sono invertiti e appaiono in Y.

Gli input di stato consentono di mettere a disposizione dell'ALU informazioni aggiuntive durante l'esecuzione di un'operazione. Tipicamente, si tratta di un singolo bit che è il riporto memorizzato da un'operazione ALU precedente in una delle uscite di stato. Le uscite di stato sono vari segnali singoli che trasmettono informazioni supplementari sul risultato dell'operazione ALU corrente. Le ALU per uso generico hanno comunemente segnali di stato come:


- Carry-out, che trasmette il riporto risultante da un'operazione di addizione o il prestito risultante da un'operazione di sottrazione.
- Zero, che indica che tutti i bit di Y sono zero logici.
- Negativo, che indica che il risultato di un'operazione aritmetica è negativo.
- Overflow, che indica che il risultato di un'operazione aritmetica ha superato l'intervallo numerico ammesso da Y (che dipende dal numero di bit che compongono Y).
- Parità, che indica se un numero pari o dispari di bit in Y è all'uno logico.

Al completamento di ciascuna operazione ALU, i segnali di uscita di stato sono generalmente memorizzati in registri esterni per renderli disponibili per future operazioni dell'ALU come segnali di stato in ingresso. L'insieme di bit corrispondenti alle uscite di stato viene spesso trattato come un unico registro, denominato "registro di stato".

3.2 Encoder

Un encoder è un circuito digitale che ha n linee di ingresso e $\lceil \log_2 n \rceil$ linee di uscita, dove $\lceil \cdot \rceil$ denota l'operatore di arrotondamento in eccesso, che restituisce l'intero più piccolo maggiore o uguale al suo argomento. Per comprendere il principio di funzionamento dell'encoder è necessario introdurre il concetto di hot-one. Considerando un insieme di bit, possiamo dire che la configurazione assunta dai bit è una configurazione hot-one se e solo se tutti i bit sono 0 tranne 1 che è 1. In altre parole, se la parola digitale è

caratterizzata da un solo bit impostato su 1, allora quella parola (o configurazione di bit) viene detta una parola (o configurazione) hot-one e l'unico bit impostato su 1 viene chiamato, appunto, hot-one. L'encoder funziona partendo dal presupposto che la parola di input sia una parola hot-one (vedremo più avanti cosa succede se questa ipotesi non è effettivamente verificata). Se questa condizione è verificata, l'encoder restituisce in uscita un numero digitale che identifica univocamente la linea di ingresso associato all'hot-one. Pertanto, un encoder è un convertitore da hot-one a binario. Tipicamente, ma non necessariamente, sono presenti 2^n linee di ingresso e n linee di uscita, ma il caso più generale è stato delineato all'inizio di questo sottocapitolo. Ad esempio, un encoder 4-a-2 prende $2^n = 4$ bit di ingresso (4 possibili linee dove potrebbe essere l'hot-one) e produce $n = 2$ bit di uscita. La tabella di verità è riportata nella figura seguente, unitamente ad una possibile implementazione circuitale, che però non è univoca. Come si può facilmente immaginare, la tabella di verità che segue chiarisce il comportamento del circuito quando la combinazione di ingresso soddisfa la condizione di hot-one. Ma che dire del caso in cui questa condizione non è soddisfatta?



Per tutte le combinazioni di input non definite in modo esplicito (vale a dire, input contenenti > 1 bit impostato su 1) le uscite dovrebbero essere trattate come se il loro valore logico non fosse di nostro interesse (ossia dovrebbero essere ignorate). Ciò significa che non siamo realmente interessati ai valori effettivi che i bit di output assumeranno per qualsiasi combinazione di input che non sia una parola hot-one. Di fatto, però, anche in presenza di una configurazione non di tipo hot-one, il circuito produrrà un determinato output tra quelli possibili. È chiaro che la parola di uscita fornirà effettivamente informazioni sulla linea di ingresso che sta trasportando un hot-one solo se la condizione hot-one sui bit di ingresso è soddisfatta. Quando non lo è (e questo non può essere rilevato dal circuito) l'uscita assumerà un valore che in teoria dovrebbe essere ignorato, poiché se lo interpretassimo come significativo commetteremmo chiaramente un errore. Ad esempio, se nel circuito in figura l'ingresso è 1111, l'uscita sarà 01 (il lettore può facilmente verificarlo). Se interpretassimo questo dato in uscita come significativo ne dedurremmo, stando alla tabella di verità, che in ingresso è presente la parola 0010, mentre ciò non è vero.

In altre parole, quando si utilizza un encoder, bisogna essere sicuri che la combinazione di ingresso sia sempre una hot-one word, poiché solo in questo caso il circuito restituisce risultati significativi e poiché il circuito non è in grado di rilevare se questa condizione è verificata o meno. Quindi è saggio usare questo circuito solo in sistemi in cui possiamo garantire che la combinazione in ingresso sarà di tipo hot-one. In altri sistemi, tuttavia, questa condizione di ingresso non può essere sempre garantita. In questi casi può essere adottata una versione migliorata di tale circuito, denominata priority encoder.


3.3 Priority Encoder

Il priority encoder è una versione migliorata dell'encoder, che risolve i problemi di quest'ultimo. Infatti, mentre la tabella di verità per tutte le combinazioni di ingresso non hot-one non è definita per l'encoder, è completamente definita per l'encoder di priorità. Pertanto, nel caso del priority encoder tutte le combinazioni di ingresso sono significative e supportate senza generare ambiguità. Se la combinazione di ingresso è una parola hot-one, il priority encoder si comporta esattamente come l'encoder. Nel caso opposto,

invece, viene introdotto il concetto di priorità, il che significa che ai vari input viene assegnata una graduatoria in termini di importanza. Ad esempio, se sono presenti n linee di ingresso (da I_0 a I_{n-1}) viene data la massima priorità alla linea I_{n-1} , seguita dalla linea I_{n-2} e così via, con la linea I_0 che ha la priorità minore. Ciò significa che, se la combinazione di ingresso è caratterizzata da più di un ingresso impostato a 1, il priority encoder si comporta come se la combinazione di ingresso fosse una parola hot-one con il bit hot-one portato dall'ingresso con la priorità più alta tra quelli effettivamente impostati a 1. Nel diagramma seguente, che riporta la disposizione del circuito e la tabella di verità di un priority encoder 4-a-2, l'ingresso con priorità più alta è I_3 , mentre "x" indica una condizione di "non interesse" (cioè un valore irrilevante – può essere 0 o 1 indifferentemente). Come si può notare, quando la linea I_3 (linea ad alta priorità) è impostata a 1, gli altri ingressi sono davvero irrilevanti in quanto il circuito si comporterà comunque come se la combinazione degli ingressi fosse 1000. Lo stesso ragionamento vale per tutte le altre linee. In particolare, esiste ancora una possibile combinazione di ingressi per la quale il circuito può dare risultati non significativi, cioè quando tutte le linee di ingresso sono impostate a 0. Questa combinazione infatti non è valida e il priority encoder può essere realizzato in modo tale che le uscite, in questo caso, assumano un qualsiasi valore (non importa quale). Tuttavia, a differenza dell'encoder, il priority encoder è in grado di rilevare questa condizione. In effetti, è presente una linea di uscita aggiuntiva ("v" per "validità"), ed è progettata per essere 0 se e solo se tutti i bit di ingresso sono impostati a 0. In altre parole, questa uscita identifica se la combinazione di ingresso è valida ($v = 1$) o meno ($v = 0$).


Questo circuito è un componente cruciale del Flash ADC, dove è obbligatorio identificare la linea con priorità più alta tra le uscite dei comparatori (studieremo il Flash ADC in dettaglio durante il corso).

I priority encoder possono essere facilmente collegati in cascata per creare priority encoder più grandi in modo modulare. Ad esempio, un priority encoder 16-a-4 può essere realizzato per mezzo di sei priority encoder 4-a-2: quattro priority encoder 4-a-2 ricevono in ingresso le 16 linee di ingresso, e i due rimanenti priority encoder 4-a-2 prendono in ingresso le uscite dei primi quattro priority encoder.



3.4 Decoder

Il circuito duale dell'encoder è il decoder, un circuito logico che ha n linee di ingresso e 2^n linee di uscita. I decoder sono utilizzati in un'ampia varietà di applicazioni, inclusi i driver video e la decodifica degli indirizzi di memoria. A differenza del caso dell'encoder, tutte le possibili combinazioni di ingresso per il decoder sono significative. La combinazione dei bit di uscita del decoder è sempre una parola hot-one, con il bit hot-one che si trova sulla linea identificata dal numero binario presente come ingresso. La tabella di verità e la realizzazione circuitale di un decoder 2-a-4 sono riportati nella figura seguente.




3.5 Multiplexer e De-multiplexer

Un multiplexer (o mux) è un dispositivo che funge da interruttore digitale ad n vie. Fondamentalmente, ha n linee di input e una linea di output. Inoltre, ha anche $\lceil \log_2 n \rceil$ linee di controllo, dove $\lceil \quad \rceil$ indica l'operatore di arrotondamento in eccesso. Il valore della linea di uscita sarà il valore di una specifica linea di ingresso, ovvero quella identificata dalle informazioni presenti sulle linee di controllo. In altre parole, il numero binario presente alle linee di controllo seleziona quale delle linee di ingresso deve propagare le sue informazioni all'uscita. Nel riquadro sinistro della figura sottostante è riportato lo schizzo di un mux 2:1, ovvero un mux con due ingressi (una linea di controllo, "sel") e un'uscita. Inoltre, viene mostrata la rappresentazione equivalente come interruttore a 2 vie. Un multiplexer consente a più segnali di viaggiare lungo una singola linea, anche se uno alla volta. Come mostrato schematicamente nel pannello di destra della figura sottostante, conversazioni differenti tra 5 mittenti e 5 ricevitori potrebbero avvenire su un'unica linea di comunicazione (condivisa) adottando un multiplexer lato dei mittenti, unitamente alla sua componente duale, un de-multiplexer, dal lato dei ricevitori. Questa tecnica non permette che due o più conversazioni avvengano contemporaneamente ma permette di condividere la risorsa (in questo caso la linea di comunicazione). Questa tecnica, chiamata time multiplexing, è usata frequentemente nelle telecomunicazioni, e anche nelle comunicazioni tra dispositivi che avvengono nei sistemi embedded, poiché consente di risparmiare spazio e costi di cablaggio aggiuntivo, sacrificando la velocità e il parallelismo.



Un de-multiplexer (o de-mux) è un dispositivo che prende un singolo segnale in ingresso e, grazie ad un insieme di n segnali di controllo, seleziona una delle 2^n uscite a cui inoltrare l'ingresso. Di seguito è riportato un esempio di multiplexer 4:1 con la sua controparte de-mux:



3.6 Circuiti Combinatori e Sequenziali

Nell'elettronica digitale si è soliti distinguere tra circuiti combinatori e sequenziali, che lavorano in modi differenti.

- Logica combinatoria - l'uscita di un circuito combinatorio al tempo t dipende solo dalla combinazione degli ingressi al tempo t (è un circuito senza memoria); in un circuito combinatorio, la stessa combinazione di ingressi risulta sempre nella stessa uscita.
- Logica sequenziale - l'uscita di un circuito sequenziale dipende dagli ingressi al tempo presente e anche passato (è un circuito con memoria); in un circuito sequenziale, la stessa combinazione di ingressi può comportare uscite diverse in momenti diversi.

Cioè, i circuiti sequenziali devono in qualche modo tenere traccia del passato, il che richiede l'inclusione di un elemento di memoria. Un'ulteriore conseguenza è che, per realizzare circuiti sequenziali, il circuito deve in qualche modo tenere traccia del tempo (cioè è necessario un segnale di clock). Di seguito, daremo un'occhiata ai circuiti che possono implementare la funzione di un orologio (clock) e a quelli che possono fungere da elemento di memoria digitale.


3.7 Clock

Come menzionato in precedenza, è importante avere un segnale di riferimento che può essere in qualche modo utilizzato dai circuiti logici come timer, o orologio, per identificare quando, nel tempo, è possibile osservare i segnali disponibili nel circuito essendo sicuri che tutti "abbiano un senso", cioè rispecchiano i valori effettivi che dovrebbero assumere le funzioni logiche incarnate dal circuito. Questa esigenza deriva dal fatto che i circuiti digitali sono, nei fatti, circuiti asincroni che necessitano di un certo tempo per processare l'informazione in modo completo. Se quindi al tempo t vengono forniti determinati valori di ingresso ad un circuito, le sue uscite assumeranno i valori corretti e corrispondenti agli ingressi effettivi solo dopo un certo tempo Δt , che dipende dalle caratteristiche del circuito stesso. Se le uscite venissero osservate prima osserveremmo dei valori che non sono significativi. Il segnale che viene usato per "cadenzare" i momenti di osservazione garantendo l'integrità dei dati osservati è chiamato clock. Come si può immaginare, il segnale

di clock deve essere molto preciso, cioè la sua frequenza deve essere molto stabile nel tempo. Tipicamente, questo si ottiene su chip utilizzando un oscillatore a cristallo. Un oscillatore a cristallo è un circuito elettronico oscillatore che utilizza la risonanza meccanica di un cristallo vibrante di materiale piezoelettrico per creare un segnale elettrico con una frequenza costante. Il tipo più comune di risonatore piezoelettrico utilizzato è il cristallo di quarzo, quindi i circuiti oscillatori che li incorporano sono diventati noti come oscillatori al quarzo, ma in circuiti simili vengono utilizzati altri materiali piezoelettrici, inclusa la ceramica policristallina. Tipicamente, il quarzo da solo fornisce oscillazioni molto deboli a una frequenza che si mantiene molto stabile nel tempo. Il segnale viene quindi amplificato per mezzo di circuiti elettronici per ottenere un segnale di clock forte e preciso. Il segnale di clock effettivo utilizzato nei circuiti digitali è un'onda quadra che indica al circuito quando osservare le informazioni nel circuito è considerato significativo. Questi istanti di tempo "chiave" sono segnalati dai fronti del segnale (i fronti di salita, oppure i fronti di discesa o anche entrambi nei circuiti avanzati ad alta velocità).

3.7.1 Ring Oscillator

Un altro modo per realizzare un segnale di clock senza utilizzare un cristallo è utilizzare una porta NOT, o una sequenza di porte NOT. Questo circuito è chiamato ring oscillator (oscillatore ad anello), ed è un generatore di onde quadre basato su una semplice catena di un numero dispari di porte NOT, collegate in un anello di feedback. L'oscillatore ad anello più semplice che si possa concepire è quindi costituito da tre porte NOT chiuse ad anello, come abbozzato nel pannello in basso a destra della figura sottostante. Il suo comportamento può essere compreso considerando che ogni singola porta NOT ha un proprio ritardo di propagazione intrinseco. Per ora consideriamo un'unica porta NOT in loop (questo circuito NON si comporterà da ring oscillator ma è utile a capire il meccanismo logico alla base del ring oscillator – la spiegazione del perché una sola porta NOT non sia sufficiente esula dallo scopo di questo corso). Supponiamo che all'istante $t = 0$ la tensione all'unico nodo del circuito (che è contemporaneamente sia l'ingresso che l'uscita della porta NOT) sia 0 V. La porta NOT legge uno 0 logico al suo ingresso e prova a reagire forzando l'uscita (cioè l'unico nodo nel circuito) all'1 logico. Tuttavia, dobbiamo attendere il ritardo di propagazione, t_D , della porta NOT affinché ciò avvenga. Pertanto, a $t = t_D$, il nodo del circuito out è forzato all'1 logico. La porta NOT ora legge un 1 logico al suo ingresso e prova a reagire forzando il nodo del circuito allo 0 logico. Tuttavia, dobbiamo attendere un altro intervallo di tempo t_D affinché ciò avvenga. Il nodo circuitale oscilla quindi spontaneamente tra 0 logico e 1 logico ad una frequenza pari a $1/(2 \cdot t_D)$, come illustrato nel riquadro sinistro della figura sottostante.




Modificando il numero di porte NOT racchiuse nel loop, come abbozzato nel pannello in basso a destra della figura sopra, possiamo modulare la frequenza dell'onda quadra. Infatti, il ritardo di propagazione totale di una catena di n porte NOT è $n \cdot t_D$. Pertanto, la frequenza del segnale di clock generato in questo caso sarà $1/(2 \cdot n \cdot t_D)$. Si noti che è richiesto un numero dispari di porte NOT, poiché un numero pari non attiva alcuna oscillazione. Il vantaggio di questo sistema è ovviamente la sua capacità di funzionare senza l'utilizzo di alcun cristallo e può essere realizzato utilizzando una manciata di transistor. Lo svantaggio principale è che è molto meno preciso e stabile rispetto agli oscillatori a cristallo.

3.8 JK Flip-Flop

Daremo ora un'occhiata al circuito chiave che costituisce l'elemento di memoria nei circuiti digitali, che consente di costruire registri e registri a scorrimento, ovvero il flip-flop. Nell'ambito di questo corso, la struttura interna di un flip-flop, il suo comportamento e la sua utilità sono da considerarsi conoscenze pregresse, pertanto lo studente è invitato a consultare il materiale didattico dei corsi precedenti qualora non questi concetti non siano del tutto familiari. Qui inizieremo la discussione presentando le operazioni che il cosiddetto flip-flop JK può effettuare. Il flip-flop JK è un flip-flop generalizzato che unisce le possibilità offerte dai flip-flop D e T (di nuovo, si ritorni ai corsi base precedenti se non si ha familiarità con i concetti di flip-flop D e T). Al contrario dei flip-flop D e T, ha due ingressi (etichettati come J e K), oltre all'ingresso di clock, e due uscite logiche opposte. Poiché questo dispositivo è sensibile al fronte di salita o di discesa del clock, a seconda della connessione della porta NOT interna al flip-flop. La modalità di funzionamento del circuito è ovviamente dettata dagli ingressi J e K. In sostanza, J e K sono simili agli ingressi S e R del latch SR. Pertanto, lasciando $J = K = 0$, il circuito sarà in modalità di attesa. Se $J = 1$ e $K = 0$, il dispositivo è in modalità set. La combinazione opposta forzerà la modalità di reset. Tuttavia, la combinazione $J = K = 1$ non è vietata e in realtà imporrà il circuito in modalità toggle. Il flip-flop JK è quindi un flip-flop universale, perché può essere configurato per funzionare come un flip-flop SR, un flip-flop D o un flip-flop T.

La figura seguente mostra il simbolo del flip-flop JK, la sua tabella caratteristica e un utile diagramma temporale che mostra come evolvono le uscite data la temporizzazione dettata dal clock e degli ingressi J e K. Si noti come le uscite cambino solo sul fronte di salita del clock, essendo insensibili ai valori effettivi degli ingressi J e K in tutti gli altri istanti di tempo. Questo può essere apprezzato in particolare osservando come la transizione "glitch" $1 \rightarrow 0 \rightarrow 1$ dell'ingresso K durante il terzo periodo di clock sia totalmente ignorata dall'uscita. Nel diagramma è possibile vedere le operazioni di set, reset e toggle.




3.9 Registri a Scorrimento

Un registro a scorrimento è un particolare tipo di registro (cioè un banco di memoria). È composto da una cascata di flip-flop D che condividono lo stesso clock in cui l'uscita di un flip-flop è collegata all'ingresso del successivo. Infatti, un registro, a seconda di come sono interconnessi i flip-flop D, può essere classificato come registro a scorrimento. Questo è il caso se è possibile non solo memorizzare e recuperare bit memorizzati, ma anche spostare (spostare di una posizione) i dati memorizzati nel registro. La connessione sopra delineata, in cui l'uscita di un flip-flop è collegata all'ingresso del successivo, insieme al fatto che i flip-flop condividono lo stesso segnale di clock, fa sì che i dati memorizzati nel sistema si spostino da una posizione a il successivo ad ogni ciclo di clock. Collegando l'ultimo flip-flop al primo, i dati possono scorrere all'interno dello shift register in loop, formando un registro a scorrimento circolare.

I registri a scorrimento possono avere ingressi e uscite sia paralleli che seriali. Questi sono spesso configurati come "serial-in, parallel-out" (SIPO) o come "parallel-in, serial-out" (PISO). Esistono anche tipi con ingresso seriale e parallelo e tipi con uscita seriale e parallela. Esistono anche registri di scorrimento "bidirezionali"

che consentono lo spostamento dei bit in entrambe le direzioni: da sinistra a destra o viceversa. L'ingresso seriale e l'ultima uscita di un registro a scorrimento possono anche essere collegati per creare un registro a scorrimento circolare.

3.9.1 Serial-In Serial-Out (SISO)




I registri a scorrimento SISO sono il tipo più semplice di registri a scorrimento. La stringa di dati viene presentata in modo seriale (cioè un bit alla volta, seguendo la frequenza di clock) all'ingresso "Data in" e viene spostata a destra di una posizione ogni volta che il clock è al suo fronte di salita (o di discesa, in dipendenza dal tipo di flip-flop). Ad ogni colpo di clock, il bit all'estrema sinistra (cioè "Data in") viene spostato all'uscita del primo flip-flop. Il bit all'estrema destra (ovvero "Data out") viene sovrascritto dall'ingresso del corrispondente flip-flop e viene dunque perso. I dati vengono memorizzati all'uscita di ogni flip-flop in corrispondenza dell'uscita "Q". Nell'esempio sopra sono disponibili quattro "slot" di archiviazione, quindi è un registro a scorrimento SISO a 4 bit. Per dare un'idea dello schema di spostamento, immagina che il registro contenga 0000 (quindi tutti gli slot di archiviazione sono vuoti). Supponendo che la linea "Data in" presenti al registro 1,0,1,1,0,0,0,0 (in quest'ordine, un bit ad ogni colpo di clock), il risultato è quello mostrato a destra. La colonna di destra corrisponde al pin di uscita del flip-flop più a destra e così via.

Time	Output 1	Output 2	Output 3	Output 4
0	0	0	0	0
1	1	0	0	0
2	0	1	0	0
3	1	0	1	0
4	1	1	0	1
5	0	1	1	0
6	0	0	1	1
7	0	0	0	1
8	0	0	0	0

Quindi l'uscita seriale dell'intero registro è 00010110. Si può vedere che se i dati dovessero continuare a essere shiftati, si otterrebbe esattamente ciò che è stato inserito (10110000), ma sfasato di quattro cicli di clock. Questa disposizione è l'equivalente hardware di una coda. È importante sottolineare che questa disposizione esegue una lettura distruttiva: ogni dato viene perso una volta che è stato spostato fuori dal flip-flop più a destra. Immaginiamo ad esempio di voler memorizzare una parola di 4 bit in questi 4 flip-flop. Lo stesso segnale di clock è dato a tutti i flip-flop. Ogni flip-flop, sul fronte di salita (o di discesa) dell'orologio, legge il suo input e lo sposta in input al flip-flop successivo, lasciando il primo flip-flop (più a sinistra) libero di ricevere il nuovo input in entrata. Dopo quattro cicli di clock, abbiamo i 4 bit memorizzati correttamente. Se si procede con il 5° ciclo di clock, il 1° bit inserito (ora immagazzinato nel flip-flop più a destra) esce dall'output (e viene perso) e un nuovo bit entra dall'input. Pertanto, l'operazione di lettura è distruttiva poiché cancella il bit memorizzato nel flip-flop più a destra.

3.9.2 Serial-In Parallel-Out (SIPO)




È simile al registro a scorrimento SISO, ma consente la lettura parallela poiché ora è disponibile l'uscita di ogni singolo flip-flop. Questa configurazione consente la conversione dal formato seriale a quello parallelo.

L'immissione dei dati è seriale, come descritto nel sottocapitolo precedente. Una volta che i dati sono stati inseriti, possono essere letti simultaneamente su ciascuna uscita o possono essere spostati. Pertanto, la SIPO può funzionare anche come SISO.

3.9.3 Parallel-In Serial-Out (PISO)

Il registro a scorrimento PISO è caratterizzato da un ingresso parallelo e da un'uscita seriale. Ciò significa che la parola di ingresso non viene fornita bit per bit su una singola linea (1 bit alla volta), ma tutti i bit vengono forniti contemporaneamente su linee di ingresso diverse. Pertanto, a differenza del SISO, consente di memorizzare tutti i bit di input contemporaneamente. Tuttavia, come il SISO, consente di spostare i bit memorizzati e fornisce un'uscita seriale. Viene spesso utilizzato per eseguire la conversione del formato da parallelo a seriale. Intuitivamente, se vogliamo realizzare la memorizzazione parallela di n bit in n flip-flop, vorremmo che ogni linea di ingresso contattasse l'ingresso D di un singolo flip-flop. Tuttavia, abbiamo visto nei precedenti sottocapitoli che se vogliamo che i bit memorizzati si spostino di una posizione verso destra dobbiamo invece collegare l'ingresso di ogni flip-flop all'uscita del precedente (tranne quello più a sinistra che prenderà il bit di input in modo direttamente). Chiaramente, queste due condizioni sono in contrasto tra loro. Poiché in un registro a scorrimento PISO vorremmo avere entrambe le caratteristiche, è necessario un circuito dedicato che possa modificare dinamicamente quali informazioni fluiscono effettivamente nell'ingresso di un determinato flip-flop: l'uscita del precedente o uno degli ingressi paralleli. Ciò è ottenuto tramite un piccolo circuito formato da due porte AND e una porta OR. Questo piccolo circuito aggiuntivo ha, in tutto, quattro ingressi (gli ingressi delle due porte AND) e un'uscita (l'uscita della porta OR). L'uscita è collegata all'ingresso del flip-flop D, mentre i quattro ingressi sono: i) una linea di ingresso parallela; ii) l'uscita del precedente flip-flop; iii) un segnale di controllo denominato shift/load; iv) il negato del segnale shift/load, reso disponibile tramite l'uso di una porta NOT. Ovviamente l'ingresso D del primo flip-flop (più a sinistra) è direttamente collegato alla prima linea di ingresso parallela (poiché non esiste un flip-flop precedente).




Shift/load è un bit di controllo che determina il comportamento del circuito (1 corrisponde alla modalità Shift, 0 a quella Load). Per comprendere meglio il principio di funzionamento viene fornito un esempio. Con riferimento alla figura sopra, se shift/load è 0, si noti che le porte AND dispari riceveranno in ingresso l'uscita del flip-flop precedente e uno 0 logico (shift/load). Ciò significa che il loro output sarà sempre 0, indipendentemente dal valore dell'output del flip-flop precedente. Al contrario, le porte AND pari riceveranno in ingresso una linea di ingresso parallela e un 1 logico. Ciò significa che la loro uscita sarà sempre uguale al valore logico della linea di ingresso parallela (qualsiasi esso sia). Ciò significa che tutti i flip-flop in realtà non sono collegati tra loro, ma i loro ingressi sono collegati individualmente alle linee di ingresso parallele. Pertanto, al colpo di clock, la parola parallela disponibile in ingresso verrà memorizzata nello shift register in colpo solo, indipendentemente dal numero di bit (e quindi di flip-flop). Se invece shift/load è 1, le

porte AND dispari riceveranno in ingresso l'uscita del precedente flip-flop e un 1 logico (shift/load). Ciò significa che la loro uscita sarà sempre uguale al valore logico dell'uscita del precedente flip-flop. Al contrario, le porte AND pari riceveranno come ingressi una linea di ingresso parallela e uno 0 logico. Ciò significa che la loro uscita sarà sempre 0, indipendentemente dal valore della linea di ingresso parallela. Ciò significa che ogni flip-flop è effettivamente connesso al precedente (tranne il primo, ovviamente, non essendoci alcun flip-flop precedente al primo), realizzando quindi una struttura SISO. Pertanto, al colpo di clock, il registro a scorrimento si comporterà come un SISO ed eseguirà uno spostamento a destra dei bit memorizzati (facendo entrare un singolo nuovo bit dalla linea di ingresso parallela più a sinistra e perdendo il bit memorizzato più a destra).

3.9.4 Parallel-In Parallel-Out (PIPO)


Il registro PIPO è tutto sommato un registro PISO in cui è consentita la lettura parallela poiché ora è disponibile l'uscita di ogni singolo flip-flop.



Una caratteristica peculiare di questo registro è che può memorizzare dati, spostarli e leggerli in parallelo dopo lo spostamento. Si noti che questo circuito può essere utilizzato come PIPO ma anche come PISO (se leggiamo solo dall'uscita più a destra), come SIPO (se manteniamo shift/load a 1) o come SISO (se manteniamo shift/load su 1 e leggiamo solo dall' output più a destra).


3.9.5 Registri a Scorrimento Bidirezionali

L'architettura precedente permette di spostare i dati solo in una direzione. È possibile, tuttavia, realizzare registri a scorrimento che consentano uno spostamento bidirezionale. Come abbiamo visto, per effettuare uno shift da sinistra a destra è sufficiente una classica architettura SISO, in cui l'ingresso di ogni flip-flop D è collegato all'uscita del precedente. Invece, per effettuare uno shift da destra a sinistra avremmo bisogno che l'ingresso di ogni flip-flop D fosse collegato all'uscita di quello successivo. Possiamo quindi sfruttare lo stesso circuito ausiliario utilizzato nel registro a scorrimento PISO, ma con l'uscita del successivo flip-flop che sostituisce il ruolo della linea di ingresso parallela. In questa architettura, il segnale di controllo è chiamato right/left invece di shift/load, poiché determina la direzione dell'operazione di shift.



3.10 Macchine a Stati Finiti

Una macchina a stati finiti (FSM) o un automa a stati finiti (FSA), o semplicemente una macchina a stati, è un modello matematico di calcolo. È una macchina astratta che può trovarsi in uno di un numero finito di stati (K) in un dato momento. L'FSM può passare da uno stato all'altro in risposta a input esterni e in base anche allo stato corrente della macchina al momento della ricezione degli input; il passaggio da uno stato all'altro è chiamato transizione. Un FSM è completamente definito dall'elenco completo di tutti (K) gli stati possibili, dal suo stato iniziale (è richiesta la definizione di uno stato iniziale) e dalle condizioni per ogni transizione, cioè è necessario definire come, per ogni possibile stato, la macchina evolve (lo stato in cui si porterà) per tutte le possibili combinazioni di input. Facoltativamente, un FSM può anche avere delle uscite, che a loro volta dipenderanno sia dallo stato corrente che dalla combinazione di ingressi.



Nell'esempio riportato nella figura sopra, consideriamo il tornello come un FSM. Può essere in due possibili stati, che sono "bloccato" o "sbloccato". Per essere coerenti, dobbiamo definire uno stato iniziale da cui parte il sistema. Questa semplice rappresentazione del tornello non ha output. L'input è rappresentato dall'azione che l'utente può eseguire. Qui, per semplicità, limiteremo le azioni possibili a due: "push", cioè l'utente prova a spingere il tornello per passare, o "coin", cioè l'utente inserisce una moneta nella fessura per le monete del tornello. Se l'ingresso è "push" quando lo stato del tornello è "bloccato", non deve verificarsi nulla. Ciò significa che lo stato successivo del sistema deve essere nuovamente "bloccato". Se l'ingresso è "coin", invece, il sistema dovrà cambiare stato in "sbloccato", ovvero il tornello sarà fisicamente sbloccato. Ora, nello stato "sbloccato", se l'ingresso è "coin", non deve succedere nulla (cioè il sistema deve rimanere nello stato "sbloccato"). Tuttavia, se l'ingresso è "push" (ovvero, l'utente è passato attraverso il tornello), lo stato successivo del tornello dovrebbe essere "bloccato", ovvero il sistema deve essere nuovamente bloccato. Questo completa la descrizione dell'FSM, poiché sono stati elencati tutti gli stati, è stato definito lo stato iniziale e sono state descritte tutte le possibili transizioni (per tutti gli stati e tutte le combinazioni di ingressi).

Si noti che gli stati e gli input possono essere tutti codificati come stringhe binarie, che possono quindi essere sfruttate per tradurre questa macchina astratta in un circuito digitale. È possibile mappare due stati utilizzando una parola a 1 bit, in modo che lo stato "bloccato" possa essere mappato su 0 e lo stato "sbloccato" su 1. È anche possibile mappare due possibili ingressi utilizzando una parola a 1 bit. Pertanto, "push" può essere mappato su 1 e "coin" su 0. Come può essere derivato il circuito logico corrispondente? In primo luogo, per includere un elemento di memoria che possa rappresentare lo stato corrente, è necessario un registro di qualche tipo, tipicamente un PIPO. Quindi è necessaria una logica combinatoria, che prenderà come ingressi lo stato corrente (l'uscita del registro) e gli ingressi dell'FSM, e avrà lo stato successivo come uscita. Se l'FSM ha anche delle uscite, anche queste saranno determinate mediante appositi circuiti combinatori. Lo stato successivo verrà inviato come input al registro PIPO, che fornirà un aggiornamento ciclico dello stato corrente dell'FSM. Il circuito combinatorio può essere facilmente derivato mediante la tabella di verità associata, come mostrato nella figura sopra.

3.11 Famiglie Logiche


La circuiteria interna delle porte logiche è costituita da MOSFET di tipo n e di tipo p, fabbricati simultaneamente sullo stesso wafer di silicio nella cosiddetta tecnologia MOS complementare (CMOS). L'evoluzione della tecnologia CMOS negli ultimi 60 anni ha seguito un paradigma noto come legge di Moore, per cui le dimensioni del singolo transistor si sono ridotte esponenzialmente nel tempo. Ciò significa che, nel tempo, le dimensioni fisiche delle singole porte logiche, e quindi dei circuiti logici, si sono ridotte, il che ha favorito il successo economico della microelettronica, poiché è stato possibile integrare sempre più chip sulla stessa area di silicio (che determina in modo preponderante il costo). Pertanto, le porte logiche possono essere classificate non solo in base alla loro funzione logica, ma anche in base alla famiglia logica di appartenenza. Quest'ultima identifica la dimensione effettiva dei transistor interni e, soprattutto, il livello di tensione che richiedono come rappresentativo dell'1 logico (lo 0 logico è sempre associato ad un livello di tensione intorno a 0 V). Infatti, al diminuire delle dimensioni dei transistor, la tensione utilizzata per rappresentare l'1 logico (che è anche la tensione di alimentazione delle porte logiche) si riduceva di conseguenza (principalmente per evitare che il campo elettrico all'interno del singolo MOSFET raggiungesse valori critici). Pertanto, due porte AND appartenenti a famiglie diverse possono avere prestazioni molto diverse (es. dissipazione di potenza, velocità massima) e, soprattutto, possono rappresentare il valore dell'1 logico utilizzando diversi livelli di tensione. Quest'ultimo punto è critico, poiché implica che queste due porte logiche non possono essere utilizzate insieme nello stesso circuito poiché non possono comunicare correttamente. Inoltre, la tensione relativamente più alta utilizzata da una delle porte AND può rappresentare un pericolo per l'altra, che potrebbe guastarsi fisicamente se esposta a tale tensione. D'altra parte, la tensione relativamente più bassa utilizzata da una delle porte AND potrebbe essere interpretata dall'altra in modo erraneo (ad esempio potrebbe essere confusa per uno 0 logico). Una tecnica per risolvere questa incompatibilità, usata frequentemente per consentire a diverse famiglie logiche di interfacciarsi correttamente tra loro, è l'interfaccia open collector (o open drain), discussa nel prossimo sottocapitolo.

Nella tabella seguente sono riportati alcuni (pochi) esempi di famiglie logiche che coprono oltre 40 anni di evoluzione tecnologica. Come regola generale, le famiglie sviluppate più di recente sono più veloci, energeticamente più efficienti e utilizzano livelli di tensione più bassi. Porte logiche fabbricate con la stessa tecnologia e all'incirca nello stesso periodo temporale possono essere disponibili in diverse versioni, in genere sacrificando la velocità per l'efficienza energetica o viceversa. Pertanto, la stessa famiglia logica può essere commercializzata nella versione ad alta velocità o in quella a bassa potenza.

Family	Description	Propagation delay (ns)	Toggle speed (MHz)	Power per gate @1 MHz (mW)	Typical supply voltage V (range)	Introduction year	Remarks
RTL	Resistor-transistor logic	500	4	10	3.3	1963	the first CPU built from integrated circuits (the Apollo Guidance Computer) used RTL
DTL	Diode-transistor logic	25		10	5	1962	Introduced by Signetics, Fairchild 930 line became industry standard in 1964
CMOS	AC/ACT	3	125	0.5	3.3 or 5 (2-6 or 4.5-5.5)	1985	ACT has TTL compatible levels
CMOS	HC/HCT	9	50	0.5	5 (2-6 or 4.5-5.5)	1982	HCT has TTL compatible levels
CMOS	4000B/74C	30	5	1.2	10V (3-18)	1970	Approximately half speed and power at 5 volts
TTL	Original series	10	25	10	5 (4.75-5.25)	1964	Several manufacturers
TTL	L	33	3	1	5 (4.75-5.25)	1964	Low power
TTL	H	6	43	22	5 (4.75-5.25)	1964	High speed
TTL	S	3	100	19	5 (4.75-5.25)	1969	Schottky high speed
TTL	LS	10	40	2	5 (4.75-5.25)	1976	Low power Schottky high speed
TTL	ALS	4	50	1.3	5 (4.5-5.5)	1976	Advanced Low power Schottky
TTL	F	3.5	100	5.4	5 (4.75-5.25)	1979	Fast
TTL	AS	2	105	8	5 (4.5-5.5)	1980	Advanced Schottky
TTL	G	1.5	1125 (1.125 GHz)		1.65 - 3.6	2004	First GHz 7400 series logic
ECL	ECL III	1	500	60	-5.2(-5.19 - -5.21)	1968	Improved ECL
ECL	MECL I	8		31	-5.2	1962	first integrated logic circuit commercially produced
ECL	ECL 10K	2	125	25	-5.2(-5.19 - -5.21)	1971	Motorola
ECL	ECL 100K	0.75	350	40	-4.5(-4.2 - -5.2)	1981	
ECL	ECL 100KH	1	250	25	-5.2(-4.9 - -5.5)	1981	

3.12 Interfaccia Open Collector

Alcune famiglie logiche sono dotate di un cosiddetto output open collector, o open drain. Questa è una caratteristica versatile poiché consente di interfacciare quella famiglia con altre famiglie logiche che utilizzano una tensione di alimentazione diversa (che rappresenta anche il livello di tensione dell'1 logico). Per capire come funziona un'interfaccia open collector o open drain, discuteremo un semplice esempio di porta logica che utilizza un'alimentazione a 5 V che deve pilotare una porta logica che utilizza invece un'alimentazione a 3 V, mostrato di seguito. Intuitivamente, il problema sorge quando la prima porta emette un 1 logico, che corrisponde ad una tensione troppo alta per la seconda porta, che può gestire correttamente segnali fino a 3 V. L'interfaccia open collector è costituita da una porta NOT che pilota il terminale di comando di un interruttore (un MOSFET di tipo n appartenente alla stessa famiglia logica). Questa ulteriore circuiteria è integrata direttamente a bordo del circuito logico a 5 V con interfaccia open collector. L'uscita logica della porta 5 V è fornita alla porta NOT, e viene quindi logicamente invertita. Quando l'uscita logica è uguale a 0, l'uscita della porta NOT sarà un 1 logico (cioè 5 V in questo esempio), il che forzerà l'interruttore nello stato chiuso. Pertanto, l'uscita fisica del chip sarà forzata a massa. Questa linea è anche l'ingresso della porta logica a 3 V. In questo caso la linea è forzata a 0 V, il che viene correttamente interpretato dalla porta alimentata a 3 V come uno 0 logico. Ciò significa che l'uscita logica della prima porta è stata correttamente trasmessa alla seconda. Si noti che la linea in esame è collegata anche ad una sorgente a 3 V tramite un resistore esterno, detto resistore di pull-up. In questo caso, poiché la linea in esame è a 0 V, una tensione di 3 V cade sul resistore di pull-up. Ciò significa che scorrerà corrente attraverso il resistore di pull-up e attraverso il MOSFET verso massa. Quando l'uscita logica della porta alimentata a 5 V è uguale all'1 logico, l'uscita della porta NOT sarà uno 0 logico (cioè 0 V), il che porterà l'interruttore nello stato aperto. Pertanto, l'uscita fisica del chip è ora fluttuante, poiché nessuna corrente può fluire attraverso l'interruttore (il MOSFET). Ciò implica anche che nessuna corrente può fluire nel resistore di pull-up, se assumiamo che l'ingresso della porta logica a 3 V non assorba corrente (questa è un'ipotesi ragionevole per le porte logiche CMOS, che prevedono gli ingressi sul terminale di gate di transistor MOSFET). Di conseguenza, non ci sarà alcuna caduta di tensione sul resistore di pull-up e di conseguenza la linea di ingresso della porta alimentata a 3 V sarà a un potenziale di 3 V. Di conseguenza, la porta da 3 V interpreta correttamente la tensione di ingresso come rappresentativa dell'1 logico, che conferma l'avvenuta trasmissione dell'uscita logica dalla porta 5 V alla porta 3 V.




Poiché l'interfaccia open collector fornisce, di fatto, un mezzo per collegare e scollegare elettricamente un chip da una linea, viene utilizzata anche quando è desiderabile che molti dispositivi comunichino su una singola linea. Nel caso dell'esempio precedente, allo stesso ingresso della porta 3 V possono essere collegate più uscite open collector a 5 V di diverse porte logiche. Finché tutte le porte a 5 V, tranne una, hanno l'uscita logica a 1, la restante porta a 5 V può comunicare efficacemente con la porta a 3 V. A turno, è possibile far cambiare nel tempo la porta 5 V coinvolta nella comunicazione, multiplexando la comunicazione su un unico bus, che consente di ridurre cablaggio, dimensioni, peso e costi.

3.13 CPUs, (GP)GPUs, Microcontrollori

Un microprocessore è un'unità di elaborazione in cui l'elaborazione dei dati, la logica e il controllo sono inclusi in un unico circuito integrato. Il microprocessore è un circuito integrato digitale multiuso, azionato da un clock e basato su registri, che accetta dati binari come input, li elabora secondo le istruzioni memorizzate nella sua memoria e fornisce risultati (anch'essi in forma binaria) come output. I microprocessori contengono sia la logica combinatoria che la logica digitale sequenziale. L'integrazione di un'intera unità di elaborazione centrale (CPU), il cui nucleo è l'ALU, su un singolo circuito integrato (IC) utilizzando un processo di fabbricazione CMOS altamente automatizzato si traduce in un prezzo unitario relativamente basso. In generale, un microprocessore è una tipologia di processore, dove quest'ultimo è un dispositivo hardware generico concepito per eseguire istruzioni. Da questo punto di vista, un microprocessore è un tipo di processore il cui hardware è contenuto in un unico circuito integrato. Tipicamente, nei sistemi complessi, sono presenti diverse CPU in diversi sottosistemi, con ciascuna CPU che governa il flusso delle operazioni nel proprio sottosistema. Tuttavia, a seconda delle operazioni specifiche da eseguire, alcuni sottosistemi potrebbero richiedere soluzioni diverse. In effetti, una CPU è un dispositivo riprogrammabile (che offre una notevole flessibilità) che tuttavia non è progettato per essere completamente ottimizzato per nessuna delle operazioni che può eseguire. Pertanto, sacrifica le prestazioni per la flessibilità. A volte altre soluzioni possono essere scelte migliori, a seconda dei vincoli specifici a livello di sistema. Ad esempio, un dato sottosistema può richiedere prestazioni di calcolo elevate che una CPU non può garantire, necessitando di circuiti integrati con un design personalizzato (denominati ASIC e discussi più avanti in questo opuscolo), realizzati proprio per risolvere un problema specifico nel modo più ottimizzato possibile, sacrificando la flessibilità per le massime prestazioni. In alcuni altri sottosistemi possono essere preferite soluzioni meno performanti ma molto più economiche, come FPGA o PLA (discusse in seguito), a seconda dello specifico compromesso tra costo e prestazioni. In altri scenari, sono necessarie unità di calcolo ad alte prestazioni perché il sistema deve eseguire attività ad alta intensità di calcolo in tempo reale. Molto spesso, tali algoritmi possono essere eseguiti in modo molto efficiente su unità di elaborazione grafica per uso generale (GPGPU). Si tratta di unità di elaborazione grafica (GPU), originariamente concepite per i gamer e la computer grafica, che sono state progettate per eseguire un numero molto ridotto di operazioni core (quelle coinvolte nei suddetti algoritmi) ma in modo molto efficiente, sfruttando appieno la vettorizzazione dei dati e il parallelismo hardware. Ad esempio, le GPGPU possono elaborare molte più immagini (provenienti da telecamere e radar) al secondo rispetto a una CPU.

Un microcontrollore (MCU) è una sorta di piccolo computer fabbricato su un singolo circuito integrato. Contiene quindi una o più CPU (o anche GPU) oltre a memoria e periferiche di input/output programmabili. Nel chip è spesso inclusa anche una memoria di programma contenente le istruzioni da eseguire (il software) tipicamente sotto forma di memoria Flash (una memoria non volatile in grado di conservare i dati anche senza alimentazione), oltre a una piccola quantità di RAM e una sezione di alimentazione dedicata. I moderni microcontrollori sono in realtà sistemi piuttosto complessi e potenti e sono dotati di convertitori A/D e D/A integrati, timer e interfacce di comunicazione (ad es. USB, SPI, SCI), come illustrato nello schema a blocchi del circuito nella figura sotto. Ciò consente a MCU compatti di interfacciarsi facilmente attraverso porte di ingresso e uscita con sensori e circuiti di condizionamento, nonché con stadi di uscita e attuatori. Tipici

dispositivi di input e output includono infatti interruttori, relè, solenoidi, LED, display a cristalli liquidi, dispositivi a radiofrequenza e tutti i tipi di sensori e circuiti di condizionamento.




Una caratteristica fondamentale del microcontrollore è che il suo microprocessore è caratterizzato da un set di istruzioni ridotto (macchina RISC), il che implica che l'hardware del microprocessore al suo interno è concepito per eseguire un numero relativamente piccolo di operazioni di base. A differenza delle macchine CISC (Complex Instruction Set), il design di un processore RISC è molto più economico, può essere ottimizzato più facilmente per essere efficiente dal punto di vista energetico e consente un design più compatto. I microcontrollori sono infatti tipicamente impiegati nelle applicazioni embedded, a differenza dei microprocessori utilizzati nei personal computer o in altre applicazioni generiche. I microcontrollori sono utilizzati in prodotti e dispositivi controllati automaticamente, come sistemi di controllo del motore di automobili, dispositivi medici impiantabili, telecomandi, macchine per ufficio, elettrodomestici, utensili elettrici, giocattoli e altri sistemi integrati. Riducendo le dimensioni e i costi rispetto a un progetto che utilizza un microprocessore separato, memoria e dispositivi di input/output, i microcontrollori rendono economico il controllo digitale numerico di dispositivi e processi. Nel contesto dell'Internet of Things, i microcontrollori sono un mezzo economico e popolare per raccogliere dati, rilevare e agire sul mondo fisico tramite dispositivi periferici. Questi sono gli ingredienti chiave dell'elettronica attualmente sfruttata a bordo di molti sistemi complessi industriali, automobilistici e IoT in cui vengono utilizzati fino a qualche centinaio di microcontrollori insieme per soddisfare scopi diversi.

I microcontrollori hanno utilizzo specifico nelle applicazioni industriali, dove molte delle istruzioni decodificate da una macchina CISC non sarebbero sfruttate. Essere compatto e a bassa potenza rappresenta un ulteriore vantaggio. Inoltre, possono essere impostati tramite programmazione software in diverse modalità a bassissimo consumo energetico (ad es. sospensione, ibernazione, ...) in cui la maggior parte delle periferiche viene temporaneamente spenta, il che consente un funzionamento duraturo in sistemi autonomi e alimentati a batteria.

3.14 PLAs e FPGAs


Le soluzioni circuitali esplorate in precedenza in questo capitolo, come CPU, GPU e microcontrollori consentono la riprogrammabilità del software, il che significa che è possibile riprogrammare la sequenza di istruzioni che l'architettura di calcolo deve eseguire, riprogrammando il sistema per risolvere un compito ogni volta diverso. Tuttavia, l'hardware non è riprogrammabile, il che significa che i suoi componenti sono interconnessi in modo predefinito e non modificabile. Tuttavia, soprattutto ma non esclusivamente durante la fase di prototipazione, è utile ed economico impiegare circuiti hardware programmabili o riprogrammabili, che offrono maggiore flessibilità e riduzione dei costi. Un interessante esempio di hardware programmabile è l'array logico programmabile (PLA). Il PLA consiste essenzialmente in un array di porte AND e un altro array di porte OR. Gli ingressi (e i loro complementi logici, realizzati tramite porte NOT) sono collegati alle porte AND tramite un piano di connessione programmabile denominato "piano AND" come mostrato nella figura a destra. I punti tra le linee sono tutti i possibili collegamenti tra le varie linee. Ad ogni punto di connessione è presente un interruttore programmabile un tantum, che si comporta nativamente come un circuito aperto. Tuttavia, può essere programmato applicando una tensione opportunamente alta, il che lo trasformerà permanentemente in un cortocircuito, fornendo un collegamento fisico tra le linee. Lo stesso schema di collegamento programmabile è applicato tra le uscite delle porte AND e gli ingressi delle porte OR. Questo layout consente di sintetizzare funzioni logiche arbitrarie nella forma canonica di somma dei prodotti (AND-OR), semplicemente applicando il teorema di Shannon. I PLA sono quindi economici da fabbricare e possono essere programmati individualmente al momento della fabbricazione o, successivamente, direttamente dal cliente. Tuttavia, sono programmabili una sola volta e non possono essere riprogrammati. I PLA sono ovviamente una soluzione interessante per la prototipazione, dal momento che è possibile acquistare un gran numero di PLA, riducendo il prezzo unitario, e utilizzarli per realizzare diversi prototipi di circuiti digitali. A volte possono essere la soluzione più economica per realizzare piccoli circuiti digitali per applicazioni specifiche.



Un'opzione più costosa ma più flessibile è il PLA programmabile, chiamato Field-Programmable Gate Array (FPGA). È un circuito integrato progettato per essere riconfigurato da un cliente o da un progettista dopo la produzione. Ciò significa che l'FPGA ha una struttura hardware interna che consente non solo di configurare alcuni blocchi funzionali per eseguire diverse funzioni di base, ma anche le loro interconnessioni. Pertanto, offre una riprogrammabilità hardware diretta. La configurazione interna dell'FPGA viene generalmente specificata utilizzando un linguaggio di descrizione hardware (HDL). Un FPGA contiene una matrice di blocchi logici programmabili, mostrati nel pannello di destra della figura seguente, e un insieme di interconnessioni riconfigurabili che consentono di cablare i blocchi insieme, come schematicamente mostrato nel pannello di sinistra della figura seguente. I blocchi logici possono essere configurati per eseguire complesse funzioni combinatorie. Nella maggior parte degli FPGA, i blocchi logici includono anche elementi di memoria, che possono essere semplici flip-flop o blocchi di memoria più completi, consentendo anche l'esecuzione di funzioni sequenziali. La struttura di un FPGA comprende generalmente:

- Matrice di CLB (Blocchi Logici Configurabili). I CLB sono costituiti da due o quattro celle logiche. Ogni cella ha una o più Look-up Table (LUT), che sono circuiti combinatori la cui tabella di verità può essere programmata, un sommatore di tipo full-adder, un flip-flop e alcuni multiplexer. Le LUT possono essere programmate individualmente per cambiare le loro tabelle di verità.
- IOB (Input-Output Blocks) posti ai bordi dei CLB, che forniscono l'interfaccia con il mondo esterno.

- Interconnessioni programmabili, realizzate tipicamente per mezzo di una rete di transistor programmabili (con il loro stato memorizzato in una apposita memoria), che forniscono opzioni di routing intelligente.



Sebbene gli FPGA rappresentino uno strumento di prototipazione molto vantaggioso, le notevoli prestazioni e flessibilità offerte dagli FPGA all'avanguardia sono tali da essere talvolta integrati direttamente a bordo di un prodotto finale.

3.15 ASICs

Un application-specific integrated circuit (ASIC) è un circuito integrato personalizzato per uno scopo particolare, piuttosto che destinato a un uso generico. Gli ASIC moderni spesso includono interi microprocessori personalizzati e blocchi di memoria, inclusi ROM, RAM, EEPROM, memorie flash e altri circuiti specifici. La particolarità dell'ASIC è che tutti gli aspetti della progettazione di ogni singolo blocco sono completamente personalizzati, inclusi e rifiniti per raggiungere le massime prestazioni e soddisfare i requisiti dell'applicazione, a scapito di una flessibilità bassa o nulla (mancanza di riprogrammabilità) e di elevati costi di progettazione e fabbricazione, insieme a un tempo di progettazione molto lungo (cioè, un lungo time-to-market). Gli ASIC completamente personalizzati sono infatti caratterizzati da una maggiore complessità nella fase di progettazione assistita da computer (CAD). I vantaggi di un design ASIC completamente personalizzato includono un'area ridotta (il che aiuta in qualche modo a contenere i costi di realizzazione, ma non quelli di progettazione), ottimizzazione delle prestazioni e anche la capacità di integrare componenti analogici e altri componenti pre-progettati, se utili al prodotto.

Per progetti più piccoli o volumi di produzione inferiori, gli FPGA possono essere più convenienti di un ASIC, anche in produzione. I produttori di dispositivi in genere preferiscono gli FPGA per la fase di prototipazione, per poi progettare e produrre ASIC per volumi di produzione molto grandi, dove i costi fissi più elevati (ad esempio quelli di progettazione) possono essere ammortizzati su un gran numero di dispositivi realizzati.

4. Sensori

In questo capitolo introdurremo e ci concentreremo sulla prima tipologia di elementi che si incontrano in un sistema elettronico: i sensori. Li definiremo, li classificheremo e forniremo una discussione sulle tipologie di sensori specifici.


Un sensore è un dispositivo che trasforma le variazioni di una grandezza fisica in una variazione correlata di una grandezza elettrica (come tensione, corrente, resistenza...). Traduce le informazioni da un dominio fisico a un altro. I sensori tipici comprendono sensori di temperatura, forza, coppia, posizione, velocità, accelerazione, campo magnetico, corrente, tensione, pressione, flusso, livello, umidità... In generale, i sensori sono esempi di trasduttori, cioè dispositivi che hanno come ingresso un variabile fisica e la convertono in una variabile dello stesso o di tipo diverso secondo una relazione ben definita. Da questo punto di vista, ogni sensore è un trasduttore ma non è sempre vero il contrario. Un trasduttore infatti può essere formato dal sensore stesso, il sensore insieme a un circuito di elaborazione, il sensore insieme a un sistema complesso. Tuttavia, oggi i due termini (sensore e trasduttore) sono usati in modo intercambiabile.

4.1. Caratteristiche

Un trasduttore è caratterizzato da un insieme di caratteristiche importanti. In generale, tali caratteristiche possono essere raggruppate in tre categorie principali: caratteristiche statiche, dinamiche e di affidabilità. Di seguito viene fornito un elenco, insieme ad esempi relativi a un generico sensore di temperatura che converte la temperatura in tensione.

4.1.1. Caratteristiche statiche

- Intervallo di ingresso (span): è l'intervallo della grandezza in ingresso per cui il sensore ha il comportamento desiderato. Idealmente, un sensore dovrebbe avere un intervallo di input infinitamente grande in cui vale un comportamento lineare. Esempio: il sensore di temperatura nel nostro caso di studio mostra, in generale, una risposta non lineare. Tuttavia, la risposta del sensore può essere approssimata come lineare nell'intervallo da 250 K a 350 K. Per $T < 250$ K o > 350 K la risposta del sensore è fortemente non lineare. Diremo che l'intervallo di ingresso del nostro sensore è compreso tra 250 K e 350 K.



- Intervallo di uscita (fondo scala): è l'intervallo coperto dalla quantità di uscita quando la grandezza di ingresso si estende attraverso l'intervallo di ingresso. Esempio: il sensore di temperatura nel nostro caso di studio mostra un valore minimo di ≈ 2.5 V in uscita quando la temperatura di ingresso è 250 K e un valore

massimo di $\approx 3.5V$ quando la temperatura di ingresso è 350K. Diremo che l'intervallo di uscita del sensore è compreso tra 2.5 V e 3.5 V.

- Sensibilità/guadagno: rappresenta quanto il sensore è sensibile alle variazioni della grandezza in ingresso. È definito come la derivata della quantità in uscita rispetto alla quantità in ingresso. Esempio: il sensore di temperatura mostra una risposta (più o meno) lineare nel suo intervallo di ingresso, quindi la sensibilità, S , è (approssimativamente) costante nell'intervallo di ingresso ed è pari a 10 mV/K:

$$S = \frac{3.5V - 2.5V}{350K - 250K} = 10 \text{ mV/K}$$

- Risoluzione: è la variazione minima della grandezza in ingresso che provoca una variazione rilevabile della grandezza in uscita, quindi la più piccola variazione in ingresso risolvibile dal sensore. Non va confusa con l'accuratezza, che invece si riferisce a quanto vicino il valore "misurato" della grandezza in ingresso (cioè determinato dal valore che assume la grandezza in uscita) è vicino al valore effettivo della grandezza in ingresso. Esempio: supponiamo che il sensore di temperatura che stiamo considerando presenti rumore alla tensione di uscita, in modo che la tensione di uscita oscilli casualmente di circa ± 10 mV attorno al suo valore medio (che dipende dalla temperatura di ingresso). Non è quindi possibile rilevare variazioni di temperatura inferiori a $\pm 10 \text{ mV/S} = \pm 1 \text{ K}$. La risoluzione del sensore è quindi $\pm 1 \text{ K}$.
- Linearità: è una metrica che rivela quanto la risposta del sensore sia lineare. Un sensore ideale ha una linearità perfetta, in tutte le condizioni. Vorremmo che la risposta di un sensore reale fosse il più possibile lineare per il più ampio intervallo di input. Esempio: il sensore di temperatura ha una sensibilità che è pressoché costante in tutto il range di ingresso (buona linearità), mentre si discosta fortemente dall'essere costante al di fuori di quel range (fortemente non lineare).
- Offset: può avere definizioni diverse. Per i nostri scopi, è il valore della quantità di input che fa sì che l'output si trovi al centro dell'intervallo di output. Esempio: il sensore di temperatura ha un offset di 300 K, poiché l'uscita è pari a 3 V (il centro del suo campo di uscita) quando viene applicata una temperatura di ingresso di 300 K.
- Ripetibilità – Stabilità: la ripetibilità rivela quanto è probabile che l'output sia lo stesso se le misurazioni ripetute vengono eseguite nelle stesse condizioni. In altre parole, indica quanto sia ripetibile una misurazione eseguita dal sensore. Questo concetto è strettamente correlato a quello di stabilità: la stabilità è una metrica che indica quanto sia stabile nel tempo il comportamento del sensore. Alcuni sensori devono essere stabili per 10 anni o più, cioè devono mantenere lo stesso comportamento per un periodo piuttosto lungo.
- Isteresi: quantifica la differenza della grandezza in uscita quando la grandezza in ingresso si avvicina allo stesso valore ma seguendo diverse evoluzioni nel tempo. Se il comportamento del sensore è tale che la grandezza in uscita all'istante t dipende solo dalla grandezza in ingresso all'istante t , e non dai valori passati assunti dalla grandezza in ingresso (quindi, senza dipendenza dalla "storia passata" del sensore), il sensore non avrà isteresi. Esempio: ipotizziamo che il sensore di temperatura che stiamo studiando sia tale che, se la temperatura supera (anche solo una volta) i 600 K, la risposta cambia permanentemente. In particolare, supponiamo che la caratteristica cambi bruscamente in modo tale che il guadagno decresca a 1 mV/K. Inoltre ipotizziamo che la tensione di uscita a 250 K rimanga ancora 2.5 V. Prima di raggiungere i 600 K, la tensione di uscita a 300 K è 3 V. Ma se aumentiamo la temperatura fino a 600 K, e poi raffreddiamo il sistema di nuovo fino a 300 K, vedremo una tensione di uscita a 300 K di soli 2.55 V. A 300 K, l'isteresi sarebbe di 0.45 V (cioè 3 V – 2.55 V).

- **Selettività:** una caratteristica cruciale per un sensore. La selettività quantifica quanto è forte la dipendenza della tensione di uscita dalla quantità di ingresso, rispetto alla sua dipendenza da altre grandezze! Idealmente, un sensore dovrebbe essere infinitamente selettivo, il che significa che la quantità di uscita dovrebbe essere una funzione della sola quantità di ingresso. In tutte le applicazioni pratiche, la quantità di uscita dipende anche da altre grandezze e vorremmo che il sensore fosse il più selettivo possibile. Esempio: il sensore di temperatura che stiamo considerando qui mostra anche una certa sensibilità all'umidità relativa. In particolare, la sua tensione di uscita varia di 0.1 mV per ogni punto percentuale di umidità relativa. Il sensore ha quindi una selettività 100 rispetto alla percentuale di umidità relativa, in quanto la variazione di uscita dovuta ad una variazione unitaria di temperatura è 100 volte maggiore di quella ottenuta con una variazione unitaria della percentuale di umidità relativa.
- **Effetti di carico sul sistema:** quantificano quanto la presenza del sensore alteri le caratteristiche della grandezza da misurare. Idealmente, un sensore non dovrebbe alterare affatto la grandezza da misurare, ma questo può essere vero solo idealmente e solo nei limiti della fisica classica. Secondo la meccanica quantistica, infatti, la presenza del sensore altererà inevitabilmente la grandezza da misurare, altrimenti l'operazione di misura non sarebbe possibile. In generale, vorremmo ridurre il più possibile gli effetti di carico. Esempio: il sensore di temperatura che stiamo studiando ha una composizione interna che include dell'elettronica attiva, che dissipa calore durante il lavoro. Questa fonte di calore diffonderà calore nell'ambiente circostante, influenzando potenzialmente la temperatura dell'ambiente stesso. Il sensore deve essere progettato in modo che la sua dissipazione di calore sia sufficientemente bassa da produrre solo variazioni insignificanti della temperatura dell'ambiente (la quale è infatti l'oggetto della misura).

4.1.2. Caratteristiche dinamiche

- **Funzione di trasferimento:** è definita come la trasformata di Laplace del rapporto tra la grandezza in uscita e la grandezza in ingresso. Include tutte le informazioni sulla risposta del sensore a qualsiasi tipo di stimolo.
- **Risposta al gradino (costante di tempo, tempo di salita, tempo di assestamento, overshoot):** grandezze che descrivono la dinamica della grandezza in uscita, ossia come questa cambia nel tempo in risposta ad un cambiamento a gradino della grandezza in ingresso.
- **Risposta in frequenza (ampiezza di banda, smorzamento, frequenza naturale):** mostra la reazione del sensore ad uno stimolo sinusoidale. In generale, se un sistema lineare (supponiamo che il nostro sensore sia lineare) è eccitato da un ingresso sinusoidale, mostrerà un'uscita sinusoidale alla stessa frequenza, con ampiezza e fase determinate dalla risposta in frequenza del sensore. Tipicamente, viene mostrato in termini di diagrammi di Bode (uno per l'ampiezza, un altro per la fase). La larghezza di banda del sensore è l'intervallo di frequenza in cui la risposta in ampiezza è sufficientemente piatta. È l'intervallo in cui la sensibilità del sensore non dipende dalla frequenza dello stimolo in ingresso (in quanto tale, è l'intervallo di frequenze in ingresso in cui i sensori funzionano come si desidera).

4.1.3. Caratteristiche di affidabilità

- **Durata nominale:** è la durata del sensore garantita dal produttore. Il produttore dichiara che il sensore si comporterà secondo le specifiche del documento tecnico che accompagna il sensore (la sua scheda tecnica) almeno fino alla sua durata nominale se utilizzato nei limiti delle condizioni operative specificate dal produttore.

- Numero di cicli di fondo scala: un ciclo di fondo scala consiste in una variazione completa della quantità in ingresso attraverso l'intero intervallo di ingresso, dal suo minimo al suo massimo e viceversa. Idealmente, un sensore dovrebbe tollerare un numero infinito di cicli di fondo scala senza mostrare alcun segno di degradazione. Tipicamente, un sensore reale è garantito in termini di tolleranza di un dato numero di cicli di fondo scala senza una degradazione significativa delle sue prestazioni.
- Tolleranza ai guasti: specifica la capacità del sensore di funzionare correttamente anche quando si verifica un guasto.

4.2. Sensori di Temperatura


Per misurare la temperatura, possiamo sfruttare molti meccanismi fisici che riguardano lo scambio termico, in particolare i flussi di calore per conduzione, convezione e irraggiamento. Mentre conduzione e convezione sono fenomeni che richiedono un mezzo per la propagazione del calore, la radiazione può propagarsi nel vuoto, il che può consentire il rilevamento della temperatura di oggetti remoti. Quando si misura la temperatura, gli effetti di carico sul sistema devono essere ridotti (in modo da non perturbare in modo significativo la temperatura da misurare). In altre parole, vorremmo avere un sensore che sia in grado di misurare la temperatura dell'ambiente in cui è collocato, $T_{\text{ENVIRONMENT}}$, evitando il più possibile che la presenza del sensore stesso influenzi la temperatura oggetto della misurazione. Per fare ciò, il sensore dovrebbe mostrare una bassa capacità termica. Ci sono una varietà di sensori di temperatura sul mercato: qui ci concentreremo su cinque categorie che sono:

- Termocoppie
- RTD (resistance temperature detectors, o termoresistenze)
- Termistori
- Sensori integrati
- Pirometri

4.2.1. Termocoppie

Le termocoppie sono sensori molto semplici, forse i sensori più semplici di tutti quelli sul mercato. Una termocoppia è composta da due pezzi di metalli diversi uniti insieme in una giunzione (detta giunzione calda). Le termocoppie sfruttano l'effetto Seebeck, e realizzano una conversione diretta in elettricità del calore presente alla giunzione dei due diversi metalli. L'effetto Seebeck, originariamente scoperto nel 1794 da Alessandro Volta, prende il nome dal fisico estone Thomas Johann Seebeck, che nel 1821 lo riscoprì autonomamente. A causa dell'effetto Seebeck, due metalli diversi uniti tra loro in una giunzione, con una differenza di temperatura tra la giunzione calda e le due estremità libere (che consideriamo alla stessa temperatura tra loro, formando virtualmente la cosiddetta giunzione fredda) presenteranno una tensione V tra le due estremità libere. Questa tensione sarà proporzionale alla differenza di temperatura tra la giunzione calda e quella fredda. Nell'approssimazione lineare, $V=S \cdot \nabla T$, dove S è il coefficiente di Seebeck. Tuttavia, le vere termocoppie non sono veramente lineari, e il coefficiente di Seebeck varia generalmente in funzione della temperatura e dipende fortemente dalla composizione dei conduttori (quindi dipende dalla scelta dei due metalli). Per i materiali ordinari a temperatura ambiente, il coefficiente di Seebeck può variare tra $-100 \mu\text{V/K}$ (o equivalentemente $\mu\text{V}/^\circ\text{C}$) e $1000 \mu\text{V/K}$.


Una breve nota: giunzione calda è solo un nome. Ciò non implica che la sua temperatura debba essere necessariamente maggiore della temperatura alla giunzione fredda. Anche giunzione fredda è solo un nome, poiché non è nemmeno propriamente una giunzione ma solo un paio di estremità libere alla stessa temperatura (le due estremità libere NON devono essere in contatto tra loro per eseguire la misurazione della tensione, altrimenti staremmo cortocircuitando l'uscita).



Alcune combinazioni di leghe sono diventate popolari come standard del settore. La scelta della combinazione dipende da costo, disponibilità, convenienza, punto di fusione, proprietà chimiche, stabilità e resa. Diversi tipi sono più o meno adatti per diverse applicazioni. Di solito vengono selezionati in base all'intervallo di temperatura e alla sensibilità necessari. Le termocoppie con sensibilità basse (tipi B, R e S) hanno risoluzioni corrispondentemente inferiori. Altri criteri di selezione includono l'inertia chimica del materiale della termocoppia e se è magnetica o meno. Di seguito sono elencati alcuni tipi di termocoppie standard in cui il primo materiale indica quello dell'elettrodo positivo.

Tipo E (chromel-costantana) ha una sensibilità relativamente elevata ($68 \mu\text{V}/^\circ\text{C}$), che lo rende adatto all'uso criogenico. Inoltre non è magnetico. Funziona tra -50°C e $+740^\circ\text{C}$ con una buona linearità nell'intervallo di ingresso da -110°C a $+140^\circ\text{C}$. Nota: la costantana è una lega di nichel-rame composta dal 55-60% di rame e dal 40-45% di nichel. La sua resistività è costante in un ampio intervallo di temperature. Un materiale simile è la manganina ($\text{Cu}_{86}\text{Mn}_{12}\text{Ni}_2$).

Tipo J (ferro-costantana) ha un intervallo più ristretto (da -40°C a $+750^\circ\text{C}$) rispetto al tipo K ma una sensibilità maggiore di circa $50 \mu\text{V}/^\circ\text{C}$. Il punto di Curie del ferro (770°C) provoca un cambiamento graduale della caratteristica, che determina il limite superiore di temperatura.




Tipo K (chromel-allumel) è la termocoppia per uso generico più comune con una sensibilità di circa $41 \mu\text{V}/^\circ\text{C}$. È poco costoso e un'ampia varietà di sonde è disponibile nella sua gamma da -200°C a $+1350^\circ\text{C}$. Il tipo K è stato ideato in un momento in cui la metallurgia era meno avanzata di quanto non lo sia oggi e di conseguenza le caratteristiche possono variare considerevolmente tra i campioni. Uno dei metalli costituenti, il nichel, è magnetico; una caratteristica delle termocoppie realizzate con materiale magnetico è che subiscono una deviazione in uscita quando il materiale raggiunge il suo punto di Curie, che si verifica per le termocoppie di tipo K a circa 185°C . Funzionano molto bene in atmosfere ossidanti. Se, tuttavia, un'atmosfera prevalentemente riducente (come idrogeno con una piccola quantità di ossigeno) viene a contatto con i fili, il cromo nella lega di chromel si ossida. Ciò riduce l'uscita. Questo fenomeno è noto come residuo verde, a causa del colore della lega ossidata che viene a formarsi. Sebbene non sia sempre di colore verde, il filo di chromel svilupperà una "pelle" argentata screziata e diventerà magnetico. Un modo semplice per verificare


la presenza di questo problema è vedere se i due fili sono magnetici (normalmente, il chromel non è magnetico). L'idrogeno nell'atmosfera è la causa tipica del residuo verde.

4.2.1.1. Legge dei metalli interposti

Per misurare la tensione prodotta dalla termocoppia è necessario utilizzare un voltmetro, collegato alle due estremità libere della termocoppia (giunto freddo), vedi figura sopra. I due terminali del voltmetro sono essi stessi costituiti da un materiale metallico che potrebbe essere facilmente diverso dai materiali metallici che compongono la termocoppia. Poiché la risposta della termocoppia si basa sul fatto che due metalli specifici sono in contatto tra loro, il collegamento di due ulteriori pezzi di metallo (i terminali del voltmetro) può modificare le proprietà della termocoppia?



Per fortuna non è così (a patto di prestare un po' di attenzione) a causa della cosiddetta legge dell'interposizione dei metalli. Se abbiamo una termocoppia (pannello sinistro nella figura sopra) e inseriamo un terzo metallo nell'anello (pannello centrale nella figura sopra), creiamo due ulteriori giunzioni (B-C e C-B nel pannello centrale). Tale inserimento non altera la risposta della termocoppia se e solo se le due nuove giunzioni create dal nuovo inserimento metallico sono alla stessa temperatura. Ciò significa che se i due terminali del voltmetro sono mantenuti alla stessa temperatura e sono dello stesso metallo (quest'ultimo può essere diverso dai materiali metallici che compongono la termocoppia), la presenza del voltmetro non altera la misura eseguita dalla termocoppia (come mostrato nella figura sopra - pannello di destra). L'importanza pratica di questa legge è che possiamo sempre trattare le giunzioni "parassite" in cascata come un'unica giunzione composta dagli stessi due tipi di metallo della giunzione di misura, purché tutte le giunzioni metalliche parassite siano (a due a due) alla stessa temperatura. Questo fatto è estremamente importante per i circuiti a semiconduttore, dove il collegamento di una termocoppia a un amplificatore elettronico comporta una lunga serie di giunzioni metalliche parassite. Nella figura sottostante vediamo una moltitudine di giunzioni parassite, formate dalle necessarie connessioni dai fili della termocoppia al substrato di silicio all'interno del chip dell'amplificatore.



Vediamo i metalli del filo della termocoppia (tipo J – ferro e costantana) che si uniscono a una coppia di viti terminali in ottone, che a loro volta si uniscono a tracce di rame su un circuito stampato, che si uniscono a saldature piombo/stagno, che si uniscono a sottili fili realizzati in kovar (una lega conduttiva), che terminano in tracce d'oro sul chip di silicio, che sono poi collegate al silicio stesso. L'effetto di ciascuna coppia di giunzioni complementari in questa catena in serie è nullo se ciascuna coppia è alla stessa temperatura. Ad es. se la giunzione oro-silicio J12 e la giunzione silicio-oro J13 sono alla stessa temperatura, i loro effetti si annullano

perché generano esattamente la stessa quantità di tensione con polarità opposte. La giunzione kovar-oro J10 si annulla con la giunzione oro-kovar J11 per lo stesso motivo; eccetera. La legge dei metalli interposti, in sostanza, afferma che, a patto di soddisfare il criterio relativo all'uniformità della temperatura delineato poc'anzi, le giunzioni da J2 a J13 prese insieme in serie hanno lo stesso effetto della sola termocoppia (giunzioni J2 e J3).

Tipicamente, una termocoppia viene scelta per un'applicazione specifica a seconda:

- Coefficiente di Seebeck (sensibilità)
- Intervallo di temperatura tollerato dalla termocoppia
- Resistenza ad ambienti ostili (es. pieni di agenti chimici, radiazioni, ...)
- Tasso di ossidazione (se la termocoppia tende a ossidarsi rapidamente, potrebbe degradarsi in un lasso di tempo relativamente breve).

4.2.1.2. *Compensazione del giunto freddo*

In generale, le termocoppie possono misurare la differenza di temperatura tra la giunzione calda e quella fredda, ma non la temperatura assoluta alla giunzione calda. Quest'ultimo dato può essere misurato implementando strategie di compensazione:

- Forzare la temperatura assoluta del giunto freddo ad un valore noto
- Misurare la temperatura assoluta al giunto freddo

La prima alternativa è tipicamente chiamata tecnica del "bagno di ghiaccio". Ad esempio, possiamo esporre la giunzione fredda a un bagno di ghiaccio (che garantisce una temperatura di 0 °C) per forzare la temperatura della giunzione fredda a 0 °C. Quindi, la misurazione della tensione di uscita darebbe una stima diretta della differenza tra la temperatura alla giunzione calda e 0 °C. Tuttavia, questo non è pratico e può essere fatto solo durante la fase di test o in scenari specifici. È abbastanza evidente che questo approccio non potrà mai funzionare, diciamo, in un ambiente industriale! In generale, il bagno di ghiaccio non è l'unico mezzo per applicare questa tecnica poiché è sufficiente forzare la temperatura di giunzione fredda ad una temperatura di riferimento (non necessariamente 0 °C). Ad esempio, potrebbe essere utilizzato un forno ben controllato che funzioni a una temperatura specifica.

Un approccio più solido e sicuro sarebbe quello di misurare la temperatura alla giunzione fredda utilizzando un altro sensore di temperatura. Questo sembra illogico, a primo acchito: perché devo usare un secondo sensore di temperatura per far funzionare la mia termocoppia? Non è solo uno spreco di risorse? Non posso semplicemente buttare via la termocoppia e utilizzare l'altro sensore che non richiede alcuna strategia di compensazione? Queste sono tutte buone argomentazioni, ma l'uso della termocoppia è ancora un'opzione molto interessante poiché è veramente poco costosa e può in genere funzionare in ambienti ostili, cosa che la maggior parte dei sensori non può fare (ad es. ambienti ossidanti). Infine, le termocoppie sono l'unico tipo di sensore in grado di resistere a temperature nell'ordine delle migliaia di °C.

FEATURES

- 80µA Supply Current
- 4V to 36V Operation
- 0.5°C Initial Accuracy (A Version)
- Compatible with Standard Thermocouples (E, J, K, R, S, T)
- Auxiliary 10mV/°C Output
- Available in 8-Lead PDIP and SO Packages

APPLICATIONS

- Thermocouple Cold Junction Compensator
- Centigrade Thermometer
- Temperature Compensation Network

DESCRIPTION

The LT1025 is a micropower thermocouple cold junction compensator for use with Type E, J, K, R, S, and T thermocouples. It utilizes voltage level and post-package trimming to achieve 0.5°C initial accuracy. Special curvature correction circuitry is used to match the "zero" found in all thermocouples so that accurate cold junction compensation is maintained over a wider temperature range.


The LT1025 will operate with supply voltages from 4V to 36V. Typical supply current is 80µA, resulting in less than 0.1°C internal temperature rise for supply voltages under 10V. A 10mV/°C output is available at low impedance, in addition to the direct thermocouple voltages of 60.9µV/°C (E), 51.7µV/°C (J), 40.9µV/°C (K, T) and 5.5µV/°C (R, S). All outputs are essentially independent of power supply voltage.

A special kit is available (LT1025) which contains an LT1025 and a custom tailored thermocouple amplifier. The amplifier and compensator are matched to allow a much tighter specification of temperature error than would be obtained by adding the compensator and amplifier errors on a worst-case basis. The amplifier from this kit is available separately as LT1026.

The LT1025 is available in either an 8-pin PDIP or 8-pin SO package for temperatures between 0°C and 70°C.


24 LT1025-1 is not recommended for use in high temperature applications.

BLOCK DIAGRAM



TYPICAL APPLICATION

Type K 10mV/°C Thermometer



Quindi, la tipica strategia di compensazione prevede la misurazione della temperatura della giunzione fredda, tipicamente per mezzo di circuiti integrati (IC) dedicati che fanno uso di un diverso tipo di sensore di temperatura. I circuiti integrati commerciali di compensazione per termocoppie presentano molteplici opzioni per consentire direttamente l'utilizzo di molti tipi di termocoppie standard (come E, J, K, R e così via). Sopra viene riportato un estratto dalla scheda tecnica di un circuito integrato di compensazione commerciale. Presenta molti pin di uscita (pannello centrale), ciascuno dei quali fornisce l'uscita ottimale per un particolare tipo di termocoppia (E, J, K, T, R, S). L'apposita uscita deve essere collegata ad una delle due estremità del giunto freddo (indicata dal segno "-" nel pannello di destra). In questo modo, l'altra estremità libera (indicata dal segno "+" nel pannello di destra) presenta una tensione proporzionale alla temperatura assoluta della giunzione calda (rispetto a massa). Nella figura sopra, è anche incluso il diagramma di un circuito aggiuntivo per amplificare il segnale in uscita dalla termocoppia.

In generale, le termocoppie sono ampiamente utilizzate nell'industria in quanto sono molto economiche, robuste, tollerano ambienti ostili, mostrano una buona stabilità nel tempo, possono essere utilizzate in un ampio intervallo di temperature e consentono un'ampia selezione di coppie metalliche (e quindi dei valori di sensibilità). D'altra parte, non sono così precise (difficile ottenere errori sistematici inferiori a 1 K) e tipicamente mostrano una bassa tensione di uscita (che è rumorosa e deve essere fortemente amplificata). Inoltre, la loro risposta non è lineare e può essere descritta da un'espressione polinomiale (i coefficienti polinomiali sono tipicamente disponibili nelle tabelle). Trovano applicazioni nei forni a induzione e in tutti quegli scenari in cui l'ambiente è troppo ostile per utilizzare altri sensori o in cui il budget è molto limitato.

4.2.2. Termoresistenze (RTD)

Le termoresistenze (RTD) sono sensori che sfruttano la dipendenza dalla temperatura della resistività nei metalli per convertire convenientemente la variazione di temperatura in variazione di resistenza elettrica. Pertanto, gli RTD sono, a tutti gli effetti, resistori. Qui ricordiamo che la resistenza di un resistore metallico è data dalla seguente equazione, dove t e S sono lo spessore e l'area dello strato metallico, mentre ρ è la resistività e dipende dalla temperatura. In particolare, ρ_0 è il valore di resistività alla temperatura T_0 e α è il coefficiente di temperatura della resistività.

$$\rho = \rho_0(1 + \alpha \cdot (T - T_0)) \quad R = \rho \cdot \frac{l}{S}$$

Gli RTD tipici sono realizzati in platino, rame o nichel. In generale, gli RTD sono molto stabili nel tempo, mostrano un'eccellente precisione e accuratezza in un ampio intervallo di temperature e mostrano una linearità sufficiente. Tuttavia, sono piuttosto costosi e risentono dell'autoriscaldamento, che potrebbe essere molto dannoso per un sensore di temperatura. Infatti, per misurare la resistività del materiale (stimando quindi la temperatura) dobbiamo misurare la resistenza del dispositivo. Questo viene in genere fatto facendo fluire una corrente attraverso il dispositivo e misurando la tensione ai suoi terminali, o viceversa (forzando una tensione e misurando la corrente che scorre). Ciò implica che una parte dell'energia elettrica verrà dissipata sul dispositivo sotto forma di calore, causando un aumento della temperatura locale. Se

l'autoriscaldamento dovuto alla dissipazione di potenza è eccessivamente elevato, l'aumento di temperatura potrebbe essere tale da alterare sensibilmente la temperatura ambiente (ovvero la grandezza da misurare). Inoltre, gli RTD sono lenti (la resistività del metallo difficilmente può seguire rapide variazioni di temperatura) poiché i materiali tipici utilizzati negli RTD hanno una grande inerzia termica. Infine, il rilevamento preciso della temperatura (e anche la misurazione delle basse temperature) richiede una configurazione del resistore a 4 contatti (il resistore a 4 contatti verrà studiato più dettagliatamente in seguito).

Il sensore RTD più utilizzato si chiama "Pt100", poiché è realizzato in platino e mostra una resistenza elettrica di 100 Ω a 0 $^{\circ}\text{C}$. È molto preciso e molto stabile nel tempo in un intervallo di temperatura da 0 $^{\circ}\text{C}$ a 500 $^{\circ}\text{C}$ e può essere utilizzato in alcuni ambienti difficili poiché non viene attaccato dalla maggior parte degli agenti chimici. Inoltre, può resistere a temperature elevate poiché il punto di fusione di Pt è molto elevato (≈ 1768 $^{\circ}\text{C}$). Presenta una buona linearità, con un coefficiente di temperatura della resistività $\alpha = 3.54$ $^{\circ}\text{C}^{-1}$ che rimane piuttosto costante nell'intervallo di temperatura da 250 $^{\circ}\text{C}$ a 350 $^{\circ}\text{C}$. Infine, Pt100 ha una lunga durata nominale. Un sensore simile è il "Pt1000", sempre in platino ma con una resistenza nominale a 0 $^{\circ}\text{C}$ di 1 k Ω .

4.2.3. Termistori

I termistori sono concettualmente simili agli RTD ma sono basati su semiconduttori, piuttosto che su metalli. In particolare, sfruttano la dipendenza dalla temperatura della conducibilità dei semiconduttori per convertire la variazione di temperatura in variazione di resistenza elettrica. Sono meno precisi degli RTD ma molto sensibili ed economici (al contrario degli RTD). Il loro essere economici è dovuto al fatto che i semiconduttori sono più economici dei metalli – il silicio è il materiale più abbondante sulla crosta terrestre mentre i metalli sono relativamente rari da trovare. Tuttavia, soffrono di una non linearità molto forte e richiedono un'elettronica complessa per compensare questo aspetto. Inoltre, a seconda della tecnologia e del package del dispositivo possono presentare una certa fragilità meccanica. I termistori trovano applicazioni tipiche negli impianti di riscaldamento, nell'elettronica industriale e di consumo e nei sistemi di telecomunicazione. A differenza degli RTD, il termistore può mostrare una dipendenza dalla temperatura sia positiva che negativa: in altre parole, la resistenza del dispositivo può aumentare o diminuire all'aumentare della temperatura. Possono quindi essere classificati in due categorie: PTC (coefficiente di temperatura positivo) e NTC (coefficiente di temperatura negativo).

4.2.3.1. PTC

I termistori PTC sono tipicamente basati su Si (silicio) e mostrano una dipendenza quasi quadratica della resistenza dalla temperatura.

$$R \cong R_0 [1 + \alpha \cdot \Delta T + \beta \cdot (\Delta T)^2] \quad \Delta T = T - T_0 \quad R_0 = R(T_0)$$

con R_0 il valore di R misurato a $T = T_0$. Data la sua dipendenza quadratica dalla temperatura, un PTC è più sensibile alle alte temperature che alle basse temperature. Date queste caratteristiche, è tipicamente utilizzato nei sistemi che devono rilevare se la temperatura aumenta oltre una soglia per attivare la protezione da surriscaldamento e sovraccarichi. Proprio come gli RTD, soffre di autoriscaldamento.

4.2.3.2. NTC

I termistori NTC, invece, sono tipicamente basati su ossidi metallici e mostrano una risposta fortemente non lineare (esponenziale).

$$R \cong R_0 e^{\beta(\frac{1}{T} - \frac{1}{T_0})}$$

Data la dipendenza esponenziale della resistenza dalla temperatura, i dispositivi NTC sono molto più sensibili alle basse temperature che alle alte temperature e sono tipicamente impiegati per misure a temperature relativamente basse. Come la loro controparte (cioè i PTC), gli NTC soffrono di autoriscaldamento.

4.2.4. Sensori Integrati

RTD e termistori sfruttano la dipendenza dalla temperatura di una precisa quantità fisica (cioè la resistività o la conducibilità) rispettivamente di materiali metallici e semiconduttori. Altri tipi di sensori sfruttano la variazione di temperatura di una determinata grandezza elettrica (corrente o tensione) all'interno di un circuito elettrico integrato basato sui semiconduttori (ad esempio la caduta di tensione su un diodo). Tali sensori sono chiamati sensori integrati e sono molto frequentemente impiegati nelle soluzioni commerciali poiché sono affidabili e precisi. Inoltre, possono anche integrare l'elettronica necessaria per la post-elaborazione dei dati e quindi possono essere dotati di un condizionamento del segnale a bordo. Possono essere molto piccoli poiché tutta l'elettronica è fabbricata simultaneamente in un singolo chip miniaturizzato. Anche grazie a questa caratteristica tendono ad essere molto lineari (sebbene tipicamente in un range ristretto, a meno che l'elettronica di bordo non fornisca correzioni di non linearità) ed economici. Trovano applicazioni tipiche nei sistemi di fascia alta che richiedono la compensazione della temperatura. Tipicamente, vengono utilizzati in frigoriferi, dispositivi consumer di fascia elevata, prodotti di consumo, e anche per la compensazione della temperatura delle giunzioni fredde delle termocoppie. Possono avere uscite sia in corrente che in tensione. La differenza principale con i termistori (anch'essi basati su semiconduttori) è che questi ultimi sfruttano le proprietà del materiale mentre i sensori integrati le proprietà del circuito elettronico che li compone.

4.2.5. Pirometri

Mentre tutti gli altri sensori di temperatura che abbiamo visto necessitano del contatto per rilevare correttamente la temperatura (poiché funzionano grazie alla convezione o alla conduzione), un pirometro può funzionare in modalità contactless poiché sfrutta il trasporto del calore tramite radiazione. In altre parole, è sensibile all'energia dell'onda elettromagnetica che colpisce il sensore e che è stata irradiata da un oggetto, la cui temperatura è ciò che vogliamo misurare. Questo fenomeno è governato dall'equazione di Stefan-Boltzmann che lega l'energia della radiazione emessa da un oggetto alla quarta potenza della sua temperatura:

$$E = \sigma T^4$$

Ciò significa che il pirometro è un sensore di temperatura fortemente non lineare, in quanto l'energia della radiazione rilevata sarà proporzionale a T^4 . Tuttavia, è molto stabile nel tempo, in genere può resistere a temperature elevate e funziona correttamente in un intervallo di temperatura esteso. La sua forte non linearità lo rende anche molto più sensibile alle alte temperature. Raramente viene impiegato in soluzioni commerciali poiché in genere è piuttosto costoso. Inoltre, le misurazioni possono essere alterate dall'eventuale assorbimento e riemissione a diverse frequenze della radiazione in ingresso da parte delle particelle nel mezzo di propagazione. A volte questa caratteristica può essere sfruttata intenzionalmente. Infatti, se c'è un oggetto (ad esempio un gas) che vogliamo caratterizzare tra una sorgente di radiazione nota e il sensore, potremmo confrontare la risposta del sensore con lo spettro elettromagnetico emesso della sorgente di radiazione per capire come l'oggetto ha interagito con la radiazione.

4.3. Sensori di Forza

I sensori di forza sono trasduttori utilizzati per misurare le forze applicate a un elemento generico. I due strumenti più adatti per farlo sono:

- Estensimetri (strain gauge)
- Sensori piezoelettrici

4.3.1. Estensimetri (strain gauge)

I sensori estensimetrici misurano la forza applicata a un oggetto rilevando la corrispondente deformazione locale della superficie. Il concetto alla base dei sensori estensimetrici è che la resistenza di un pezzo di metallo cambia in seguito alla deformazione. Pertanto, se un pezzo di metallo viene incollato su un oggetto che subisce una deformazione, potremmo percepire la quantità di deformazione e stimare la forza che lo ha causato semplicemente misurando la sua resistenza. Infatti, sotto l'ipotesi di deformazione elastica si può mettere in relazione la deformazione relativa di un corpo, $\Delta l/l$, con la tensione, T , e la forza, F , che causano la deformazione.

$$T = \text{tensione} \quad , \quad E = \text{Modulo di Young} \quad \rightarrow \quad T = \frac{F}{A} = E \cdot \frac{\Delta l}{l}$$

dove E è il modulo di Young (modulo di elasticità), F è la forza esercitata su un oggetto in tensione, A è l'area della sezione trasversale effettiva, che è uguale all'area della sezione perpendicolare alla forza applicata, Δl è la variazione della lunghezza dell'oggetto (Δl è positivo se il materiale è allungato e negativo quando il materiale è compresso), l è la lunghezza originale dell'oggetto. Pertanto, in regime elastico, possiamo stimare la forza misurando la relativa deformazione e conoscendo il modulo di Young e la sezione trasversale del corpo.

I sensori estensimetrici possono misurare la deformazione relativa sfruttando la dipendenza della resistenza di un pezzo di metallo dalla sua geometria. Infatti, la resistenza di un metallo è proporzionale alla sua resistività, ρ , (che dipende principalmente dalla tipologia del materiale e dalla temperatura), alla sua lunghezza, l , e alla sua sezione trasversale, S . Questa relazione è nota come seconda Legge di Ohm (vedi equazione sotto). Differenziandola, otteniamo che la variazione relativa di resistenza dipende dalla variazione relativa di resistività, dalla variazione relativa di lunghezza e dalla variazione relativa di sezione.

$$R = \rho \cdot \frac{l}{S} \quad \rightarrow \quad \frac{dR}{R} = \frac{d\rho}{\rho} + \frac{dl}{l} - \frac{dS}{S} \quad \text{dove} \quad \frac{d\rho}{\rho} = \text{piezoresistività}$$

Questa equazione è la chiave per comprendere il principio di funzionamento dei sensori estensimetrici. Nello specifico, se si applica una forza ad un oggetto, la deformazione risultante sarà presente anche sull'estensimetro (cioè un pezzo di metallo incollato sull'oggetto). In linea di principio la deformazione può cambiare la sua resistività, la sua lunghezza e la sua sezione trasversale. Tuttavia, solo una particolare classe di materiali cambia la propria resistività per deformazione e sono chiamati piezoresistivi. Pertanto, in questi materiali una deformazione diversa da zero risulterà in un $d\rho/\rho$ diverso da zero. Nella loro implementazione più semplice, i sensori estensimetrici sono realizzati con materiali non piezoresistivi (sebbene alcuni siano realizzati con materiali piezoresistivi), in modo tale che anche in caso di deformazione il risultante $d\rho/\rho$ sia sempre zero. Pertanto, l'equazione può essere semplificata:

$$\frac{dR}{R} = \frac{dl}{l} - \frac{dS}{S}$$

Questo dispositivo è fondamentalmente un resistore e per avere la sua resistenza nominale (R - la resistenza quando non viene applicata alcuna forza) abbastanza grande, il resistore deve essere molto lungo e con una piccola sezione trasversale. Come vedremo, una resistenza nominale elevata migliora la sensibilità del sensore. Per mantenerlo compatto, il resistore è piegato a forma di serpentina (vedi figura successiva). Con riferimento alla figura seguente, se l'oggetto subisce una sollecitazione (e deformazione) uniassiale in direzione orizzontale, la lunghezza dei segmenti cambia, ma la loro sezione trasversale no, ovvero nell'equazione precedente l'unico fattore diverso da zero sarà dl/l . Pertanto, supponendo una deformazione uniassiale (per semplicità) e che l'estensimetro sia posizionato sull'oggetto lungo l'asse di deformazione, l'equazione può essere ulteriormente semplificata in:

$$\frac{dR}{R} = \frac{dl}{l} \quad \text{che può essere scritto come} \quad \frac{dR/R}{dl/l} = 1$$


il che significa che misurare la variazione relativa di resistenza fornisce direttamente la deformazione relativa. Tuttavia, in uno scenario reale, una sollecitazione uniassiale non produce quasi mai una deformazione puramente uniassiale e l'equazione di cui sopra non è adatta a descrivere correttamente la relazione tra la deformazione e la relativa variazione di resistenza. Infatti, anche applicando una sollecitazione perfettamente uniassiale, la deformazione risultante non sarà perfettamente uniassiale a causa del cosiddetto effetto Poisson, che descrive l'espansione di un materiale in direzioni perpendicolari alla direzione di compressione. Ciò significa che non possiamo davvero trascurare il termine dS/S . Inoltre, alcuni materiali utilizzati nei moderni estensimetri sono in realtà piezoresistivi, per cui anche il termine dp/p non può essere trascurato. Per considerare tutti questi effetti in una formulazione compatta, possiamo modificare la formula precedente (per piccole deformazioni) assumendo che il rapporto tra la variazione di resistenza relativa e la deformazione non sia unitario, ma sia uguale ad una costante, G , chiamata Gauge Factor, che dipende dalle proprietà del materiale (il suo rapporto di Poisson – tecnicamente il rapporto negativo tra la deformazione trasversale e quella assiale – e la sua possibile piezoresistività):

$$\frac{dR/R}{dl/l} = G \quad \frac{R - R_0}{R_0} = G \frac{l - l_0}{l_0} = G\varepsilon \quad R = R_0(1 + G\varepsilon)$$

dove ε è la deformazione relativa (dl/l), R è la resistenza misurata quando viene applicata la sollecitazione, R_0 la resistenza nominale, l la lunghezza dell'estensimetro quando viene applicata la sollecitazione, l_0 la lunghezza nominale dell'estensimetro. Il fattore di gauge è di circa 2 per la maggior parte dei metalli, 6 per il platino e può assumere valori molto maggiori per altri materiali (fino a poche centinaia). Tipicamente, la deformazione relativa che misuriamo (e che è una quantità adimensionale) è molto piccola, quindi introduciamo un'unità di misura adatta: la microdeformazione, indicata dal simbolo $\mu\varepsilon$.


$$\text{microdeformazione} = \mu\varepsilon = 10^{-6}$$

La deformazione massima che può essere correttamente rilevata dagli estensimetri è di circa 40k $\mu\varepsilon$. Il sensore estensimetrico appare tipicamente come nella figura seguente ed è incollato sull'oggetto di cui si vuole misurare la deformazione. I componenti importanti sono evidenziati. Le linguette a saldare sono i due terminali della resistenza (che servono per interfacciare il sensore con un circuito di misura). La loro dimensione è molto più grande dell'estensimetro per ridurre al minimo il loro contributo alla resistenza complessiva. Sono presenti alcuni segni di allineamento, che consentono il posizionamento preciso dell'estensimetro sull'oggetto. La griglia attiva è l'elemento sensibile effettivo. L'intero sensore viene incapsulato e posizionato su un supporto (chiamato backing, che viene poi effettivamente incollato sull'oggetto).



Il problema principale con l'estensimetro è la dipendenza della resistività dalla temperatura. Infatti, se la temperatura cambia, cambia anche la resistenza (a causa di una variazione della resistività) e potremmo non essere in grado di dire se la variazione della resistenza misurata è dovuta alla sollecitazione applicata o alla temperatura. Per mitigare questo problema, possiamo proporre alcune strategie:

- Realizzare la griglia attiva utilizzando materiali (tipicamente alcune leghe) con un coefficiente di temperatura di resistività basso, per ridurre al minimo la variazione di resistività con la temperatura;
- Compensare gli effetti della temperatura utilizzando un misuratore fittizio. Se la deformazione è perfettamente uniassiale, possiamo posizionare un estensimetro nella direzione della deformazione uniassiale e un altro estensimetro (chiamato dummy gauge) in direzione ortogonale, come nella figura seguente. Mentre il primo estensimetro cambierà la sua resistenza in risposta sia allo stress che alle variazioni di temperatura, il secondo risponderà solo alle variazioni di temperatura. Pertanto, sottraendo le due variazioni di resistenza, possiamo compensare gli effetti della temperatura.



Un altro importante effetto che può derivare dagli effetti della temperatura è il possibile stress parassitario indotto dalla dilatazione termica. Se la temperatura cambia, cambia anche il volume dell'oggetto, subendo espansione o contrazione (a seconda che la temperatura aumenti o diminuisca). Per lo stesso motivo cambia anche il volume dell'estensimetro. Tuttavia, se l'oggetto e l'estensimetro hanno coefficienti di espansione termica diversi, le variazioni di volume relative dell'oggetto e dell'estensimetro non saranno le stesse. Ciò creerà uno stress superficiale parassita che causerà una deformazione parassita che verrà misurata dall'estensimetro. Per mitigare questo problema, possiamo utilizzare un supporto con lo stesso coefficiente di dilatazione termica dell'oggetto. Va sottolineato che questo problema non è correlato alla variazione della resistività dell'estensimetro con la temperatura, sebbene sia correlato alla temperatura.

Gli estensimetri possono essere utilizzati in ambienti estremi, con variazioni di temperatura selvagge da -269 °C a 1300 °C, in zone di irraggiamento, e anche in presenza di forti vibrazioni. La resistenza viene generalmente misurata utilizzando specifici circuiti di misurazione della resistenza.

Applicazioni tipiche:

- Celle di carico, monitoraggio strutture (ponti, edifici);
- Trasduttori di forza, coppia, pressione, accelerazione.

4.3.2. Sensori Piezoelettrici

Un'altra classe di sensori di forza è quella dei sensori piezoelettrici. Questi sensori sono basati su materiali piezoelettrici, che rispondono alle sollecitazioni meccaniche generando una tensione. Questa proprietà non deve essere confusa con la piezoresistività: all'applicazione di una sollecitazione meccanica, quest'ultima determina una variazione della resistività, mentre la prima determina la generazione di una tensione. Pertanto, un materiale piezoelettrico converte l'energia meccanica in energia elettrica. I sensori piezoelettrici funzionano in modo simile agli estensimetri (in quanto misurano le deformazioni) ma la quantità elettrica in uscita è una tensione, non un valore di resistenza. Sono in genere molto sensibili, con una gamma dinamica compresa tra pochi Hz e diverse decine di kHz, che li rendono adatti per applicazioni a ultrasuoni. Inoltre, l'effetto piezoelettrico è reversibile: non solo viene prodotta una tensione se viene applicata una certa sollecitazione meccanica, ma è anche vero che se viene applicata una certa tensione, il materiale si deformerà. Pertanto, funziona sia come sensore (cioè, se applichiamo una certa sollecitazione possiamo misurarla misurando la tensione generata) che come attuatore (cioè, se applichiamo una tensione possiamo indurre una deformazione traducendo l'energia elettrica in energia meccanica).

Solitamente sono sfruttati per realizzare sensori di pressione, sensori di vibrazione, microfoni e altoparlanti, sonar, sensori di livello e prossimità.

4.4. Sensori di Coppia


Sono trasduttori in grado di misurare la coppia (es. torsione di un albero). Possono essere realizzati sfruttando molti principi:

- Estensimetri;
- Accoppiamenti magnetici e/o induttivi;
- Accoppiamenti ottici.



4.4.1. Sensori di Coppia con Estensimetri

Per misurare la coppia su un albero rotante è possibile sfruttare sensori estensimetrici posizionati sull'albero. Un arrangement tipico consiste nel posizionare due estensimetri sull'albero lungo direzioni specifiche (a 45° rispetto all'asse dell'albero e perpendicolari tra loro), come nella figura seguente. Infatti, se viene applicata una certa coppia, l'albero subirà una deformazione di compressione lungo una direzione specifica (freccie arancioni) e una deformazione di trazione lungo un'altra direzione specifica (freccie nere).




Questo è sufficiente per calcolare la coppia applicata all'albero. Tuttavia, il sistema estensimetrico necessita di alcuni circuiti elettronici per eseguire misurazioni della resistenza e calcoli successivi. Ciò significa che alcuni fili devono collegare gli estensimetri al circuito (ad esempio una centralina elettronica). Tuttavia, i fili collegati a un meccanismo rotante probabilmente si aggroviglieranno mentre il meccanismo ruota. Una possibile soluzione sarebbe quella di integrare il circuito vicino agli estensimetri, sull'albero. Tuttavia, un tale circuito richiederebbe alimentazione (che, ancora una volta, viene generalmente fornita utilizzando cavi). Pertanto, come possiamo fornire energia e recuperare il segnale da un sensore posizionato su un meccanismo rotante senza utilizzare fili?

- Il sistema potrebbe essere alimentato a batterie. Lo svantaggio è che le batterie dovranno essere sostituite periodicamente, causando lo spegnimento periodico del sistema per manutenzione.
- Anche i circuiti di energy harvesting, in grado di recuperare energia dall'ambiente (ad esempio energia termica o elettromagnetica) e trasformarla in energia elettrica, sono una soluzione. Non necessitano di sostituzioni periodiche, ma non è banale garantire la continuità energetica nel tempo.
- Comunicazione wireless (es. Radiofrequenza, Wi-Fi, infrarossi). Un circuito locale (a batteria o alimentato da un circuito di harvesting) può misurare l'uscita dei sensori e trasmettere l'informazione utilizzando un protocollo wireless (per evitare l'uso di cavi) a un'unità di controllo remoto.

4.4.2. Sensori di Coppia Ottici

Un'altra possibilità è quella di utilizzare sensori ottici. Sono composti da due dischi, chiamati unità di trasmissione della luce e unità di ricezione della luce. L'unità di trasmissione della luce è collegata meccanicamente all'albero rotante e dispone di una serie di LED disposti in cerchio. L'unità di ricezione della luce è collegata meccanicamente a un pezzo del sistema che non ruota insieme all'albero e presenta una serie di fotodiodi disposti in cerchio. Misurando la risposta dei fotodiodi è possibile ottenere la velocità di rotazione e, indirettamente, la coppia. Qui la segnalazione (cioè la trasmissione di informazioni) è ottica (i LED possono essere scelti per emettere luce visibile o luce UV/infrarossa, a seconda delle applicazioni). Ovviamente entrambe le unità necessitano di un'alimentazione locale (l'unità di trasmissione della luce ne ha bisogno per alimentare i LED, l'unità di ricezione della luce ne ha bisogno per leggere il segnale dai fotodiodi e trasmettere le informazioni in modalità wireless all'unità di controllo remoto). I sensori di coppia ottici sono tuttavia delicati e costosi.



4.5. Sensori di Posizione


I sensori di posizione vengono utilizzati per misurare la posizione degli oggetti, che può essere una posizione lineare (cioè la posizione di un oggetto in movimento lineare) o una posizione angolare (l'angolo tra un oggetto rotante e un asse di riferimento). Qui viene presentato un elenco non esaustivo di sensori di posizione angolari e lineari.

Sensori di Posizione Angolare	Sensori di Posizione Lineare
Potenzimetri rotazionali	Potenzimetri lineari
Encoder	Encoder
Resolver	Magnetoresistivi
Rotazionali Induttivi (RVDT)	Lineari Induttivi (LVDT)
Rotazionali Capacitivi (RCDT)	Lineari Capacitivi (LCDT)

Di seguito parleremo di alcuni di questi sensori.


4.5.1. Potenzimetri

I potenzimetri sono trasduttori di posizione analogici, il che significa che la quantità di uscita è analogica. Possono essere lineari o rotazionali. Un potenziometro è fondamentalmente un resistore a tre terminali con un elemento scorrevole (se lineare) o rotante (se angolare) dotato di un contatto elettrico, che forma un partitore di tensione regolabile. È costituito da un binario conduttivo (cioè resistivo) dotato di due contatti elettrici (li chiameremo contatti di ingresso). Tipicamente, questi due contatti vengono utilizzati per fornire la tensione o la corrente di ingresso al dispositivo e la resistenza vista da questi due contatti è fissa. Il terzo contatto (che chiameremo contatto di uscita) è collegato all'elemento scorrevole (o rotante) tramite un cursore che scorre (o ruota) seguendo la posizione dell'oggetto da monitorare. Se questo contatto viene utilizzato insieme a uno solo degli altri due terminali, esso funge da resistore variabile.



Il materiale che compone la pista conduttiva è costruito per essere il più uniforme possibile, quindi la sua resistenza per unità di lunghezza (R/l_0 dove R è la resistenza totale della pista conduttiva e l_0 la sua lunghezza totale) è la stessa lungo tutta la pista. Se viene applicata una tensione ai due terminali di ingresso, una certa corrente scorrerà nel potenziometro. Se misuriamo la tensione tra il contatto di uscita e uno dei due terminali di ingresso utilizzando un voltmetro, misureremo una tensione che è una frazione della tensione di ingresso. In particolare, il rapporto tra la tensione misurata (V_{out}) e la tensione di ingresso (E) è uguale alla posizione relativa del cursore lungo la pista conduttiva ($\alpha = x/l_0$ dove x è la posizione del cursore lungo la pista conduttiva): ad esempio, se il rapporto è $\frac{1}{2}$, il cursore si trova al centro della pista conduttiva. Più in generale, avremo $\frac{V_{out}}{E} = \alpha$. Pertanto, il sensore mostra una risposta molto lineare. Tuttavia, uno dei principali problemi mostrati dal potenziometro è la sua risposta non lineare quando vengono presi in considerazione gli effetti non ideali. Infatti, nell'analisi precedente abbiamo intrinsecamente ipotizzato che tutta la corrente iniettata da un terminale di ingresso fluisca attraverso la pista conduttiva (la cui resistenza totale è R) fino all'altro terminale di ingresso, senza che la corrente venga deviata attraverso il terminale di uscita (dove è posizionato

il voltmetro). In altre parole, supponevamo un voltmetro ideale caratterizzato da un'impedenza di ingresso infinita.



Nel mondo reale, il voltmetro (o il circuito che legge la tensione) assorbirà una certa corrente e la sua impedenza di ingresso non può essere considerata infinita. Pertanto, la presenza del voltmetro deve essere considerata aggiungendo una resistenza extra nel circuito (R_{out}), che è la rappresentazione equivalente del voltmetro. In questo modo rappresentiamo il vero voltmetro all'interno del circuito. Rivalutando la tensione di uscita, otteniamo:

$$\frac{V_{out}}{E} = \alpha \cdot \frac{R_{out}/R}{-\alpha^2 + \alpha + R_{out}/R}$$

Il termine che moltiplica α è un fattore di correzione che considera l'effetto dell'impedenza di ingresso finita del voltmetro. Infatti, se R_{out} è infinita, il fattore corretto è unitario e viene ripristinata la perfetta linearità (tra x/l_0 e V_{out}/E). In caso contrario, la deviazione dalla linearità sarà visibile, soprattutto per R_{out} piccoli (quando diventa paragonabile a R) e per grandi valori di α .




I potenziometri sono comunemente usati per controllare dispositivi elettrici come i controlli del volume sulle apparecchiature audio. I potenziometri azionati da un meccanismo possono essere utilizzati come trasduttori di posizione, ad esempio in un joystick. I potenziometri sono usati raramente per controllare direttamente potenze significative (più di un watt), poiché la potenza dissipata nel potenziometro sarebbe paragonabile alla potenza nel carico controllato. Poiché utilizzano contatti scorrevoli, tendono a soffrire di problemi di affidabilità (i contatti scorrevoli tendono ad usurarsi) e di bassa precisione. D'altra parte sono molto economici e non risentono gravemente degli effetti della temperatura, poiché (almeno per carichi ad alta impedenza) il rapporto tra la tensione di uscita e la posizione non dipende dal valore della resistenza di pista conduttiva (che cambia con la temperatura). Sono tipicamente impiegati nel rilevamento della posizione grossolana (non precisa) a bassa potenza (ad esempio, la manopola analogica che regola la temperatura dell'aria nella maggior parte dei veicoli).

4.5.2. Encoder

L'encoder è un sensore di posizione che, a differenza del potenziometro, ha un'uscita digitale. Gli encoder possono essere lineari o rotazionali. È costituito da un disco (se rotativo) o da una striscia (se lineare) di materiale opaco con una serie di fori (il numero, la forma e la posizione dei fori dipende dalla tipologia di encoder e sarà discusso di seguito). Il disco/striscia è collegato all'oggetto che si muove. Ai due lati del disco/striscia (quindi davanti e dietro ad esso) sono posti rispettivamente un LED e un fotodiodo (o più LED e fotodiodi, a seconda della tipologia di encoder). Il disco/striscia si muove quindi mentre le altre parti (LED e fotodiodo) sono ferme. Nella trattazione seguente ci riferiremo all'encoder angolare (quindi verrà utilizzata la parola disco) ma tutti i concetti valgono anche per l'encoder lineare (in cui il disco viene sostituito da una striscia). Gli encoder sono divisi in due categorie: incrementali e assoluti. Differiscono in molti aspetti e presentano vantaggi e svantaggi distinti; pertanto, saranno discussi separatamente.


Encoder Incrementale

Nell'encoder incrementale il disco opaco mostra una serie di fori identici, equidistanti e disposti ad anello. Il principio di funzionamento si basa sul fatto che il LED dietro il disco emette sempre luce, mentre il fotodiodo non sempre riceverà luce. Mentre il disco ruota, il fotodiodo riceverà luce solo quando il disco è in una posizione tale che uno dei fori sia in linea con il LED e il fotodiodo. Il segnale generato dal fotodiodo è intrinsecamente digitale (il fotodiodo riceve piena luce oppure buio completo), poiché l'intensità luminosa del LED viene sempre mantenuta invariata. Mentre il disco ruota, il fotodiodo emetterà un impulso ogni volta che viene colpito dalla luce. Contando semplicemente quanti impulsi genera il fotodiodo, è possibile capire l'angolo di rotazione. In particolare, ad ogni impulso generato dal fotodiodo corrisponde una rotazione di $r=360^\circ/n$, dove n è il numero totale di fori. Ovviamente r è anche la risoluzione del sensore (ovvero la rotazione minima rilevabile dal sensore). L'encoder incrementale è denominato in questo modo perché non può risolvere la posizione angolare assoluta dell'oggetto ma può solo determinare la rotazione incrementale (rispetto alla posizione angolare precedente). Per il suo principio di funzionamento, l'encoder incrementale necessita di un contatore (un circuito elettronico in grado di contare quanti impulsi vengono generati dal fotodiodo) e di uno starter (sostanzialmente un marker sul disco) che definisca la posizione di partenza del sensore (per definizione la posizione di zero gradi), unitamente ad un sistema meccanico che ripristini la posizione dopo ogni rotazione. Inoltre, in questa semplice disposizione l'encoder incrementale non è in grado di distinguere il senso di rotazione (orario o antiorario) poiché entrambi i tipi di rotazione daranno la stessa uscita. Tuttavia, questo problema può essere costantemente risolto con piccole modifiche al sensore. Per fare ciò, invece di una coppia vengono utilizzati due LED e due fotodiodi. I due fotodiodi sono posti ai due bordi opposti di una fascia trasparente (foro – vedi figura seguente). Naturalmente i LED sono posizionati in modo tale che ogni LED emetta luce nella direzione di un fotodiodo. In questo modo, a seconda del senso di rotazione, la luce verrà rilevata prima su un fotodiodo e poi sull'altro. Nell'esempio seguente, se il disco si sposta verso destra (in senso orario), il canale A vedrà prima la luce e il canale B seguirà con un ritardo. Se invece il disco si muove in senso antiorario (verso sinistra), il canale B anticiperà il canale A. In questo modo è quindi possibile discriminare anche il senso di rotazione. A volte, per i due canali vengono utilizzate due serie indipendenti di fori.



Encoder Assoluto

L'encoder assoluto è simile alla sua controparte incrementale, ma mostra alcune differenze e vantaggi. L'encoder assoluto condivide lo stesso principio di funzionamento dell'encoder incrementale (cioè il disco opaco presenta una serie di fori attraverso i quali può passare la luce proveniente da un LED e colpire un fotodiodo). Tuttavia, il numero, la forma e la posizione di ciascun foro sono completamente diversi rispetto all'encoder incrementale. Nello specifico, i fori non sono identici tra loro e non sono posti lungo un unico anello. Infatti, i fori sono disposti lungo molti anelli concentrici (il numero degli anelli è k). L'anello più interno ha un solo foro, che occupa metà dell'area dell'anello. Pertanto, metà dell'anello più interno è opaca e l'altra metà è trasparente. Il secondo anello più interno ha due fori, ciascuno dei quali occupa un quarto dell'area dell'anello. Pertanto, anche in questo caso metà dell'anello è opaca e l'altra metà è trasparente, sebbene siano presenti due sezioni opache e due trasparenti. In generale, l' i -esimo anello più interno ha 2^{i-1} fori. Naturalmente, spostandosi dall'anello più interno verso l'anello più esterno, la dimensione dei fori in un dato anello diminuisce e il loro numero aumenta (ogni anello ha più fori ma più piccoli, rispetto agli anelli interni). Inoltre, se sono presenti k anelli, ci saranno anche k LED e k fotodiodi, con ciascuna coppia allineata con ciascun anello. Posizionando correttamente i fori, ogni posizione angolare sarà associata ad una combinazione unica di fotodiodi in uscita. In questo modo è possibile leggere l'uscita dei fotodiodi e determinare immediatamente la posizione angolare assoluta, senza utilizzare alcuno starter e/o contatore. Il numero di anelli (k) determina il numero di bit della parola digitale di uscita (k , dato che abbiamo k fotodiodi ciascuno che contribuisce con un bit) e la risoluzione dell'encoder assoluto (che è $360^\circ/2^k$).




Angle (°)	Binary	Gray	Decimal
0	0000	0000	0
22.5	0001	0001	1
45	0010	0011	2
67.5	0011	0010	3
90	0100	0110	4
112.5	0101	0111	5
135	0110	0101	6
157.5	0111	0100	7
180	1000	1100	8
202.5	1001	1101	9
225	1010	1111	10
247.5	1011	1110	11
270	1100	1010	12
292.5	1101	1011	13
315	1110	1001	14
337.5	1111	1000	15
360	0000	0000	0

In particolare, ci sono molte (e non solo una) possibili disposizioni delle posizioni dei fori che funzionano bene. Ciò consente di adottare codici specifici (es. binario, BCD, Gray, ASCII). Ad esempio, adottare un codice binario (e supponendo $k=4$ che significa una risoluzione di 22.5°) significa disporre le posizioni dei fori in modo tale che la posizione angolare 0° corrisponda al codice di uscita 0000, la posizione angolare successiva (22.5°) al codice di uscita 0001, quella ancora successiva (45°) al codice 0010 e così via. Pertanto, scegliendo il codice binario, il numero digitale in uscita aumenterà all'aumentare delle posizioni angolari. Tuttavia, possono essere adottati codici diversi, con alcuni vantaggi. Ad esempio, il codice Gray viene adottato frequentemente. Il codice Gray è un ordinamento del sistema numerico binario in modo tale che due valori successivi differiscano in un solo bit. È stato originariamente progettato per prevenire errori nella gestione degli interruttori elettromeccanici e viene adottato negli encoder per lo stesso motivo. Infatti, adottando il codice Gray, se il sistema che elabora l'uscita dei fotodiodi rileva più di un bit che cambia contemporaneamente, allora questo verrà interpretato come un guasto. Ciò non è possibile con il codice binario standard, pertanto l'utilizzo del codice Gray consente il rilevamento automatico dei guasti.

L'encoder assoluto:

- Costa di più di quello incrementale (più difficile da produrre);
- Funziona tipicamente fino a 80-100 °C. L'intervallo di temperatura non è così ampio e non è il massimo per ambienti difficili;
- Il montaggio richiede cautela (evitare errori di allineamento);
- Può anche essere magnetico. Quest'ultimo ha una maggiore durata, affidabilità e intervallo di temperatura di esercizio. Può avere un'uscita analogica. Ha alta precisione e alto costo. Un esempio di encoder magnetico è mostrato qui a destra. Un magnete permanente è montato sull'elemento rotante e un sensore magnetico rileva la direzione del campo magnetico.



4.5.3. Resolver


Il resolver è un trasduttore di posizione angolare molto comunemente impiegato basato sull'induzione magnetica. È molto robusto e affidabile, anche in ambienti difficili. Per questo motivo è spesso utilizzato nel settore automobilistico, ed è un elemento chiave nella catena cinematica dei veicoli elettrici e ibridi. Il resolver sfrutta il principio dell'induzione magnetica, che è la produzione di una forza elettromotrice (cioè, tensione) attraverso un conduttore elettrico immerso in un campo magnetico che cambia nel tempo. Immaginiamo di avere una bobina. È noto che facendo scorrere della corrente in una bobina, si genera un campo magnetico la cui intensità (a una distanza fissa dall'avvolgimento) sarà proporzionale all'entità della corrente. Pertanto, una corrente continua genera un campo magnetico costante nel tempo. Al contrario, una corrente alternata produrrà un campo magnetico che cambia nel tempo allo stesso modo della corrente alternata. Pertanto, una bobina pilotata da una corrente (o tensione) AC genererà un campo magnetico che cambia nel tempo. Grazie all'induzione magnetica, questo campo magnetico che cambia nel tempo produrrà una tensione (e una corrente) AC in un'altra bobina. La tensione alternata indotta su quest'ultima bobina (denominata bobina secondaria o avvolgimento secondario) avrà la stessa frequenza della tensione alternata utilizzata per generare il campo magnetico (applicata alla cosiddetta bobina primaria o avvolgimento primario). Inoltre, le due tensioni saranno in fase. L'entità della tensione alternata indotta sull'avvolgimento secondario dipende dall'entità della tensione alternata sull'avvolgimento primario (E_0), dall'angolo formato dai due avvolgimenti (α) e dalla distanza tra gli avvolgimenti e dalla loro composizione (questi effetti sono raggruppati in un unico parametro chiamato T , il rapporto di trasformazione, poiché le due bobine costituiscono effettivamente un trasformatore). Se la tensione AC applicata all'avvolgimento primario (e che quindi genera il campo magnetico) è

$$V_{gen}(t) = E_0 \sin(\omega t + \varphi)$$

allora la tensione indotta sul secondario sarà:

$$V_{ind}(t) = E_0 T \cos(\alpha) \sin(\omega t + \varphi)$$

Pertanto, l'ampiezza della tensione AC indotta sull'avvolgimento secondario codifica le informazioni sul coseno dell'angolo tra l'avvolgimento primario e quello secondario. Questo principio è alla base del resolver.



Il resolver è composto da due parti: il rotore (che ruota insieme all'oggetto rotante che si vuole monitorare) con un avvolgimento (eccitato da una tensione alternata) che genera il campo magnetico alternato; e lo statore (che sta fermo) con due avvolgimenti ortogonali sui quali verrà indotta una certa tensione alternata a causa dell'induzione elettromagnetica e da cui vengono lette due forme d'onda di tensione in uscita. Il circuito che genera la tensione AC che stimola l'avvolgimento del rotore è tipicamente a bordo del rotore per evitare che i fili si attorciglino. In riferimento alla figura sopra, se l'avvolgimento del rotore è eccitato con una tensione AC

$$V_{ex}(t) = E_0 \sin(\omega t)$$

poiché l'angolo tra l'avvolgimento del rotore e l'avvolgimento dello statore S2 è θ , la tensione indotta nell'avvolgimento dello statore S2 sarà


$$V_{S2}(t) = E_0 T \cos(\theta) \sin(\omega t)$$

dove l'angolo θ è mostrato nella figura sopra e rappresenta la posizione angolare del rotore. Invece, poiché l'angolo tra l'avvolgimento del rotore e l'avvolgimento dello statore S1 è 90° inferiore a θ , la tensione indotta nell'avvolgimento dello statore S1 sarà

$$V_{S1}(t) = E_0 T \cos\left(\theta - \frac{\pi}{2}\right) \sin(\omega t) = E_0 T \sin(\theta) \sin(\omega t)$$

Pertanto, le due tensioni di uscita codificheranno le informazioni sul coseno e sul seno dell'angolo tra l'avvolgimento primario e quello secondario S2. Infatti, il segnale in S2 è tipicamente chiamato "il segnale del coseno" e il segnale in S1 "il segnale del seno". Nella figura seguente, ci sono alcuni esempi di tipiche forme d'onda di uscita (sin e cos, nella figura) rispetto alla forma d'onda che pilota l'avvolgimento di rotore (ref nella figura) in diverse posizioni angolari.

Quando $\theta = 0^\circ$, R è allineato con S2 e perpendicolare a S1: il segnale coseno è piatto e il segnale seno ha ampiezza massima (sempre inferiore al segnale ref, poiché T è sempre minore di 1). Quando $\theta = 90^\circ$, il segnale seno è piatto e il segnale coseno ha ampiezza massima. Quando $\theta = 45^\circ$, entrambi i segnali hanno la stessa ampiezza (inferiore al massimo) e in fase tra loro. Infine, quando $\theta = 135^\circ$, entrambi i segnali hanno la stessa ampiezza proprio come quando $\theta = 45^\circ$ ma i due segnali saranno in opposizione di fase.




Le informazioni codificate nei due segnali di uscita possono essere sfruttate per recuperare il valore dell'angolo senza ambiguità. Infatti, conoscere solo il coseno (o seno) di un angolo non è sufficiente per determinare inequivocabilmente l'angolo corrispondente. Tuttavia, conoscere entrambi consente di determinare l'angolo. Dividendo V_{S1} e V_{S2} per V_{ex} e poi per T , si calcola il coseno e il seno dell'angolo, il che permette di determinare l'angolo stesso. Tuttavia, a volte è problematico avere accesso diretto al segnale V_{ex} , poiché ciò implicherebbe l'utilizzo di fili montati sul rotore (che si aggroviglierebbero). In questo caso, se si può accedere solo a V_{S1} e V_{S2} , possiamo avere solo una risoluzione di 180° . Il lettore è incoraggiato a verificare quanto segue con l'ausilio di strumenti di plotting (come MATLAB®, o strumenti online come [desmos.com/calculator](https://www.desmos.com/calculator)). Quando θ varia da 0° a 180° , è possibile calcolare l'angolo confrontando le due forme d'onda di uscita. È abbastanza facile estrarre l'ampiezza di ogni forma d'onda e vedere se sono in fase o in controfase: questo è sufficiente per estrarre l'angolo. Tuttavia, quando θ varia da 180° a 360° , si osserva lo stesso comportamento di quando θ varia da 0° a 180° , limitando quindi la risoluzione a soli 180° . Per estendere la risoluzione a 360° o anche più (alcuni resolver possono anche fornire informazioni su quanti giri completi di 360° ha effettuato il rotore) vengono utilizzati algoritmi e tecniche sofisticati (ad esempio, utilizzando convertitori di precisione Resolver-to-Digital o impiegando due avvolgimenti di rotore anziché uno solo). Una discussione dettagliata (ma piuttosto tecnica e difficile) sull'uso dei convertitori Resolver-to-Digital può essere trovata online (almeno alla data di scrittura di questo opuscolo) all'indirizzo: <https://www.analog.com/en/analog-dialogue/articles/precision-rtddc-measures-angular-position-and-velocity.html>

In generale i resolver:

- Sono alimentati a 5-15 V_{RMS} (ma talvolta anche a tensioni più elevate fino a 100 V_{RMS}) a circa 1-15 kHz;
- Sono in grado di resistere a temperature da $-50^\circ C$ a $150^\circ C$ (compatibile con le specifiche automotive);
- Sono limitati in termini di velocità di rotazione massima del rotore a circa 10.000 giri/min.

4.6. Sensori di Accelerazione

Sono usati per misurare le accelerazioni. Possono essere lineari (mono-bi-tri assiali) o rotazionali (tipicamente fabbricati con tecnologia MEMS). La loro sensibilità è misurata tipicamente in mV/ms^{-2} (quando l'uscita è una tensione) o pC/ms^{-2} (quando la quantità di uscita è una capacità). Possono essere fabbricati in una varietà di tecnologie, ad esempio piezoelettriche, piezoresistive, meccaniche, capacitive e integrate. Le principali applicazioni sono nel settore automobilistico (ad esempio, airbag, sospensioni attive, allarmi, freni adattivi, ESP), nei crash test, nella robotica, nel monitoraggio delle vibrazioni, nel monitoraggio sismico, nei rilevatori di impatto. Il sistema prototipale per capire come si può misurare l'accelerazione è il cosiddetto sistema sismico, abbozzato nella figura seguente. È composto da una molla, una massa e un ammortizzatore. La sua dinamica è governata da un'equazione differenziale del secondo ordine, la cui soluzione è la posizione della massa nel tempo. Differenziando doppiamente la posizione rispetto al tempo possiamo calcolare l'accelerazione. Quindi, un possibile modo per stimare l'accelerazione sarebbe implementare un sistema sismico e quindi utilizzare un sensore di posizione sulla massa. Un altro modo possibile sarebbe applicare un estensimetro sulla molla per ottenere la sua deformazione, che fornisce anche informazioni sulla posizione della massa, per poi calcolare l'accelerazione.



Pertanto, diverse soluzioni possono essere utilizzate per realizzare sensori di accelerazione, a seconda delle applicazioni specifiche. Qui vedremo i vantaggi e gli svantaggi di due categorie di sensori di accelerazione ampiamente utilizzate: piezo (sia piezoelettrico che piezoresistivo) e MEMS.

4.6.1. Piezo

Le accelerazioni possono essere rilevate utilizzando materiali piezoelettrici (cristalli che reagiscono alle deformazioni generando una tensione) e materiali piezoresistivi (materiali che cambiano la loro resistività in risposta alla deformazione).

I sensori piezoelettrici non sono in grado di monitorare accelerazioni continue. Soffrono di limitazioni nella larghezza di banda: la frequenza di accelerazione minima che possono misurare è limitata dalla costante di tempo del cristallo (una proprietà del materiale piezoelettrico), mentre la frequenza massima è limitata dalla risonanza meccanica. Per questo motivo non vengono utilizzati negli airbag. Infatti, in questa applicazione un'accelerazione molto impulsiva è ciò che fa scattare gli airbag: lo spettro di frequenza di un segnale impulsivo è per lo più concentrato alle alte frequenze, che potrebbero essere difficili da rilevare con un sensore di accelerazione piezoelettrico. Inoltre, richiedono un cablaggio speciale per ridurre al minimo il rumore triboelettrico. Tra gli aspetti positivi, hanno in genere un'ampia sensibilità e un ampio intervallo di funzionamento termico (possono funzionare in ambienti molto caldi e molto freddi) e hanno una buona risposta nel tempo (il sensore reagisce in un tempo molto breve, cioè c'è un ritardo molto piccolo tra l'applicazione di input e la risposta di output).

I sensori piezoresistivi possono invece monitorare le accelerazioni continue poiché non c'è nulla che ne limiti la larghezza di banda alle basse frequenze. Mostrano una buona immunità ai campi elettromagnetici ma una sensibilità piuttosto ampia alle variazioni di temperatura.


4.6.2. MEMS (Micro Electro Mechanical Systems)

I sistemi microelettromeccanici (MEMS) costituiscono una interessantissima alternativa basata sulla stessa tecnologia usata per produrre i circuiti integrati su microscala. Se realizzati su scala nanometrica vengono denominati nanoelettromeccanici (NEMS) e costituiscono una prima vera applicazione delle nanotecnologie. I MEMS sono costituiti da componenti di dimensioni comprese tra 1 e 100 micrometri (cioè da 0,001 a 0,1 mm) e i dispositivi MEMS generalmente hanno dimensioni comprese tra 20 micrometri e un millimetro (cioè da 0,02 a 1,0 mm), sebbene i componenti disposti in array (es., dispositivi digitali a microspecchi) possono essere più grandi di 1000 mm². Di solito sono costituiti da un'unità centrale che elabora i dati (un chip integrato come un microprocessore) e diversi componenti che interagiscono con l'ambiente circostante (microsensori). A causa dell'ampio rapporto superficie/volume dei MEMS, le forze prodotte dall'elettromagnetismo ambientale (ad es. cariche elettrostatiche e momenti magnetici) e dalla fluidodinamica (ad es. tensione superficiale e viscosità) acquisiscono ampia rilevanza rispetto ai dispositivi meccanici su larga scala. La tecnologia MEMS si distingue dalla nanotecnologia molecolare o dall'elettronica molecolare in quanto quest'ultima deve considerare anche la chimica delle superfici. Il potenziale di sfruttamento di macchine molto piccole $\S$ (miniaturizzate) è stato apprezzato prima che esistesse la tecnologia in grado di realizzarle (vedi, ad esempio, la famosa conferenza di Richard Feynman del 1959 "There's plenty of room at the bottom"). I MEMS sono diventati pratici una volta che potevano essere

fabbricati utilizzando tecnologie di fabbricazione di dispositivi semiconduttori, normalmente utilizzate per produrre microchip elettronici. Il punto chiave è che circuiti elettronici e sistemi micromeccanici/fluidici possono essere prodotti insieme, in modo integrato, utilizzando la stessa tecnologia. Pertanto, è possibile fabbricare sensori micro integrati insieme ai circuiti elettronici che devono elaborare l'output dei sensori. La tecnologia MEMS consente di fabbricare un'ampia varietà di sensori sfruttando molti materiali per diverse applicazioni, ad esempio:

- Stampanti a getto d'inchiostro, che utilizzano l'emissione piezoelettriche di bolle di inchiostro per depositare l'inchiostro sulla carta;
- Accelerometri per vari scopi (ad esempio, attivazione dell'airbag, sicurezza, controllo di edifici);
- Giroscopi per molti scopi (ad es. controllo della stabilità, guida di droni);
- Sensori magnetici MEMS per Sistemi di Navigazione Inerziale (INS);
- Microfoni MEMS per smartphone, wearable, applicazioni smart home;
- Sensori di pressione al silicio, ad es. sensori di pressione sanguigna monouso;
- Applicazioni Bio-MEMS come biosensori, incorporati in dispositivi medici come stent;
- Raccolta di energia su microscala;
- Trasduttori a ultrasuoni per applicazioni di monitoraggio della salute (es. ecografia);
- Altoparlanti basati su MEMS per cuffie intrauricolari e apparecchi acustici;

Qui ci concentreremo sulla struttura tipica dei sensori di accelerazione MEMS. Grazie alla tecnologia della microfabbricazione, un complesso sistema di masse mobili e stazionarie può essere ricavato nel silicio, creando un sistema sismico, come nella figura seguente.



La microfotografia a sinistra mostra la struttura reale, che è schematicamente riportata a destra. Una massa mobile, che mostra una struttura interdigitata, è collegata tramite una molla al supporto, che è invece fisso. Tra le dita della massa mobile ci sono delle dita fisse: le dita fisse e mobili sono separate dall'aria (che è un dielettrico) e formano le piastre di un condensatore. Il moto della massa varia la distanza (t nella seguente equazione) tra le dita (le due piastre del condensatore), tipicamente di poche decine di micron. Pertanto, realizzando un accelerometro compatto massa-molla-smorzatore direttamente sulla base di silicio del chip, possiamo anche implementare i circuiti elettronici necessari per rilevare le variazioni di capacità e recuperare la posizione della massa mobile, quindi calcolare l'accelerazione.

$$C = \frac{A \cdot \epsilon_{0x}}{t} \quad \text{dove} \quad \begin{cases} C = \text{capacità} \\ A = \text{area} \\ t = \text{distanza tra le dita} \\ \epsilon_{0x} = \text{costante dielettrica} \end{cases}$$

Per eliminare la non linearità nel rapporto tra distanza e capacità, è sufficiente valutare direttamente l'impedenza (che è proporzionale a $1/C$). Sono anche possibili tecniche alternative, come valutare la capacità tra il dito mobile e sia il dito fisso sopra di esso che quello sotto di esso (C_1 e C_2 nella figura sopra). Poiché il cambiamento di uno è opposto all'altro, la combinazione dei due ha una relazione pressoché lineare con il movimento della massa. Tipicamente, vengono utilizzate molte lamelle (dita) in parallelo per massimizzare l'area equivalente del condensatore e quindi la sensibilità del sensore. Come tutti i MEMS, deve essere progettato per ridurre al minimo gli effetti delle forze elettrostatiche, molto dannose su microscala.

4.7. Sensori Magnetici

I sensori magnetici sono impiegati per monitorare e misurare i campi magnetici. Esistono molte tipologie di sensori magnetici tra cui troviamo:

- Sensori di Hall. Sono i più utilizzati e si basano sull'effetto Hall (a sua volta basato sulla forza di Lorentz);
- Sensori Magnetoresistivi (conosciuti con molti acronimi come MR, AMR, GMR, CMR, EMR). Sfruttano le proprietà di una particolare classe di materiali, detti materiali magnetoresistivi;
- Sensori Magnetostrittivi, basati su materiali magnetostrittivi che sfruttano la cosiddetta magnetostrizione. Questa è una proprietà che provoca un cambiamento nella forma o nelle dimensioni di tali materiali durante il processo di magnetizzazione (l'analogo magnetico dell'effetto piezoelettrico).

I sensori magnetici vengono utilizzati anche per rilevare indirettamente le correnti, poiché le correnti sono sorgenti di campi magnetici.


4.7.1. Sensori di Hall

I sensori di Hall sono sensori magnetici che sfruttano la forza di Lorentz per rilevare un campo magnetico. La forza di Lorentz è la forza esercitata da un campo magnetico su una particella carica (come un elettrone) che si muove. In particolare, è data dall'equazione vettoriale:

$$\vec{F} = q\vec{v} \times \vec{B}$$

dove $\vec{F}$ è la Forza di Lorentz, q la carica elettrica della particella, $\vec{v}$ la sua velocità e $\vec{B}$ il campo magnetico che insiste sulla particella. È importante notare che l'intensità della forza è proporzionale all'intensità del campo magnetico e alla velocità della particella, ma anche alla direzione relativa di $\vec{v}$ e $\vec{B}$. In particolare, se la velocità della particella e il campo magnetico sono paralleli tra loro, la forza svanisce. Al contrario, se sono ortogonali tra loro, la forza è massimizzata. La direzione della forza è sempre ortogonale sia a $\vec{v}$ che a $\vec{B}$ e può essere determinata applicando la cosiddetta regola della mano destra per l'operazione del prodotto vettoriale.

Questo principio trova applicazione nei sensori Hall, come illustrato nella figura sopra. Si supponga di avere un sottile film metallico (quindi conduttivo), il cui spessore è s , a forma di parallelepipedo (quindi a 6 facce, sinistra e destra, su e giù, dietro e davanti). Supponiamo che siano presenti quattro contatti (uno su ciascuna faccia tranne su e giù) e assumiamo che non ci sia campo magnetico. Si supponga di fornire a questo film




metallico una corrente costante, I , utilizzando una sorgente di corrente collegata tra i contatti anteriore e posteriore (non mostrato nella figura sopra). In questa condizione, le particelle cariche (elettroni) nel film metallico si muovono nella direzione indicata dalla freccia verde. Naturalmente, dal momento che stiamo lasciando della corrente fluire nel metallo, sarà presente una caduta di tensione tra i contatti anteriore e posteriore. Tuttavia, non verrà misurata alcuna caduta di tensione tra i contatti sinistro e destro, poiché non c'è flusso di corrente in quella direzione.

Quando è presente un campo magnetico, gli elettroni in movimento che costituiscono la corrente I possono sperimentare la forza di Lorentz e quindi possono essere deviati. Se vengono deviati, la corrente non segue più un percorso rettilineo ma mostrerà una componente nella direzione della forza di Lorentz. Nella figura sopra, immaginiamo la presenza di un campo magnetico in direzione verticale, quindi perpendicolare alla corrente che scorre invece lungo la direzione fronte-retro. Secondo l'equazione sopra riportata, gli elettroni sperimenteranno una forza nella direzione sinistra-destra. Se gli elettroni vengono accelerati nella direzione sinistra-destra, è possibile misurare anche una componente di corrente in quella direzione. E poiché il film metallico è conduttivo (si comporta come un resistore), misureremo anche una tensione, V , tra i contatti sinistro-destro. Nello specifico:

$$V = KBI = \frac{\mu_q \cdot \rho}{s} BI \quad \text{e si può definire} \quad \frac{V}{I} \stackrel{\text{def}}{=} R_h = \frac{\mu_q \cdot \rho}{s} B = \text{Resistenza di Hall}$$

dove I è la corrente iniettata nella direzione fronte-retro, K è una costante che dipende dalle proprietà del film metallico, B l'intensità del campo magnetico. K dipende dalla mobilità dei portatori di carica nel materiale, μ_q , dalla resistività del materiale, ρ , e dal suo spessore s . È possibile definire la cosiddetta resistenza di Hall, R_h , come nell'equazione sopra, che dipende solo dal campo magnetico e dalle proprietà del materiale. Va notato che si tratta di un tipo particolare di resistenza, concettualmente diverso da quello che abbiamo definito per un resistore. In effetti, è il rapporto tra una tensione su due pin (in questo esempio, sinistra-destra) e una corrente che non scorre attraverso gli stessi due pin (in questo caso, I è la corrente iniettata dal terminale posteriore)! I sensori Hall sono generalmente utilizzati negli inverter elettrici e come sensori di corrente indiretta. Sono utilizzati anche in strumenti scientifici e rivelatori per segnali fino a una larghezza di banda di ≈ 100 kHz. Tuttavia, possono sorgere problemi nell'affidabilità dei sensori Hall se esposti per un tempo relativamente lungo a campi magnetici relativamente forti, a causa di fenomeni fisici legati alla magnetizzazione. Nello specifico, l'elemento sensibile del sensore Hall (il film metallico, chiamato elemento Hall) potrebbe modificare il proprio comportamento, portando il sistema a malfunzionamenti. Pertanto, quando devono essere misurati campi magnetici significativi, vengono utilizzati approcci intelligenti per evitare tali problemi. Un caso tipico è quello in cui un sensore Hall viene utilizzato per rilevare la corrente che scorre in un azionamento elettrico. In effetti, questa corrente è tipicamente molto alta e produce un forte campo magnetico. Se un campo magnetico così forte viene misurato da un semplice sensore Hall, potrebbero sorgere problemi nel tempo. Per ridurre al minimo il verificarsi di questi problemi, viene utilizzata una soluzione con feedback. In questa soluzione, il campo magnetico sul sensore Hall è fortemente attenuato da un campo magnetico secondario "compensante", B_{comp} , prodotto da specifici circuiti, in modo tale da esporre il sensore Hall ad un debole campo magnetico netto, B_{net} , pur rimanendo in grado di misurare il forte campo magnetico "originale", B . Di seguito, discuteremo una delle disposizioni con feedback più semplici che da realizzare con un sensore di Hall prendendo a pretesto un'applicazione reale: la misura indiretta di una corrente molto elevata tramite la misurazione del campo magnetico (elevato) da essa generato.



Nella figura sopra è riportato un filo giallo che rappresenta il filo in cui scorre la corrente da misurare. Questa corrente genera un campo magnetico, la cui intensità è proporzionale alla corrente, e ovviamente dipenderà dalla distanza dal filo. Un nucleo ferromagnetico a forma di C è posizionato attorno al filo per focalizzare il campo magnetico sulla sua apertura, dove è posizionato un sensore di Hall. In queste condizioni il campo magnetico generato dalla corrente e incidente sul sensore di Hall sarà perpendicolare al piano del sensore e la sua intensità sarà:

$$B = \alpha I$$

essendo I la corrente che vogliamo misurare e α una costante (nota) che dipende dalla distanza tra il filo e il sensore. Tuttavia, sappiamo che in una disposizione a feedback ci sarà anche un altro campo magnetico, B_{comp} , che riduce il campo magnetico effettivo al sensore di Hall ad un valore netto B_{net} (vedremo tra breve come ciò accadrà). Questo è il valore rilevato dal sensore Hall, quindi la sua uscita sarà:

$$V_H = K I_{bias} B_{net}$$

dove I_{bias} è la corrente che viene usata per alimentare il sensore di Hall (non la corrente che vogliamo misurare!) e K è la costante del sensore di Hall. Questa tensione viene convertita in una corrente, chiamata I_{comp} , da uno specifico circuito amplificatore con guadagno β :

$$I_{comp} = \beta V_H = \beta K I_{bias} B_{net} = \beta K I_{bias} (B - B_{comp}) = \beta K I_{bias} (\alpha I - B_{comp}) = \gamma (\alpha I - B_{comp})$$

Questa corrente viene inviata su una bobina che si avvolge N volte attorno al nucleo ferromagnetico (descrivendo quindi N giri attorno al nucleo). Questo genera il campo magnetico secondario "compensante" B_{comp} . In particolare, se volessimo impostare la corrente inviata in questi avvolgimenti ad un valore N volte minore della corrente che vogliamo misurare, I , avremmo:

$$I_{comp} = I/N$$

Il campo magnetico generato da questa corrente sarà proporzionale alla corrente stessa:

$$B_{comp} = \varepsilon I/N$$

dove ε è una costante di proporzionalità (nota). Dunque:

$$I_{comp} = \gamma (\alpha I - B_{comp}) \rightarrow \frac{I}{N} = \gamma (\alpha I - \varepsilon I/N) \rightarrow \gamma = \frac{\frac{1}{N}}{\alpha - \frac{\varepsilon}{N}} = \beta K I_{bias}$$

$$\beta = \frac{\frac{1}{N}}{K I_{bias} \left(\alpha - \frac{\varepsilon}{N} \right)}$$

Ciò significa che il guadagno del circuito del convertitore tensione-corrente necessario per avere $I_{comp}=I/N$ può essere completamente determinato da costanti note. La corrente che scorre negli avvolgimenti viene quindi inviata attraverso un resistore, R_L , a massa. La tensione su questo resistore sarà:

$$V_{out} = R_L I_{comp} = R_L \frac{I}{N}$$

Pertanto, misurando questa tensione possiamo stimare la corrente che vogliamo misurare:


$$I = V_{out} \frac{N}{R_L}$$

In questo modo, dimensionando opportunamente il guadagno dello stadio convertitore tensione-corrente, possiamo facilmente misurare una grande corrente che genera un grande campo magnetico anche se il campo magnetico effettivo che cade sull'elemento di Hall è debole (il che risolve possibili problemi di affidabilità che possono sorgere quando un sensore di Hall è esposto a campi magnetici intensi per un tempo relativamente lungo).

Abbiamo studiato la disposizione più semplice (anello di controllo proporzionale), e ci sono molte altre possibilità che garantiscono prestazioni migliori (ad esempio un controllo proporzionale-integrale). Tuttavia, la discussione di tali accordi esula dallo scopo di questo corso.

4.7.2. Sensori Magnetoresistivi

Questi sensori si basano sul cosiddetto disco di Corbino, che è un disco formato da due anelli conduttivi (interno ed esterno, che realizzano i due elettrodi del sensore) con un materiale magnetoresistivo nel mezzo. Tali materiali possono cambiare la loro resistenza in funzione dell'intensità di un campo magnetico esterno. Sono molto compatti ed economici e, come il sensore di Hall, si basano sempre sulla forza di Lorentz: il movimento delle cariche è deviato dalla presenza di un campo magnetico. Quando non viene applicato alcun campo magnetico, applicando una tensione ai due elettrodi, la corrente fluirebbe tra l'anello interno ed esterno viaggiando in direzione radiale (riferendosi alla figura seguente, è presente solo la componente I_p , con $I_\theta = 0$). Il rapporto tra la tensione applicata e la corrente misurata è la resistenza nominale del sensore, R_0 . Quando viene applicato un campo magnetico, B , questo devierà i portatori di carica che fluiscono tra gli anelli a causa della forza di Lorentz, costringendo il contributo di I_θ a essere diverso da zero. Ciò aumenterà la lunghezza del percorso che le cariche devono percorrere per passare da un anello all'altro.



Pertanto, se la tensione applicata è la stessa, la corrente misurata sarà inferiore, e quindi la resistenza misurata, R , aumenterà rispetto a R_0 . Misurando la resistenza, è possibile recuperare l'ampiezza del campo magnetico. Nel pannello di destra della figura sopra, è riportato il valore della resistenza normalizzata R/R_0 rispetto al campo magnetico applicato B , per due diversi sensori che utilizzano diversi materiali magnetoresistivi. Si può facilmente notare che il sensore non è lineare, in quanto R/R_0 mostra una dipendenza quasi quadratica da B . Inoltre si osserva una significativa dipendenza dalla temperatura (il

senore ha una scarsa selettività). Pertanto, è importante accoppiarli con sensori di temperatura. Una caratteristica importante di tali sensori è che è impossibile distinguere l'orientamento del campo B, a meno che non vengano utilizzati due sensori contemporaneamente. In questo caso si possono rilevare non solo le variazioni temporali ma anche le variazioni spaziali di B.

4.8. Sensori di Corrente


I sensori di corrente vengono utilizzati per misurare l'entità delle correnti. Quest'ultima, come detto in precedenza, può essere misurata in modo non invasivo per mezzo di sensori magnetici. Tuttavia, qui verranno studiati specifici sensori di corrente. Nello specifico verranno discusse due tipologie, sensori shunt e trasformatori.

4.8.1. Shunt

Uno shunt è fondamentalmente un resistore con una resistenza molto piccola (in genere inferiore a 1 Ω). Sono collegati in serie con l'elemento in cui scorre la corrente: questo provocherà una caduta di tensione su questa resistenza che può essere misurata per poi determinare il valore della corrente. Maggiore è la corrente da misurare, minore deve essere la resistenza del sensore shunt, altrimenti si formerà una tensione eccessiva sul resistore (cosa non pratica e talvolta anche pericolosa da misurare). Tuttavia, gestire valori di resistenza molto piccoli non è banale. Infatti, fisicamente, un resistore comprende anche i suoi terminali che consentono di collegarlo ad altri dispositivi. Questi terminali sono metallici e hanno una propria resistenza. Questa è in genere molto piccola e quindi trascurabile. Tuttavia, quando la resistenza nominale del resistore (R) inizia ad essere molto bassa, non è possibile trascurare gli effetti delle resistenze parassite dei terminali (2r, supponendo che ogni terminale abbia una resistenza parassita pari a r). La legge di Ohm deve essere quindi riscritta come:

$$I = \frac{V}{R + 2r}$$



Mentre R è noto, r è sconosciuto e difficile da stimare. Pertanto, quando R inizia ad essere paragonabile ai valori tipici di r (nell'intervallo delle decine di m Ω), la resistenza totale (R+2r) esibita dal resistore non è più dominata da R, e diventa in gran parte sconosciuta. Pertanto, misurare la caduta di tensione sul resistore non è una soluzione praticabile per recuperare la corrente da misurare. Per superare tale limitazione, i resistori con una resistenza nominale molto piccola sono costruiti in modo peculiare e sono chiamati resistori Kelvin o resistori a 4 terminali. Oltre ai pin standard (chiamati qui pin di corrente) sono forniti due pin aggiuntivi (chiamati pin di tensione). Mentre i pin di corrente e i relativi terminali sono fabbricati come per i resistori standard, i pin di tensione sono fabbricati con particolare cura, utilizzando materiali specifici a bassissima resistività (e quindi molto costosi), limitandone il più possibile la lunghezza e posizionandoli proprio ai bordi della resistenza. Ciò garantisce che questi pin avranno una resistenza parassita trascurabile. I pin di corrente del sensore shunt verranno posti in serie al ramo su cui scorre la corrente da misurare, mentre i pin di tensione verranno utilizzati per misurare la tensione proprio ai capi della resistenza stessa, escludendo tutte le cadute di tensione sulla resistenza parassita dei terminali che collegano la resistenza ai pin di corrente. Inoltre, poiché il circuito che legge la tensione mostra tipicamente una grande impedenza di ingresso, quasi nessuna corrente scorrerà sui pin di tensione, diminuendo ulteriormente gli effetti negativi della loro inevitabile (sebbene già molto piccola) resistenza parassita.



I sensori shunt sono:

- Adatti per correnti DC e AC fino alle alte frequenze. Tuttavia, per frequenze molto elevate, gli effetti induttivi parassiti diventano dominanti, insieme agli di prossimità e al cosiddetto "effetto pelle";
- Semplici, robusti e affidabili;
- Interessati dal problema dell'autoriscaldamento: la corrente nella resistenza provocherà un riscaldamento Joule che influirà sul valore della resistenza.
- Non una buona scelta se è necessario l'isolamento galvanico;
- Ingombranti e pesanti: per misurare correnti elevate possono essere necessari shunt che pesano fino a 10 kg.

4.8.2. Trasformatori



I sensori di corrente basati su trasformatore sfruttano dispositivi elettrici detti trasformatore per scalare correnti molto elevate a valori inferiori, rendendo possibile la loro misura con altri sensori di corrente (ad esempio un sensore shunt). Il trasformatore sfrutta l'induzione magnetica per generare un campo magnetico, facendo fluire la corrente da misurare in una bobina primaria. Questo campo magnetico si accoppierà a una bobina secondaria e indurrà una corrente, la cui ampiezza è proporzionale all'ampiezza della corrente nella bobina primaria tramite un "rapporto di trasformazione" costante, α . Quest'ultimo può essere dimensionato scegliendo opportunamente il numero di avvolgimenti nelle due bobine, N_1 e N_2 . Viene tipicamente utilizzato per correnti molto elevate (oltre 10 A). Poiché sfrutta l'induzione magnetica, questo sensore permette una misura di corrente non invasiva (se si trascura la resistenza in serie che inevitabilmente accompagna la bobina primaria). Lo svantaggio principale è la risoluzione ridotta. Infatti, supponendo di utilizzare un sensore di corrente con una determinata risoluzione, R , per misurare la corrente nella bobina secondaria, e supponendo di ridurre la corrente da misurare di un fattore α , allora la risoluzione effettiva del sensore sarà R/α . Ad esempio, se $R = 1 \text{ mA}$, $I_1 = 10 \text{ kA}$ e $I_2 = 1 \text{ A}$ (stiamo scalando la corrente di un fattore $\alpha = I_2/I_1 = 10^{-4}$), allora la risoluzione effettiva con cui possiamo misurare I_1 sarà $R/\alpha = 10 \text{ A}$, e non $R = 1 \text{ mA}$.

Un vantaggio di questo tipo di sensore è l'isolamento galvanico. D'altra parte, non può funzionare con correnti DC poiché non generano campi magnetici variabili nel tempo (e non ci sarà induzione magnetica nella bobina secondaria).

5. Attuatori


In questo capitolo introdurremo e ci concentreremo sugli elementi che hanno la responsabilità di agire effettivamente sul sistema fisico controllato dall'elettronica: questi sono gli attuatori. Li definiremo, li classificheremo e forniremo una discussione sulle tipologie di attuatori specifici.

Un attuttore è un dispositivo che trasforma le variazioni di una grandezza elettrica in una variazione correlata di una grandezza fisica appartenente ad un altro dominio (es. posizione, temperatura, pressione, ecc.). Traducono le informazioni da un dominio fisico a un altro, ma in modo duale rispetto ai sensori. Gli attuatori tipici possono quindi avere un'uscita che è una quantità come temperatura, forza, coppia, posizione, velocità, accelerazione, campo magnetico, corrente, tensione, pressione, flusso, livello, umidità... A differenza dei sensori, gli attuatori in genere devono erogare una quantità significativa di potenza in uscita (ad esempio, spostare un oggetto o riscaldare uno spazio richiede una quantità significativa di energia), il che implica anche la necessità di gestire correttamente una quantità significativa di potenza in ingresso (che è anche maggiore della potenza in uscita, poiché l'efficienza di conversione della potenza è sempre inferiore al 100%).

Di seguito, analizzeremo più da vicino i principi di funzionamento e le caratteristiche delle classi di attuatori più frequentemente utilizzate, con particolare attenzione agli attuatori di temperatura, attuatori di luce, attuatori di forza e movimento, attuatori di pressione.

5.1 Attuatori Termici

Un attuttore di temperatura viene utilizzato per controllare la temperatura dello spazio circostante. Gli attuatori di temperatura più semplici possono solo aumentare la temperatura dello spazio circostante (ad esempio un elemento riscaldante), mentre altri possono anche ridurla (ad esempio un frigorifero). Per semplicità, ci concentreremo su semplici riscaldatori. Questi ultimi sono, in sostanza, dispositivi che sfruttano l'effetto Joule per trasformare efficacemente la potenza elettrica dissipata su un conduttore in calore, fornendo così un modo per aumentare la temperatura locale. La loro struttura, abbozzata nel riquadro sinistro della figura sottostante, è molto semplice, in quanto si tratta solo di barre metalliche (cioè di fatto resistenze), tipicamente disposte a serpentina per renderle compatte, e rappresentano una buona soluzione per livelli di potenza da pochi W fino a pochi kW – con un limite alla temperatura massima che possono raggiungere che è dettato principalmente dal punto di fusione del metallo impiegato e dai cavi (potrebbero essere richiesti cavi speciali per resistere a correnti molto elevate). Quando si tratta di potenze elevate è necessario adottare materiali e cavi speciali.



La barra metallica a serpentina ha tipicamente una sezione molto ampia (ad es. la serpentina presente in qualsiasi forno) per ridurre al minimo la resistenza dell'attuttore, che infatti dovrebbe essere molto bassa per massimizzare la dissipazione di potenza per una data tensione di pilotaggio, poiché $P = V^2/R$. Infatti, conoscendo la resistenza della barra metallica, è possibile regolare la tensione di pilotaggio per impostare correttamente la potenza dissipata. Tuttavia, è importante sapere quanto un aumento di temperatura

(rispetto alla temperatura dell'ambiente) risulterà da una data dissipazione di potenza. Questa informazione è racchiusa in un'importante caratteristica fisica del resistore denominata resistenza termica (misurata in K/W), che rivela infatti l'aumento di temperatura per unità di potenza dissipata. Quest'ultima può essere funzione della temperatura stessa, poiché la resistività del metallo cambia con la temperatura. Tuttavia, la potenza elettrica dissipata sull'elemento non può essere arbitrariamente elevata, in quanto questi attuatori sono caratterizzati da una temperatura massima (dettata per lo più dal punto di fusione del metallo) e da certa una potenza nominale (cioè la massima potenza dissipabile senza danneggiare l'attuatore). Uno dei materiali più adatti è il tungsteno, a causa del suo alto punto di fusione, ma anche il disegno geometrico di una resistenza può avere un impatto significativo sulle prestazioni complessive.

Si noti che, in questa trattazione, ci riferiamo alla temperatura interna della parte attiva dell'attuatore, ovvero la porzione dell'attuatore che effettivamente è responsabile della conversione dell'energia. Tuttavia, questa temperatura non è ovviamente la stessa dell'ambiente (naturalmente, la temperatura diminuirà con la distanza dall'attuatore). Inoltre, l'attuatore stesso non è composto solo dal suo elemento attivo, ma potrebbe includere un involucro che lo racchiude e altri elementi. Per controllare in modo appropriato la temperatura target (ovvero la temperatura dell'ambiente attorno all'attuatore), è indispensabile considerare il percorso del calore generato dall'elemento attivo nell'attuatore che va dall'elemento attivo verso l'esterno (verso l'ambiente, attraverso i diversi elementi aggiuntivi che l'attuatore incorpora). In generale, possiamo esprimere la differenza tra la temperatura dell'elemento attivo dell'attuatore (tipicamente chiamato "giunzione"), T_J , e la temperatura dell'ambiente, T_E , come prodotto del flusso di calore (che deve essere calcolato utilizzando l'equazione del calore di Fourier – tipicamente risolta tramite simulazione, come nell'esempio nel pannello di destra della figura sopra), $\dot{Q}$, moltiplicato per la somma delle resistenze termiche di tutte le interfacce che separano la giunzione dall'ambiente. Questa relazione è mostrata nell'equazione seguente per un semplice scenario in cui consideriamo l'attuatore come costituito da un elemento attivo (giunzione) e da un involucro. L'interfaccia della giunzione con l'involucro fornisce una resistenza termica R_{J-C} e quella tra involucro e ambiente fornisce una resistenza termica R_{C-E} . Chiaramente, la somma di queste due componenti è la resistenza termica equivalente, R_{J-E} , di un dispositivo equivalente con una sola interfaccia (giunzione-ambiente).

$$T_J - T_E = \dot{Q}(R_{J-C} + R_{C-E}) = \dot{Q}(R_{J-E})$$

Allo stesso modo è anche possibile calcolare la temperatura dell'involucro, T_C , che può essere importante per garantire l'integrità dell'involucro stesso, utilizzando una delle due seguenti equazioni derivate dalla precedente.

$$T_C - T_E = \dot{Q}R_{C-E}$$

$$T_J - T_C = \dot{Q}R_{J-C}$$

Queste equazioni sono utili per comprendere la quantità di dissipazione di potenza necessaria per generare una data temperatura di giunzione, e quindi una data temperatura ambiente (desiderata). Allo stesso tempo, è possibile tenere conto anche della temperatura a tutte le interfacce intermedie, per prevenire surriscaldamenti indesiderati e per stimare la durata prevista delle diverse parti degli attuatori in condizioni operative (poiché potrebbero usurarsi più o meno rapidamente a seconda della loro temperatura).


Come nota finale, esistono chiaramente attuatori in grado di abbassare la temperatura dell'ambiente (ad esempio i normali frigoriferi). Un buon attuatore a stato solido in grado di svolgere questo compito è la cella di Peltier. Questi ultimi sono dispositivi basati su semiconduttori in grado di dissipare il calore e mostrano il notevole vantaggio di essere compatti e affidabili. Ancora più importante, rispetto ad altri attuatori non allo stato solido, non necessitano di sfati, il che ne aumenta notevolmente l'affidabilità, riducendone anche il costo, le dimensioni e le esigenze in termini di manutenzione.

5.2 Diodi Emittitori di Luce

Un diodo a emissione di luce (LED) è un particolare tipo di diodo. Come tutti i diodi, è costituito da una giunzione tra due materiali semiconduttori con drogaggio diverso (una cosiddetta giunzione p-n). Tuttavia, i materiali impiegati devono essere semiconduttori a bandgap diretto (chiarire il significato specifico di questo termine esula dagli scopi di questo opuscolo). Pertanto, non possono essere realizzati in Si (che è un semiconduttore a bandgap indiretto). Invece, sono tipicamente costituiti da semiconduttori composti come GaAs (arseniuro di gallio), InGaAs (arseniuro di gallio-indio), GaN (nitruro di gallio), InGaN (nitruro di gallio-indio), AlGaN (nitruro di gallio-alluminio) e così via. Tipicamente, hanno una tensione di lavoro più alta (fino a 4 V) rispetto ai diodi Si standard (inferiore a 0.7 V) e, a seconda del materiale impiegato, l'emissione della luce sarà a una lunghezza d'onda diversa (cioè di colore diverso). Sono disponibili in commercio LED che vanno dall'infrarosso (come quelli utilizzati nei telecomandi TV) all'ultravioletto.

Il principio di funzionamento è molto semplice: quando questo diodo è polarizzato in diretta emette luce con un'intensità controllata dalla quantità di corrente che scorre nel diodo. Sono emettitori di luce molto efficienti, poiché solo il 4-5% della potenza elettrica dissipata viene trasformata in calore, il che fa sì che i LED raggiungano efficienze energetiche intorno al 95%. La loro straordinaria efficienza energetica (soprattutto rispetto alle tradizionali lampadine a filamento di tungsteno) è il fattore principale per il loro massiccio utilizzo in molti settori come l'illuminazione pubblica e privata, i display, le comunicazioni wireless. In particolare, l'invenzione del LED blu ad alta potenza e ad alta luminosità a base di GaN costruito su substrati di zaffiro da parte di Isamu Akasaki e Hiroshi Amano dell'Università di Nagoya ha rivoluzionato l'illuminazione a LED, rendendo praticamente possibile realizzare sorgenti di luce blu ad alta potenza, che hanno portato, tra le altre cose, allo sviluppo di tecnologie come il Blu-ray. Insieme a un altro scienziato pionieristico nel campo, Nakamura, Hiroshi Amano e Isamu Akasaki hanno ricevuto il Premio Nobel per la Fisica nel 2014.

Quando accoppiati a fototransistor/fotodiodi, i LED sono anche una valida opzione per ottenere l'optoisolamento, che consente a due circuiti di comunicare senza essere collegati fisicamente, come illustrato di seguito. In parole povere, l'informazione viene convertita dal LED dal dominio elettrico al dominio ottico e quindi trasformata nuovamente nel dominio elettrico da un fotorilevatore. Questa è un'opzione utile per interfacciare circuiti che funzionano con tensioni notevolmente diverse.



5.3 Solenoidi

Un solenoide è un dispositivo a due terminali costituito essenzialmente da una bobina elettrica e da un nucleo ferromagnetico. Quest'ultimo è in qualche modo libero di muoversi all'interno della bobina. Può essere realizzato per essere compatibile con ingresso analogico o digitale.

Il principio di funzionamento di un solenoide è semplice. L'ingresso elettrico è una corrente, che alimenta la bobina. La bobina eccitata genera un campo magnetico, che attirerà il nucleo ferromagnetico verso il centro (o lo respingerà lontano dal centro a seconda della direzione della corrente). La forza attrattiva (o repulsiva) sarà una funzione della corrente nella bobina. Molti solenoidi sono attuatori lineari, in modo che la corrente nella bobina generi un movimento/forza lineare con l'intensità della corrente. Il movimento del nucleo ferromagnetico all'interno della bobina è




tipicamente vincolato da una molla, ma il nucleo può anche essere libero di muoversi. Solitamente vengono inclusi dei tappi per evitare che il nucleo ferromagnetico fuoriesca completamente dalla parte interna della bobina.

I solenoidi progettati per supportare specificamente le correnti di ingresso digitali (on/off) sono realizzati in modo tale che, nei due stati (quando la corrente scorre o non scorre nella bobina) il nucleo si muova in una direzione (dettata dallo stato) e raggiunga un punto morto (tipicamente per mezzo di tappi). Questo produce un'uscita di posizione binaria, tipicamente usata per pilotare elettrovalvole di tipo on-off. Queste ultime sono dispositivi elettromeccanici in cui la parte meccanica del solenoide regola direttamente l'apertura di una valvola, consentendo o impedendo il flusso di fluido al suo interno. Le elettrovalvole analogiche vengono utilizzate anche per modulare l'apertura della valvola (invece di poter semplicemente aprire o chiudere completamente la valvola). Esistono anche solenoidi toroidali e vengono utilizzati come attuatori di movimento rotatorio.

5.4 Altoparlanti

Un attuttore (elettro)acustico converte un segnale elettrico in un'onda sonora (pressione) corrispondente. Il più utilizzato è l'altoparlante dinamico, abbozzato nella figura a destra. Nell'altoparlante dinamico, un segnale AC viene applicato a una bobina sospesa in uno spazio tra i poli di un magnete permanente. Quando la bobina viene eccitata dal segnale AC, genera un campo magnetico che interagisce con il campo magnetico generato dal magnete permanente. Ciò fa sì che la bobina si muova avanti e indietro seguendo la forma d'onda del



1. Magnet
2. Cooler
3. Coil
4. Suspension
5. Diaphragm

segnale CA a causa della legge di Faraday. Un diaframma (solitamente di forma conica) è fissato alla bobina per mezzo di una sospensione, anch'essa mobile (nella direzione avanti-indietro). Ciò fa vibrare l'aria attorno al diaframma creando onde di pressione. Tipicamente, un dispositivo di raffreddamento (dissipatore di calore) viene impiegato quando si usano altoparlanti di grandi dimensioni in grado di gestire segnali ad alta potenza che possono causare una notevole dissipazione di calore. Questi altoparlanti non sono efficienti dal punto di vista energetico e pertanto la sorgente sonora (ad esempio un microfono o un lettore audio) deve essere amplificata con un amplificatore di potenza audio prima che il segnale possa essere utilizzato per pilotare efficacemente l'altoparlante. Sebbene possano riprodurre molto fedelmente la forma d'onda del segnale in ingresso con una distorsione minima (trovano infatti applicazione nei sistemi Hi-Fi), la necessità di un diaframma largo (soprattutto per riprodurre correttamente i suoni a bassa frequenza) ne esclude l'uso in oggetti di piccole dimensioni come, ad esempio, telefoni cellulari. Per dotare i cellulari di altoparlanti, quindi, occorre utilizzare una tecnologia diversa. In linea di principio, il loro funzionamento non è limitato alla gamma di frequenze audio, ma può estendersi sia al di sotto (infrasuoni - utilizzati per la misurazione e il rilevamento di oggetti lontani) che al di sopra (ultrasuoni - utilizzati nel rilevamento di ostacoli a corto raggio, imaging medico e analisi dei materiali). Tuttavia, soprattutto nel secondo caso, viene utilizzata una tecnologia diversa e più praticabile, quella basata sui MEMS.

5.5 Attuatori Piezoelettrici (MEMS)


I materiali piezoelettrici sono comunemente usati per realizzare membrane di dimensioni miniaturizzate che possono essere usate in altoparlanti e attuatori di pressione compatti e potenti. A frequenze relativamente alte (ad esempio, ultrasuoni) l'altoparlante dinamico non è generalmente considerato una soluzione praticabile, ed è quindi sostituito da un attuttore piezoelettrico. L'attuttore piezoelettrico funziona come la sua controparte sensore, poiché l'effetto piezoelettrico è reversibile (l'applicazione di una tensione provoca una deformazione fisica, l'applicazione di una deformazione fisica genera una tensione). Un altoparlante

piezoelettrico (noto anche come "piezo", cicalino, altoparlante a cristallo, beeper, buzzer) è un altoparlante che sfrutta l'effetto piezoelettrico per generare onde di pressione. Il movimento meccanico iniziale viene creato applicando una tensione a un materiale piezoelettrico e la vibrazione di quest'ultimo viene tipicamente convertita in fluttuazioni più ampie utilizzando diaframmi e risonatori. Tutti gli altoparlanti dei dispositivi portatili sono realizzati con questa tecnologia (ad es. nei telefoni cellulari e nei registratori tascabili).

Questo tipo di attuatore può essere utilizzato come strumento diagnostico, realizzando ciò che è ampiamente noto come ecografia. Le onde ultrasoniche sono generate per mezzo di un attuatore piezoelettrico e sono guidate verso la regione del corpo da scansionare. Queste onde di pressione si propagano nel corpo e vengono riflesse dai tessuti interni. Il segnale riflesso viene rilevato da un sensore piezoelettrico. Analizzando il ritardo tra le onde trasmesse e ricevute, insieme al confronto della loro forma d'onda, è possibile ricostruire la forma e la composizione del mezzo in modo non invasivo. L'ecografia 3D è possibile sfruttando array di elementi piezoelettrici.

Il principale vantaggio di questo approccio è la possibilità di eliminare i grandi diaframmi, rendendo possibile la realizzazione di dispositivi compatti. È possibile costruire dispositivi piezoelettrici con una gamma dinamica molto ampia, risultando in altoparlanti tascabili piccoli, potenti e affidabili (e microfoni, se utilizzati come sensori). Inoltre, questi oggetti possono essere realizzati in tecnologia MEMS, che permette di integrarli completamente nei circuiti integrati, con evidenti vantaggi in termini di riduzione dei costi, affidabilità, controllo e riproducibilità. Nella figura seguente è riportato uno schizzo di una membrana PZT (titanato di piombo-zirconio) che viene deviata su e giù. Applicando tensioni fino a pochi volt si possono ottenere deformazioni verticali fino a una piccola % del diametro della membrana in oggetti di dimensioni micrometriche. Inoltre, modificando la geometria (ad esempio, il diametro di una membrana circolare) è possibile progettare diverse risposte alla tensione di ingresso.

In genere, funzionano bene nell'intervallo 1 – 100 kHz.




Oltre all'imaging medico e alla riproduzione audio nei dispositivi portatili, i sensori piezoelettrici trovano applicazione anche nella tecnologia di assistenza al parcheggio (simile all'imaging medico - vengono generate onde di pressione ultrasoniche mentre l'eventuale eco viene rilevata da un elemento piezoelettrico per calcolare la distanza da un ostacolo vicino) e nella cancellazione attiva del rumore (dove un sensore piezoelettrico agisce come un microfono, uno specifico algoritmo isola il rumore, e quest'ultimo viene utilizzato per produrre un segnale che guida un altoparlante piezoelettrico per fargli produrre una specifica forma d'onda sonora che corrisponde esattamente al rumore, ma con fase opposta, in modo da cancellarlo).

5.6 Ponte H

Studieremo ora il comportamento di un circuito che è frequentemente impiegato nel controllo di una specifica classe di attuatori (es. motori DC, non approfonditi in questo opuscolo) e che fa uso del concetto di commutazione di potenza. Considereremo il motore DC come una “scatola nera” che converte l'energia elettrica in energia meccanica rotazionale. In poche parole, a un motore DC viene fornita una tensione DC, la cui entità sarà proporzionale alla velocità di rotazione del motore. La polarità della tensione continua applicata determina il senso di rotazione (orario o antiorario). Se vengono applicati 0 V al motore, il motore frenerà fino a riposo. Se il motore viene lasciato flottante (ovvero, viene forzata una corrente nulla), sarà semplicemente in corsa libera.


Il circuito che viene tipicamente utilizzato per controllare il motore DC è chiamato Ponte H, H Bridge, o Full Bridge, e consente di impostare il motore in rotazione in senso orario o antiorario, corsa libera (inerziale) e frenatura. Il circuito è composto da una sorgente di tensione DC (ovvero la tensione DC che dovrebbe essere applicata al motore DC per farlo funzionare) e quattro interruttori, etichettati da S1 a S4 nella figura a lato. Configurando opportunamente gli interruttori (cioè selezionando quali sono chiusi e quali sono aperti) è



possibile comandare il motore in corrente continua (M nella figura seguente). In particolare, se gli interruttori S1 e S4 sono chiusi con S2 e S3 aperti, la tensione DC in ingresso, V_{in} , cadrà ai capi del motore (con il terminale sinistro ad una tensione V_{in} rispetto al destro) il che farà girare il motore DC in una determinata direzione (ad esempio in senso orario). La velocità di rotazione del motore dipende solo dal valore di V_{in} . Al contrario, se gli interruttori S1 e S4 sono aperti con S2 e S3 chiusi, la tensione DC in ingresso, V_{in} , cadrà sul motore con polarità opposta rispetto al caso precedente, il che metterà il motore DC in rotazione nella direzione opposta (ad es. in senso antiorario). Se gli interruttori S2 e S4 sono chiusi, con S1 e S3 aperti, i terminali del motore sono cortocircuitati e non c'è caduta di tensione su di essi. Pertanto, il motore frena (cioè riduce progressivamente e velocemente la sua velocità di rotazione fino a quando non smette completamente di ruotare). Si noti che lo stesso effetto può essere ottenuto anche chiudendo S1 e S3 mantenendo aperti S2 e S4. Infine, se tutti gli interruttori sono aperti, il motore è flottante e non può fluire corrente attraverso di esso, il che metterà il motore in marcia libera (condizione di inerzia). In questo stato il motore manterrà la condizione di rotazione precedente (se era in rotazione prima di aprire tutti gli interruttori, continuerà a ruotare fino a quando l'attrito non lo rallenta). Queste 5 configurazioni sono quelle effettivamente utilizzate per controllare il motore. Tuttavia, poiché il circuito è composto da 4 interruttori (ciascuno dei quali può essere chiuso o aperto) ci sono 16 possibili configurazioni per gli interruttori, non solo 5. Tuttavia, la maggior parte di esse (7 su 16) sono effettivamente vietate, in quanto comporterebbero un serio pericolo e comprometterebbero la funzionalità del circuito, eventualmente danneggiando il motore e gli interruttori. Le 7 combinazioni vietate sono quelle per le quali i due interruttori appartenenti allo stesso ramo verticale (o S1 e S2, oppure S3 e S4, o tutti) sono chiusi contemporaneamente. Infatti, in queste condizioni, la sorgente di tensione DC in ingresso verrebbe cortocircuitata, causando un serio pericolo per gli interruttori e il motore. Le restanti 4 configurazioni sono quelle per cui un ramo ha gli interruttori aperti e nell'altro ramo un interruttore è chiuso e l'altro è aperto. Queste configurazioni sono simili a quella in cui tutti gli interruttori sono aperti, in quanto il motore sarà flottante e non sono praticamente utilizzate.

Nei circuiti a ponte H reali, gli interruttori sono tipicamente implementati per mezzo di MOSFET o BJT, come illustrato di seguito. Ciascun interruttore è tipicamente accoppiato a un diodo di ricircolo per prevenire picchi di alta tensione durante l'accensione e lo spegnimento di carichi induttivi (tipicamente, i motori DC si comportano come carichi induttivi). Nella maggior parte dei transistor di potenza commerciali, questo diodo

di ricircolo è già incorporato nella struttura del transistor, ma può anche essere inserito nel circuito come componente esterno, nel caso il transistor selezionato non ne abbia uno già realizzato al proprio interno. La figura seguente mostra il percorso della corrente quando il motore è impostato in rotazione nei due sensi.



Una considerazione importante da fare riguarda il tipo di transistor da impiegare. Qui faremo riferimento ai MOSFET, ma una discussione simile può essere fatta quando si utilizzano i BJT. Poiché i MOSFET esistono in due versioni (tipo n e tipo p), potremmo chiederci se esiste una scelta preferenziale per i 4 MOSFET da utilizzare in questo circuito. Una scelta naturale sarebbe utilizzare due MOSFET di tipo n per la commutazione low-side (S2 e S4) e MOSFET di tipo p per la commutazione high-side (S1 e S3). Analizziamo ora il motivo di questa scelta. Nei MOSFET di tipo n la corrente scorre dal drain al source, mentre nei MOSFET di tipo p scorre dal source al drain. In entrambi i casi, lo stato dell'interruttore è controllato dalla tensione gate-source, V_{GS} . Pertanto, per rispettare la direzione naturale del flusso di corrente mostrata nella figura sopra, S1 e S3 (tipo p) dovrebbero avere i source collegati all'alimentazione DC e il drain al terminale del motore. Allo stesso modo, S2 e S4 (tipo n) dovrebbero avere il source collegato a massa e il loro drain al terminale del motore. In questa configurazione, i terminali di source di tutti gli interruttori sono a valori di tensione ben definiti e noti. Pertanto, è facile calcolare quale tensione di gate, V_G , è necessaria per ogni interruttore per accenderlo e spegnerlo, poiché:

$$V_{GS} = V_G(\text{controllata}) - V_S(\text{fissata})$$

Tuttavia, questa configurazione ha una limitazione. Infatti, se consideriamo un MOSFET di tipo n e un MOSFET di tipo p della stessa dimensione, il MOSFET di tipo n trasporterà naturalmente circa 3 volte più corrente del MOSFET di tipo p (il motivo risiede nella fisica di trasporto di carica nei MOSFET). Ciò significa che, per avere un circuito bilanciato, i MOSFET di tipo p (S1 e S3) dovrebbero essere 3 volte più grandi dei MOSFET di tipo n (S2 e S4), il che ovviamente comporta un costo aggiuntivo. Un'alternativa più economica potrebbe essere quella di implementare anche gli interruttori high-side utilizzando MOSFET di tipo n. In questo caso, S1 e S3 (ora di tipo n) dovrebbero avere i loro drain collegati all'alimentazione DC e i source ai terminali del motore. Tuttavia, ciò impedisce di calcolare quale tensione di gate, V_G , è necessaria per l'accensione e lo spegnimento di questi interruttori, poiché ora i source non sono a una tensione nota e fissa. Tuttavia, è ancora possibile aggirare questo problema pilotando i gate degli interruttori di tipo n high-side per mezzo di alcuni circuiti aggiuntivi (chiamati gate driver). Anche se questo circuito aggiuntivo ha un suo costo aggiuntivo, questa soluzione è più economica e in genere più utilizzata rispetto alla precedente.

5.7 Modulazione di Larghezza di Impulso


Qui affrontiamo una tecnica specifica che viene spesso impiegata per controllare la potenza erogata agli attuatori, chiamata Pulse Width Modulation (PWM). Da un punto di vista generale, l'obiettivo della tecnica PWM è generare un segnale ad onda quadra con duty cycle ben controllato. La tecnica PWM può essere

applicata per risolvere una varietà di problemi, tra i quali c'è il controllo della potenza media erogata a un carico quando si utilizza un transistor come interruttore, come delineato in precedenza. Qui faremo l'esempio usando un BJT, ma è possibile utilizzare qualsiasi transistor. Il sistema è composto da tre parti principali, come illustrato di seguito: un generatore di tensione a rampa, un comparatore e un interruttore. Il circuito PWM effettivo comprende solo il generatore di rampa e il comparatore, poiché l'uscita del comparatore sarà effettivamente l'onda quadra con duty cycle controllato. Il resto del circuito è infatti solo composto dall'interruttore e dal carico. Il generatore di tensione di rampa produce una tensione che aumenta linearmente nel tempo dal suo valore minimo, V_{MIN} , al suo valore massimo, V_{MAX} , per poi tornare bruscamente a V_{MIN} (avendo, appunto, una forma a rampa). Il suo periodo determina il periodo dell'onda quadra di uscita (saranno gli stessi). Questa tensione viene confrontata con una tensione di controllo, $V_{CONTROL}$, che deve essere sempre compresa tra V_{MIN} e V_{MAX} . Il valore di $V_{CONTROL}$ determina il duty cycle dell'onda quadra. Si può infatti facilmente dimostrare che il duty cycle, D , dell'onda quadra di uscita è:

$$D = \frac{V_{CONTROL} - V_{MIN}}{V_{MAX} - V_{MIN}}$$

Se, come spesso succede, $V_{MIN} = 0$ V, allora

$$D = \frac{V_{CONTROL}}{V_{MAX}}$$



Per avere un determinato valore di D , $V_{CONTROL}$ deve essere impostata a:

$$V_{CONTROL} = D(V_{MAX} - V_{MIN}) + V_{MIN}$$

che per $V_{MIN} = 0$ V si semplifica in:

$$V_{CONTROL} = DV_{MAX}$$

Questa tecnica può quindi facilmente fornire un'onda quadra con duty cycle ben controllato che a sua volta può essere utilizzata per controllare la potenza media fornita a un carico per mezzo di un interruttore di alimentazione. Quando l'onda quadra in uscita è bassa, la tensione (che viene usata per pilotare l'interruttore) è tale per cui l'interruttore sarà in stato di off.

$$P_{OFF} = 0$$

Di conseguenza non scorre corrente sul carico e la potenza dissipata sul carico è nulla. Quando invece l'onda quadra in uscita è allo stato alto, l'interruttore sarà in stato di on. Di conseguenza scorre corrente sul carico e la potenza dissipata sul carico è (trascurando la caduta di tensione sull'interruttore):

$$P_{ON} = \frac{V_S^2}{R}$$

dove V_s è la tensione di alimentazione (vedi figura sopra) e R la resistenza del carico. Poiché l'interruttore commuta tra i due stati con un duty cycle D , in media la potenza dissipata sul carico sarà:

$$P_{AVG} = DP_{ON} + (1 - D)P_{OFF} = DP_{ON} = D \frac{V_s^2}{R}$$

Si noti che questa tecnica è molto efficace, sebbene fornisca solo il controllo sulla potenza media erogata al carico e non sulla potenza istantanea (che può assumere solo due valori). Immaginiamo di avere, come carico nel circuito PWM di cui sopra, una lampadina (cioè, tutto sommato, un semplice resistore). Se impostiamo la frequenza dell'onda quadra su un valore relativamente basso (ad es. 1 Hz), vedremo la luce accendersi periodicamente (piena intensità) e spegnersi (intensità zero) quando guardiamo la lampadina. Se ora aumentiamo gradualmente la frequenza, vedremo la luce accendersi e spegnersi sempre più velocemente, fino a raggiungere una frequenza abbastanza grande tale da non poter essere seguita dai nostri occhi. Infatti, i nostri occhi "scattano" circa 25 fotogrammi al secondo, così che, se la frequenza è molto maggiore di 25 Hz, vedremo una luce continua emessa dalla lampadina (anche se tecnicamente non è ciò che accade) con un'intensità che è una frazione dell'intensità piena. Il fattore di proporzionalità è fissato dal duty cycle, che possiamo controllare in virtù delle proprietà del circuito PWM. Questo è il principio del dimmer (che permette di regolare l'intensità luminosa di alcune lampadine).

Solo per citare altre applicazioni, l'approccio PWM viene utilizzato anche per generare forme d'onda arbitrarie (cioè con forma arbitraria). In questo caso la tensione di controllo viene variata nel tempo da un microcontrollore e l'uscita del comparatore non viene fornita a un interruttore, ma viene inviata a un filtro passa basso con una frequenza di taglio inferiore alla frequenza dell'onda quadra. Questo filtro passa basso svolge un ruolo simile a quello di un filtro di ricostruzione (quello che si trova tipicamente dopo un DAC). Sebbene la maggior parte di questi concetti non siano stati introdotti in questo momento, diventeranno chiari in seguito e l'uso di PWM come generatore di forme d'onda arbitrarie sarà più chiaro e facilmente comprensibile.


6. Circuiti di Alimentazione

Un aspetto importante dei sistemi elettronici è l'alimentazione. La maggior parte dei circuiti necessita infatti di una tensione continua stabile per funzionare correttamente, dalla quale traggono l'energia necessaria per il funzionamento. Ad esempio, il circuito del ponte H che abbiamo visto prima necessita di una tensione continua stabile che deve anche essere in grado di fornire la corrente necessaria richiesta dal motore DC (e la richiesta di corrente non è costante nel tempo ma dipende dall'evoluzione dello stato degli interruttori). A questo scopo, è importante capire come sia possibile realizzare circuiti in grado di fornire in modo affidabile una tensione continua così stabile. Tipicamente, una sorgente di tensione continua si ottiene manipolando opportunamente i) sorgenti di tensione quasi continua come le batterie (che sono infatti un'approssimazione di una sorgente di tensione continua ideale fino a quando non iniziano a scaricarsi in modo significativo); ii) una sorgente di tensione alternata come quella disponibile dalla rete elettrica (in Italia è una sorgente di tensione sinusoidale a 50 Hz 230 V_{RMS}). In quest'ultimo caso, la tensione alternata viene prima convertita in una tensione quasi continua per mezzo di trasformatori (circuiti che possono abbassare o aumentare il livello di tensione) e raddrizzatori (circuiti specifici che possono trasformare una tensione alternata in una tensione quasi continua). In ogni caso, la tensione quasi continua viene poi elaborata per mezzo di circuiti specifici detti convertitori DC-DC. Come suggerisce il nome, i convertitori DC-DC sono circuiti che prendono in ingresso un segnale di tensione quasi DC (che tecnicamente potrebbe non essere proprio DC, nel senso che può mostrare una componente DC "utile" con anche del rumore sovrapposto e/o qualche disturbo o fluttuazione) e hanno in uscita un altro segnale di tensione DC (tipicamente "pulito", cioè senza rumore o disturbo). Il livello DC della tensione di uscita è tipicamente diverso da quello della tensione di ingresso ed è uno dei parametri principali da controllare. L'obiettivo dei convertitori DC-DC è infatti quello di produrre alla loro uscita una tensione continua della grandezza desiderata e caratterizzata da alcune proprietà utili. In particolare, i) indipendenza del livello di tensione continua di uscita dal carico (almeno in un determinato intervallo di possibile variazione del carico); ii) indipendenza del livello di tensione di uscita DC rispetto al livello di tensione di ingresso DC (almeno in un intervallo di tensione DC di ingresso specificato); iii) basso livello di disturbo e/o fluttuazioni in uscita (il livello basso considerato accettabile dipende dalle specifiche del circuito).

Tali soluzioni sono quindi frequentemente utilizzate per progettare circuiti di alimentazione robusti. In effetti, tutti i circuiti attivi in qualsiasi sistema elettronico devono essere alimentati con una tensione di alimentazione DC, ovvero necessitano di tensioni di polarizzazione appropriate. Quest'ultima potrebbe essere diversa per i diversi circuiti e/o sottocircuiti del sistema e deve essere opportunamente generata. Inoltre, la tensione di alimentazione per un dato sottocircuito non deve essere soggetta a variazioni e/o disturbi indesiderati. Di seguito illustriamo brevemente una tipica applicazione in cui vengono utilizzati i convertitori DC-DC: caricatori per laptop e smartphone. Questi sistemi ricevono in ingresso l'onda sinusoidale di tensione AC 50 Hz 230 V_{RMS} dalla rete (poiché sono collegati alle prese elettriche sulla parete), che viene generalmente ridimensionata utilizzando un trasformatore di tensione e rettificata (cioè trasformata in una tensione quasi continua) per mezzo di un raddrizzatore. La forma d'onda di tensione risultante può essere descritta come un segnale DC con qualche ondulazione aggiuntiva. Questo segnale viene quindi inviato a un convertitore DC-DC, che produrrà alla sua uscita una tensione DC molto stabile di 5 V senza ondulazione e che soddisfa le caratteristiche sopra descritte, ad esempio manterrà il segnale di uscita a 5 V indipendentemente dell'entità del suo carico, ovvero lo stato della batteria dello smartphone. Si noti che la batteria di uno smartphone è un buon esempio di carico variabile nel tempo, poiché la sua impedenza equivalente varierà in base al suo stato di carica (cioè se la batteria è scarica o meno). In tutti i casi, vorremmo che la nostra tensione in uscita fosse di 5 V. Il segnale di uscita del convertitore DC-DC è ora qualitativamente sufficientemente buono da poter essere utilizzato per ricaricare la batteria dello smartphone tramite un cavo USB. Si noti che il fatto che il livello di tensione in uscita debba essere 5 V è un requisito del cavo USB utilizzato

tipicamente per ricaricare gli smartphone e non è un requisito del convertitore DC-DC di per sé. In effetti, i convertitori DC-DC possono essere progettati per fornire un valore di tensione arbitrario alla loro uscita.

Un'idea preliminare per progettare un convertitore DC-DC (che però non funzionerà) sarebbe quella di utilizzare un semplice partitore di tensione, abbozzato di seguito.




In effetti, a prima vista, si direbbe che se la tensione di ingresso è effettivamente DC, anche la tensione di uscita sarà DC. Tuttavia, questo circuito non soddisfa nessuno dei requisiti dei convertitori DC-DC. Infatti, tutte le variazioni e i disturbi presenti in ingresso si riflettono linearmente in uscita, poiché la tensione di uscita è semplicemente proporzionale alla tensione di ingresso. Inoltre, l'eventuale presenza di un carico (non esplicitamente riportato nello schematico sopra) che potrebbe variare anche nel tempo influenza anche il valore della tensione continua in uscita. Infatti, abbiamo:

$$V_{out}(t) = V_{in}(t) \frac{R_2 || R_{load}(t)}{R_1 + R_2 || R_{load}(t)}$$


in cui è stata esplicitamente riportata la possibile dipendenza temporale delle tensioni di ingresso e uscita e del carico. Per progettare un convertitore DC-DC adatto, è necessaria una disposizione circuitale che produca una tensione DC alla sua uscita che sia resiliente alle variazioni della tensione di ingresso e alle possibili variazioni del carico. Tuttavia, sebbene non adatto ai nostri scopi, abbiamo introdotto in questo contesto il semplice partitore di tensione per un motivo ben preciso. In effetti, il lettore è incoraggiato a notare che, in uno scenario abbastanza idealizzato, se il resistore inferiore R_2 variasse automaticamente in modo intelligente, potrebbe effettivamente assorbire le variazioni della tensione di ingresso e le variazioni di carico per ottenere una tensione di uscita stabile e pulita. In altre parole, se R_2 non è realmente un resistore ma piuttosto un altro dispositivo la cui resistenza può effettivamente variare in modo intelligente nel tempo, allora la sua resistenza potrebbe variare in modo tale da compensare le variazioni temporali di V_{in} e R_{load} , dando un V_{out} costante. Pertanto, vorremmo sostituire R_2 con un dispositivo che può effettivamente mantenere la stessa tensione su sé stesso indipendentemente da quanta corrente scorre al suo interno (e in effetti, ciò significherebbe che la sua resistenza equivalente varia automaticamente in base alla quantità di corrente che lo attraversa). Questo è il principio base alla base della prima categoria di convertitori DC-DC affrontata in questo libretto, che va sotto il nome di regolatori lineari. Verrà affrontata anche un'altra categoria di convertitori DC-DC, che si basa però su un principio di base completamente diverso, chiamata convertitori switching. Entrambe le categorie sono ampiamente utilizzate in un'ampia varietà di applicazioni e sono caratterizzate da diversi vantaggi e svantaggi.

6.1 Regolatori Lineari

In questo sottocapitolo esploriamo la categoria dei regolatori lineari discutendo la loro struttura interna di base, e vedremo anche come funzionano alcune soluzioni commerciali basate su questa struttura (distinguendo tra regolatori fissi e regolatori variabili). L'idea principale alla base dei regolatori lineari è quella di utilizzare un diodo Zener al posto del resistore inferiore in un partitore di tensione, come riportato nella figura seguente.




Ricordiamo che il diodo Zener è una specifica tipologia di diodo appositamente progettato e costruito per funzionare nella regione di breakdown. Tipicamente, per i diodi ordinari, polarizzare il dispositivo in questa regione provocherebbe rapidamente la distruzione termica del dispositivo a causa del grande flusso di corrente inversa che porta a un'enorme dissipazione di potenza e relativo aumento di temperatura che possono fondere la struttura del dispositivo causando danni permanenti. Al contrario, i diodi Zener sono costruiti per resistere a questa grande dissipazione di potenza e sono in effetti tipicamente polarizzati in questa regione. Avere la possibilità di lavorare nella regione Zener è vantaggioso, in quanto la caratteristica I-V è localmente estremamente ripida



Come si può apprezzare dal pannello di destra della figura sopra, la caratteristica I-V del diodo Zener è tutto sommato quella del diodo ordinario. Tuttavia, mentre un diodo ordinario può funzionare senza problemi solo per tensioni positive (regione di polarizzazione diretta) e per tensioni negative relativamente piccole (regione di polarizzazione inversa), ma non per grandi tensioni negative (regione Zener o di breakdown), il diodo Zener può anche lavorare in quest'ultima regione senza problemi specifici. È interessante notare che nella regione Zener la caratteristica I-V è estremamente ripida: ciò significa che per un ampio intervallo di valori di corrente (tra i valori etichettati come $I_{z(min)}$ e $I_{z(max)}$ nella figura sopra) la tensione ai capi del diodo Zener è, in prima approssimazione, costante e uguale a $-V_z$, dove V_z è la cosiddetta tensione Zener. Esistono diodi Zener con diversi valori V_z . I due valori limite di corrente $I_{z(min)}$ e $I_{z(max)}$ esistono perché: i) se la corrente è minore (in valore assoluto) di $I_{z(min)}$, allora il diodo è polarizzato nella regione di polarizzazione inversa, non nella regione Zener, e quindi la tensione ai suoi capi cambia in modo significativo per qualsiasi variazione della corrente (la caratteristica locale è tutt'altro che ripida, anzi piuttosto piatta); ii) se la corrente è maggiore (in valore assoluto) di $I_{z(max)}$, la dissipazione di potenza diventa eccessiva e si verifica un danno permanente. Tutto sommato, il diodo Zener può funzionare approssimativamente come una batteria fornendo una tensione $-V_z$ se la corrente che lo attraversa è compresa tra $I_{z(min)}$ e $I_{z(max)}$. Si noti che nel tipico formalismo utilizzato per i diodi, che è anche quello utilizzato nella curva I-V tracciata sopra, un valore di tensione positivo significa che l'anodo è a un potenziale maggiore rispetto al catodo; corrente positiva significa che la corrente scorre dall'anodo al catodo. In questo formalismo, $I_{z(min)}$ e $I_{z(max)}$ sono negative. Tuttavia, questo formalismo può essere facilmente sovvertito nell'analisi dei circuiti, come faremo tra poco (ricordiamo che la scelta della direzione della corrente positiva - o delle tensioni positive - è arbitraria).

Il diodo Zener può quindi essere utilizzato al posto del resistore inferiore in un partitore di tensione per fornire una tensione di uscita costante, resiliente alle variazioni della tensione di ingresso (in un determinato intervallo) e nella resistenza di carico (in un determinato intervallo). Di seguito viene fornito un esempio numerico, per capire meglio come funziona il regolatore lineare basato sul diodo Zener. Supponiamo di avere un diodo Zener con $V_z = 3\text{ V}$ (ciò significa che $-V_z = -3\text{ V}$), $I_{z(\min)} = -1\text{ mA}$, e $I_{z(\max)} = -10\text{ mA}$ (ciò significa che il diodo sarà nella regione Zener se una corrente compresa tra 1 mA e 10 mA scorre dal catodo all'anodo). Supponiamo che la tensione di ingresso sia $V_{in} = 12\text{ V}$, che la resistenza serie sia $R_s = 1\text{ k}\Omega$ e che il carico sia un circuito aperto (ci riferiamo al circuito mostrato a fianco).



Attenzione: Si noti che nello schema elettrico la direzione della corrente positiva nel diodo, I_z , è stata scelta come orientata dal catodo all'anodo e che la tensione è considerata positiva se il catodo ha un potenziale maggiore dell'anodo (vedi direzione di V_z). Questo è il contrario di quanto adottato nel grafico della curva I-V, ma non deve confondere il lettore, che deve stare attento nel valutare il segno delle grandezze nel circuito e nell'analisi successiva.

Se il diodo è effettivamente polarizzato nella regione Zener, allora $V_{out} = V_z = 3\text{ V}$ e la corrente attraverso il resistore in serie sarà:

$$I_s = \frac{V_{in} - V_z}{R_s} = \frac{12\text{ V} - 3\text{ V}}{1\text{ k}\Omega} = 9\text{ mA}$$

La stessa corrente scorre anche nel diodo Zener, poiché il carico è un circuito aperto. Si noti che la direzione della corrente positiva nel diodo Zener scelta arbitrariamente nel circuito sopra è coerente con la direzione della corrente positiva nel resistore in serie ma è diretta dal catodo all'anodo, ovvero l'opposto di ciò che accade tipicamente per i diodi ordinari. Ciò significa che, secondo i calcoli precedenti, una corrente di 9 mA fluisce dal catodo all'anodo, che è un valore compreso tra $I_{z(\min)}$ e $I_{z(\max)}$. Pertanto, il diodo è effettivamente polarizzato nella regione Zener. In questo contesto, se la tensione di ingresso varia (entro un determinato intervallo) la corrente nel circuito cambierà ma, in prima approssimazione, la tensione ai capi del diodo Zener rimarrà invariata. Infatti, V_{in} può aumentare fino al punto in cui la corrente che scorre nel diodo Zener è $I_{z(\max)}$:

$$V_{in(\max)} = V_z + R_s \cdot (-I_{z(\max)}) = 13\text{ V}$$

Se V_{in} aumenta ulteriormente, la corrente nel circuito andrebbe oltre i limiti consentiti dal diodo e quindi il diodo subirebbe un danno permanente. Allo stesso modo, V_{in} può diminuire fino al punto in cui la corrente che scorre nel diodo Zener è $I_{z(\min)}$:

$$V_{in(\min)} = V_z + R_s \cdot (-I_{z(\min)}) = 4\text{ V}$$

Nel complesso, il circuito fornirà una tensione di uscita costante di 3 V DC per tensioni di ingresso comprese tra 4 V e 13 V , se il carico è un circuito aperto.

Consideriamo ora l'effetto di un carico finito $R_L = 1\text{ k}\Omega$. In questo caso, la corrente nel diodo Zener non è la stessa della corrente nel resistore in serie. In effetti, una frazione della corrente nel resistore in serie scorrerà nel carico e la frazione rimanente scorrerà sul diodo Zener. Tuttavia, se la corrente che scorre nel diodo è tale che il diodo è polarizzato nella regione Zener, la tensione d'uscita (sul carico) è costante e quindi anche la corrente nel carico è costante (per un carico costante) e uguale a V_z/R_L . Calcoliamo ora come si comporta il circuito per $V_{in} = 12\text{ V}$. In questo caso, se il diodo è nella regione Zener, $V_{out} = 3\text{ V}$, $I_L = 3\text{ mA}$, $I_s = 9\text{ mA}$, e solo 6 mA ora andranno nel diodo, quindi il suo punto di polarizzazione è cambiato a causa della presenza del carico. Tuttavia, la quantità di corrente nel diodo è tale che il diodo è ancora nella regione Zener, quindi il circuito funziona correttamente. Si noti che, alla condizione $R_L = 1\text{ k}\Omega$, cambia il range di tensione di ingresso che garantisce il corretto funzionamento rispetto al caso precedente in cui il carico era un circuito aperto.

Infatti la condizione limite per la quale scorre 1 mA nel diodo corrisponde ad un flusso di corrente nel resistore che non è 1 mA (come nel caso di un carico infinito) ma 4 mA.

$$I_{S(\min)} = -I_{Z(\min)} + \frac{V_Z}{R_L} = 1 \text{ mA} + 3 \text{ mA} = 4 \text{ mA}$$

$$V_{in(\min)} = V_Z + R_S \cdot I_{S(\min)} = 7 \text{ V}$$

Allo stesso modo, la condizione limite per cui 10 mA fluiscono nel diodo corrisponde a un flusso di corrente nel resistore che non è 10 mA (come nel caso di un carico infinito) ma piuttosto 13 mA.

$$I_{S(\max)} = -I_{Z(\max)} + \frac{V_Z}{R_L} = 10 \text{ mA} + 3 \text{ mA} = 13 \text{ mA}$$

$$V_{in(\max)} = V_Z + R_S \cdot I_{S(\max)} = 16 \text{ V}$$

Pertanto, sotto un carico finito, il range di tensione che consente il corretto funzionamento cambia rispetto allo scenario di un carico infinito. Di conseguenza, possiamo dire che il range di tensione cambia in funzione del carico. Finora abbiamo calcolato la tolleranza alle variazioni di ingresso della tensione sotto un carico fisso. Analizziamo ora la situazione opposta: quanto possono essere grandi le variazioni di carico per una tensione di ingresso fissa? Notiamo immediatamente che in queste condizioni la corrente nel resistore in serie è fissa quando il diodo Zener è effettivamente polarizzato nella regione Zener. Questa corrente si dividerà tra il diodo e il carico a seconda del valore del carico. Tuttavia, per un corretto funzionamento, almeno $-I_{Z(\min)}$ deve fluire nel diodo. Pertanto, la massima corrente che può fluire nel carico è (per il caso in cui $V_{in} = 12 \text{ V}$):

$$I_{L(\max)} = \frac{V_{in} - V_Z}{R_S} - (-I_{Z(\min)}) = 9 \text{ mA} - 1 \text{ mA} = 8 \text{ mA}$$

Questo corrisponde al valore minimo per il carico che è:

$$R_{L(\min)} = \frac{V_Z}{I_{L(\max)}} = \frac{3 \text{ V}}{8 \text{ mA}} = 375 \Omega$$

Si noti che, per il valore scelto di $V_{in} = 12 \text{ V}$, la corrente nel resistore in serie è fissata a 9 mA. Resta inteso che, per carichi maggiori di 375Ω , almeno 1 mA di questi 9 mA fluirà nel diodo e la parte rimanente nel carico. Se il carico aumenta, la corrente nel diodo aumenta mentre quella nel carico diminuisce, ma la loro somma è sempre limitata a 9 mA. Nel caso estremo di un carico infinito, la corrente nel diodo sarebbe 9 mA. Questo valore di corrente è ancora tale da polarizzare il diodo nella regione Zener. Pertanto, non esiste un limite superiore ai valori che il carico può assumere. Tuttavia, questa non è una conclusione generalizzabile. In effetti, vediamo cosa succede per un diverso valore di V_{in} , diciamo 16 V. Ora la corrente nel resistore in serie è destinata ad essere:

$$I_S = \frac{V_{in} - V_Z}{R_S} = \frac{16 \text{ V} - 3 \text{ V}}{1 \text{ k}\Omega} = 13 \text{ mA}$$

Chiaramente, questa corrente non può fluire interamente sul diodo Zener perché causerebbe il guasto del dispositivo (cioè, questo valore è maggiore di $-I_{Z(\max)}$). Pertanto, in tutti i casi esiste una corrente minima che deve essere assorbita dal carico:

$$I_{L(\min)} = \frac{V_{in} - V_Z}{R_S} - (-I_{Z(\max)}) = 13 \text{ mA} - 10 \text{ mA} = 3 \text{ mA}$$

Il valore di carico per il quale ciò accade è:

$$R_{L(\max)} = \frac{V_z}{I_{L(\min)}} = \frac{3 \text{ V}}{3 \text{ mA}} = 1 \text{ k}\Omega$$

In questo caso, se il carico supera 1 kΩ, la corrente nel carico scenderebbe al di sotto di 3 mA, forzando più di 10 mA nel diodo, compromettendo il corretto funzionamento del circuito. Pertanto, in questo caso il limite superiore per il carico non è infinito, ma di appena 1 kΩ. Naturalmente, c'è sempre un limite inferiore per il carico al di sotto del quale il diodo sarebbe attraversato da troppa poca corrente, uscendo dalla zona Zener:


$$I_{L(\max)} = \frac{V_{in} - V_z}{R_s} - (-I_{z(\min)}) = 13 \text{ mA} - 1 \text{ mA} = 12 \text{ mA}$$

$$R_{L(\min)} = \frac{V_z}{I_{L(\max)}} = \frac{3 \text{ V}}{12 \text{ mA}} = 250 \Omega$$

Pertanto, mentre per $V_{in} = 12 \text{ V}$ il range consentito per il carico è $[375 \Omega, \infty \Omega]$, per $V_{in} = 16 \text{ V}$ è molto più piccolo e pari a $[250 \Omega, 1 \text{ k}\Omega]$.

Per riassumere, i limiti dell'intervallo di tensione di ingresso consentiti cambiano se cambia il carico e i limiti dell'intervallo di carico cambiano se cambia la tensione di ingresso. Un'attenta analisi deve essere effettuata per identificare quale regione delle possibili combinazioni (V_{in} , R_L) consente il corretto funzionamento.


Uno dei risultati principali dell'analisi è che le variazioni di carico sono dannose perché perturbano il valore della corrente nel diodo. Se le variazioni di carico sono significative, lo saranno anche le variazioni di corrente nel diodo. Di conseguenza, il diodo potrebbe uscire fuori dalla regione Zener. Per mitigare ciò, una possibile soluzione è introdurre un amplificatore di corrente nel circuito. Un amplificatore di corrente è un circuito attivo che stabilisce una relazione lineare tra la corrente di ingresso e la corrente di uscita, in modo che quest'ultima sia un multiplo (grande) della prima. Ciò significa che, per un dato valore della corrente di uscita, la corrente di ingresso sarà notevolmente inferiore. Pertanto, se tra il catodo del diodo Zener e il carico viene inserito un amplificatore di corrente, le grandi variazioni di corrente risultanti dalle variazioni di carico si tradurranno in piccole variazioni di corrente nel resistore in serie, e quindi nel diodo. La soluzione è abbozzata nel pannello centrale dello schema sottostante, in cui l'amplificatore di corrente (C.A.) è evidenziato come una scatola nera. Si noti che è presente una linea tratteggiata che simboleggia l'ingresso di alimentazione dell'amplificatore. Il ruolo di questa scatola nera va visto nel modo seguente: per un dato valore di variazione di corrente richiesta dal carico è effettivamente necessaria solo una piccola frazione della stessa all'ingresso dell'amplificatore, quindi questa piccola variazione di corrente è quella che viene vista dal regolatore lineare. In altre parole, il carico visto dal regolatore non è più il carico effettivo, ma piuttosto l'ingresso dell'amplificatore di corrente, che richiede molta meno corrente. La stragrande maggioranza della corrente di carico è quindi fornita dall'amplificatore stesso. Poiché l'amplificatore non può creare energia dal nulla, la stragrande maggioranza della corrente di carico viene effettivamente erogata dalla connessione di alimentazione, quindi dalla sorgente di tensione che costituisce l'ingresso dell'intero convertitore DC-DC. L'effettiva implementazione avviene tramite un transistor bipolare a giunzione (pannello a destra dello schema seguente) e la descrizione dei dettagli del principio di funzionamento del circuito completo esula dagli scopi di questo opuscolo. Vale la pena ricordare, però, che in questo circuito la tensione erogata al carico è inferiore alla tensione Zener, per la presenza del transistor bipolare a giunzione. Tipicamente, la caduta di tensione sulla giunzione base-emettitore di questo elemento è dell'ordine di 0,6 V – 0,7 V. Questa caduta di tensione aggiuntiva deve essere presa in considerazione quando si seleziona il diodo Zener.




Il principale risultato dell'introduzione di un amplificatore di corrente può essere riassunto come segue: il valore di carico minimo scende di un fattore sostanzialmente uguale al guadagno di corrente dell'amplificatore (β nello schematico sopra). Considerazioni finali sui regolatori lineari: i) dato il loro principio di funzionamento, la tensione di uscita regolata di un regolatore lineare deve essere sempre inferiore alla tensione di ingresso; infatti, dato il valore della tensione di uscita, esiste sempre un valore minimo al di sotto del quale la tensione di ingresso non deve scendere; la differenza tra la tensione minima di ingresso e la tensione di uscita è chiamata dropout; ii) la loro efficienza energetica è limitata, poiché una potenza significativa viene sprecata sia sul resistore in serie che sul diodo (e sull'amplificatore di corrente, se presente), con solo una frazione relativamente piccola della potenza in ingresso effettivamente trasferita al carico.

6.1.1 Regolatori Fissi

I regolatori fissi sono un esempio commerciale di regolatori lineari. Sono circuiti integrati commercializzati in package a 3 terminali e sono caratterizzati da un valore di tensione di uscita fisso. I tre terminali devono essere collegati rispettivamente all'ingresso, alla massa e all'uscita. Una serie commerciale di successo è la cosiddetta 78xx, dove xx sono due cifre che possono variare e simboleggiano il valore della tensione di uscita, come risulta dalla tabella sottostante. Ogni componente ha anche un dato dropout, che si riflette nella tensione di ingresso minima esplicitamente riportata nella scheda tecnica del componente. Nella scheda tecnica, il produttore suggerisce anche il modo ottimale per disporre l'IC in una scheda, accoppiando il regolatore con alcuni condensatori per garantire la reiezione di possibili disturbi. Una caratteristica specifica di questi regolatori è che il secondo terminale (detto "gnd") deve infatti essere collegato a massa. La circuiteria interna funzionerà in modo tale da mantenere fissa e stabile la differenza di tensione tra il terminale di uscita e il terminale "gnd".



6.1.2 Regolatori Variabili



I regolatori variabili (o regolabili) sono molto simili ai regolatori fissi, ma mostrano una notevole differenza. Il secondo terminale (ora chiamato “adjust” invece di “gnd”) non deve essere necessariamente collegato a massa. Un circuito integrato commerciale abbastanza noto di questa famiglia è l'LM317. Proprio come un regolatore fisso, anche il regolatore variabile lavora per mantenere fissa la differenza di tensione tra il terminale di uscita e il terminale di “adjust”. Tuttavia, la possibilità di collegare il terminale “adjust” a punti del circuito non a 0 V apre interessanti prospettive, come la possibilità di regolare il valore della tensione di uscita, da cui il nome regolatore regolabile. Inoltre, il circuito interno garantisce che la corrente che esce dal terminale “adjust”, I_{adj} , sia piccola e costante, tipicamente dell'ordine di 100 μA o meno.

Ad esempio, l'LM317 sviluppa e mantiene una differenza nominale di 1,25 V tra la sua uscita e il terminale di “adjust”. Con riferimento allo schema elettrico sopra, questa tensione viene convertita in una corrente da R_1 , e questa corrente costante scorre anche attraverso R_2 verso massa.

$$I_1 = \frac{1.25 \text{ V}}{R_1}$$



$$V_{out} = (I_1 + I_{adj})R_2 + 1.25 \text{ V} = \frac{1.25 \text{ V}}{R_1} R_2 + I_{adj} R_2 + 1.25 \text{ V}$$

$$V_{out} = 1.25 \text{ V} \left(1 + \frac{R_2}{R_1} \right) + I_{adj} R_2$$

In questo modo, scegliendo R_2 come resistore variabile (un reostato, o un potenziometro), possiamo regolare il valore di V_{out} . Poiché la corrente generata dal terminale “adjust” è in genere molto più piccola della corrente in R_1 , il secondo termine del secondo membro dell'equazione sopra può essere trattato come un termine di errore e può essere trascurato (oppure preso in considerazione se è necessaria una regolazione extra-fine di V_{out}). Tipicamente, infatti, R_1 viene scelto per soddisfare questo vincolo.

Si tenga presente che nei regolatori variabili è possibile il funzionamento ad alte tensioni (rispetto a massa), contrariamente al caso dei regolatori fissi. Quello che si deve infatti garantire è che la differenza di tensione tra il terminale di ingresso e il terminale di “adjust” sia tollerabile. Tuttavia, possono essere entrambi molto maggiori di 0 V. Ad esempio, il funzionamento con $V_{in} = 300 \text{ V}$ e $V_{out} = 295 \text{ V}$ è perfettamente fattibile, mentre questo non è il caso dei regolatori fissi. Infatti, la differenza di tensione tra i terminali di ingresso e di “adjust” sarebbe di appena 6,25 V, ben tollerato dall'LM317 (per maggiori informazioni vedere la sua scheda tecnica).

6.1.3 Regolatori Low-Dropout



I regolatori a bassa caduta di tensione sono una categoria particolare di regolatori lineari che includono nei loro circuiti interni alcuni componenti extra, come un MOSFET di potenza e un amplificatore differenziale. Con riferimento allo schema sopra, l'ingresso negativo dell'amplificatore differenziale controlla la frazione della tensione di uscita determinata dal partitore di tensione implementato da R_1 e R_2 , e rilevata al terminale di "adjust". L'ingresso positivo all'amplificatore differenziale è collegato a un riferimento di tensione interno stabile (riferimento "bandgap"). Se la tensione di uscita aumenta troppo rispetto alla tensione di riferimento, l'amplificatore differenziale rileverà un ingresso differenziale più elevato e piloterà il MOSFET di potenza che a sua volta agirà in modo tale da mantenere una tensione di uscita costante. Il vantaggio principale di questi regolatori è che assicurano che il dropout sia basso quanto la tensione di saturazione del transistor, che può essere anche di poche centinaia di millivolt. Il loro svantaggio è l'aumento del costo.


6.2 Convertitori a Commutazione (switching)

Un convertitore DC-DC a commutazione agisce immagazzinando periodicamente l'energia in ingresso e quindi rilasciandola all'uscita a una tensione diversa. L'energia viene tipicamente immagazzinata in un campo magnetico (cioè in un componente come un induttore o un trasformatore) o in un campo elettrico (cioè in un componente come un condensatore). I convertitori basati su trasformatore forniscono anche l'isolamento tra l'ingresso e l'uscita. I convertitori switching offrono due vantaggi principali rispetto ai regolatori lineari: i) l'efficienza di conversione della potenza è molto più elevata; ii) l'energia immagazzinata da un induttore in un regolatore a commutazione può essere trasformata in tensioni di uscita che possono essere inferiori all'ingresso (step-down o buck) o maggiori dell'ingresso (step-up o boost). Tuttavia, presentano anche alcuni svantaggi: i) sono molto più rumorosi; ii) richiedono la gestione sotto forma di un circuito di controllo, sebbene i moderni chip di controllo semplifichino il compito di controllo.

In sostanza, un convertitore DC-DC a commutazione utilizza un interruttore, un induttore, un diodo e un condensatore per trasferire l'energia dall'ingresso all'uscita. Questi possono essere organizzati in vari modi, due dei quali verranno affrontati di seguito.

6.2.1 Convertitore Buck

Il convertitore buck (o step-down) è un regolatore a commutazione caratterizzato dal fatto che la tensione di uscita può essere regolata ma sarà sempre inferiore alla tensione di ingresso, da cui il nome step-down. È composto da quattro elementi: un interruttore, un induttore, un diodo e un condensatore. Nello schema riportato di seguito è inclusa anche una resistenza, che rappresenta il carico.




I convertitori buck sono semplici, robusti e molto efficienti (in genere la loro efficienza, η , è maggiore del 90%), in quanto quasi tutta l'energia disponibile in ingresso viene trasferita all'uscita. Tuttavia, sono meno precisi e più rumorosi dei regolatori lineari. Inoltre, fanno uso di un induttore ingombrante.

Il principio di funzionamento del circuito si basa sulla commutazione periodica dell'interruttore tra gli stati di accensione e spegnimento. L'interruttore è quindi pilotato da un segnale periodico, ovvero un'onda quadra con periodo T (cioè frequenza $f = 1/T$) e duty cycle D .

$$T = \frac{1}{f} = T_{on} + T_{off} \quad , \quad \text{duty cycle} = D = \frac{T_{on}}{T} \quad \text{dove} \quad 0 \leq D \leq 1$$


Pertanto, possiamo scrivere (come illustrato anche nella figura seguente):

$$T_{on} = DT \quad \text{and} \quad T_{off} = (1 - D)T$$



Per comprendere il comportamento del circuito e come riesce ad eseguire la conversione step-down, è istruttivo eseguire analisi separate per i due stati dell'interruttore. Di seguito, assumeremo che l'induttore, il condensatore, l'interruttore e il diodo siano tutti ideali. Inoltre, supponiamo che V_{IN} sia DC e positiva, e facciamo l'ulteriore ipotesi (da verificare) che anche V_{OUT} sia DC e positiva.

Quando l'interruttore è nello stato di ON, la tensione di ingresso cade interamente sul diodo (dal catodo all'anodo) che è quindi polarizzato inversamente e si comporta come un circuito aperto e la corrente non può fluire in esso.



La caduta di tensione sull'induttore è:


$$V_L = V_{IN} - V_{OUT} = \text{tensione DC} > 0 \quad V_L = L \cdot \frac{dI_L}{dt}$$

Pertanto, poiché V_L è costante nel tempo e positiva, la corrente nell'induttore, I_L , aumenta linearmente nel tempo. Questa condizione non specifica di per sé quale sia il valore iniziale della corrente nell'induttore (al momento dell'accensione dell'interruttore). In generale, etichettiamo questo valore iniziale come I_{min} .

Pertanto, l'aumento della corrente nell'induttore durante il periodo di accensione può essere calcolato integrando l'equazione di cui sopra nel tempo da $t = 0$ fino a $t = T_{on} = DT$:

$$\Delta I_{L,on} = \int_0^{T_{on}} \frac{V_L}{L} dt = \frac{(V_{IN} - V_{OUT})}{L} \cdot T_{on} = \frac{(V_{IN} - V_{OUT})}{L} \cdot DT$$

Nello stato di OFF l'interruttore è aperto e la parte sinistra del circuito è isolata. La corrente che scorre attraverso l'induttore si divide tra il carico e il condensatore e quindi ricircola attraverso il diodo (chiamato diodo di ricircolo). Ciò implica che il diodo sia acceso e che si comporti (in prima approssimazione) come un cortocircuito, bloccando effettivamente a 0 V il terminale sinistro dell'induttore.



La tensione sull'induttore è quindi:

$$V_L = 0 - V_{OUT} = \text{tensione DC} < 0 \quad V_L = L \cdot \frac{dI_L}{dt}$$

In questo caso, la tensione costante ai capi dell'induttore è negativa, il che implica che la corrente nell'induttore diminuirà linearmente. Attenzione: questo NON significa che la corrente cambia segno! La corrente nell'induttore scorre sempre da sinistra verso destra. La diminuzione della corrente nell'induttore durante il periodo di spegnimento può essere calcolata integrando l'equazione sopra da $t = T_{on} = DT$ fino a $t = T_{on} + T_{off} = T$:

$$\Delta I_{L,off} = \int_{T_{on}}^{T_{on}+T_{off}} \frac{V_L}{L} dt = -\frac{V_{OUT}}{L} \cdot T_{off} = -\frac{V_{OUT}}{L} \cdot (1 - D) \cdot T$$


Tutto sommato, durante un periodo di commutazione (che dura per un intervallo di tempo = T) la corrente nell'induttore parte da I_{min} , aumenta linearmente quando l'interruttore è acceso fino ad un valore massimo I_{max} , per poi diminuire linearmente quando l'interruttore è spento. Facciamo ora l'ipotesi della condizione di "stato stazionario": l'energia magnetica accumulata nell'induttore durante lo stato acceso viene interamente rilasciata dall'induttore durante lo stato spento. Pertanto, durante un intero ciclo di commutazione l'induttore non accumula energia netta. In queste condizioni, l'incremento di corrente nello stato acceso deve corrispondere alla diminuzione della corrente nello stato spento. Pertanto, durante lo stato spento la corrente nell'induttore scende da I_{max} a I_{min} (questo implica che all'inizio di ogni ciclo la corrente nell'induttore sarà sempre I_{min}). Inoltre, per il momento stiamo implicitamente supponendo che la corrente I_{min} sia positiva, e quindi che la corrente nell'induttore non vada mai a zero. Ciò significa infatti che il processo di scarica dell'induttore dura effettivamente per l'intera durata dello stato off. Pertanto, otteniamo:

$$\Delta I_{L,on} + \Delta I_{L,off} = 0 \rightarrow \frac{(V_{IN} - V_{OUT})}{L} \cdot DT = \frac{V_{OUT}}{L} \cdot (1 - D) \cdot T \rightarrow D = \frac{V_{OUT}}{V_{IN}}$$

Poiché D è un numero reale compreso tra 0 e 1, se la tensione di ingresso è DC (una delle nostre ipotesi), anche la tensione di uscita è DC e l'ipotesi iniziale è confermata. È evidente che la tensione di uscita può essere regolata scegliendo opportunamente il valore del duty cycle. È interessante notare che otteniamo una relazione molto semplice tra la tensione di ingresso e quella di uscita, essendo D l'unico parametro che regola la loro relazione; gli altri parametri del circuito (ad esempio la capacità del condensatore, l'induttanza


dell'induttore, il carico, la frequenza di commutazione) non svolgono, in prima approssimazione, alcun ruolo. Questo è un vantaggio molto interessante, poiché indica una forte stabilità della tensione di uscita rispetto alle variazioni di carico. Notiamo anche che, poiché D è un numero compreso tra 0 e 1, è possibile solo che la tensione di uscita sia inferiore o uguale alla tensione di ingresso. Tuttavia, l'equazione di cui sopra suggerisce che la tensione di uscita sarà influenzata dalle variazioni della tensione di ingresso se D viene mantenuto costante. Pertanto, per rendere il circuito resiliente alle variazioni della tensione di ingresso, dobbiamo includere un circuito di controllo ad anello chiuso (non mostrato) che in qualche modo misuri la tensione di uscita e controlli il duty cycle dell'interruttore in modo da mantenere la tensione di uscita al livello desiderato.

Nel diagramma seguente è mostrato il comportamento nel tempo dello stato dell'interruttore, la tensione di uscita (V_o , linea blu), la tensione di ingresso (V_i , linea nera tratteggiata), la tensione ai capi del diodo (V_d , linea nera continua), la tensione sull'induttore (V_L , linea rossa) e la corrente nell'induttore.



Si noti che, se la tensione di uscita (cioè la tensione ai capi del carico) è costante, anche la corrente nel carico deve essere costante (supponendo appunto un carico resistivo). Tuttavia, attraverso l'induttore scorre una corrente variabile nel tempo (che periodicamente aumenta e diminuisce) che è la somma della corrente attraverso il carico e attraverso il condensatore. Pertanto, la corrente nell'induttore può essere vista come composta da due componenti: la media temporale (I_{av} nel grafico sopra, che corrisponde alla corrente costante che scorre attraverso il carico) e le deviazioni da essa, che possono essere negative (quando il carico necessita di più corrente di quella attualmente fornita dall'induttore – in questo caso la corrente extra è data dal condensatore) o positiva (la corrente nell'induttore è maggiore di quella richiesta dal carico, e la corrente extra carica il condensatore). Di conseguenza, durante il normale funzionamento c'è una corrente variabile nel tempo nel condensatore che è a volte positiva e a volte negativa. Nello specifico è negativa (cioè il condensatore si scarica e fornisce corrente al carico insieme all'induttore) durante la parte iniziale dello stato acceso, quando I_L è minore di I_{av} ; è positiva (cioè il condensatore si carica ed è alimentato dall'induttore) durante la parte finale dello stato acceso, quando I_L è maggiore di I_{av} ; è di nuovo positiva (cioè il condensatore si carica ed è alimentato dall'induttore) durante la parte iniziale dello stato off, quando I_L è maggiore di I_{av} ; è di nuovo negativa (cioè il condensatore si scarica e fornisce corrente al carico insieme all'induttore) durante la parte finale dello stato off, quando I_L è inferiore a I_{av} . Si può però notare un'incongruenza: come mai la tensione di uscita è sempre costante, mentre il condensatore si carica e si scarica? Dopotutto, se il condensatore si carica e si scarica, la tensione ai suoi capi (che è la stessa della tensione di uscita) dovrebbe aumentare e diminuire, rispettivamente. In effetti, questo è esattamente ciò che accade. In conseguenza della dinamica della corrente nel circuito, la tensione di uscita non è perfettamente costante nel tempo ma presenta delle ondulazioni, dovute ai processi di carica e scarica capacitiva. Per ridurre al minimo

l'ondulazione (chiamata ripple), la capacità del condensatore viene scelta sufficientemente grande, poiché una capacità maggiore implica minori variazioni di tensione per la stessa corrente (poiché $I = C \, dV/dt$). Tuttavia, una grande capacità richiede in genere un condensatore ingombrante e costoso. Una soluzione al problema sta nell'aumentare la frequenza di commutazione: così facendo, il condensatore ha meno tempo per caricarsi e scaricarsi, il che riduce il ripple. Allo stesso modo, aumentando la frequenza di commutazione, si può scegliere un condensatore più piccolo a parità di ripple sulla tensione in uscita. Lo svantaggio è che commutare l'interruttore a frequenze più alte aumenta il rumore prodotto dall'interruttore e anche le perdite di potenza (come discusso più avanti), diminuendo quindi l'efficienza energetica del circuito.



Discutiamo ora cosa succede se una delle ipotesi che abbiamo fatto non viene soddisfatta. Nello specifico, nel derivare la semplice relazione tra D , V_{out} e V_{in} abbiamo supposto implicitamente che la corrente I_{min} fosse positiva, e quindi che la corrente nell'induttore non andasse mai a zero. Si noti che un I_{min} più grande significa anche, in generale, un I_{av} più grande. Ricordiamo inoltre che I_{av} è la corrente che scorre nel carico, data anche dal rapporto tra la tensione di uscita e la resistenza del carico. Pertanto, finché la resistenza del carico è sufficientemente bassa (cioè, alla tensione di uscita nominale fornita dal convertitore il carico richiede una corrente elevata), allora I_{av} sarà grande e I_{min} sarà probabilmente maggiore di zero, il che verifica la nostra ipotesi. Tuttavia, quando il carico diventa sufficientemente piccolo, la corrente richiesta dal carico (a una tensione di uscita fissa) diminuirà in modo significativo, portando I_{min} pericolosamente vicino a zero. Cosa succede quando effettivamente I_{min} va a zero? La situazione è mostrata nel pannello di destra della figura sopra. In questo caso la corrente nell'induttore durante lo stato spento scende da I_{max} a I_{min} (che è zero) in un tempo che non è necessariamente uguale all'intera durata dello stato spento T_{off} , ma che è in genere inferiore. In questo caso, sebbene la condizione $\Delta I_{L,on} + \Delta I_{L,off} = 0$ sia ancora verificata, il secondo termine del primo membro deve essere calcolato come segue:

$$\Delta I_{L,off} = \int_{T_{on}}^{T_{on} + \delta T} \frac{V_L}{L} dt$$

dove δT è il tempo effettivo in cui avviene la scarica dell'induttore (che è inferiore a T_{off}). Il calcolo di questo integrale esula dallo scopo di questo opuscolo. Tuttavia, così facendo e includendo il risultato nell'equazione $\Delta I_{L,on} + \Delta I_{L,off} = 0$ si ottiene un'equazione molto più complicata della semplice $D = V_{out}/V_{in}$. In realtà, l'equazione che si ottiene (non mostrata) evidenzia che in questo caso la relazione tra V_{out} e V_{in} dipende non solo da D , ma anche da tutti i restanti parametri del circuito, come C , L , f , e così via. Questo è ovviamente uno svantaggio, poiché in questo scenario la regolazione della tensione di uscita diventa molto più complicata.

Possiamo quindi identificare due modalità di funzionamento per questo tipo di circuito. Il primo è quello in cui la corrente nel carico è abbastanza grande perché la corrente nell'induttore sia sempre positiva. In questo caso la tensione di uscita (per un dato valore di tensione di ingresso) dipende solo da D ed è indipendente

dalle variazioni del carico. Questa modalità è etichettata come "modalità continua". Il secondo è quello in cui la corrente nel carico è abbastanza piccola da portare a zero la corrente nell'induttore. In questo caso la tensione di uscita (per un dato valore di tensione di ingresso) dipende da D e da molti altri fattori, comprese le variazioni di carico. Questa modalità è etichettata come "modalità discontinua". Il pannello di sinistra nella figura sopra (in cui è riportata la tensione di uscita normalizzata V_{out}/V_{in} rispetto alla corrente di uscita normalizzata I_L/I_{max}) evidenzia il confine tra le due modalità di funzionamento. È evidente che, per valori di corrente di carico sufficientemente grandi, la tensione di uscita (per un valore fisso della tensione di ingresso) dipende solo da D ed è insensibile alle variazioni del carico (cioè variazioni della corrente nel carico), mentre per un carico sufficientemente piccolo la tensione di uscita (per un valore fisso della tensione di ingresso) dipende anche delle variazioni del carico. Tuttavia, si noti che la modalità discontinua mostra anche alcuni vantaggi ed è talvolta particolarmente ricercata. Infatti, in questa regione i) il circuito raggiunge la massima efficienza (fino a oltre il 98%) in quanto le perdite di energia sono inferiori; ii) tipicamente l'induttore può essere scelto più piccolo (poiché la corrente che lo attraversa è minore) e quindi meno ingombrante.


Infine, possiamo fare alcune considerazioni sull'efficienza energetica di questo circuito. In teoria, se tutti i componenti sono considerati come ideali, l'efficienza energetica è del 100%. Tuttavia, quando si considerano le non idealità dei componenti, l'efficienza diminuisce. Le perdite di energia sono principalmente legate a (vedi tabella sotto):

- La caduta di tensione diversa da zero sul diodo durante lo stato acceso (ridotta utilizzando il diodo Schottky);
- La resistenza diversa da zero dell'interruttore nello stato acceso (è necessario un interruttore a bassa resistenza);
- La dissipazione di potenza diversa da zero nell'interruttore alle transizioni off/on e on/off (maggiore per alte frequenze);
- La resistenza in serie del condensatore e dell'induttore.

Cause	Power Lost
Diode	$P_D = V_D I_{L(off)} (1 - D)$
Switch on resistance	$P_{on} = I_{L(on)(rms)}^2 R_{on} D$
Inductor DCR	$P_L = \left(I_{out}^2 + \frac{\Delta I_L^2}{12} \right) R_L$
Input Capacitor ESR	$P_{C_{in}} = D \left(I_{out}^2 (1 - D) + \frac{\Delta I_L^2}{12} \right) R_C$
Output Capacitor ESR	$P_{C_{out}} = \frac{\Delta I_L^2}{12} R_C$
Transistor switching	$P_{SW} + P_G = (V I_{L(on)} (t_{rise} + t_{fall}) + Q_G V_{GS}) f_{SW}$

6.2.2 Convertitore Boost

Questo circuito è il gemello del convertitore Buck (costituito dagli stessi componenti, ma disposti in modo diverso – si veda il pannello di sinistra della figura sotto). Funziona in modo simile e il suo comportamento è facile da capire se il comportamento del convertitore Buck è ben compreso. La differenza principale rispetto al convertitore Buck è che il Boost realizza una conversione step-up, il che significa che la tensione di uscita sarà sempre maggiore della tensione di ingresso. Questa è una caratteristica specifica che non può essere ottenuta con i regolatori lineari. Attenzione che, in tutti i casi e sia per il convertitore Buck che per quello Boost, la potenza in uscita sarà sempre inferiore (idealmente uguale) alla potenza in ingresso. Proprio come il Buck, il Boost è molto efficiente (tipicamente $\eta > 90\%$).



Come nel caso del convertitore Buck, eseguiamo analisi separate per gli stati di accensione e spegnimento dello switch e riteniamo che tutti i componenti siano ideali. Facciamo anche l'ipotesi che sia la tensione di ingresso che quella di uscita siano DC e positive (con la tensione di uscita maggiore della tensione di ingresso). I circuiti equivalenti sono riportati nei pannelli di destra della figura sopra. Quando l'interruttore è chiuso (stato acceso), il terminale sinistro del diodo è bloccato dall'interruttore a 0 V, mentre il suo terminale destro è a una tensione positiva (V_{OUT}). Pertanto, il diodo è spento e la parte sinistra del circuito è scollegata elettricamente dal carico e dal condensatore. In questo regime, l'induttore viene caricato dalla sorgente di tensione in ingresso, mentre la corrente al carico è interamente fornita dal condensatore. Questa è una differenza significativa rispetto al convertitore Buck, in cui (almeno in modalità continua) la corrente nel carico non è mai fornita solo dal condensatore ma c'è sempre una componente fornita dall'induttore. In queste condizioni:

$$V_L = V_{IN} \text{ tensione DC fissa} > 0 \quad V_L = L \cdot \frac{dI_L}{dt}$$

La corrente nell'induttore aumenta linearmente (supponiamo ancora una volta che la corrente iniziale nell'induttore abbia un valore generico di I_{min}):

$$\Delta I_{L,on} = \int_0^{T_{on}} \frac{V_L}{L} dt = \frac{V_{IN}}{L} \cdot T_{on} = \frac{V_{IN}}{L} \cdot DT$$

Quando l'interruttore è aperto (stato spento), il diodo è polarizzato in diretta e si comporta come un cortocircuito. Pertanto, la tensione ai capi dell'induttore sarà costante e negativa (poiché la tensione di uscita è maggiore della tensione di ingresso):

$$V_L = (V_{IN} - V_{OUT}) = \text{tensione DC fissa} < 0 \quad V_L = L \cdot \frac{dI_L}{dt}$$

Pertanto, la corrente nell'induttore diminuisce linearmente:


$$\Delta I_{L,off} = \int_{T_{on}}^{T_{on}+T_{off}} \frac{(V_{IN} - V_{OUT})}{L} dt = \frac{(V_{IN} - V_{OUT})}{L} \cdot T_{off} = \frac{(V_{IN} - V_{OUT})}{L} \cdot (1 - D)T$$

Come abbiamo fatto nel caso del convertitore Buck, facciamo l'ipotesi della condizione di "stato stazionario":

$$\Delta I_{L,on} + \Delta I_{L,off} = 0 \rightarrow \frac{V_{IN}}{L} \cdot DT + \frac{(V_{IN} - V_{OUT})}{L} \cdot (1 - D)T = 0 \rightarrow \frac{V_{OUT}}{V_{IN}} = \frac{1}{1 - D}$$

Anche in questo caso otteniamo una relazione molto semplice tra la tensione di ingresso e quella di uscita, regolata solo da D. Come nel caso del convertitore Buck, se la tensione di ingresso è DC, anche la tensione di uscita è DC. In particolare, poiché D è un numero compreso tra 0 e 1, la tensione di uscita è in realtà sempre maggiore di quella di ingresso, confermando la nostra ipotesi iniziale.


Nel diagramma seguente è mostrato il comportamento nel tempo dello stato dell'interruttore, la tensione di uscita (V_o , linea blu), la tensione di ingresso (V_i , linea nera tratteggiata), la tensione sull'interruttore (V_s , linea nera continua), la tensione sull'induttore (V_L , linea rossa), la corrente nell'induttore (I_L , linea nera), la corrente nel diodo (I_D , linea blu) e la corrente nell'interruttore (I_s , linea rossa).



Si noti che, nello stato acceso, nessuna frazione della corrente nell'induttore scorre nel carico. La corrente nel carico (costante per tensione di uscita costante e carico costante) è interamente erogata dal condensatore (che infatti si scarica effettivamente, diminuendo quindi realmente la tensione di uscita e provocando un certa ripple nella tensione di uscita). Durante lo stato spento, la corrente nell'induttore (che è uguale a quella nel diodo) è probabilmente maggiore di quella richiesta dal carico. Pertanto, una parte della corrente dell'induttore passerà attraverso il carico mentre la parte rimanente ricaricherà il condensatore. Alla fine, durante lo stato spento, la corrente nell'induttore scenderà al di sotto della corrente richiesta dal carico. A questo punto, l'intera corrente dell'induttore attraverserà il carico, insieme a un po' di corrente proveniente dal condensatore (che fornirà infatti la corrente extra che l'induttore non è in grado di fornire). Analoghe considerazioni sulle modalità di conduzione continua e discontinua, e sulle principali fonti di perdita di efficienza energetica valgono per il caso del convertitore Boost.

6.2.3 Convertitore Bidirezionale

Tutti i convertitori switching studiati finora trasferiscono energia solo in una direzione (da ingresso a uscita). Tuttavia, in alcune applicazioni è altamente auspicabile disporre di convertitori DC-DC bidirezionali, come, ad esempio, negli azionamenti per motori DC, nell'accumulo di energia nei sistemi di energia rinnovabile (ad esempio, circuiti di gestione per pannelli solari), celle a combustibile e frenata rigenerativa dove l'energia deve fluire dalle ruote dell'auto alle batterie e viceversa. Pertanto, vale la pena spendere qualche parola su di loro.



La struttura di base del convertitore DC-DC bidirezionale, mostrata sopra, rispecchia quella del convertitore Buck, con il diodo sostituito da un secondo interruttore sincronizzato con il primo in modo che lavorino in mutua esclusione (quando il primo è aperto il secondo è chiuso e viceversa). Sostanzialmente l'idea è che il secondo interruttore possa sostituire il diodo svolgendo esattamente lo stesso ruolo, ma, a differenza del diodo, possa consentire il flusso di corrente in entrambe le direzioni, consentendo quindi il flusso di energia anche dal carico alla sorgente di tensione di ingresso.

7 Conversione A/D e D/A

7.1 Conversione Analogico/Digitale

Il processo di conversione da analogico a digitale ha lo scopo di tradurre segnali analogici, segnali del mondo reale come temperatura, pressione, tensione, corrente, distanza o intensità della luce, in una rappresentazione digitale di quel segnale. Questa rappresentazione digitale può quindi essere elaborata, manipolata, calcolata, trasmessa o archiviata da specifico hardware digitale. Per comprendere i dettagli del processo è indispensabile comprendere alcune caratteristiche distinte della rappresentazione analogica e digitale di un segnale.

Segnale analogico: è un segnale continuo a valore reale, cioè definito con precisione arbitraria (il segnale può assumere in un dato istante di tempo uno degli infiniti valori possibili). Il fatto che un segnale analogico sia continuo e a valore reale significa che è continuo nel suo dominio (è definito in ogni istante di tempo) e che il suo valore in un dato istante di tempo è un numero reale (in generale è definito con precisione arbitraria, il che significa che potremmo aver bisogno di un numero infinito di cifre per specificarlo pienamente).


Segnale digitale: è un segnale discreto a valore binario, cioè definito con precisione fissa (il segnale può assumere in un dato istante di tempo uno di due soli valori possibili). Il fatto che un segnale digitale sia discreto e a valore binario significa che è discreto nel suo dominio (è definito solo in precisi istanti di tempo) e che il suo valore può essere scritto con un numero finito di cifre binarie (es. sequenza di 0 e 1).

Da quanto sopra sintetizzato risulta evidente che la conversione da analogico a digitale deve comportare un insieme di operazioni tali da interrompere la continuità temporale, cioè prendiamo un segnale che è definito in ogni istante e lo traduciamo in segnale definito solo in precisi istanti di tempo. Questo può essere fatto prendendo "istantanee" del segnale analogico in istanti di tempo predeterminati (quelli in cui vogliamo che sia definita la rappresentazione digitale del segnale) scartando ciò che accade nel mezzo. Inoltre, dobbiamo ridurre la precisione di rappresentazione del valore del segnale da arbitrario (cioè infinito) a un valore finito. Infine, i valori (ora a precisione finita) devono essere esplicitamente codificati in base 2 (cioè in forma binaria). Nello specifico, ciò avviene mediante tre operazioni sequenziali denominate campionamento, quantizzazione e codifica, che costituiscono la base della conversione da analogico a digitale. Un punto cruciale dell'intera conversione da analogico a digitale è mantenere inalterate le informazioni. Ciò significa che vorremmo escogitare una strategia che permetta di cambiare la rappresentazione del segnale da analogico a digitale (e anche da digitale ad analogico) in modo tale che le informazioni contenute nelle due rappresentazioni siano le stesse. Deve quindi essere possibile prendere un segnale analogico, convertirlo nel suo equivalente digitale, e poi riconvertirlo nella rappresentazione analogica (quest'ultimo segnale deve essere identico a quello iniziale). Come vedremo in seguito, ciò è possibile solo se vengono soddisfatti alcuni vincoli.

7.1.1 Campionamento

Il processo di campionamento è il primo passo della conversione da analogico a digitale e il suo scopo è quello di "scattare istantanee" del segnale analogico in ingresso. In altre parole, l'operazione di campionamento produrrà idealmente un segnale di uscita (segnale campionato) che è definito solo in predeterminati istanti di tempo, preservando il valore del segnale analogico in ingresso in quegli istanti di tempo. Il segnale campionato (ideale) può essere immaginato come una serie di impulsi di durata zero (cioè matematicamente delle delta di Dirac) chiamati campioni, ciascuno dei quali rappresenta l'ampiezza del segnale in un dato momento. Pertanto, il segnale campionato non è continuo nel tempo ma è ancora a valore reale. Idealmente, vorremmo prendere singoli punti (di durata infinitesimale) a intervalli di tempo a spaziatura costante. La durata di questo intervallo è chiamata periodo di campionamento o tempo di campionamento e la frequenza di campionamento è definita come il suo reciproco. Nella figura seguente è possibile apprezzare l'aspetto di

un segnale campionato ideale. La figura a sinistra mostra un segnale analogico arbitrario (curva verde) che rappresenta il segnale che vogliamo campionare. Scegliamo un tempo di campionamento uguale a T e consideriamo solo i punti del segnale a multipli interi di T (punti blu), scartando tutti i punti rimanenti. Ad ogni punto considerato posizioniamo una delta di Dirac avente un'ampiezza uguale all'ampiezza del segnale analogico in quel punto (barre verticali blu).




Il segnale campionato è l'insieme di tutte queste delta di Dirac. Un altro esempio è mostrato nel pannello di destra con il segnale di ingresso analogico mostrato in blu e il segnale campionato mostrato in rosso. Intuitivamente, più campioni prendiamo in un dato periodo di tempo (cioè più breve è il tempo di campionamento), più la forma complessiva del segnale campionato in uscita rifletterà quella del segnale in ingresso. Questo perché il segnale campionato non è definito tra due punti di campionamento consecutivi (quindi non è definito per la maggior parte del tempo) e tutta la dinamica del segnale analogico che si verifica nel mezzo viene scartata. Tuttavia, nei circuiti reali non è possibile produrre un segnale campionato ideale come quelli mostrati nella figura sopra perché:

- Non è praticamente possibile produrre una perfetta delta di Dirac a durata temporale nulla;
- Anche se immaginiamo di avere una “scatola nera” in grado di produrre in qualche modo un perfetto segnale delta di Dirac, dovremmo definire l'ampiezza di ciascun segnale delta in modo molto preciso (deve essere uguale all'ampiezza del segnale analogico in ingresso ad un momento ben definito). Ciò implica che dobbiamo in qualche modo misurare l'ampiezza del segnale di ingresso in un singolo momento. Tuttavia, questo non è possibile, poiché quando misuriamo l'ampiezza di un segnale dobbiamo sempre misurarlo per una durata temporale diversa da zero (anche se molto piccola), il che significa che la durata della misura non può essere zero. Ciò introduce il cosiddetto errore di apertura;
- Idealmente il periodo di campionamento dovrebbe rimanere sempre costante, cioè i campioni devono essere tutti prelevati a multipli interi del tempo di campionamento. Tuttavia, nei circuiti reali non è possibile controllare i tempi dell'operazione con precisione arbitraria. Ciò significa che la distanza temporale tra due campioni consecutivi sarà solo approssimativamente sempre uguale al tempo di campionamento, con una certa incertezza casuale (errore di jitter).

Sebbene possa sembrare impossibile preservare l'intera informazione del segnale di ingresso analogico se scartiamo quasi tutti i suoi punti, vedremo nel seguente sottocapitolo che effettivamente è possibile, a condizione che sia verificato un criterio specifico, chiamato teorema di Shannon-Nyquist. Nello specifico, questo teorema pone un vincolo sulla scelta del tempo di campionamento per un campionamento corretto (cioè, per eseguire un'operazione di campionamento che conservi effettivamente tutte le informazioni del segnale analogico in ingresso).

7.1.2 Aliasing


In questo sottocapitolo discutiamo il teorema di Shannon-Nyquist insieme alle sue conseguenze, in particolare il fenomeno indesiderato chiamato aliasing che emerge quando il vincolo posto dal teorema non è verificato. Per comprendere il teorema e il fenomeno dell'aliasing, dobbiamo prima comprendere più in dettaglio le relazioni che esistono tra un segnale analogico e il suo corrispondente segnale campionato. Abbiamo visto nel precedente sottocapitolo qual è la relazione di queste due entità nel dominio del tempo, cioè il segnale campionato è, idealmente, una sequenza di delta di Dirac omogeneamente distanziate nel tempo, ciascuna avente un'ampiezza uguale all'ampiezza del segnale analogico nel momento corrispondente. Nello specifico, con riferimento alla figura seguente, il segnale campionato (e) può essere visto come il prodotto (croce arancione) del segnale analogico (a) e un treno di delta di Dirac di ampiezza unitaria (c). Ora, esamineremo questa corrispondenza da un altro punto di vista, cioè nel dominio della frequenza. In altre parole, vorremmo capire qual è la relazione tra lo spettro di un segnale analogico e lo spettro della sua controparte campionata. Questa relazione è mostrata nella figura seguente: dato lo spettro (a doppio lato) del segnale di ingresso (b), lo spettro del segnale campionato (f) sarà dato dalla convoluzione (asterisco rosso) dello spettro (a doppio lato) del segnale di ingresso (b) con lo spettro del treno di delta di Dirac (d). Si noti che quest'ultimo è anch'esso un treno di delta di Dirac equidistanti (la loro interdistanza è la frequenza di campionamento, f_s) con ampiezza $1/T$. Ciò significa che lo spettro del segnale campionato (f) sarà dato dallo spettro (a doppia lato) del segnale analogico sovrapposto a copie di quest'ultimo centrate a multipli interi della frequenza di campionamento (che chiameremo informalmente "repliche").



Osservando i pannelli (b) e (f) del diagramma precedente, è evidente che il segnale analogico di ingresso $x(t)$ ha una larghezza di banda finita f_0 . Una larghezza di banda finita significa che il suo spettro è limitato, cioè esiste una frequenza f_0 al di sopra della quale la trasformata di Fourier del segnale $X(f)$ è 0 , che può essere scritta come $X(f > f_0) = 0$. Inoltre, definiamo la frequenza di Nyquist come metà della frequenza di campionamento, cioè $f_n = f_s/2$. Si noti dal pannello (f) del diagramma precedente che in questo particolare esempio la frequenza di campionamento è stata scelta in modo che la frequenza di Nyquist sia maggiore della larghezza di banda del segnale analogico, ovvero $f_n > f_0$. In questa condizione, il campionamento viene eseguito correttamente. In effetti, questa è esattamente la condizione posta dal teorema di Shannon-Nyquist, secondo il quale la frequenza di campionamento deve essere maggiore di due volte la larghezza di banda del


segnale analogico. Sebbene non dimostreremo questo teorema matematicamente, la dimostrazione non è di per sé difficile e può essere dedotta dalla trasformata di Fourier e delle sue proprietà. Il lettore che vuole scavare più a fondo nei dettagli matematici del teorema può trovare la dimostrazione quasi ovunque online.

La principale conseguenza del mancato rispetto del teorema di Shannon-Nyquist è l'emergere del fenomeno indesiderato chiamato *aliasing*. Con riferimento al pannello (f) nella figura sopra, è intuitivo notare che se il teorema non è soddisfatto, le code di repliche adiacenti si sovrapporranno. Questo non è di per sé dannoso, ma rende impossibile ricostruire il segnale analogico originale a partire dalla sua controparte campionata. Questo perché, abbastanza intuitivamente, se si ricostruisce il segnale analogico originale partendo dalla sua controparte campionata, sarebbe sufficiente elaborare il segnale campionato utilizzando un filtro passa basso ideale, ossia un circuito capace di essere trasparente ad input di frequenze sufficientemente basse e in grado di bloccare (non trasferire in uscita) input di frequenze sufficientemente alte, avendo cura di impostare lo "spartiacque" tra i due comportamenti alla frequenza di Nyquist. In questo caso lo spettro del segnale di uscita sarà esattamente lo spettro del segnale analogico originale, il che significa che il segnale di ingresso è esattamente ricostruito (cioè, l'informazione è stata preservata attraverso l'intero processo di campionamento e ricostruzione). Tuttavia, ciò è possibile solo se viene verificato il teorema di Shannon-Nyquist. Nel caso opposto, lo spettro del segnale all'uscita del filtro passa basso non sarà identico al segnale analogico originale a causa della sovrapposizione delle code. Ciò è evidenziato nella figura seguente, dove l'area ombreggiata in blu rappresenta il lato destro dello spettro a doppio lato di un segnale analogico e le aree ombreggiate in rosso sono rappresentative delle repliche introdotte dal campionamento. Se la frequenza di Nyquist è inferiore alla larghezza di banda del segnale analogico, la sovrapposizione della coda distorce una parte dello spettro. Pertanto, la porzione di spettro isolata dal filtro passa-basso non sarà identica allo spettro del segnale originale e la ricostruzione fallisce.



Il fenomeno della sovrapposizione della coda è tecnicamente chiamato *aliasing*. Il nome trae origine da ciò che succede nel dominio del tempo. Prendiamo come esempio la figura seguente in cui un'onda sinusoidale con frequenza $\approx 0,9$ Hz è mostrata con una linea rossa. Chiaramente, questo è un segnale a banda limitata con larghezza di banda $\approx 0,9$ Hz (in quanto il suo spettro è addirittura composto da una componente sola). Supponiamo di campionare questa forma d'onda utilizzando una frequenza di campionamento che non soddisfa il teorema di Shannon-Nyquist, diciamo 1 Hz. I punti campionati sono mostrati in nero. Ora processiamo il segnale campionato (non mostrato) con un filtro passa basso ideale con frequenza di taglio pari alla frequenza di Nyquist $f_n = f_s/2 = 0,5$ Hz. Il segnale di uscita risultante è mostrato in blu nella figura seguente ed è chiaramente diverso dal segnale originale. In particolare, è ciò che chiamiamo *alias* (dal latino *alias*, altro) del segnale di ingresso, da cui il nome *aliasing*. Il lettore è incoraggiato a i) costruire lo spettro a doppio lato dell'onda sinusoidale a 0,9 Hz e lo spettro del segnale campionato (con $f_s = 1$ Hz); ii) ricontrollare che, a causa dell'*aliasing*, una componente di frequenza indesiderata emerga a 0,1 Hz; iii) verificare che questa sia esattamente l'unica componente che il filtro passa basso con frequenza d'angolo $f_n = f_s/2 = 0,5$ Hz

lascerebbe passare; iv) verificare che la rappresentazione nel dominio del tempo del segnale all'uscita del filtro passa basso sia l'onda sinusoidale blu nella figura seguente.



Se dovessimo raddoppiare la frequenza di campionamento (in modo che ora soddisfi il teorema), verrebbero presi più punti durante il processo di campionamento e la linea blu non si adatterebbe più all'intero insieme di punti presi durante il campionamento (nessun aliasing). Questa è la controparte nel dominio del tempo del fenomeno della sovrapposizione della coda nel dominio della frequenza. Una realizzazione comunemente sperimentata dell'aliasing è l'effetto che si può apprezzare guardando le ruote di un'auto che ruotano a velocità crescente (quando la velocità raggiunge un determinato valore sembra che la ruota smetta quasi di ruotare e poi inizi a ruotare nella direzione opposta - mentre sappiamo che in realtà la ruota continua ad accelerare sempre nello stesso verso).

Per prevenire il verificarsi del campionamento nei circuiti reali dobbiamo assicurarci che il segnale sia limitato in banda e che la sua larghezza di banda soddisfi il teorema. Supponendo di avere un circuito di campionamento e di conoscerne la frequenza di campionamento, possiamo impostare un limite di banda ai possibili segnali in ingresso introducendo il filtro anti-aliasing. Essenzialmente è un filtro passa basso posto prima di un circuito di campionamento per limitare la larghezza di banda di un segnale per soddisfare il teorema di Shannon-Nyquist in modo che non si verifichi alcun aliasing. Si noti che questo filtro passa basso è diverso da quello discusso sopra, che è invece chiamato filtro di ricostruzione (e viene applicato ai segnali campionati, mentre il filtro anti-aliasing viene applicato al segnale analogico prima del campionamento). Idealmente, un filtro anti-alias dovrebbe avere una transizione infinitamente ripida dalla banda passante alla banda di arresto (cioè dovrebbe essere di ordine infinito), in modo che nessuna componente di frequenza al di sopra della frequenza di Nyquist possa passare e causare aliasing. Un vero filtro anti-aliasing, tuttavia, non può essere di ordine infinito, e quindi mette in trade-off complessità e quantità di aliasing. Un vero filtro anti-aliasing generalmente consente l'insorgere di un po' di aliasing oppure attenua alcune frequenze della banda di ingresso vicine al limite di Nyquist. Inoltre, un filtro vero e proprio non elimina mai completamente, ma attenua le componenti di frequenza indesiderate, quindi l'aliasing non può essere completamente eliminato. Questo è il motivo per cui nei sistemi reali la frequenza di campionamento è tipicamente presa da 5 a 10 volte maggiore della larghezza di banda (invece del fattore canonico di 2 posto dal teorema), il che garantisce un margine extra per tenere conto delle non idealità del filtro.

7.1.3 Quantizzazione

Dopo che la fase di campionamento è stata eseguita correttamente, il segnale campionato è effettivamente una rappresentazione discreta nel tempo ma con valori reali del segnale analogico, che conserva tutte le sue informazioni. Un secondo passaggio è ora necessario per ridurre a un valore finito la precisione con cui ogni campione è rappresentato numericamente, in modo che possa essere scritto con un numero finito di cifre binarie. Questo secondo passaggio è chiamato quantizzazione.




Il processo di quantizzazione agisce su ogni singolo campione di un segnale campionato e sostituisce il numero reale rappresentativo di ciascun campione con un valore preso da un insieme finito di N valori discreti che possono essere scritti con precisione finita. Per identificare l'insieme dei valori discreti, l'escursione complessiva del segnale (cioè l'intervallo che va dal minimo assoluto, $V_{\min}$, al massimo assoluto, $V_{\max}$, del segnale) viene suddivisa in N intervalli (che chiameremo informalmente “bande”) di uguale estensione Q , quindi

$$Q = \frac{V_{\max} - V_{\min}}{N}$$

Ciascuna banda è identificata da un valore rappresentativo, che è tipicamente (ma non necessariamente) il valore medio della banda (a volte viene scelto l'estremo inferiore). Quindi, il valore reale di ciascun campione del segnale campionato viene sostituito dal valore rappresentativo della banda in cui cade. Un esempio è mostrato nella figura sopra, in cui un segnale campionato (verde) è quantizzato (giallo). I valori rappresentativi delle varie fasce sono identificati dalle linee orizzontali blu. Il segnale quantizzato viene costruito sostituendo ogni campione del segnale campionato con il valore rappresentativo della banda in cui cade (ovvero la linea blu più vicina). La differenza tra il segnale campionato e quello quantizzato è chiamato errore di quantizzazione (linea rossa), che può essere positivo o negativo ma sempre compreso tra $-Q/2$ e $Q/2$ (cioè l'escursione picco-picco dell'errore di quantizzazione è al massimo uguale a Q). Ciò conferma anche il fatto intuitivo che maggiore N , minore Q , minore è l'errore di quantizzazione, maggiore è l'accuratezza con cui viene quantizzato il segnale campionato. Si noti che, in generale, i valori rappresentativi delle bande sono valori reali e quindi definiti con precisione arbitraria. Tuttavia, il segnale quantizzato può assumere solo N valori che possono quindi essere associati a “etichette” di precisione finita (es. 0, 1, 2, 3, ..., $N-1$). Ciò significa che ogni campione del segnale quantizzato ha un valore identificabile con un intero compreso tra 0 e $N-1$.

7.1.4 Codifica

La fase di codifica è l'ultima nella conversione da analogico a digitale, e viene eseguita per rappresentare ogni campione del segnale quantizzato (ovvero un numero intero compreso tra 0 e $N-1$) in formato binario. In parole povere, la fase di codifica associa a ciascuno dei suddetti interi la sua rappresentazione binaria, in modo che ogni campione sia ora rappresentato da una stringa di M bit, dove $M = \lceil \log_2 N \rceil$. Il simbolo $[x]$ identifica l'operatore parte intera superiore, che restituisce la parte intera del suo argomento più uno. Si noti che lo stesso valore di M corrisponde a valori diversi di N . Ad esempio, sia $N = 12$ che $N = 14$ danno come risultato $M = 4$. È quindi conveniente, per una M fissa, scegliere il massimo N possibile che soddisfi l'equazione, poiché un N maggiore diminuisce l'errore di quantizzazione. Ciò si ottiene scegliendo N come potenza di due, come si fa tipicamente (ma non sempre).



Nella figura sopra è riassunto il processo di quantizzazione e codifica. Con riferimento al grafico a sinistra, l'asse x mostra l'escursione complessiva del segnale campionato (scelto arbitrariamente da 0 a $V_{\max}$), mentre l'asse y riporta l'insieme degli N valori discreti consentiti dalla quantizzazione, espressi direttamente come stringhe binarie associate (codifica). In dettaglio, Δ rappresenta – a titolo di esempio - il valore di riferimento della seconda fascia (etichettata come fascia 1). In questo esempio, $N = 8$ e quindi $M = 3$ (e infatti le stringhe binarie sull'asse y sono scritte con 3 bit). La curva nera della scala rappresenta la risposta di una scatola nera che esegue la quantizzazione e la codifica, quindi incarna la relazione tra il segnale digitale e il segnale campionato. Ogni gradino della scala rappresenta l'estensione Q della fascia. Si noti che, aumentando N, i gradini diventerebbero più piccoli e più vicini tra loro, così che il limite della scala per $N \rightarrow \infty$ è una linea retta (linea tratteggiata nel grafico). Per maggior chiarezza, nelle tabelle è riportato un esempio numerico. Supponiamo che il segnale campionato sia compreso tra 0 V e 10 V, e utilizziamo $N = 8$. L'estensione Q è quindi 1,25 V. La tabella centrale mostra la divisione dell'intero intervallo del segnale (fondo scala) nelle 8 bande (numerare da 0 a 7), specificando i campi di tensione associati. La tabella a destra associa ogni numero di banda al suo equivalente binario. Questo è un esempio di conversione A/D a 3 bit. Si noti che un convertitore A/D a 8 bit produce 256 bande, un convertitore A/D a 16 bit in 65536 bande e un A/D a 24 bit ben 16,8 milioni di bande. Solo per riferimento, l'errore di quantizzazione massimo per un segnale di fondo scala a 10 V convertito con un convertitore A/D a 8 bit è leggermente inferiore a 20 mV, mentre scende a meno di 0,3 μ V per un convertitore A/D a 24 bit.


Dopo la codifica, il segnale può essere espresso in forma completamente digitale, cioè come una sequenza di bit in cui ogni campione è rappresentato da una M-tupla di bit, finalizzando così il processo di conversione A/D.

7.1.5 Circuito di Campionamento

Diamo ora un'occhiata ai circuiti che possono effettivamente eseguire l'operazione di conversione A/D. Naturalmente, l'intero circuito sarà composto da due blocchi successivi, il primo dedicato alla fase di campionamento e il secondo dedicato alla quantizzazione e alla codifica complessiva. La prima cosa su cui concentrarsi, quando si ha a che fare con l'implementazione del circuito della conversione A/D, è la tempistica dell'intera operazione. Il nostro obiettivo principale è considerare il valore del segnale di ingresso analogico in determinati istanti di tempo (cioè multipli interi del tempo di campionamento). Tuttavia, dobbiamo considerare che i) il circuito che esegue la misurazione dei valori del segnale analogico (cioè il campionamento) avrà bisogno di un tempo diverso da zero per eseguire ciascuna misurazione; ii) il valore misurato dal circuito di campionamento deve essere mantenuto stabile per un certo tempo, affinché il circuito che esegue la quantizzazione abbia il tempo necessario per farlo; iii) la somma di questi due tempi non deve essere maggiore del tempo di campionamento. Nella prima finestra temporale il circuito di campionamento funzionerà (cioè eseguirà la misura) mentre il circuito di quantizzazione rimarrà non operativo: questa è chiamata fase di campionamento. Al termine della fase di campionamento il circuito di

campionamento non reagirà più alle variazioni della tensione analogica in ingresso e la sua uscita sarà stabile per tutta la durata della seconda finestra temporale, in cui lavorerà il circuito di quantizzazione: questa è la fase di quantizzazione. Il tutto poi si ripete ad ogni multiplo intero del tempo di campionamento. Pertanto, la prima cosa di cui abbiamo veramente bisogno è un segnale di temporizzazione, chiamato clock, che possa dettare la durata delle due fasi. Questo segnale di clock ovviamente funzionerà alla frequenza di campionamento (cioè, il suo periodo è il tempo di campionamento).

Siamo ora pronti per studiare una topologia circuitale in grado di implementare la fase di campionamento. Il circuito, mostrato di seguito, è chiamato Sample and Hold, poiché durante la fase di campionamento campiona effettivamente il segnale analogico in ingresso, mentre in fase di quantizzazione manterrà il valore misurato durante la fase di campionamento in modo che sia stabile per tutta la fase di quantizzazione (e il circuito di quantizzazione può fare il suo lavoro correttamente). È composto da due buffer di tensione, un interruttore e un condensatore. Il funzionamento del circuito è piuttosto semplice. Un interruttore, controllato dal segnale di clock, seleziona tra due modalità di funzionamento: sample (durante la fase di campionamento) o hold (durante la fase di quantizzazione).




Durante la fase di campionamento, l'interruttore è acceso (simile a un cortocircuito). La tensione di ingresso (che nel frattempo varia nel tempo) viene processata da un buffer per evitare di caricare il circuito che effettivamente la fornisce (circuito a monte). La tensione di ingresso viene quindi copiata sul condensatore (cioè, la tensione sul condensatore segue la tensione di ingresso). Allo stesso tempo, la tensione ai capi del condensatore (che è uguale alla tensione di ingresso) viene copiata anche sul terminale di uscita in virtù del secondo buffer. Pertanto, in fase di campionamento, la tensione di uscita segue fedelmente la tensione di ingresso (almeno nell'ipotesi di interruttore e buffer ideali). Al termine della fase di campionamento, l'interruttore si spegne (simile a un circuito aperto) e inizia la fase di quantizzazione. Il condensatore è caricato al valore dalla tensione di ingresso nel momento in cui l'interruttore passa da acceso a spento (che è il valore che effettivamente campioniamo). Da questo momento in poi il condensatore è fisicamente scollegato dall'ingresso e non ha modo di scaricarsi, poiché è flottante (grazie all'impedenza infinita mostrata sia dall'interruttore in stato di spegnimento che dall'ingresso non invertente del buffer). Pertanto, per tutta la durata della fase di quantizzazione, la tensione ai capi del condensatore (e quindi anche la tensione in uscita) non cambierà e sarà mantenuta stabile al valore assunto dalla tensione di ingresso nel momento in cui l'interruttore passa da acceso a spento (vale a dire, il valore campionato). Quindi, al termine della fase di quantizzazione, il ciclo ricomincia.

Ci si può chiedere perché la fase di campionamento debba avere una durata prolungata nel tempo. Infatti, durante la fase di campionamento, in ogni istante la tensione ai capi del condensatore è uguale alla tensione di ingresso, quindi non ha senso attendere un po' di tempo prima di spegnere l'interruttore e campionare effettivamente l'ingresso. La risposta a questo punto sta nel fatto che un vero interruttore (ad esempio un transistor) nello stato acceso è più simile a un resistore che a un cortocircuito. Ciò significa che in realtà la tensione ai capi del condensatore non è realmente uguale alla tensione di ingresso in tutti gli istanti di tempo, poiché la resistenza dell'interruttore nello stato acceso e il condensatore formano un circuito RC. Ciò significa che è necessario un tempo diverso da zero affinché la tensione ai capi del condensatore sia in grado di seguire il segnale di ingresso. Di seguito viene mostrato il comportamento del circuito quando si considera questo aspetto non ideale. L'onda sinusoidale tratteggiata rappresenta il segnale analogico di ingresso che varia nel

tempo, la linea continua rappresenta la tensione di uscita e nella parte inferiore della figura è evidenziato il diagramma temporale del segnale di clock. T_{acq} è la durata della fase di campionamento, T_C la durata della fase di quantizzazione. All'accensione dell'interruttore (quando inizia la fase di campionamento) la tensione di uscita e quella di ingresso possono avere valori diversi (se il motivo non è al momento chiaro al lettore, verrà chiarito tra poco). Da questo momento in poi, la tensione di uscita (che è uguale alla tensione ai capi del condensatore, V_C) cerca di seguire la tensione di ingresso e le sue variazioni seguendo la dinamica dettata dal circuito RC, cioè:

$$RC \frac{dV_C(t)}{dt} + V_C(t) = V_{in}(t)$$



La dinamica può essere apprezzata nella figura sopra: ci vuole un tempo finito, dell'ordine di RC , perché la tensione di uscita sia in grado di tracciare la tensione di ingresso. Infatti, non appena inizia la fase di campionamento, la tensione di uscita cercherà di seguire la tensione di ingresso (che, nel frattempo, varia nel tempo) e proverà effettivamente a convergere ad essa con alcune oscillazioni smorzate caratterizzate da overshoot e undershoot progressivamente minori. Ciò significa che il momento di campionamento effettivo (ovvero il momento in cui l'interruttore viene spento) non deve avvenire troppo presto, e che bisogna attendere che le oscillazioni siano abbastanza smorzate, altrimenti il valore campionato non sarebbe rappresentativo del valore effettivo della tensione di ingresso, motivo della durata diversa da zero di T_{acq} . Questo può essere ridotto adottando interruttori con una resistenza molto bassa (poiché il tempo di assestamento del sistema si riduce). Quando l'interruttore è effettivamente spento, il valore campionato viene mantenuto costante in uscita mentre il segnale di ingresso continua a variare. Durante questa finestra di tempo, il circuito di quantizzazione seguente sarà in grado di svolgere facilmente il suo compito, poiché il circuito di campionamento gli fornisce una tensione stabile. Si noti che quando la fase di quantizzazione è terminata e l'interruttore sta per essere riaperto, le tensioni di uscita e di ingresso sono, in generale, diverse. Ciò è dovuto al fatto che la tensione di uscita è stata mantenuta costante mentre la tensione di ingresso ha continuato a variare nel tempo, il che chiarisce quanto affermato poche righe sopra.

Come nota finale, se l'equazione differenziale di cui sopra viene risolta per il caso di un'onda sinusoidale in ingresso alla frequenza di Nyquist (che è la frequenza massima che può esserci nel circuito se includiamo un filtro anti-aliasing ideale prima del campionamento), è possibile calcolare quanto il valore richiesto a T_{acq} affinché il segnale di uscita sia in grado di inseguire il segnale di ingresso con un errore al di sotto di una soglia determinata - tipicamente scelto inferiore all'estensione di banda, Q , del circuito di quantizzazione seguente. Ciò garantisce infatti che il valore campionato sia una rappresentazione sufficientemente buona del valore effettivo del segnale di ingresso (abbastanza buona per cui il circuito di quantizzazione che ne deriva non possa distinguere la differenza).

7.2 Tipologie di ADC


In questo sottocapitolo affronteremo le tipologie più importanti e utilizzate di convertitori A/D (abbreviati in ADC). In realtà, stiamo ora discutendo del circuito di quantizzazione, che è solo una parte dell'intera catena di conversione A/D. Tuttavia, informalmente, viene usato il nome ADC per riferirsi a circuiti di quantizzazione. Tutti questi circuiti saranno pilotati dallo stesso segnale di clock che pilota il campionatore, poiché ovviamente i due circuiti devono lavorare in sincronia in quanto il circuito di quantizzazione produrrà risultati affidabili solo durante la fase di quantizzazione, cioè quando il suo ingresso è stabile nel tempo.

7.2.1 Flash ADC

L'approccio su cui si basa il Flash ADC è piuttosto semplice. Sappiamo che le diverse bande (discusse in precedenza in questo capitolo) sono separate tra loro da specifiche tensioni di soglia. Nello specifico, per una quantizzazione a n bit ci saranno $2^n - 1$ soglie e l' i -esima soglia sarà:

$$V_{th}^i = V_{min} + i \frac{V_{max} - V_{min}}{2^n} \quad i \in N \quad i \in [1, 2^n - 1]$$

Pertanto, se si confronta la tensione di ingresso con ciascuna di queste soglie, è possibile scoprire facilmente a quale banda appartiene il segnale di ingresso. Per fare ciò, il Flash ADC comprende una serie di 2^n resistori identici e $2^n - 1$ comparatori. I resistori sono collegati in serie formando una scala e la scala è collegata a due sorgenti di tensione che rappresentano V_{max} e V_{min} . Nel formalismo che qui adottiamo, il primo resistore è quello connesso a V_{min} mentre il 2^n -esimo è quello connesso a V_{max} . È facile verificare che la tensione nel punto di connessione tra la i -esima e la $i+1$ -esima resistenza sia effettivamente la i -esima soglia. Ogni comparatore riceve la tensione di ingresso (proveniente dal campionatore) al suo ingresso non invertente, e una soglia specifica all'ingresso invertente (infatti, poiché ci sono $2^n - 1$ soglie, ci saranno $2^n - 1$ comparatori). Vale a dire, l' i -esimo comparatore riceverà la i -esima soglia.



L'uscita del comparatore è per sua natura digitale e indica se la tensione di ingresso è maggiore (uno logico) o minore (zero logico) di una specifica soglia. Pertanto, analizzando lo stato logico di tutti i comparatori è possibile identificare la banda a cui appartiene il campione. Nello specifico, se tutte le uscite dei comparatori sono a zero logico, allora il campione è minore di tutte le soglie e quindi appartiene alla prima banda. Se l'uscita del primo comparatore è a uno logico mentre tutti gli altri sono a zero logico, allora il campione è


maggiore della prima soglia ma più piccolo di tutte le altre, e quindi appartiene alla seconda banda. In generale, se l'uscita dell' i -esimo comparatore è a uno logico mentre quelle di tutti i j -esimi comparatori (con $j > i$) sono a zero logico, allora il campione apparterrà alla $i+1$ -esima banda. A questo punto abbiamo $2^n - 1$ uscite binarie (le uscite dei comparatori), il che significa $2^n - 1$ bit, per rappresentare 2^n combinazioni possibili (le 2^n bande possibili). Questa rappresentazione è ridondante, poiché per rappresentare 2^n etichette distinte abbiamo solo bisogno di n bit. Per ovviare a questo inconveniente, le uscite dei $2^n - 1$ comparatori (insieme ad una linea aggiuntiva posta alla tensione di alimentazione, rappresentante un 1 logico fisso) sono collegate agli ingressi di un circuito di tipo priority encoder. In questo modo, il numero binario rappresentato dagli n bit di uscita è il numero ordinale della banda a cui appartiene il campione. Il priority encoder ha un ingresso dedicato aggiuntivo che riceve il segnale di clock (enable pulse nello schema sopra) in modo che funzioni solo durante la fase di quantizzazione.

Lo schema sopra mostra un esempio di un'architettura Flash ADC a 3 bit in cui, per semplicità, $V_{\max}$ è considerata una tensione positiva arbitraria V_{ref} , mentre $V_{\min}$ è 0 V (e infatti il terminale inferiore della scala è collegato a terra).

Il Flash ADC è semplice e velocissimo, poiché tutti i comparatori lavorano in parallelo ed il ritardo complessivo introdotto dal circuito è minimo (solo quello introdotto da un singolo comparatore, indipendentemente da quanti ce ne siano, e quello introdotto dal priority encoder). Consente quindi di ridurre il tempo di campionamento complessivo ed è infatti frequentemente adottato nel caso di frequenze di campionamento elevate. Tuttavia, è praticamente limitato a basse risoluzioni (cioè, n piccolo), poiché per ogni bit di risoluzione aggiuntivo (ogni aumento unitario di n), il numero dei comparatori quasi raddoppia e quello dei resistori raddoppia esattamente, aumentando notevolmente la dimensione e il costo del circuito (per $n = 8$ bit sono necessari 256 resistori e 255 comparatori).

7.2.2 ADC ad Approssimazioni Successive

Uno degli ADC più comunemente utilizzati in applicazioni che richiedono una frequenza di campionamento < 10 Mega-campioni al secondo (cioè segnali campionati al di sotto dei 10 MHz) è l'ADC ad approssimazioni successive (chiamato ADC con registro ad approssimazione successiva, o SAR), ideale per le applicazioni che richiedono una risoluzione tra 8-16 bit. L'ADC SAR è uno degli ADC più intuitivi da comprendere e l'analisi del suo principio di funzionamento rivela chiaramente i suoi punti di forza e di debolezza. Il circuito, mostrato di seguito, include molti componenti: un comparatore, un SAR (registro ad approssimazioni successive) e un DAC (cioè un convertitore da digitale ad analogico), oltre a un buffer di uscita digitale (etichettato SRG nel diagramma seguente). Stranamente, questo ADC ha bisogno di un DAC per funzionare. Senza entrare nella discussione sul funzionamento interno del DAC, di cui parleremo più avanti in questo opuscolo, astraiamo semplicemente il comportamento di questo componente affermando che riceve in ingresso una parola digitale (dall'uscita SAR) e produce un valore analogico DC stabile alla sua uscita che sia rappresentativo della parola digitale di ingresso.




Nell'esempio sopra, il DAC è alimentato con le tensioni di alimentazione V_{DD} e massa. L'intervallo della tensione di alimentazione (in questo caso da 0 V a V_{DD}) deve essere uguale al fondo scala del segnale di ingresso. L'uscita del DAC è:

$$V_{DAC} = \frac{V_{DD}}{2^N} \cdot \sum_{n=1}^N D_n 2^{n-1}$$

dove N rappresenta il numero di linee di ingresso al DAC, la sua risoluzione e la risoluzione dell'intero ADC. Le quantità D_n sono i valori digitali di ciascuna delle N linee all'ingresso del DAC. Nell'equazione precedente, il risultato della somma è in buona sostanza l'equivalente decimale del numero binario rappresentato dalle N linee all'ingresso del DAC. In altre parole, il DAC produce una tensione continua stabile che può coprire l'intero intervallo del segnale analogico di ingresso all'ADC, e proporzionale al valore del numero digitale che riceve al suo ingresso. Infatti, se tutti i bit D_n sono 0, V_{DAC} è 0 V (il minimo dell'intero intervallo di ingresso). Al contrario, se tutti i bit D_n sono 1, V_{DAC} è (quasi) V_{DD} (il massimo dell'intero intervallo di ingresso). La tensione prodotta dal DAC viene alimentata al comparatore, che la confronta con la tensione di ingresso.

Il criterio alla base del funzionamento dell'ADC SAR è che possiamo iniziare indovinando quale dovrebbe essere la parola di uscita digitale, convertire questa parola di prova digitale nel formato analogico, confrontare quest'ultima con la tensione di ingresso, quindi capire se la nostra ipotesi iniziale era superiore o inferiore alla tensione di ingresso e, infine, modificare la nostra ipotesi di conseguenza. Ripetendo questo meccanismo più volte, possiamo convergere al risultato finale. Per fare ciò, il SAR riceve in ingresso un segnale di clock (molto più veloce di quello del circuito sample and hold) e l'uscita del comparatore. Inizialmente, quando inizia il primo ciclo di clock, il SAR imposta tutti i suoi bit di uscita a 0 tranne il bit più significativo (MSB), che è impostato a 1. Pertanto, la parola di uscita sarà 1000... Dalla formula sopra, è facile per capire che il V_{DAC} prodotto dal DAC in questo caso è $V_{DD}/2$. Questo valore viene fornito al comparatore, che confronta questa tensione con la tensione di ingresso. Fondamentalmente, questa prima iterazione rivela se la tensione di ingresso è nella metà superiore o inferiore del suo fondo scala. Se appartiene alla metà superiore, l'uscita del comparatore sarà un 1 logico, altrimenti uno 0 logico. Questo segnale viene interpretato dal SAR nel modo seguente: se è un 1 logico, lasciare l'MSB a 1, altrimenti cambiarlo a 0. Con questa procedura abbiamo individuato una porzione del fondo scala a cui appartiene sicuramente il segnale di ingresso. Il SAR quindi, al ciclo di clock successivo, lascia l'MSB come chiarito sopra, e si occupa del 2° MSB, e lo imposta a 1, lasciando tutti i bit meno significativi a 0. Questo sostanzialmente riavvia l'algoritmo con lo scopo di ridurre ulteriormente l'estensione della porzione di fondo scala a cui appartiene sicuramente il segnale di ingresso. Ad ogni iterazione, l'estensione di questa porzione viene effettivamente dimezzata. L'algoritmo si ripete per N volte (fino a quando l'LSB non è correttamente impostato su 0 o 1 a seconda del risultato dell'operazione di confronto), riducendo l'estensione di questa porzione a una singola banda, completando la conversione A/D. Quando finalmente il SAR imposta il valore dell'LSB, comanda al registro di uscita di tipo PIPO di portare in uscita la parola digitale all'uscita del SAR, che rappresenta il corretto equivalente digitale della tensione di ingresso. Tutta l'operazione svolta dal SAR ADC è, in realtà, un algoritmo di ricerca binaria, che è astratto nel diagramma di flusso nel pannello di destra della figura sopra.




Nel pannello superiore della figura sopra, viene riportato un esempio di come l'uscita della tensione del DAC cambia nel tempo per ciascun campione della tensione di ingresso. Si noti che, per ogni campione, la tensione DAC converge gradualmente alla tensione di ingresso (meglio ancora al valore di tensione che è rappresentativo della banda in cui appartiene la tensione di ingresso). Nel pannello inferiore viene riportato il valore della parola di uscita digitale.

Si noti che, per ogni campione al suo ingresso (mantenuto stabile dal circuito sample and hold, proprio come nel caso del Flash ADC), il SAR ADC reitera l'algoritmo N volte, il che significa che il periodo del segnale di clock ricevuto dal SAR deve essere almeno N volte più veloce della sottoporzione di quantizzazione del periodo di campionamento. L'aumento della risoluzione, cioè N, richiede circuiti digitali più veloci. Questo circuito necessita di un singolo comparatore (indipendentemente dalla risoluzione) e di un DAC (che però è più complesso per N più grandi, il che è uno svantaggio) ma è sufficientemente veloce (anche se non veloce come un Flash ADC). La velocità dipende ovviamente da N, poiché l'algoritmo viene ripetuto N volte.

7.2.3 Comparazione tra ADC


Di seguito una tabella insieme ad un grafico in cui vengono confrontate tre tipologie di ADC: le due viste fino ad ora e un'altra che non tratteremo in dettaglio (detto "a doppia rampa") in termini di velocità, costo e risoluzione tipica.



Type	Speed	Cost	Resolution
Flash	Very Fast	High	Low
Dual Slope	Slow	Medium	High
SAR	Fast	Low	Medium

7.2.4 ADC Avanzati: l'ADC Sigma-Delta

Una classe molto popolare di ADC è il cosiddetto ADC sigma-delta. Questi convertitori si basano sull'architettura che viene mostrata di seguito in modo semplificato (alcuni componenti sono omessi), che comprende un amplificatore differenziale, un integratore, un comparatore (che in effetti è un ADC a 1 bit, se si ci pensa), e un DAC a 1 bit in una configurazione di feedback. Il vantaggio principale di questo ADC è che, utilizzando elementi a bassa risoluzione ed economici, può ottenere una risoluzione equivalente molto elevata alla sua uscita per mezzo di alcuni trucchi intelligenti (come il ricampionamento ad alta frequenza e il filtraggio digitale). Il funzionamento interno è complicato da descrivere e un'analisi rigorosa va ben oltre lo scopo di questo opuscolo. Sono economici, veloci e possono raggiungere risoluzioni elevatissime come 24 o addirittura 32 bit. Un ulteriore vantaggio è il cosiddetto noise shaping: questi ADC possono attenuare il rumore presente nella banda del segnale "spostandolo" a frequenze più alte (che vengono poi tagliate dal filtro digitale).



7.3 Tipologie di DAC

Un convertitore digitale-analogico (abbreviato in DAC) è il componente duale dell'ADC. Riceve un ingresso digitale, tipicamente in modo parallelo (cioè, n linee ciascuna con un singolo bit) e lo converte in un'uscita analogica costante. Esistono diverse architetture DAC e ci concentreremo in particolare sul cosiddetto DAC R-2R Ladder e sul DAC ad approssimazioni successive, fornendo anche alcuni cenni sul DAC Sigma-Delta.


In generale, l'idoneità di uno specifico DAC per una particolare applicazione è determinata da alcune figure di merito, tra cui (ma non solo):

- Risoluzione: numero di bit di ingresso; è anche correlato al numero possibile di livelli di uscita analogica, poiché n bit di ingresso corrispondono a 2^n possibili numeri digitali diversi in ingresso, e quindi 2^n livelli di uscita analogica;
- Frequenza di campionamento massima: la velocità massima alla quale il DAC può accettare nuovi dati e comportarsi correttamente, ovvero completare la conversione D/A prima che venga presentato l'ingresso digitale successivo;
- Monotonicità: la capacità dell'uscita analogica di un DAC di spostarsi da un livello di uscita analogica all'altro solo nella direzione lungo la quale si muove l'ingresso digitale (cioè, se l'ingresso aumenta, l'uscita non si abbassa prima di aumentare, ma aumenta e basta); è importante per i segnali a bassa frequenza.
- THD (distorsione armonica totale) e rumore: misurano la distorsione e il rumore introdotti dal DAC. Il rumore può essere visto come un segnale casuale aggiuntivo (tipicamente a media zero) che viene sovrapposto al segnale di uscita. È sempre prodotto dai dispositivi elettronici, e quindi sempre presente. Il rumore generato dal DAC deve essere meno potente per un DAC a risoluzione più elevata (poiché la distanza tra i livelli di uscita adiacenti diminuisce). THD si riferisce alle caratteristiche dei sistemi non lineari. Idealmente, un DAC dovrebbe essere un circuito lineare, ma in pratica non lo è. Quando un sistema non lineare viene alimentato con un'onda sinusoidale a una data frequenza, l'uscita mostrerà un segnale alla stessa frequenza, ma sovrapposto a oscillazioni aggiuntive e indesiderate a frequenze più alte (chiamate armoniche di ordine superiore). Ciò significa che l'output è distorto rispetto a quello atteso dalla risposta di un sistema perfettamente lineare. THD misura la percentuale della potenza di uscita totale data da armoniche di ordine superiore indesiderate.
- Range dinamico: la differenza tra il segnale più grande e quello più piccolo che il DAC può leggere e riprodurre, espressa in decibel.
- Consumo di energia

7.3.1 DAC R-2R

L'idea di un DAC R-2R è quella di impiegare un circuito in grado di generare una corrente, il cui valore è proporzionale al numero rappresentato dal valore dell'ingresso digitale, per poi convertire la corrente in tensione tramite un amplificatore. L'architettura circuitale, di seguito abbozzata con riferimento ad un esempio con tre bit di ingresso, può quindi essere suddivisa in due blocchi. La prima parte (a sinistra) del circuito agisce come un generatore di corrente controllato digitalmente, mentre la seconda converte la corrente in tensione con un amplificatore apposito, detto a transimpedenza.


Digitally-controlled current generator



Il nome R-2R deriva dal progetto del circuito, che alterna una serie di resistori di valore R e resistori di valore 2R, in modo ordinato, per generare correttamente la corrente. Il circuito riceve in ingresso n linee digitali che controllano n interruttori (nella figura sopra, $n = 3$). L'MSB controlla l'interruttore più a destra (quello più vicino all'ingresso dell'amplificatore a transimpedenza), mentre l'LSB controlla quello più a sinistra. In particolare, se il bit di ingresso è a 1 logico, il deviatore collega il ramo sovrastante ad una tensione di riferimento, V_{ref} , mentre lo collega a massa nel caso opposto.

La chiave per capire il comportamento del circuito sta nel capire qual è la corrente generata da ogni singolo bit di ingresso quando è impostato a 1 logico o 0 logico. Sapendo questo, è quindi sufficiente sommare la corrente generata da ogni bit di ingresso (conoscendone i valori, ovvero conoscendo la parola digitale in ingresso). Per farlo, possiamo sfruttare il principio di sovrapposizione (spiegato nel secondo capitolo di questo libretto): se vogliamo capire la corrente generata da un singolo bit di ingresso, possiamo risolvere il circuito che si ottiene supponendo che tutti gli altri interruttori ricevano uno 0 logico, e quindi collegando a massa i rami corrispondenti. In questa analisi è sempre bene ricordare che, a causa dell'effetto di cortocircuito virtuale, l'ingresso invertente dell'amplificatore a transimpedenza è a massa.


Notiamo subito che, indipendentemente dal bit di input su cui ci stiamo concentrando, se è impostato a 0 logico allora anche la corrente generata da esso è zero. Infatti, in tal caso, il circuito che dobbiamo risolvere ha tutti gli interruttori che collegano i loro rami a massa (cioè il bit che stiamo considerando è alimentato con uno 0 logico, e quindi collega il suo ramo a massa, e poiché stiamo applicando il principio di sovrapposizione, tutti gli altri fanno lo stesso) e nessuna corrente può fluire nel circuito del generatore di corrente poiché non ci sono sorgenti di tensione ad esso collegate. Un altro modo per vedere questo aspetto è considerare che tutti i possibili percorsi di corrente sono in realtà costituiti da elementi resistivi che collegano due masse, il che si traduce in assenza di corrente. Dobbiamo ora discutere il caso in cui il bit che stiamo considerando è impostato a 1 logico, il che è meno banale. Quando un bit di ingresso attiva (chiude) un interruttore, una corrente inizia a fluire nel circuito. Tuttavia, ogni ramo (ciascuno associato a un bit diverso) fornisce una diversa quantità di corrente: più significativo è il bit, maggiore sarà la corrente. Per facilitare la comprensione del principio di funzionamento di questo DAC, faremo riferimento all'esempio di un DAC a 3 bit, come nelle figure sopra e sotto. Partiremo dall'analisi della corrente generata dall'MSB quando impostato a 1 logico. Il circuito equivalente è mostrato nella figura seguente, ed equivale a considerare la combinazione di ingresso 100.



In questo caso, notiamo che il resistore $2R$ rivolto verso l'interruttore B_2 si trova tra V_{ref} (poiché l'interruttore è chiuso) e massa (data dall'effetto di cortocircuito virtuale). Tutta la parte rimanente della rete di resistori si trova tra estremità a massa e quindi può essere scartata, come mostrato nel pannello di destra della figura sopra. Si noti che nella parte scartata del circuito non può fluire corrente. Pertanto, il collegamento a massa riportato nel pannello di destra della figura sopra è tratteggiato per indicare che la corrente può fluire solo a destra. Ciò significa che la corrente generata dal bit più significativo quando impostato su 1 logico scorre interamente attraverso il resistore di retroazione dell'amplificatore a transimpedenza. Il suo valore e il valore della tensione di uscita sono:

$$I_{100} = \frac{V_{ref}}{2 \cdot R} \quad V_{out,100} = -RI_{100} = -\frac{V_{ref}}{2}$$

Calcoliamo ora la corrente generata dal 2° MSB quando impostato a 1 logico. Il circuito equivalente è mostrato nel pannello di sinistra della figura seguente, ed equivale a considerare la combinazione di ingresso 010.



Si noti che la resistenza $2R$ collegata all'interruttore B_2 si trova tra due masse (una fisica, una virtuale) e può quindi essere eliminata. Il circuito equivalente, ottenuto tramite semplici riduzioni, è mostrato nel pannello di destra della figura sopra. Questa volta, con riferimento al circuito nel pannello di destra della figura sopra, la corrente iniettata nel resistore $2R$ collegato all'interruttore B_1 fluirà in parte attraverso l'altro resistore $2R$, e in parte scorrerà attraverso l'amplificatore (questa è la porzione che ci interessa, poiché questa frazione di corrente è quella che determina il valore della tensione di uscita). Ora risolveremo il circuito per determinare la quantità di corrente che scorre attraverso l'amplificatore (o meglio, attraverso il suo resistore di feedback). Notiamo che i due resistori evidenziati dalle caselle arancioni sono in parallelo, e si comportano effettivamente come un unico resistore di valore:

$$R_{eq} = \frac{2R \cdot R}{2R + R} = \frac{2}{3}R$$

Pertanto, il resistore $2R$ non boxato è effettivamente in serie con R_{eq} , che è a sua volta collegata a massa. La corrente che scorre nel resistore $2R$ non boxato è:

$$I = \frac{V_{ref}}{2R + R_{eq}} = \frac{V_{ref}}{2R + \frac{2}{3}R} = \frac{3}{8} \frac{V_{ref}}{R}$$

Tuttavia, solo una frazione di questa corrente scorre attraverso il resistore R boxato e quindi attraverso il resistore di retroazione dell'amplificatore, poiché i due resistori boxati formano un partitore di corrente:

$$I_{010} = I \frac{2R}{2R + R} = I \frac{2}{3} = \frac{3}{8} \frac{V_{ref}}{R} \frac{2}{3} = \frac{V_{ref}}{4R} = \frac{I_{100}}{2} \quad V_{out,010} = -\frac{V_{ref}}{4} = \frac{V_{out,100}}{2}$$

In particolare, il 2° MSB, quando impostato a 1 logico, genera un contributo di corrente (diretto verso l'amplificatore) che è la metà di quello generato dall'MSB. Allo stesso modo, la tensione di uscita segue la stessa regola.

Se l'analisi viene ripetuta anche per il 3° MSB, che nel nostro esempio è l'LSB, è facile scoprire che il suo contributo sarà la metà di quello generato dal 2° MSB. Si invita il lettore a disegnare in questo caso il circuito equivalente e a risolverlo, calcolando la corrente generata da questo bit e confermando il risultato sopra enunciato. Se si considera un numero maggiore di bit, la regola si applica in modo concatenato poiché il circuito si ripeterebbe più e più volte identico a sé stesso se si dovessero aggiungere più rami, con la corrente generata dall'ennesimo bit che è sempre la metà di quella generata da quello immediatamente più significativo.

La corrente generata da una parola digitale di ingresso arbitraria è la somma delle correnti generate dai singoli bit. Possiamo estrarre da questi risultati una relazione più generale, valida per il caso generale di una parola di ingresso a n bit:

$$I_{tot} = \sum_{n=1}^N \frac{V_{ref}}{2^n \cdot R} \cdot D_n = \frac{V_{ref}}{R} \sum_{n=1}^N \frac{D_n}{2^n}$$

dove N è il numero complessivo di bit e D_n rappresenta l'ennesimo ingresso digitale. A differenza delle figure, nelle equazioni sopra $n = 1$ si riferisce all'MSB e $n = N$ si riferisce all'LSB. È facile vedere che se un bit specifico è zero ($D_n = 0$), il suo contributo in corrente è zero. Al contrario, il suo contributo è la metà di quello del bit immediatamente più significativo (per il quale n aumenterebbe di un'unità). Nell'ultima equazione, il termine in sommatoria è in realtà il valore del numero rappresentato dalla parola digitale di ingresso, D , normalizzato a 2^N .

$$\sum_{n=1}^N \frac{D_n}{2^n} = \frac{D_1}{2^1} + \frac{D_2}{2^2} + \dots + \frac{D_N}{2^N} = \frac{1}{2^N} [D_1 2^{N-1} + D_2 2^{N-2} + \dots + D_N] = \frac{D}{2^N}$$

Quindi:

$$I_{tot} = \frac{V_{ref}}{R} \sum_{n=1}^N \frac{D_n}{2^n} = \frac{V_{ref}}{2^N \cdot R} D$$


$$V_{out} = -\frac{V_{ref}}{2^N} \cdot D$$

Tutto sommato, la tensione di uscita generata dal circuito è proporzionale a D (il valore del numero rappresentato dalla parola digitale di ingresso) e (a parte il segno, che è negativo per il guadagno negativo dell'amplificatore) può spaziare tra 0 V e V_{ref} .

I principali svantaggi di questo circuito sono che la sua precisione dipende in modo critico dalla tolleranza dei resistori R e $2R$: un resistore reale avrà una tolleranza per la sua resistenza (circa il 5% per resistori commerciali economici, che può scendere a pochi ppm per resistori sofisticati e molto costosi) e questo introduce discrepanze nell'analisi di cui sopra che si traducono in disturbi all'uscita. Inoltre, le approssimazioni sulla perfetta costanza di V_{ref} e sull'idealità sia degli interruttori che dell'Op-Amp determinano deviazioni dal comportamento qui descritto, che devono essere prese in considerazione in fase di progettazione. D'altra parte, questo circuito è molto veloce e la sua velocità non è limitata dalla risoluzione poiché tutti i bit di ingresso vengono elaborati in parallelo. La limitazione in velocità è rappresentata dalla larghezza di banda dell'amplificatore, che può essere tuttavia molto elevata.

7.3.2 DAC ad Approssimazioni Successive

Simile, concettualmente, alla sua controparte ADC, il DAC ad approssimazioni successive presenta al suo ingresso una parola digitale parallela e fornisce un'uscita analogica rappresentativa dell'ingresso digitale mediante n iterazioni, dove n è il numero di bit di ingresso. Per fare ciò avviene una conversione da parallelo a seriale per mezzo di un circuito digitale shift register PISO che trasforma la parola di ingresso parallela in un flusso seriale di bit che vengono dati in pasto al resto del circuito uno alla volta, partendo dall'LSB (questo aspetto è fondamentale). L'uscita di questo circuito digitale (cioè il valore dei singoli bit di ingresso) controlla il comportamento di due interruttori. In particolare, se il bit in esame è impostato a 1 logico, allora l'interruttore che è rivolto alla tensione di riferimento, V_{ref} , è chiuso e l'interruttore che è rivolto a massa è aperto. Il contrario accade se il bit in esame è impostato a 0 logico. Pertanto, gli switches lavorano in mutua esclusione. Lo stato degli interruttori, e quindi il valore del bit in esame, determina se il nodo sommatore (tipicamente implementato tramite un amplificatore sommatore) riceve V_{ref} oppure massa al suo primo ingresso. Il suo secondo input è direttamente collegato al nodo di output. L'uscita del nodo sommatore viene fornita a un circuito di campionamento sample and hold, ed è ulteriormente divisa per due (tramite un attenuatore di precisione) per generare la tensione di uscita.



Il principio di funzionamento è iterativo: i bit in ingresso vengono presi in analisi uno per volta partendo dal LSB. Ad ogni iterazione il primo ingresso del nodo sommatore è V_{ref} oppure massa a seconda del valore del bit preso in esame. Questo valore è sommato al valore attuale della tensione di uscita, la somma è quindi campionata e divisa per due. Questo valore va ad aggiornare la tensione di uscita e il ciclo si ripeta. Il criterio di funzionamento può essere riassunto come segue: se un bit di ingresso è zero, il nodo riceve 0 V ad uno dei suoi ingressi, il che non porta alcun contributo in termini di tensione di uscita. Tuttavia, se l'input è un 1 logico, il nodo sommatore riceve V_{ref} ad uno dei suoi ingressi. Questo valore eseguirà $n - m$ loop nel circuito, dove m rappresenta l'ordine del bit di ingresso considerato ($m = 0$ è l'LSB, $m = n - 1$ è l'MSB). Ad ogni loop, il suo valore sarà diviso per due, in modo che se l' m -esimo bit è impostato a 1 logico, contribuirà alla tensione di uscita

con un valore finale pari a $V_{ref}/2^{n-m}$. La tensione di uscita complessiva risultante è la somma dei contributi apportati da tutti i bit.

Per chiarire ulteriormente il meccanismo di funzionamento di questo DAC, elaboreremo l'esempio di un DAC a 3 bit che riceve la combinazione 110 in ingresso. Assumiamo una condizione iniziale con $V_{out} = 0$ V. Inizialmente, l'LSB viene presentato al circuito. Poiché il suo valore è impostato su 0 logico, gli ingressi al nodo sommatore saranno massa e $V_{out} = 0$ V. La loro somma è ovviamente 0 V. Questo valore verrà campionato e diviso per due, che di nuovo produce 0 V come nuovo valore di V_{out} . Il 2° LSB viene ora presentato al circuito. Poiché il suo valore è impostato su 1 logico, gli ingressi al nodo sommatore saranno V_{ref} e $V_{out} = 0$ V. La loro somma è V_{ref} . Questo valore verrà campionato e diviso per due, ottenendo $V_{ref}/2$ come nuovo valore di V_{out} . Il 3° LSB (che è l'MSB) viene ora presentato al circuito. Poiché il suo valore è impostato su 1 logico, gli ingressi al nodo sommatore saranno V_{ref} e $V_{out} = V_{ref}/2$. La loro somma è $3V_{ref}/2$. Questo valore verrà campionato e diviso per due, ottenendo $3 V_{ref}/4 = 6 V_{ref}/8$ come nuovo valore di V_{out} . Poiché l'ultimo bit è stato elaborato, la conversione è terminata e il valore effettivo di V_{out} è il valore finale dell'uscita analogica. Si noti che questo è esattamente ciò che ci aspettavamo, poiché la parola digitale 110 è 6 in decimale e con tre bit possiamo rappresentare fino a 8 numeri. Pertanto, ci aspettiamo che l'output sia 6/8 del fondo scala (ovvero V_{ref}), che è esattamente quello che abbiamo ottenuto.

In generale:


$$V_{out} = V_{ref} \sum_{m=0}^{n-1} \frac{D_m}{2^{n-m}} = \frac{V_{ref}}{2^n} D$$

È facile verificare che nell'esempio precedente $n = 3$, $D = (110)_2 = (6)_{10}$, ed effettivamente $V_{out} = 6 V_{ref}/8$.

Il vantaggio principale di questa soluzione circuitale è che non sono richiesti resistori ad alta precisione e si basa principalmente su circuiti digitali, quindi è un'alternativa economica e precisa. Tuttavia, poiché esegue l'operazione in modo iterativo, è più lenta dell'alternativa R-2R e sacrifica velocità per una migliore risoluzione. Gli aspetti non ideali del nodo sommatore e la precisione del guadagno dell'attenuatore (che deve essere il più vicino possibile a 1/2) possono essere fattori critici, specialmente ad alte risoluzioni.

7.3.3 DAC Sigma-Delta


Fondamentalmente, è il gemello dell'ADC sigma-delta, segue gli stessi principi e condivide gli stessi vantaggi. Nello specifico, il circuito è complesso ma può essere costruito con semplici componenti a bassa risoluzione. Può raggiungere una risoluzione equivalente molto elevata adottando una frequenza di campionamento elevata e può vantare basso rumore.



7.4 Filtro di Ricostruzione

Per concludere la discussione sulla conversione A/D e D/A è obbligatorio ricostruire l'intera catena che può portarci da un segnale analogico alla sua rappresentazione digitale e viceversa. Innanzitutto, è necessario un filtro anti-aliasing per prevenire il più possibile l'aliasing. Dopo il filtro anti-aliasing, utilizziamo un circuito di


campionamento sample and hold seguito da un circuito di quantizzazione a nostra scelta (ad esempio, un Flash ADC). A questo punto il segnale è completamente digitalizzato. Se il teorema di Shannon-Nyquist è stato rispettato, il segnale digitale è una rappresentazione fedele del segnale analogico originale senza (idealmente) nessuna perdita di informazioni (in realtà, poiché l'aliasing non può essere completamente evitato, una certa perdita – per quanto minimale – di informazione ci sarà sempre). Se vogliamo riconvertire questo segnale digitale nella sua controparte analogica, il segnale può essere inviato a uno dei DAC che abbiamo studiato. Tuttavia, è necessario un componente aggiuntivo dopo il DAC per finalizzare la conversione D/A in modo appropriato. Dopotutto, il DAC esegue la conversione di una parola digitale a n bit e la converte in una tensione stabile alla sua uscita. Questa tensione sarà stabile fino a quando una nuova parola digitale non sarà inviata al DAC. Pertanto, il segnale di uscita di un DAC è caratterizzato da una forma d'onda a gradini che in qualche modo (molto vagamente) ricorda il segnale analogico originale. Nella figura seguente, un segnale analogico è riportato in grigio. Questo segnale viene convertito nel dominio digitale e riconvertito in analogico tramite il DAC. L'uscita del DAC è mostrata in rosso. Le variazioni discontinue nel dominio del tempo (transizioni verticali) corrispondono a componenti ad alta frequenza nello spettro del segnale rosso. Pertanto, se queste componenti ad alta frequenza vengono tagliate, il segnale risultante sarà più uniforme e coerente con il segnale analogico originale. In effetti, se si utilizza un filtro passa-basso che ha la stessa frequenza di taglio di quella del filtro anti-aliasing, si ottiene esattamente il segnale analogico originale. Questo filtro passa basso da inserire dopo il DAC è chiamato filtro di ricostruzione.



In poche parole, il filtro di ricostruzione leviga la forma d'onda per rimuovere le frequenze immagine (copie) al di sopra del limite di Nyquist. Idealmente, entrambi i filtri (ricostruzione e anti-aliasing) dovrebbero avere:

- Ritardo di fase costante in banda passante;
- Risposta in frequenza piatta costante in banda passante;
- Risposta nulla oltre la frequenza di Nyquist.

Queste proprietà possono essere soddisfatte contemporaneamente solo da un filtro con una risposta all'impulso di tipo "seno cardinale". La funzione seno cardinale, chiamata *sinc*, corrisponde a $\sin(x)/x$ e il suo grafico è mostrato nella figura seguente. Tuttavia, un filtro con una tale risposta all'impulso non è fisico, quindi impossibile da realizzare (è anti-causale, cioè in un tale sistema l'effetto precederebbe la causa). La dimostrazione rigorosa di questa relazione anti-causale va oltre lo scopo di questo opuscolo e può essere trovata in qualsiasi libro di testo di teoria dei controlli. Di conseguenza, i filtri di ricostruzione (e anti-aliasing) reali in genere lasciano passare un po' di segnale anche per componenti al di sopra della frequenza di Nyquist e/o attenuano alcune frequenze in banda passante. Inoltre, a causa della risposta di fase non perfettamente piatta nella banda passante, diverse componenti in frequenza sperimenteranno ritardi (leggermente) diversi, con conseguente (leggero) spostamento relativo nel tempo di una componente rispetto all'altra.



8. Protocolli di Comunicazione Cablata

Un protocollo di comunicazione è un sistema di regole che consente a due o più entità di un sistema di comunicazione di trasmettere informazioni tramite qualsiasi tipo di variazione di una quantità fisica. Il protocollo definisce le regole, la sintassi, la semantica e la sincronizzazione della comunicazione e i possibili metodi di gestione degli errori. I protocolli possono essere implementati da hardware, software o una combinazione di entrambi. I sistemi di comunicazione utilizzano formati ben definiti per lo scambio di vari messaggi. Più protocolli spesso descrivono aspetti diversi di una singola comunicazione. Un gruppo di protocolli progettati per funzionare insieme è noto come suite di protocolli; quando implementati nel software sono uno stack di protocollo. La maggior parte dei protocolli standard sono pubblicati e regolamentati da comitati riconosciuti di esperti e associazioni di professionisti del settore. Ad esempio, i protocolli di comunicazione Internet sono pubblicati dall'Internet Engineering Task Force (IETF). L'IEEE (Institute of Electrical and Electronics Engineers) gestisce le reti cablate e wireless e l'International Organization for Standardization (ISO) gestisce altri tipi di protocolli.


Gestire il flusso dei dati attraverso una rete è lo scopo principale (ma non l'unico) di un protocollo. I protocolli devono quindi specificare le regole che disciplinano la trasmissione dati su una rete di comunicazione. In generale, i seguenti aspetti devono essere specificati:

Formato dei dati

Riguarda la struttura delle stringhe di bit dei messaggi digitali che vengono scambiati. Le stringhe di bit sono suddivise in campi e ogni campo contiene informazioni specifiche. Concettualmente la stringa di bit è divisa in due parti denominate header e payload. Il messaggio vero e proprio viene inserito nel payload. L'header (intestazione) contiene i campi rilevanti per il funzionamento stesso del protocollo e in genere fornisce informazioni accessorie.

Formato degli indirizzi

Gli indirizzi vengono utilizzati per identificare i destinatari previsti. Gli indirizzi sono riportati nell'area di header delle stringhe di bit, consentendo ai ricevitori di determinare se le stringhe di bit sono di interesse e devono essere elaborate o devono essere ignorate perché destinate ad altri. Una connessione tra un mittente e un destinatario può essere identificata utilizzando una coppia di indirizzi (indirizzo del mittente, indirizzo del destinatario) sebbene in molti casi solo l'indirizzo del destinatario venga inviato attraverso la rete di comunicazione. Di solito, alcuni valori di indirizzo specifici e predeterminati hanno significati speciali. Ad esempio, un indirizzo composto da tutti 1 logici potrebbe essere inteso come un indirizzamento collettivo di tutte le stazioni sulla rete, quindi l'invio a questo indirizzo risulterebbe in una trasmissione globale sulla rete. In una rete di comunicazione, infatti, un messaggio generato da un determinato mittente può essere inviato a un determinato destinatario (comunicazione 1-a-1 detta anche unicast), a più destinatari specifici (comunicazione 1-a-molti detta anche multicast), oppure a tutti i destinatari della rete (comunicazione 1-a-tutti detta anche broadcast). Le regole che descrivono i significati degli indirizzi e i relativi schemi vengono collettivamente chiamate schema di indirizzamento.



Rilevamento degli errori di comunicazione

Il rilevamento degli errori è necessario sulle reti in cui è possibile il danneggiamento irreparabile dei dati. Non tutti i protocolli di comunicazione offrono questa possibilità, sebbene molti lo facciano in una certa misura. Tipicamente, alla fine dei pacchetti di dati inviati viene aggiunto un CRC (Cyclic Redundancy Check) del payload, ossia una stringa di bit aggiuntivi calcolati con un particolare algoritmo a partire dai dati che costituiscono il payload. Ciò consente al ricevitore di rilevare l'integrità dei dati ricevuti e di capire se si è verificata una corruzione dei dati. In tal caso il ricevitore rifiuta i pacchetti ricevuti e organizza in qualche modo la ritrasmissione dei dati.

Riconoscimento di ricezione

Il riconoscimento della corretta ricezione dei pacchetti (acknowledgment) è spesso usato (non sempre) ed è molto utile per verificare l'avvenuta trasmissione dei dati. Segnali di conferma vengono inviate dai destinatari ai rispettivi mittenti.

Direzione del flusso di informazioni

I protocolli possono essere classificati in base alla direzione del flusso di informazioni. In effetti, alcuni protocolli consentono alle informazioni di viaggiare in una sola direzione e sono chiamati protocolli di comunicazione simplex. Ad esempio, nelle trasmissioni televisive e radiofoniche "classiche", le informazioni fluiscono solo dal sito trasmittente a più ricevitori e mai nella direzione opposta. Pertanto, i relativi protocolli sono di tipo simplex. Alcuni altri sistemi hanno un canale di comunicazione che opera in entrambe le direzioni ma non simultaneamente; questo è chiamato half duplex. Un paio di ricetrasmittenti walkie-talkie forniscono un circuito di comunicazione half-duplex: solo una parte alla volta può parlare, mentre l'altra ascolta. Tuttavia entrambe hanno possibilità di parlare. Il mezzo di trasmissione (in questo caso il segnale radio) può trasportare informazioni in entrambe le direzioni ma non contemporaneamente. Infine, in un sistema full duplex, entrambe le parti possono comunicare tra loro contemporaneamente. Un esempio di dispositivo full duplex è un semplice servizio telefonico; le parti coinvolte in una chiamata possono parlare ed ascoltare contemporaneamente. L'auricolare riproduce il parlato dell'interlocutore remoto mentre il microfono trasmette il parlato dell'interlocutore locale. C'è un canale di comunicazione bidirezionale tra di loro, o più precisamente, ci sono due canali di comunicazione tra di loro e sono simultaneamente attivi.

La direzione deve essere ben specificata se le trasmissioni possono avvenire solo in una direzione alla volta come su collegamenti half-duplex o da un mittente alla volta come su un supporto condiviso (cosiddetto controllo dell'accesso ai media). Devono essere presi accordi per gestire i casi di collisione o contesa in cui due parti rispettivamente trasmettono o desiderano trasmettere simultaneamente.

Controllo di sequenza

Se le stringhe di bit lunghe vengono suddivise in pezzi e quindi inviate alla rete singolarmente, i pezzi potrebbero andare persi o arrivare in ritardo o, su alcuni tipi di rete, prendere percorsi diversi da quello previsto viaggiando verso la loro destinazione. Di conseguenza, i pezzi potrebbero arrivare non nella sequenza corretta. Le possibili ritrasmissioni di alcuni pezzi (ad esempio in caso di rifiuto da parte del ricevente a causa di rilevamento di corruzione dei dati) possono causare ulteriori complicazioni. Contrassegnando i vari pezzi con informazioni relative alla sequenza (ad esempio un numero ordinale), il ricevente può determinare cosa è andato perso o duplicato, chiedere le necessarie ritrasmissioni e rimontare il messaggio originale.

Controllo di flusso


Il controllo del flusso è necessario quando il mittente trasmette più velocemente di quanto il ricevitore o le apparecchiature di rete intermedie possano elaborare le trasmissioni. Il controllo del flusso può essere implementato tramite messaggi dal destinatario al mittente.

Esistono diversi protocolli di interesse e che meritano approfondimenti, sia per quanto riguarda i protocolli cablati che per quanto riguarda quelli wireless. I protocolli cablati sono quelli per i quali il mezzo di trasmissione è un mezzo solido (tipicamente un cavo o una pista di rame), al contrario dei protocolli wireless per i quali il mezzo di trasmissione è tipicamente l'aria (es. WiFi, Bluetooth, LTE, 5G). Ai fini di questo corso, ci concentreremo sui due protocolli cablati più frequentemente utilizzati che vengono utilizzati sulle schede elettroniche e sui microcontrollori, che sono il protocollo Serial Peripheral Interface (SPI) e il protocollo Inter-Integrated Circuit (I²C).

8.1 Serial Peripheral Interface (SPI)

La Serial Peripheral Interface (SPI) è un'interfaccia di comunicazione seriale sincrona utilizzata per la comunicazione a breve distanza, principalmente nei sistemi embedded. L'interfaccia è stata originariamente sviluppata da Motorola negli anni '80 ed è diventata di fatto uno standard ampiamente utilizzato anche ai giorni nostri, soprattutto nelle comunicazioni tra sensori e microcontrollori integrati, schede Secure Digital e driver di display a cristalli liquidi (tra molti altre applicazioni).

I dispositivi SPI comunicano in modalità full duplex utilizzando un'architettura master-slave con un unico master. Per essere più precisi, SPI consente una comunicazione master e multi slave. Ciò significa che, mentre è possibile coinvolgere più di due dispositivi in un processo di comunicazione, c'è sempre uno (e solo uno) dispositivo che funge da master della comunicazione, dettando i dettagli del processo di comunicazione, con gli altri dispositivi che seguono le regole dettate dal master. A volte il bus SPI è chiamato bus seriale a quattro fili (poiché utilizza effettivamente quattro fili per attivare la comunicazione), in contrasto con bus seriali a tre, due e un filo. L'SPI può essere accuratamente descritto come un'interfaccia seriale sincrona, ma è diverso dal protocollo Synchronous Serial Interface (SSI), che è anche un protocollo di comunicazione seriale sincrona a quattro fili che tuttavia fornisce un solo canale di comunicazione simplex. Viceversa, come schematizzato nella figura sottostante, il protocollo SPI è full duplex ciò significa che c'è una trasmissione simultanea di dati dal master allo slave e dallo slave al master.



Il bus SPI specifica quattro segnali logici che viaggiano su quattro fili:


- SCLK: Serial Clock (uscita del master, ingresso per lo slave)
- MOSI: Master Out Slave In (uscita dati dal master, in ingresso allo slave)
- MISO: Master In Slave Out (uscita dati dallo slave, in ingresso al master)
- SS: Slave Select (spesso attivo nello stato logico basso, uscita del master, ingresso dello slave)

Come si può vedere nel diagramma sopra, ogni pin sul master si collega allo stesso pin sullo slave, ad esempio, MOSI su un master si collega a MOSI su uno slave, e allo stesso modo MISO su un master si collega a MISO su uno slave. La linea SCLK trasporta un segnale di clock che determina i tempi della comunicazione. La linea SS porta un segnale che viene impostato dal master per identificare univocamente lo slave con cui avverrà la comunicazione. Si noti che, tipicamente, la linea SS è "attiva bassa", il che significa che la linea è considerata attiva quando sulla linea è presente un segnale basso (0 logico), al contrario delle linee "attive alte" che sono considerate attive quando un segnale alto (logico 1) è presente. I nomi dei segnali sopra riportati vengono

utilizzati per etichettare in modo univoco i pin del dispositivo nonché le linee di segnale tra di essi e sono i più comuni nei prodotti moderni. Tuttavia, i prodotti meno recenti possono avere nomi di pin SPI non standard.

8.1.1 Principio di Funzionamento

Il protocollo SPI opera con un unico dispositivo master e con uno o più dispositivi slave. Si noti che molto spesso l'hardware che costituisce l'interfaccia SPI non viene fornito con una configurazione fissa (master o slave) ma deve essere configurato per agire come master o come slave. Ciò significa che è possibile riconfigurare uno slave in modo che si comporti come master e viceversa. Se ci sono più dispositivi slave sulla rete, è richiesto che il master abbia un segnale SS indipendente per ciascun dispositivo slave (a meno che non venga utilizzata la configurazione daisy chain, come discusso più avanti). La maggior parte dei dispositivi slave ha uscite a tre stati (ovvero, pin che possono essere pilotati all'1 logico, allo 0 logico o disconnessi cioè in alta impedenza), quindi il loro segnale MISO diventa ad alta impedenza (scollegato elettricamente) quando il dispositivo non è attivo e coinvolto in una comunicazione. Ciò consente di condividere la stessa linea tra più di due dispositivi. Di fatto, i dispositivi senza uscite a tre stati non possono condividere segmenti di bus SPI con altri dispositivi senza utilizzare un buffer a tre stati esterno.




Per iniziare la comunicazione, il master configura il segnale di clock, utilizzando una frequenza supportata dal dispositivo slave, tipicamente fino a pochi MHz, e abilita il segnale di clock sulla linea SCLK. Il master seleziona quindi il dispositivo slave forzando uno 0 logico sulla linea SS, di fatto avviando la comunicazione. Da questo momento in poi, ad ogni fronte di discesa (o di salita, vedere i dettagli più avanti) di clock viene trasmesso un singolo bit dal master allo slave sulla linea MOSI e contemporaneamente un bit viene trasmesso dallo slave al master sulla linea MISO, ovvero, durante ogni ciclo di clock SPI si verifica una trasmissione full-duplex di 1 bit. Questa strategia viene mantenuta anche quando è previsto un mero trasferimento di dati unidirezionale. Le trasmissioni di dati normalmente coinvolgono due registri a scorrimento di una determinata dimensione, ad esempio otto bit, uno nel master e uno nello slave. Per mezzo della linea MOSI e MISO sono collegati in una topologia ad anello, il che significa che i due registri a scorrimento fisici collegati tra loro formano virtualmente un unico registro a scorrimento circolare. I dati vengono solitamente spostati partendo dal bit più significativo (ma non necessariamente). Sul fronte del clock, sia il master che lo slave shiftano un bit sulla linea di trasmissione (MISO/MOSI) rendendolo disponibile alla controparte. Sul fronte di clock successivo, il bit viene campionato dalla linea di trasmissione e impostato come nuovo bit meno significativo dello shift register. Dopo che tutti i bit nei registri a scorrimento sono stati trasmessi, il master e lo slave si sono in effetti scambiati il contenuto dei registri. Se è necessario scambiare più dati, i registri a scorrimento vengono ricaricati con dati nuovi e il processo si ripete. La trasmissione può continuare per un numero qualsiasi di cicli di trasmissione. Al termine, il master interrompe la trasmissione deselectando lo slave (ovvero forzando la linea SS a 1 logico). Le trasmissioni spesso sono orchestrate in parole da otto bit. Tuttavia, sono possibili configurazioni con un numero di bit differente, come parole a dodici bit utilizzate da molti convertitori digitale-analogico o analogico-digitale e parole fino a sedici bit tipicamente utilizzate per controller touch-screen o codec audio.

Quando nella rete sono presenti più di due dispositivi, il master deve selezionare lo slave con cui vuole comunicare tramite la linea SS dedicata. Ogni slave sul bus che non è stato attivato utilizzando la sua linea SS

deve ignorare i segnali di ingresso SCLK e MOSI e non deve pilotare MISO (cioè, deve avere un'uscita a tre stati lasciata ad alta impedenza). Tuttavia, esiste più di un modo possibile per organizzare la trasmissione dei dati in una rete composta da più di due dispositivi. Qui esamineremo le due alternative più comuni, ovvero la configurazione slave indipendente e la configurazione daisy chain.

8.1.2 Slaves Indipendenti


Nell'esempio riportato di seguito, quattro dispositivi formano una rete di comunicazione tramite un bus SPI condiviso nella cosiddetta configurazione a slaves indipendenti. In questa configurazione è presente una linea SS indipendente per ogni slave. Questo è il modo in cui viene normalmente utilizzato il protocollo SPI. Il master può comunicare con un solo slave alla volta e seleziona il dispositivo di destinazione asserendo la relativa linea SS per un solo slave alla volta. Si consiglia di usare resistori di pull-up (come quelli utilizzati nella configurazione open collector delle porte logiche) tra la fonte di alimentazione e le linee SS in modo che le linee SS non selezionate siano portate di default allo stato logico alto, prevenendo errori.



Poiché i pin MISO degli slave sono collegati tra loro, le uscite MISO devono essere necessariamente a tre stati, e l'uscita ad alta impedenza deve essere applicata quando lo slave non è coinvolto in una comunicazione. I dispositivi slave che non hanno pin tri-state possono essere utilizzati in una configurazione slave indipendente aggiungendo un buffer aggiuntivo a tre stati controllato dal segnale SS. Si noti che anche le linee SCLK e MOSI sono condivise dagli slave, ma sono sempre pilotate dal master quindi non sono richiesti pin tri-state per queste linee.


8.1.3 Daisy Chain

In questa configurazione la comunicazione è gestita in modo diverso, e tutti gli slave sono attivi contemporaneamente (tipicamente detti slave cooperativi). In questa configurazione, denominata daisy chain, il MOSI del master è collegato solo al MOSI del primo slave. Quindi, il MISO del primo slave viene collegato al MOSI del secondo slave. Il MISO del secondo slave è collegato al MOSI del terzo slave e così via. Il MISO dell'ultimo slave è collegato al MISO del master. In questo modo, l'intera catena forma un unico grande registro a scorrimento circolare. Pertanto, i dati del master vengono trasferiti al primo slave mentre, contemporaneamente, i dati del primo slave vengono trasferiti al secondo slave e così via. Tale caratteristica richiede solo una singola linea SS al master, piuttosto che una linea SS separata per ogni slave, utile in quelle applicazioni in cui è obbligatorio ridurre il numero di fili e cavi. Le linee SS e SCLK sono condivise tra tutti i dispositivi.



8.1.4 Polarità e Fase del Clock

È ora istruttivo dare un'occhiata al diagramma temporale di una comunicazione SPI completa tra un master e uno slave. Un esempio è mostrato nella figura seguente in cui le linee rosse denotano i fronti di salita del clock e le linee blu denotano i fronti di discesa.



Dalla figura sopra, è facile vedere che la comunicazione inizia quando viene asserito il segnale SS (cioè, pilotato al livello logico basso) e termina quando viene disattivato (cioè, pilotato al livello logico alto). Da quel momento in poi, i fronti di commutazione della linea SCLK (di discesa o di salita) determinano gli istanti di tempo in cui ogni singolo bit viene trasferito in modalità full duplex. Tuttavia, l'utente ha la libertà di decidere alcuni dettagli importanti della comunicazione che identificano appunto con precisione gli istanti di tempo in cui i dati da trasferire vengono inseriti sul bus dal mittente e gli istanti di tempo in cui i dati disponibili sulla linea di comunicazione vengono effettivamente letti dal ricevitore. Ciò è possibile impostando correttamente due parametri importanti, chiamati polarità di clock (CPOL) e fase di clock (CPHA). Questi parametri sono impostati dal master. Nello specifico, CPOL determina la polarità del clock, mentre CPHA determina la temporizzazione (cioè la fase) dei bit di dati rispetto agli impulsi di clock. Se CPOL = 0, il clock è inattivo a 0 e attivo a livello logico 1. Ciò significa che il fronte di salita precede temporalmente quello di discesa. Se invece CPOL = 1 allora il clock è inattivo a 1, e attivo a livello logico 0. Ciò significa che il fronte di salita segue temporalmente quello di discesa. Questo è chiaramente abbozzato nella figura sopra.

Mode	CPOL	CPHA	First bit written	Other bits written	Data read
0	0	0	Prior to first SCLK rising edge	SCLK falling edge	SCLK rising edge
1	0	1	First SCLK rising edge	SCLK rising edge	SCLK falling edge
2	1	0	Prior to first SCLK falling edge	SCLK rising edge	SCLK falling edge
3	1	1	First SCLK falling edge	SCLK falling edge	SCLK rising edge

Le impostazioni di CPHA sono meno intuitive ma ugualmente importanti. In particolare, per CPHA = 0, il mittente imposta i dati disponibili in uscita sul secondo fronte del ciclo di clock precedente, mentre il ricevitore legge i dati sul primo fronte del ciclo di clock corrente. Il mittente mantiene i dati validi fino al secondo fronte del ciclo di clock corrente. Al primo ciclo di clock, il primo bit deve trovarsi sulla linea MOSI/MISO prima del fronte di clock iniziale. Per CPHA = 1, il mittente modifica i dati disponibili alla sua uscita sul primo fronte del ciclo di clock corrente, mentre il ricevitore legge i dati sul secondo fronte del ciclo di clock corrente. Il mittente mantiene i dati validi fino al primo fronte del ciclo di clock successivo. All'ultimo ciclo, lo slave mantiene stabile il dato disponibile sulla linea MISO fino a quando la selezione dello slave non viene disattivata. Pertanto, a seconda delle possibili combinazioni di CPOL e CPHA si hanno quattro possibili schemi leggermente diversi, detti modi di trasmissione dei dati, che differiscono per la precisa tempistica con cui i dati vengono scritti sulle linee e letti dai ricevitori, come sintetizzato nella tabella sopra.

8.1.5 Registri SPI ed Errori

L'interfaccia SPI deve essere configurata correttamente prima che possa aver luogo un'eventuale operazione. Per procedere con la configurazione è necessario scrivere correttamente alcuni registri di memoria. Ogni bit specifico di ogni registro specifico avrà un ruolo specifico e detterà un aspetto specifico relativo alla configurazione dell'interfaccia SPI. In generale, SPI ha sette registri, ma solo cinque di questi registri sono pensati per scopi di configurazione. I due restanti registri sono destinati esclusivamente alla verifica funzionale. I cinque registri di configurazione sono chiamati control register, status register, data register, clock counter register e interrupt flag register. Di seguito descriveremo il ruolo svolto da ogni singolo bit di questi cinque registri.

Name	Descriptive Name	Description	Access
SOSPCR	Control Register	Controls the SPI operation	R/W
SOSPSR	Status Register	Shows the status of the SPI	Read Only
SOSPDR	Data Register	Contains the data to be written and read	R/W
SOSPCCR	Clock Counter Register	Controls the frequency of the SCLK	R/W
SOSPINT	Interrupt Flag Register	Contains the interrupt flag	R/W

Control Register

L'SOSPCR è composto da 16 bit numerati da 0 a 15. I bit 0 e 1 sono riservati, il che significa che l'utente non deve scrivere un 1 logico in queste posizioni. Ciò significa che quando si scrive l'SOSPCR, i due bit meno significativi devono essere sempre impostati a 0. Il bit 2 è chiamato Bit Enable e specifica la quantità di bit dei dati da trasferire ad ogni ciclo di trasmissione dati. In particolare, se Bit Enable è impostato su 0, il controller SPI invia e riceve 8 bit di dati per ciclo di trasferimento. Al contrario, se Bit Enable è impostato su 1, il controller SPI invia e riceve ad ogni ciclo di trasferimento un numero di bit di dati identificati dal valore dei Bit da 8 a 11 dell'SOSPCR. Il bit 3 controlla direttamente il valore di CPHA. Il bit 4 controlla direttamente il valore di CPOL. Il bit 5 è chiamato Master (MSTR) e determina se l'interfaccia SPI deve comportarsi come un master (MSTR = 1) o come uno slave (MSTR = 0). Il bit 6 è chiamato LSB First (LSBF) e controlla la direzione


con cui vengono trasferiti i dati, ovvero LSB first e MSB last (LSBF = 1) o MSB first e LSB last (LSBF = 0). Il bit 7 è chiamato Interrupt Enable (SPIE) e determina il comportamento dell'SPI quando vengono verificate alcune condizioni specifiche. Nello specifico, ogni volta che vengono attivati i bit SPIF o MODF (vedi più avanti), se SPIE = 0 non succede nulla, altrimenti viene generato un interrupt di processo. I bit da 8 a 11 sono importanti solo quando Bit Enable è impostato su 1. In questo caso, i bit da 8 a 11 specificano il numero di bit di dati per ciclo di trasferimento, come segue:

Bit 11	Bit 10	Bit 9	Bit 8	Bits per transfer
1	0	0	0	8
1	0	0	1	9
1	0	1	0	10
1	0	1	1	11
1	1	0	0	12
1	1	0	1	13
1	1	1	0	14
1	1	1	1	15
0	0	0	0	16

Infine, i bit da 12 a 15 sono riservati.

Data Register

L'SOSPDR è composto da un numero di bit che può variare da 8 a 16 a seconda delle impostazioni dell'SOSPCR. Questo è un registro bidirezionale che fornisce i dati da trasmettere così come i dati ricevuti ad ogni ciclo di trasferimento. I dati da trasmettere devono essere scritti sull'SOSPDR prima del trasferimento e i dati ricevuti dopo il trasferimento possono essere letti da questo registro.



Si noti che non è presente alcun buffer tra il registro dati e il registro a scorrimento interno. Una scrittura sul data register va direttamente a scrivere il registro a scorrimento interno, sovrascrivendone il contenuto. Pertanto, i dati dovrebbero essere scritti in questo registro solo quando una trasmissione non è attualmente in corso, altrimenti si verifica un errore noto come collisione di scrittura (dettagliato più avanti). Al contrario, i dati letti vengono memorizzati in un buffer di lettura che si interfaccia a sua volta con il data register. Ciò significa che quando un processo di trasferimento è completato, i dati ricevuti (disponibili nello shift register) vengono automaticamente trasferiti al buffer, dal quale vengono successivamente letti quando si effettua una lettura del data register. Pertanto, una lettura del data register restituisce il valore del buffer. Ciò significa anche che è possibile leggere il pacchetto di dati ricevuti anche quando è in corso un altro trasferimento, poiché durante il processo di trasferimento il contenuto del buffer di lettura non viene alterato (cambia solo il contenuto dello shift register). Naturalmente, se il contenuto del buffer di dati non viene letto prima della fine del processo di trasferimento successivo, il buffer di dati viene sovrascritto con il contenuto del registro a scorrimento (nuovi dati ricevuti) e i dati ricevuti al ciclo di trasferimento dati precedente (che non sono stati letti) vengono persi definitivamente. Questo è un errore chiamato read overrun (dettagliato più avanti). Gli 8 bit meno significativi del registro dati sono sempre ben definiti in quanto il numero minimo di bit

trasferibili è 8. Gli 8 bit più significativi possono contenere informazioni o meno, a seconda dell'impostazione dell'SOSPCR. Quando vengono selezionati meno di 16 bit, il più significativo tra questi bit viene letto come zero.

Status Register

L'SOSPSR è composto da 8 bit ed è un registro di sola lettura. I bit da 0 a 2 sono riservati. Il bit 3 è chiamato Slave Abort (ABRT). Quando 1, ABRT indica che si è verificata un'interruzione dello slave. Un trasferimento slave viene considerato interrotto se il segnale SS diventa inattivo (quindi alto nella maggior parte delle interfacce) prima che il trasferimento sia completo. In caso di interruzione dello slave, i dati trasmessi vengono persi e viene attivato il bit ABRT nel registro di stato. Questo bit viene cancellato leggendo SOSPSR. Il bit 4 è chiamato Mode Fault (MODF). Quando è 1, questo bit indica che si è verificata una condizione di errore di modalità. Se il segnale SS diventa attivo quando il blocco SPI è un master, ciò indica che un altro master ha selezionato lo stesso dispositivo come slave. Quando viene rilevato un errore di modalità, verrà attivato il bit di errore di modalità (MODF) nel registro di stato. Questo bit viene cancellato leggendo SOSPSR e quindi scrivendo SOSPCR (per correggere l'errore). Il bit 5 è chiamato Read Overrun (ROVR). Quando è 1, questo bit indica che si è verificata una condizione di overrun di lettura. Un overrun di lettura si verifica quando il buffer di lettura interno del blocco SPI contiene dati che non sono stati letti (tramite lettura del data register) e viene completato un nuovo trasferimento sovrascrivendo il vecchio contenuto che viene quindi perso permanentemente. Il fatto che il buffer di lettura contenga dati validi e pronti per essere letti è indicato dal bit SPIF nell'SOSPSR attivo (vedere più avanti in questa sottosezione). Al termine di un trasferimento, il blocco SPI deve spostare i dati ricevuti nel buffer di lettura. Se il bit SPIF è attivo (il buffer di lettura è pieno e non è stato letto – dettagliato più avanti), i vecchi dati ricevuti andranno persi e il bit ROVR nell'SOSPSR verrà attivato. Questo bit viene cancellato leggendo SOSPSR. Il bit 6 è chiamato Write Collision (WCOL). Quando è 1, questo bit indica che si è verificata una condizione di collisione di scrittura. Come affermato in precedenza, non esiste un buffer di scrittura tra l'SOSPDR e lo shift register interno. Di conseguenza, i dati non devono essere scritti nell'SOSPDR quando è in corso un trasferimento di dati. L'intervallo di tempo in cui i dati non possono essere scritti nell'SOSPDR va da quando inizia il trasferimento fino a quando l'SOSPSR è stato letto (con il bit SPIF attivo, il che indica che sono disponibili dati nuovi da leggere). Se l'SOSPDR viene scritto in questo intervallo di tempo, i dati andranno persi e il bit WCOL verrà attivato. Questo bit viene cancellato leggendo SOSPSR e quindi accedendo a SOSPCR. Infine, il bit 7 è chiamato SPI Transfer Complete Flag (SPIF). Quando è 1, questo bit indica che un processo di trasferimento è stato completato. Quando il dispositivo è un master, questo bit viene impostato al termine dell'ultimo ciclo di trasferimento. Invece, quando il dispositivo è uno slave, questo bit è impostato sull'ultimo fronte di campionamento dati (lettura) dell'SCLK. Questo bit viene cancellato leggendo prima SOSPSR, quindi accedendo a SOSPCR.

Interrupt Flag Register

L'SOSPINT è composto da 8 bit, ma i bit da 1 a 7 sono riservati. In effetti, l'unico bit rilevante di SOSPINT è il Bit 0, che viene chiamato SPI Interrupt Flag (da non confondere con il bit SPIF in SOSPSR). Questo bit viene impostato dall'interfaccia SPI per generare un interrupt di processo. Può essere cancellato scrivendo un 1 in questo bit.

Clock Counter Register

L'SOSPCCR è composto da un numero di bit che può variare da interfaccia SPI a interfaccia SPI. Questo registro controlla la frequenza del segnale SCLK del master. Tale segnale viene infatti tipicamente creato internamente prendendo un segnale di clock esterno (PCLK) e dandolo in pasto a un divisore di frequenza. Il segnale di clock risultante (che sarà l'SCLK) sarà quindi a una frequenza inferiore rispetto a PCLK. SOSPCCR indica il numero di cicli PCLK che compongono un ciclo SCLK. Pertanto, contiene il divisore utilizzato dal

divisore di frequenza. Il valore di S0SPCCR deve essere sempre un numero pari. Di conseguenza, il bit 0 deve essere sempre 0.

8.1.6 Sequenza delle Operazioni

In questa sezione illustreremo la sequenza di operazioni necessarie per configurare correttamente il dispositivo e trasferire i dati nel caso in cui il dispositivo sia impostato come master e anche nel caso in cui il dispositivo sia impostato come slave.

Master

La sequenza seguente descrive come orchestrare un trasferimento di dati con il protocollo SPI quando il dispositivo in questione è impostato per essere il master. Questo processo presuppone che qualsiasi trasferimento di dati precedente sia già stato completato. Inizialmente, l'S0SPCCR deve essere impostato correttamente sulla frequenza di clock desiderata. Quindi, S0SPCR deve essere scritto in base alle impostazioni desiderate. Naturalmente il bit MSTR deve essere impostato a 1. Per avviare un trasferimento dati, i dati da trasmettere devono essere scritti nell'S0SPDR. Questo evento avvia effettivamente il trasferimento dei dati SPI. Dal punto di vista hardware, in questo momento verrà attivata la linea SS (impostata a 0 logico) e verrà attivato il segnale SCLK (che comincerà a oscillare alla frequenza impostata in precedenza). Al completamento del processo di trasferimento dei dati, il segnale SCLK si fermerà e quindi il segnale SS verrà disattivato. A questo punto (dopo l'ultimo ciclo di trasferimento dati SPI) il bit SPIF nell'S0SPSR sarà impostato a 1. Il suo stato può essere controllato leggendo continuamente l'S0SPSR fino a che non si trova un 1 sul bit SPIF. A questo punto è possibile leggere l'S0SPDR, se lo si desidera, per leggere i dati ricevuti. Per trasmettere più dati, è possibile eseguire un'altra scrittura sull'S0SPDR, ripetendo la procedura. Si noti che è necessaria una lettura o scrittura di S0SPDR per cancellare il bit SPIF. Pertanto, se non avviene la lettura facoltativa dell'S0SPDR, è necessaria una scrittura su questo registro per azzerare il bit SPIF.

Slave

La sequenza seguente descrive come elaborare un trasferimento di dati con il protocollo SPI quando il dispositivo in questione è impostato per essere lo slave. Questo processo presuppone che qualsiasi trasferimento di dati precedente sia già stato completato. Inizialmente, l'S0SPCR deve essere scritto in base alle impostazioni desiderate. Naturalmente il bit MSTR deve essere impostato a 0. Opzionalmente, i dati da trasmettere devono essere scritti sull'S0SPDR. Si noti che questo può essere fatto solo quando non è in corso un trasferimento SPI slave. È quindi necessario attendere che il bit SPIF venga impostato a 1. A questo punto (dopo l'ultimo fronte di clock di campionamento del trasferimento dati SPI) il bit SPIF nell'S0SPSR verrà impostato a 1. Il suo stato può essere controllato leggendo continuamente S0SPSR fino a quando non viene trovato un 1 sul bit SPIF. A questo punto è possibile leggere l'S0SPDR, se lo si desidera, per leggere i dati ricevuti. Per trasmettere più dati, è possibile eseguire un'altra scrittura sull'S0SPDR, ripetendo la procedura. Si noti che è necessaria una lettura o scrittura di S0SPDR per cancellare il bit SPIF. Pertanto, per cancellare il bit SPIF deve avvenire almeno una lettura o scrittura dell'S0SPDR.

8.1.7 Vantaggi e Svantaggi

I principali vantaggi offerti dal protocollo SPI sono principalmente legati alla sua comunicazione full duplex. Inoltre, offre un'elevata velocità rispetto a I²C. Si noti che la velocità di comunicazione non è di per sé limitata a nessuna velocità di clock massima, consentendo velocità potenzialmente molto elevate se supportate dall'hardware. Il protocollo offre una completa flessibilità per quanto riguarda il numero di bit trasferiti e la parola non è limitata a 8 bit ma può arrivare fino a 16. Il contenuto del messaggio da trasferire è del tutto arbitrario, così come il suo scopo. L'interfaccia hardware e il collegamento sono molto semplici e richiedono

una modesta quantità di energia, in genere inferiore a I²C, poiché utilizza meno circuiti. Un altro vantaggio è che il clock è generato direttamente dal master, il che significa che lo slave non deve necessariamente avere a bordo oscillatori precisi e circuiti dedicati per produrre localmente un segnale di clock stabile. Inoltre, gli slaves vengono selezionati direttamente e quindi non necessitano di alcun indirizzo univoco, a differenza di I²C.


Tuttavia, il protocollo SPI mostra anche alcuni svantaggi. In particolare, richiede più pin rispetto a I²C. Non esiste un meccanismo per il riconoscimento dello slave (il master potrebbe trasmettere dati a uno slave inesistente senza saperlo). Supporta un solo dispositivo master (sebbene la comunicazione multi-master sia tecnicamente possibile in alcune implementazioni SPI avanzate). Infine, gestisce solo brevi distanze rispetto ad altri bus come RS-232, RS-485 o CAN-bus (non trattati in questo corso).

La modalità full-duplex rende SPI molto semplice ed efficiente per applicazioni single master/single slave. Alcuni dispositivi utilizzano la modalità full-duplex per implementare un flusso di dati efficiente per applicazioni quali audio digitale, elaborazione del segnale digitale o gestione dei canali di telecomunicazione. SPI viene utilizzato per comunicare con una varietà di periferiche, come sensori (temperatura, pressione, ADC, touchscreen, controller per videogiochi...), dispositivi di controllo (codec audio, potenziometri digitali, DAC...), fotocamere, chip di memoria (come Chip Flash e EEPROM), display, schede MMC o SD.


Il bus SPI è uno standard de facto. Tuttavia, la mancanza di uno standard formale si riflette in un'ampia varietà di opzioni di protocollo. Sono comuni dimensioni di parole diverse da quelle canoniche viste finora. Ogni dispositivo definisce il proprio protocollo in modo diverso. Alcuni dispositivi sono di sola trasmissione; altri possono essere di sola ricezione. Gli SS a volte sono attivi allo stato logico alto piuttosto che a quello basso. Alcuni protocolli inviano prima il bit meno significativo. È quindi indispensabile selezionare attentamente l'interfaccia SPI più adatta per ogni specifica applicazione e leggere attentamente la scheda tecnica. Potrebbero esserci anche, in alcuni casi, differenze a livello di hardware. Alcuni chip combinano MOSI e MISO in un'unica linea dati (SI/SO); questo è talvolta chiamato protocollo "a tre fili" (in contrasto con il normale SPI "a quattro fili"). Un'altra variante di SPI rimuove la linea SS, indirizzando gli slave tramite altri metodi.

8.2 Protocollo Inter-Integrated Circuit (I²C)

L'acronimo I²C o I2C deriva dal termine Inter-Integrated Circuit. Poiché I²C è implementato solo da tramite due fili (chiamati SDA e SCL), è anche chiamato TWI (Two Wire Interface). I²C è un protocollo a bassa larghezza di banda e a breve distanza per le comunicazioni a bordo scheda, più o meno come SPI. Tutti i dispositivi sono collegati tramite due fili condivisi: dati seriali (SDA) e clock seriale (SCL). Il principale vantaggio di questo protocollo è che queste due linee sono condivise tra tutti gli elementi della rete. Questo è molto vantaggioso in diversi casi, ad esempio quando si collegano più dispositivi a un microcontrollore. Generalmente si potrebbe pensare di collegare la linea dati di ciascun dispositivo individualmente, ognuna ad un pin diverso del microcontrollore. Ciò occuperebbe pin preziosi sul microcontrollore, provocherebbe molte tracce di rame da dover realizzare sulla scheda PCB e richiederebbe più componenti per collegare tutto insieme. Ciò ha reso questi sistemi costosi da produrre e suscettibili a interferenze e rumore. Da questo punto di vista, il protocollo I²C richiede solo due pin, indipendentemente dal numero di elementi sulla rete, il che rappresenta un vantaggio critico.




I²C è una tecnologia di comunicazione seriale sincrona originariamente progettata per lo scambio di dati tra più chip integrati. Il meccanismo di comunicazione è progettato in modo molto intelligente e richiede solo due linee. Una delle linee è utilizzata per inviare il segnale di clock (poiché la comunicazione è sincrona, quindi è necessario un segnale di clock) e l'altra linea è per inviare/ricevere dati. Queste linee sono condivise in generale da più dispositivi. Questo protocollo di comunicazione funziona come in modalità Master-Slave, con un master che controlla le comunicazioni con uno o più slave. Indipendentemente dal numero di unità slave collegate al bus I²C, ci sono solo due terminali che collegano tutte le unità. Di conseguenza, è necessario un meccanismo di indirizzamento affinché il dispositivo master comunichi con un dispositivo slave specifico. Poiché tutta la comunicazione avviene su due soli fili e non esiste una linea di selezione slave, tutti i dispositivi devono avere un indirizzo univoco per identificarlo sul bus. In alcuni casi, valori di indirizzo specifici possono identificare un gruppo di dispositivi o la totalità dei dispositivi per consentire la comunicazione multicast o broadcast.



Come illustrato nella figura sopra, il protocollo I²C offre effettivamente il supporto per il funzionamento multi-master. In questo caso, ci sono diversi dispositivi configurati come slave, un dispositivo configurato come master (master principale) e alcuni dispositivi che possono essere sia slave che master e che possono cambiare dinamicamente il proprio ruolo. Si dice che il dispositivo che in un dato istante si comporta effettivamente come il master detenga "l'arbitrato". L'arbitrato e la sua perdita sono orchestrati dal master principale.


Anche se il protocollo I²C richiede solo due linee, in alcune applicazioni reali vengono fornite anche un paio di linee aggiuntive per consentire di fornire l'alimentazione e la il riferimento comune a massa a ciascuno dei chip collegati in rete, come mostrato a destra. Per questo motivo deve essere previsto un collegamento a quattro fili, con alcune resistenze di pull-up che collegano le linee SDA e SCL alla linea di alimentazione.



8.2.1 Principi di Funzionamento

L'I²C è un protocollo master/slave. Il master avvia e controlla la comunicazione. La sequenza di eventi necessari per eseguire una comunicazione è la seguente. Inizialmente, il dispositivo master emette una condizione di avvio (dettagliata più avanti). Questa condizione informa tutti i dispositivi slave nella rete di


rimanere in ascolto sulla linea dati seriale per ricevere istruzioni. Il dispositivo master invia quindi l'indirizzo del dispositivo slave con cui desidera comunicare, seguito da un flag di lettura/scrittura. Questo flag indica se il master desidera inviare informazioni allo/agli slave o ricevere comunicazioni da uno slave. Nel caso di scrittura, l'indirizzo può anche identificare più di uno slave (cioè per comunicazioni multicast o broadcast). Il dispositivo slave con l'indirizzo corrispondente risponde con un segnale di conferma. A questo punto la comunicazione tra il master e lo slave sul bus dati procede. Si noti che, poiché esiste un'unica linea dati, la comunicazione è half-duplex e non full-duplex. Pertanto, sia il master che lo slave possono ricevere o trasmettere dati a seconda del flag di lettura/scrittura. Il trasmettitore (master o slave, a seconda del valore del flag di lettura/scrittura) invia 8 bit di dati al ricevitore che risponde con un bit di conferma di avvenuta ricezione. La comunicazione prosegue seguendo questo schema fino al trasferimento di tutti i dati da trasferire. Al termine, quando la comunicazione è completa, il master emette una condizione di stop (dettagliata più avanti) che indica la fine della comunicazione.



Di seguito si riporta una vista più dettagliata della struttura dei bit che viaggiano sulla linea SDA.



È ora istruttivo dare un'occhiata a come le condizioni di partenza e di arresto vengono emesse dal master. Va detto che la condizione di riposo sia per la linea SDA che per quella SCL è al livello logico alto.



La condizione iniziale è una transizione da livello logico alto a livello logico basso sulla linea SDA quando l'SCL è ancora alto. Pertanto, la linea SCL inizia a commutare dopo la condizione di avvio, e la frequenza del segnale sulla linea SCL determina la velocità alla quale i bit viaggiano sulla linea SDA. Allo stesso modo, la condizione di arresto è una transizione da basso ad alto sulla linea SDA quando l'SCL è già stabilmente al livello logico alto. Pertanto, la linea SCL deve interrompere la commutazione prima che venga emessa la condizione di arresto.

8.2.2 Vantaggi e Svantaggi

Tra i vantaggi del protocollo I²C c'è il fatto che richiede solo due linee. Inoltre, I²C supporta velocità dati multiple. Tuttavia, diversamente dall'SPI, la frequenza di clock non può essere impostata in modo arbitrario.

Esistono infatti tre tipi di velocità per l'interfaccia I²C: standard (100 kbps), veloce (400 kbps) e ad alta velocità (3.4 Mbps). Questo protocollo ha anche un meccanismo integrato di rilevamento delle collisioni di dati (può rilevare se più di un dispositivo sta tentando di forzare la comunicazione sulle linee condivise). Supporta l'indirizzamento a 10 bit, il che significa che il numero di dispositivi che possono condividere le stesse linee è molto grande (cioè 2¹⁰). Inoltre, supporta una implementazione multi-master abbastanza semplice. Infine, la comunicazione multicast e broadcast può essere facilmente implementata utilizzando indirizzi speciali. D'altro canto, I²C offre solo comunicazioni half-duplex ed è caratterizzato da consumo energetico relativamente elevato, bassa velocità e basso throughput rispetto a SPI. Infine, ha bisogno di driver open collector e resistori di pull-up (in genere da 2.2 kΩ) su ciascuna linea poiché le linee SDA e SCL sono inattive a livello logico alto.

9. Dichiarazione di Non Responsabilità

La maggior parte delle immagini riportate in questo libretto sono prese (con alcuni adattamenti) da internet e su queste non detengo alcun diritto d'autore. Tali immagini sono utilizzate solo a scopo didattico ed è severamente vietato qualsiasi uso commerciale sia delle immagini che dell'intero libretto.